

UNIVERSITÉ DU QUÉBEC À MONTRÉAL

DÉTECTION TEMPORELLE DE DÉGRADATIONS COMPORTEMENTALES ASSOCIÉES AU RISQUE DE BOITERIE
CHEZ LES VACHES LAITIÈRES ÉQUIPÉES DE CAPTEURS ICEQUBE

MÉMOIRE

PRÉSENTÉ

COMME EXIGENCE PARTIELLE

DE LA MAÎTRISE EN INFORMATIQUE

CONCENTRATION : SYSTÈMES ÉLECTRONIQUES

PAR

ALIOU BARRY

JUIN 2026

*À la mémoire de mon père,
dont l'exemple, les valeurs et la confiance
continuent de guider chacun de mes pas.*

*À ma mère,
pour son courage et sa force inébranlable
depuis son départ.*

*Ce travail est le fruit
de tout ce qu'ils m'ont transmis.*

REMERCIEMENTS

Je tiens à exprimer ma profonde gratitude envers mon directeur de recherche, le professeur Abdoulaye Baniré Diallo, pour son encadrement scientifique rigoureux, sa confiance et sa disponibilité tout au long de ce projet. Ses conseils méthodologiques et sa vision ont été déterminants dans l'aboutissement de ce mémoire.

Je remercie sincèrement mon codirecteur, Zakaria El Alaoui Ismaili, pour son accompagnement, ses retours constructifs et son expertise qui ont enrichi ce travail à chaque étape.

Ce mémoire a été réalisé au sein du Laboratoire de bio-informatique de l'UQAM, un environnement de recherche stimulant et collaboratif. Je remercie l'ensemble des membres du laboratoire pour les échanges scientifiques et le soutien quotidien.

Je tiens également à remercier l'équipe du projet Well-E, regroupant des chercheurs de l'UQAM et de McGill, pour le cadre applicatif et les données qui ont rendu ce travail possible.

Un merci particulier à mes collègues François Gonothié Touré et Armand Bandiang Massoua, pour leur camaraderie, les discussions enrichissantes et l'entraide qui ont ponctué ces années de maîtrise.

Je remercie les membres du jury pour le temps consacré à l'évaluation de ce mémoire et pour leurs commentaires constructifs.

Enfin, je remercie ma famille et mes proches pour leur soutien indéfectible et leurs encouragements constants.

TABLE DES MATIÈRES

TABLE DES FIGURES	x
LISTE DES TABLEAUX	xii
Liste des acronymes et abréviations	xiv
Liste des symboles	xvi
RÉSUMÉ	xvii
ABSTRACT	xviii
INTRODUCTION	1
CHAPITRE 1 CONTEXTE ET REVUE DE LITTÉRATURE	6
1.1 Cadre général	6
1.1.1 Impact économique	6
1.1.2 Étiologie et facteurs de risque	7
1.1.3 Importance de la détection précoce	8
1.2 Approches conventionnelles : observation et notation locomotrice	8
1.2.1 Lecture opérationnelle du score locomoteur	9
1.3 Approches basées sur des capteurs et apprentissage	10
1.3.1 Isolation Forest	12
1.3.2 Local Outlier Factor	12
1.3.3 Comparaison synthétique IF et LOF	13
1.3.4 Choix méthodologique et travaux directement pertinents	13
1.4 Capteurs et variables comportementales	15
1.5 Hétérogénéité des protocoles : un obstacle à la comparaison	18
1.6 Détection temporelle de changements persistants	20
1.7 Synthèse critique	20

1.8	Positionnement du mémoire	21
CHAPITRE 2 DONNÉES ET MÉTHODOLOGIE		23
2.1	Plan d'étude	23
2.2	Corpus principal IceQube 2023	23
2.2.1	Variables disponibles	24
2.2.2	Statistiques descriptives et variabilité inter-individuelle	24
2.2.3	Choix de la résolution temporelle	25
2.2.4	Contrôles d'intégrité et admissibilité	25
2.2.5	Traçabilité et provenance des données.....	27
2.2.6	Variables dérivées	27
2.3	Cohorte IceTag-SLS de l'hiver 2019.....	27
2.4	Période de référence individuelle et contrôle de qualité	28
2.5	Branche HYPO : baisse comportementale persistante.....	28
2.6	Branche INSTABILITÉ : mouvement disproportionné et posture fragmentée	30
2.7	Fusion des branches.....	31
2.8	Validation technique principale du module HYPO	32
2.9	Extension bidirectionnelle et contrôles de confusion	32
2.10	Métriques et analyses de sensibilité	33
2.10.1	Recouvrement temporel (IoU)	33
2.10.2	Métriques attribuables et unité statistique	34
2.11	Analyse SLS	35
2.12	Reproductibilité	35
CHAPITRE 3 ARCHITECTURE ET IMPLÉMENTATION		36

3.1	Organisation du logiciel	36
3.2	Flux de traitement	37
3.3	Implémentation des deux persistances	37
3.4	Fusion hiérarchique	38
3.5	Comparateurs Isolation Forest et Local Outlier Factor	39
3.5.1	Isolation Forest	39
3.5.2	Local Outlier Factor	40
3.6	Implémentation des validations	40
3.6.1	Génération déterministe	40
3.6.2	Exécution de référence et attribution	40
3.6.3	Contrôles bloquants	41
3.7	Évaluation du temps d'exécution	41
3.8	Technologies et dépendances	41
3.9	Interface Streamlit	42
3.9.1	Niveaux de priorité et action associée.....	42
3.10	Tests et traçabilité	45
CHAPITRE 4 VALIDATION ET RÉSULTATS		47
4.1	Intégrité des protocoles.....	47
4.2	Validation technique principale du module HYPO	48
4.2.1	Résultats attribuables par profil	48
4.2.2	Typologie des modes de défaillance	49
4.2.3	Robustesse locale des paramètres HYPO	50
4.2.4	Calibration individuelle exploratoire.....	52

4.2.5	Compromis entre réponse technique et charge de fond	52
4.2.6	Ablation contre IF, LOF et comparateur pédométrique	53
4.2.7	Temps d'exécution	55
4.3	Extension bidirectionnelle exploratoire	55
4.3.1	Comparaison des règles de fusion	55
4.3.2	Résultats par scénario	56
4.3.3	Sensibilité des paramètres INSTABILITÉ	57
4.4	Concordance observationnelle avec les scores SLS	57
4.5	Inspection visuelle ciblée	58
4.6	Correspondance entre objectifs et résultats	60
4.7	Synthèse	60
CHAPITRE 5 DISCUSSION ET LIMITES		61
5.1	Réponse à la question principale	61
5.2	Niveau de preuve des principales conclusions	61
5.3	Apport de l'ablation et de l'OFAT	62
5.4	Portée de l'extension bidirectionnelle	63
5.5	Contrôles et facteurs confondants	63
5.6	Charge opérationnelle et performance	64
5.7	Portée de l'analyse SLS	64
5.8	Mise en perspective avec la littérature	64
5.9	Comparaison avec les systèmes commerciaux	65
5.10	Implications pratiques pour l'éleveur	65
5.11	Forces et limites	66

5.12	Menaces à la validité	66
5.12.1	Validité de construit	66
5.12.2	Validité interne	67
5.12.3	Validité externe	67
5.12.4	Validité statistique	67
5.13	Usage prévu et implications éthiques	67
5.14	Travaux nécessaires avant une revendication clinique	68
5.15	Bilan	68
	CONCLUSION	69
	ANNEXE A REPRODUCTIBILITÉ ET CONTRÔLES COMPLÉMENTAIRES	71
A.1	Environnement	71
A.2	Commandes de reproduction	71
A.2.1	Validation et ablation du module HYPO	71
A.2.2	Typologie des modes de défaillance	72
A.2.3	Analyse OFAT du module HYPO	72
A.2.4	Traçabilité des données (provenance CowAlert)	72
A.2.5	Intervalles de confiance et tailles d'effet	72
A.2.6	Calibration individuelle et courbe détection-charge	73
A.2.7	Comparaison exploratoire des fusions	73
A.2.8	Évaluation du temps d'exécution	73
A.2.9	Analyse IceTag-SLS	73
A.2.10	Figures du manuscrit	74
A.2.11	Tests et interface	74

A.2.12	Compilation	74
A.3	Artefacts principaux	75
A.4	Amplitudes des profils d'injection	76
A.5	Invariants des injections	78
A.6	Unité statistique	78
A.7	Variabilité inter-vache du fond.....	78
A.8	Intégrité des fichiers	79
A.9	Règles d'interprétation.....	79
BIBLIOGRAPHIE		81

TABLE DES FIGURES

Figure 1.1	Étiologie multifactorielle de la boiterie bovine.	7
Figure 1.2	Seuil opérationnel du score locomoteur.....	9
Figure 1.3	Taxonomie des approches de détection automatisée.....	11
Figure 1.4	Principe d'Isolation Forest.	12
Figure 1.5	Schéma du capteur IceQube.....	17
Figure 1.6	Positionnement du capteur IceQube.....	17
Figure 2.1	Plan d'étude.	23
Figure 2.2	Admissibilité des vaches.	26
Figure 2.3	Pseudocode de la détection HYPO.	29
Figure 2.4	Détection attribuable au niveau de l'événement.....	30
Figure 3.1	Architecture du système.	37
Figure 3.2	Pseudocode de la fusion hiérarchique des deux branches.....	38
Figure 3.3	Analyse individuelle du tableau de bord.	43
Figure 3.4	Signaux de la vache 8116.	43
Figure 3.5	Animaux à vérifier en priorité.	44
Figure 3.6	Classement du troupeau.....	44
Figure 3.7	Alertes journalières par animal.....	45
Figure 3.8	Chaîne de reproductibilité.	46
Figure 4.1	Sensibilité locale des paramètres HYPO.....	51
Figure 4.2	Compromis détection-charge de fond.....	53

Figure 4.3	Comparaison des règles de fusion.	56
Figure 4.4	Réponse par scénario contrôlé.	57
Figure 4.5	Notifications précédant le score SLS.	58
Figure 4.6	Inspection visuelle de scénarios représentatifs.....	59

LISTE DES TABLEAUX

Tableau 1.1	Composantes du coût économique de la boiterie par cas clinique.	6
Tableau 1.2	Lecture clinique et opérationnelle simplifiée du score locomoteur.	10
Tableau 1.3	Comparaison des propriétés d'Isolation Forest et de Local Outlier Factor.....	13
Tableau 1.4	Travaux directement reliés aux choix méthodologiques.	14
Tableau 1.5	Principales familles de capteurs étudiées.	16
Tableau 2.1	Caractéristiques vérifiées du corpus IceQube 2023.	24
Tableau 2.2	Variables brutes du corpus IceQube 2023.	24
Tableau 2.3	Statistiques descriptives des variables de mouvement (par intervalle de 15 min).	25
Tableau 2.4	Variabilité inter-individuelle des principales variables (moyenne par vache).	25
Tableau 2.5	Familles de variables dérivées par variable comportementale brute.....	27
Tableau 2.6	Paramètres de référence des deux branches.	31
Tableau 2.7	Scénarios de la validation technique.	33
Tableau 3.1	Modules qui produisent les sorties du mémoire.....	36
Tableau 3.2	Hyperparamètres figés d'Isolation Forest (comparateur).	39
Tableau 3.3	Principales technologies de la version reproductible.	42
Tableau 3.4	Niveaux de priorité de l'interface et action de vérification associée.....	42
Tableau 4.1	Clés de lecture du chapitre.	47
Tableau 4.2	Contrôles automatiques communs aux campagnes techniques.	48
Tableau 4.3	Résultats attribuables du module HYPO.....	48
Tableau 4.4	Modes de défaillance observés.	49

Tableau 4.5	Plages d'écarts signés pour les paramètres HYPO les plus structurants.	51
Tableau 4.6	Ablation attribuable du module HYPO	53
Tableau 4.7	Comparaison exploratoire des règles de fusion sur 132 événements.	55
Tableau 4.8	Réponse de la fusion hiérarchique par scénario.	56
Tableau 4.9	Correspondance entre objectifs et résultats.	60
Tableau 5.1	Portée des conclusions principales.	62
Tableau 5.2	Forces et limites du travail.	66
Tableau A.1	Artefacts qui soutiennent les résultats.	75
Tableau A.2	Profils de la validation principale HYPO.	77
Tableau A.3	Profils bidirectionnels et contrôles de confusion.	77
Tableau A.4	Distribution du fond de notifications HYPO par vache (campagne principale).	78

LISTE DES ACRONYMES ET ABRÉVIATIONS

AUC	<i>Area Under the Curve</i> : aire sous la courbe ROC utilisée ici comme mesure descriptive exploratoire
CSV	<i>Comma-Separated Values</i> : format de fichier tabulaire
CUSUM	<i>Cumulative Sum</i> : somme cumulative pour la détection de changements persistants
FAIR	<i>Findable, Accessible, Interoperable, Reusable</i> : principes de gestion des données scientifiques
IF	<i>Isolation Forest</i> : algorithme de détection d'anomalies par isolation
HYPO	Branche temporelle recherchant une baisse persistante et multivariée de l'activité
INSTABILITÉ	Branche temporelle recherchant un mouvement disproportionné, des transitions denses et une posture fragmentée
IoU	<i>Intersection over Union</i> : mesure de recouvrement temporel
JSON	<i>JavaScript Object Notation</i> : format d'échange de données
LOF	<i>Local Outlier Factor</i> : détecteur d'anomalies fondé sur la densité locale
MAD	<i>Median Absolute Deviation</i> : écart absolu médian
MI	<i>Motion Index</i> : indice de mouvement fourni par le capteur
PLF	<i>Precision Livestock Farming</i> : élevage de précision
SHA-256	Fonction de hachage cryptographique utilisée pour vérifier l'intégrité des artefacts
SLS	Score observationnel de la cohorte IceTag-SLS, somme de quatre composantes binaires dans les fichiers étudiés

Termes techniques

Alerte comportementale	Signal indiquant une dégradation persistante de plusieurs familles de mesures ; elle doit être vérifiée et n'est pas un diagnostic
Période de référence	Partie initiale de la série d'une vache utilisée pour estimer son comportement attendu
Boiterie	Altération de la locomotion dont l'évaluation clinique repose sur la démarche, la posture, l'appui et, au besoin, l'examen du pied
Couverture	Proportion des mesures attendues effectivement observées dans un intervalle
Créneau horaire	Position dans le cycle journalier utilisée pour comparer un signal à des périodes homologues de la période de référence
Événement en période future	Perturbation injectée uniquement après la partie utilisée pour construire la référence
Inspection visuelle	Contrôle humain de la cohérence technique des événements et des sorties, sans adjudication clinique
Notification de fond	Notification observée hors fenêtre injectée sur des données non étiquetées ; elle ne peut être qualifiée de vraie ou fausse alerte clinique
Notification de vérification	Sortie de priorité 2 ou 3 demandant une observation ciblée de l'animal, sans conclure à une boiterie
Période réfractaire	Durée minimale entre deux notifications ; elle dépend de la branche et vaut 12 heures pour la fusion principale
Chaîne de traitement (pipeline)	Suite des opérations allant de l'ingestion des données aux épisodes et aux notifications

LISTE DES SYMBOLES

$r_j(t)$	Ratio entre le signal agrégé observé et sa référence attendue pour la famille j au temps t
$d_j(t)$	Déficit unilatéral d'une famille d'activité : $\max(0, 1 - r_j(t))$
$d_{posture}$	Déficit postural combinant l'excès de temps couché et le déficit de temps debout
$S_H(t)$	Score comportemental instantané de dégradation, borné entre 0 et 1 et non interprétable comme une probabilité clinique
e_t	Évidence temporelle issue du score et de la baisse progressive
C_t	Somme cumulative unilatérale (CUSUM) au temps t
k	Dérive soustraite à chaque mise à jour du CUSUM
E	Fenêtre temporelle d'un événement injecté
A	Épisode d'alerte produit par le détecteur
IoU	<i>Intersection over Union</i> : $\frac{ E \cap A }{ E \cup A }$, mesure du recouvrement temporel
n	Nombre d'unités statistiques ou d'événements, selon le tableau
ρ	Coefficient de corrélation de rang de Spearman

RÉSUMÉ

La boiterie demeure un problème majeur de bien-être et de performance en élevage laitier. Son repérage repose encore largement sur l'observation humaine et le score locomoteur, qui sont indispensables mais difficiles à maintenir de façon continue dans les troupeaux. Les capteurs d'activité offrent une surveillance complémentaire : ils ne diagnostiquent pas la boiterie, mais peuvent signaler des changements comportementaux persistants qui justifient une vérification terrain. Ce mémoire conçoit et évalue un système reproductible d'**alerte comportementale précoce** à partir de capteurs IceQube fixés à la patte.

La contribution principale est la branche temporelle HYPO. Elle compare chaque vache à sa propre période de référence et recherche une baisse graduelle, persistante et concordante de plusieurs familles de signaux : pas, *Motion Index*, transitions posturales, temps couché et temps debout. Cette logique individualisée transforme des séries indirectes en priorités de vérification traçables. La validation technique repose sur des événements injectés uniquement après la période de référence, puis comparés à une exécution propre de la même vache afin d'isoler les alertes réellement attribuables à l'événement. Sur les dégradations graduelles évaluées, HYPO recouvre la grande majorité des événements et localise mieux les épisodes que les comparateurs Isolation Forest et Local Outlier Factor. Le contrôle bref isolé est rejeté, ce qui montre que le système ne réagit pas simplement à toute fluctuation ponctuelle.

Le mémoire explore aussi une extension bidirectionnelle fondée sur une branche INSTABILITÉ. Cette branche représente des situations où un inconfort locomoteur pourrait s'accompagner d'agitation, de transitions plus fréquentes ou de fragmentation posturale. Elle reste séparée de HYPO : l'instabilité isolée produit une sortie de surveillance, tandis que la notification de vérification reste réservée aux baisses persistantes ou aux séquences instabilité-hypoactivité. Cette extension rend le système plus expressif, mais elle augmente la charge de vérification et reste vulnérable aux causes non locomotrices. Elle constitue donc une piste opérationnelle prudente, et non une preuve clinique.

Une analyse complémentaire IceTag-SLS synchronisée confronte les sorties aux scores locomoteurs en utilisant uniquement des données capteurs antérieures à l'évaluation. Elle est méthodologiquement correcte, mais limitée par le faible nombre de vaches à score élevé et par l'entrelacement avec le groupe *Exercise*. Le résultat central du mémoire est donc un détecteur temporel défendable, une interface de priorisation et un protocole reproductible qui sépare clairement performance logicielle, hypothèse comportementale et validation clinique.

Mots-clés : boiterie bovine, alerte comportementale, capteur IceQube, détection de changement, élevage de précision.

ABSTRACT

Lameness remains a major welfare and performance issue in dairy farming. Its detection still relies largely on human observation and locomotion scoring, which are essential but difficult to maintain continuously at herd scale. Activity sensors provide a complementary form of monitoring: they do not diagnose lameness, but they can signal persistent behavioral changes that justify on-farm verification. This thesis designs and evaluates a reproducible **early behavioral-alert** system based on leg-mounted IceQube sensors.

The main contribution is the temporal HYPO branch. It compares each cow with her own reference period and searches for a gradual, persistent and concordant decline across several signal families: steps, motion index, postural transitions, lying time and standing time. This individualized logic converts indirect time series into traceable verification priorities. Technical validation uses events injected strictly after the reference period and compares each injected run with a clean run of the same cow, so that only attributable alerts are credited. On gradual degradations, HYPO recovers most events and localizes episodes better than Isolation Forest and Local Outlier Factor comparators. The isolated brief variation is rejected, showing that the system does not simply react to any short fluctuation.

The thesis also explores a bidirectional extension based on an INSTABILITY branch. This branch represents situations in which locomotor discomfort could involve agitation, more frequent transitions or fragmented posture. It remains separated from HYPO: isolated instability produces a surveillance output, whereas verification notifications are reserved for persistent decreases or instability-to-hypoactivity sequences. This extension makes the system more expressive, but it also increases the verification load and remains vulnerable to non-locomotor causes. It is therefore a cautious operational direction, not clinical proof.

A synchronized IceTag-SLS analysis compares the outputs with locomotion scores using only sensor data collected before the evaluation. It is methodologically sound, but limited by the small number of cows with elevated scores and by the overlap with the *Exercise* group. The central result of the thesis is therefore a defensible temporal detector, a prioritization interface and a reproducible protocol that clearly separates software performance, behavioral hypothesis and clinical validation.

Keywords: bovine lameness, behavioral alert, IceQube sensor, change detection, precision livestock farming.

INTRODUCTION

Motivation

La boiterie désigne une altération de la locomotion, le plus souvent causée par la douleur d'une lésion du pied ou du membre. Elle se reconnaît cliniquement à une démarche irrégulière, un dos voûté, une répartition inégale du poids entre les membres et une réticence à se déplacer ; son évaluation de référence repose sur une notation locomotrice standardisée (Sprecher *et al.*, 1997 ; Chapinal *et al.*, 2011). Cette définition est importante : tout le monde distingue la boiterie, phénomène *clinique*, des changements *de comportement* mesurés par les capteurs, qui n'en sont qu'un reflet indirect.

La boiterie constitue un problème majeur de bien-être et de performance en élevage laitier. Les prévalences publiées varient généralement entre 20 et 55 %, selon la population, la saison et la définition clinique retenue (Whay *et al.*, 2003 ; Flower et Weary, 2006). Ses conséquences comprennent la douleur, la baisse de production, une fertilité dégradée, des soins supplémentaires et des réformes anticipées (Green *et al.*, 2002 ; Bruijnis *et al.*, 2010). Les estimations publiées situent le coût entre 75 et plus de 300 USD par cas clinique, en incluant des pertes de production laitière pouvant atteindre plusieurs centaines de kilogrammes par lactation ; pour un troupeau de 100 vaches soumis à une prévalence de 25 %, la perte annuelle attribuable aux seuls cas incidents se chiffre en milliers de dollars. Au-delà du coût, la douleur associée est reconnue comme l'une des principales sources de souffrance chronique chez la vache laitière (Whay *et al.*, 2003). Une identification plus précoce peut donc orienter l'examen du pied et la prise en charge avant l'installation d'un épisode chronique.

L'élevage de précision propose de compléter l'observation humaine par une surveillance continue au moyen de capteurs portés (Bewley *et al.*, 2015). Cette surveillance ne résout toutefois pas, à elle seule, le problème de terrain : les accéléromètres et podomètres mesurent des comportements, non la douleur ou la lésion. Une alerte produite à partir des pas, de la posture ou de l'intensité de mouvement ne peut ainsi être assimilée à un diagnostic clinique (Alsaad *et al.*, 2019 ; O'Leary *et al.*, 2020). L'enjeu devient donc de transformer des séries comportementales indirectes en priorités d'observation fiables, traçables et utilisables par l'éleveur.

Problématique

Dans cette perspective, la manifestation la mieux étayée dans les données disponibles est une réduction durable de l'activité locomotrice : diminution des pas, du mouvement et des transitions, accompagnée de changements posturaux. Ces signaux restent néanmoins non spécifiques, car une autre maladie, la chaleur ou le contexte d'élevage peuvent produire une forme semblable. Une difficulté supplémentaire est que certaines situations douloureuses pourraient s'accompagner d'agitation ou d'instabilité avant une hypoactivité, mais cette trajectoire n'est pas démontrée dans le corpus principal. Une hausse brute du *Motion Index* peut aussi refléter l'exercice, l'œstrus, une manipulation ou un artefact de capteur.

La réponse proposée est donc graduée. Elle ne cherche pas à remplacer le jugement clinique, mais à ordonner le travail de vérification : repérer d'abord les trajectoires d'hypoactivité persistantes par HYPO, puis explorer séparément les profils d'instabilité afin de mesurer ce qu'ils ajoutent réellement et ce qu'ils coûtent en charge de vérification.

La question principale est donc la suivante : *comment détecter de façon reproductible des dégradations comportementales graduelles et persistantes à partir de séries IceQube non étiquetées, sans les assimiler à un diagnostic de boiterie ?* Une question secondaire explore si une branche d'instabilité peut apporter une information complémentaire sans dégrader excessivement la localisation temporelle et la charge de vérification.

Objectifs

L'objectif général est de concevoir et d'évaluer une chaîne de priorisation comportementale fondée sur HYPO, puis d'en tester l'extension par une branche INSTABILITÉ. Il se décline en six objectifs spécifiques :

1. construire une période de référence chronologique propre à chaque vache et à chaque créneau horaire ;
2. détecter les baisses multivariées persistantes par une branche HYPO ;
3. évaluer HYPO au niveau de l'événement et de la vache, sur des événements postérieurs à la période de référence, avec une ablation contre Isolation Forest, LOF et un comparateur pédométrique, et une analyse de sensibilité des paramètres ;
4. explorer une branche INSTABILITÉ, des persistances distinctes et cinq règles de fusion ;
5. mesurer explicitement les contrôles brefs, les facteurs confondants, la charge de fond et le coût d'exécution de la chaîne de traitement complète ;

6. confronter, sans réglage a posteriori, les sorties à une cohorte IceTag–SLS contemporaine des mesures capteurs.

Hypothèses de travail

L'hypothèse principale est qu'une baisse graduelle touchant plusieurs familles de signaux est mieux représentée par une détection directionnelle, individualisée et temporelle que par une succession d'anomalies ponctuelles. L'hypothèse exploratoire est qu'une instabilité définie par des rapports de mouvement, des transitions et une fragmentation posturale peut compléter HYPO, à condition de conserver une sortie de surveillance distincte et une persistance plus courte. Ces hypothèses portent sur le comportement du logiciel et ne préjugent pas de la cause clinique des événements.

Positionnement et portée

Le système produit des *alertes comportementales à vérifier*, c'est-à-dire une aide à la décision pour le suivi d'élevage et non un dispositif de diagnostic vétérinaire. Ce positionnement est volontaire et imposé par les données : le corpus ne dispose d'aucun étalon clinique synchronisé avec les enregistrements capteurs sur l'ensemble des animaux et des périodes. Les taux de détection rapportés caractérisent donc le comportement du logiciel face à des perturbations connues, et non une sensibilité ou une spécificité cliniques. Ce cadrage fixe le niveau de preuve tout en laissant apparaître l'apport opérationnel recherché : transformer des signaux continus en priorités de vérification traçables. Il rejoint les recommandations de la littérature, qui distingue nettement détection automatisée et outil diagnostique validé (Alsaad *et al.*, 2019).

Démarche méthodologique

Le corpus principal contient 37 839 mesures de 28 vaches. Les 60 % premiers intervalles admissibles de chaque série constituent la période de référence et les 40 % suivants la période surveillée. HYPO utilise des totaux glissants sur douze heures, une persistance de six heures, un score multivarié et un CUSUM unilatéral. Sa campagne principale comporte 33 dégradations graduelles et 11 contrôles brefs répartis entre onze vaches. Une exécution propre de la même vache, sans injection, est soustraite (comparaison contre-factuelle) afin de ne créditer que les alertes réellement attribuables à l'événement.

L'évaluation porte sur l'événement et sur la vache, non sur chaque intervalle de capteur : chaque dégradation injectée compte comme un épisode unique, dont on mesure la détection et la localisation temporelle par un indice de recouvrement, tandis que les indicateurs sont agrégés par vache et assortis d'intervalles de confiance obtenus par rééchantillonnage des vaches. Ce choix évite de traiter des intervalles successifs fortement corrélés comme autant d'observations indépendantes. La même campagne situe HYPO face aux comparateurs Isolation Forest, LOF et pédométrie, trace une courbe reliant la détection à la charge de vérification et scelle les résultats par un manifeste cryptographique.

L'extension INSTABILITÉ utilise une agrégation de trois heures et une persistance de deux heures. Elle est évaluée avec HYPO sur 132 scénarios comprenant intensités, séquence, contrôles et facteurs confondants. Une fusion hiérarchique conserve l'instabilité isolée comme surveillance et réserve la notification de vérification à HYPO ou à une convergence. Ces résultats constituent une extension exploratoire qui enrichit la lecture opérationnelle du système sans remplacer la validation technique plus ciblée de HYPO.

Contributions

Le mémoire apporte une chaîne complète qui va du signal brut à une priorité de vérification reproductible. Ses contributions sont les suivantes :

1. un détecteur HYPO directionnel, persistant et interprétable, centré sur la trajectoire individuelle de chaque vache ;
2. une validation attribuable au niveau de l'événement et de la vache après la période de référence, une ablation contre Isolation Forest, LOF et un comparateur pédométrie, et une analyse OFAT de vingt variantes ;
3. une extension bidirectionnelle exploratoire avec persistances séparées et cinq règles de fusion ;
4. des contrôles brefs et des facteurs confondants qui rendent visibles les limites de spécificité au lieu de les masquer ;
5. une évaluation du temps d'exécution de la chaîne complète, une analyse SLS synchronisée, une interface Streamlit et une suite de tests reproductibles.

L'originalité du travail tient moins à un modèle complexe qu'à l'articulation contrôlée de quatre exigences souvent séparées : individualisation, temporalité, attribution et reproductibilité.

Structure du mémoire

Le Chapitre 1 présente la boîtierie, les signaux comportementaux et les méthodes de détection. Le Chapitre 2 décrit les corpus, HYPO, l'extension INSTABILITÉ et les protocoles d'évaluation. Le Chapitre 3 expose l'implémentation et l'interface. Le Chapitre 4 rapporte d'abord les preuves techniques du module HYPO, puis les résultats de l'extension et l'analyse SLS. Le Chapitre 5 discute séparément les conclusions établies et les hypothèses encore exploratoires.

CHAPITRE 1

CONTEXTE ET REVUE DE LITTÉRATURE

1.1 Cadre général

La boiterie bovine est un problème de santé majeur en élevage laitier, avec des conséquences directes sur le bien-être animal, la productivité et la rentabilité des exploitations (Rodrigues *et al.*, 2017). Des études épidémiologiques rapportent des prévalences allant de 20% à plus de 50% selon les régions, les systèmes d'élevage et les critères de diagnostic utilisés (Whay *et al.*, 2003; Cook, 2003). Les pathologies du pied, qu'elles soient infectieuses (*dermatite digitale*, *phlegmon interdigité*) ou non infectieuses (*ulcère de la sole*, *maladie de la ligne blanche*), comptent parmi les principales causes de boiterie chez les vaches laitières (Merck Veterinary Manual, 2024a; Flower et Weary, 2006).

1.1.1 Impact économique

L'impact économique de la boiterie est substantiel et multidimensionnel. Le Tableau 1.1 synthétise les principales composantes du coût *par cas clinique*, c'est-à-dire par épisode de boiterie diagnostiqué chez une vache au cours d'une lactation, d'après les estimations publiées dans la littérature.

Tableau 1.1 Composantes du coût économique de la boiterie par cas clinique.

Composante	Estimation	Source
Perte de production laitière	270-574 kg/lactation	Green <i>et al.</i> (2002)
Coût vétérinaire direct	25-90 USD/cas	Bruijnis <i>et al.</i> (2010)
Dégradation de la fertilité	+30-50 jours ouverts	Green <i>et al.</i> (2002)
Réforme anticipée	75-300 USD/cas	Bruijnis <i>et al.</i> (2010)
Coût total estimé	75-300+ USD/cas	

Quatre postes principaux composent le coût d'un cas clinique : la perte de production laitière (270 à 574 kg par lactation), liée à la baisse de l'ingestion et de l'activité ; le coût vétérinaire direct (25 à 90 USD par cas), qui inclut la consultation, le parage, les traitements et le matériel de soin ; la dégradation de la fertilité, mesurée par une hausse de 30 à 50 *jours ouverts*, soit l'intervalle entre le vêlage et la conception suivante, avec un décalage de la lactation suivante ; et la réforme anticipée (75 à 300 USD par cas), liée à la perte de

valeur résiduelle d'une vache écartée avant la fin de sa carrière productive. Ces postes se cumulent selon la sévérité et la chronicité de l'épisode. À l'échelle d'un troupeau de 100 vaches avec une prévalence de 25 %, le coût annuel cumulé est estimé entre 1 900 et 7 500 USD pour les seuls cas incidents. Au-delà de l'impact financier, la boiterie soulève un enjeu éthique de bien-être animal : la douleur associée est reconnue comme l'une des principales sources de souffrance chronique chez les vaches laitières (Whay *et al.*, 2003; Broom, 2017). Ces conséquences justifient une compréhension fine des mécanismes de boiterie, afin d'orienter la prévention, la détection et la prise en charge.

1.1.2 Étiologie et facteurs de risque

Les causes de la boiterie sont multifactorielles. La Figure 1.1 les organise en quatre catégories : causes directes infectieuses ou non infectieuses, et facteurs modulateurs environnementaux ou individuels. Les causes directes regroupent des affections bactériennes, comme la *dermatite digitale* ou le *phlegmon interdigité*, et des lésions mécaniques, comme l'*ulcère de la sole* ou la *maladie de la ligne blanche*. Les facteurs environnementaux (sol, hygiène, humidité) modulent l'exposition, tandis que les facteurs individuels (parité, âge, stade de lactation) modulent la susceptibilité. Cette structure multifactorielle explique qu'aucun indicateur unique ne suffise et justifie une approche fondée sur plusieurs signaux pour la détection précoce (Merck Veterinary Manual, 2024a ; DairyNZ, 2025a).




Figure 1.1 Étiologie multifactorielle de la boiterie bovine.

1.1.3 Importance de la détection précoce

La littérature sur la boiterie bovine souligne l'importance d'une détection précoce pour limiter la dégradation du bien-être animal et les impacts de production. Les ressources vétérinaires de référence et les guides techniques convergent sur deux idées : une surveillance régulière est indispensable, et la prise en charge doit être structurée et rapide selon la sévérité du cas (Merck Veterinary Manual, 2024b ; DairyNZ, 2025b).

La détection précoce (score locomoteur 2 sur une échelle de 1 à 5) ouvre la voie au traitement des cas avant qu'ils ne deviennent chroniques. Les études montrent qu'un retard de traitement de quelques jours peut multiplier la durée de récupération et le coût associé (Green *et al.*, 2002). Les capteurs portés et les systèmes de mesure de la démarche permettent de quantifier objectivement des modifications d'activité ou de locomotion associées à la boiterie (Chapinal *et al.*, 2011 ; Pastell et Kujala, 2007). Le délai avec lequel ces modifications deviennent détectables avant une observation clinique dépend toutefois du capteur, de la définition du cas et du protocole ; il ne peut donc pas être généralisé à partir de ces travaux. En pratique, les boiteries légères restent difficiles à repérer de façon régulière par la seule observation visuelle.

Des revues de synthèse en élevage de précision montrent aussi que la boiterie fait partie des cas d'usage les plus importants, mais également des plus difficiles à stabiliser, car les signaux disponibles restent indirects, multifactoriels et fortement dépendants du contexte d'élevage (Palma *et al.*, 2025 ; Michelena *et al.*, 2025).

1.2 Approches conventionnelles : observation et notation locomotrice

Les approches conventionnelles reposent principalement sur l'observation humaine et les grilles de notation locomotrice. La grille proposée par Sprecher *et al.* (1997) reste l'une des plus utilisées en pratique. Elle attribue un score de 1 (*normal*) à 5 (*sévèrement boiteux*) en se basant sur la posture du dos et la démarche (Flower et Weary, 2009). La fiche opérationnelle de l'AHDB propose une grille complémentaire adaptée au contexte britannique et associe le score 2 à une intervention rapide, généralement dans les 48 heures (AHDB, 2025a).

Les approches conventionnelles restent pertinentes en élevage car elles sont simples à déployer et directement interprétables par les équipes terrain. Elles présentent toutefois plusieurs limites opérationnelles. La première tient à la subjectivité inter-observateurs : même avec des grilles standardisées, la concordance entre évaluateurs peut varier significativement (Flower et Weary, 2006 ; March *et al.*, 2007). La deuxième

concerne le temps requis : dans les grands troupeaux, l'observation systématique de chaque animal à chaque traite est difficile à maintenir. Enfin, les boiteries légères (score 2) restent difficiles à repérer de manière reproductible par la seule observation visuelle (Whay *et al.*, 2003; March *et al.*, 2007).

Pour dépasser ces limites, le recours à des signaux capteurs vient compléter la surveillance humaine, sans la remplacer.

1.2.1 Lecture opérationnelle du score locomoteur

Au-delà de sa fonction descriptive, l'évaluation locomotrice est aussi un outil de priorisation. Dans la fiche opérationnelle de l'AHDB, le passage du score 1 (*normal*) au score 2 (*boiterie légère*) appelle une intervention rapide, généralement dans les 48 heures (AHDB, 2025a). Cette logique explique pourquoi un système automatisé peut viser une fonction plus prudente que la reproduction d'une note clinique : signaler une dégradation comportementale suffisamment tôt pour déclencher une vérification sur le terrain.

La Figure 1.2 synthétise la lecture opérationnelle du score locomoteur : le passage vers le score 2 constitue la zone d'intérêt pour une alerte précoce, car il marque l'entrée dans une situation où l'observation humaine ou l'examen du pied devient prioritaire (Sprecher *et al.*, 1997; AHDB, 2025a).




Figure 1.2 Seuil opérationnel du score locomoteur pour la détection précoce.

Le Tableau 1.2 précise la lecture clinique simplifiée et l'action associée à chaque score, d'après la grille de Sprecher *et al.* (1997) et les recommandations AHDB (AHDB, 2025b).

Tableau 1.2 Lecture clinique et opérationnelle simplifiée du score locomoteur.

Score	Lecture clinique simplifiée	Lecture opérationnelle
1	Dos plat en station et en marche.	Surveillance usuelle.
2	Dos plat à l'arrêt, légèrement arqué en marche.	Intervention rapide : zone clé pour la détection précoce.
3	Dos arqué en permanence.	Vérification prioritaire.
4	Atteinte locomotrice visible.	Prise en charge urgente.
5	Appui très limité.	Prise en charge immédiate.

La lecture par seuil transforme la notation locomotrice en problème d'alerte : il ne s'agit plus seulement de décrire une boiterie, mais de repérer l'entrée dans une zone d'intervention. Ce déplacement justifie le recours à des signaux capteurs et à des méthodes d'apprentissage capables de suivre les changements comportementaux dans le temps.

1.3 Approches basées sur des capteurs et apprentissage

Les approches basées sur des capteurs visent à détecter des déviations comportementales (activité, transitions, dynamique de mouvement) qui peuvent être associées à la boiterie, sans être spécifiques à cette affection. La littérature distingue trois familles principales : l'analyse de la démarche par vision par ordinateur (Van Hertem *et al.*, 2014 ; Lavrova *et al.*, 2023), la classification de comportements par accélérométrie (O'Leary *et al.*, 2020 ; Alsaaod *et al.*, 2019 ; Balasso *et al.*, 2023 ; Benaissa *et al.*, 2019) et la détection d'anomalies sur des indicateurs dérivés (Qiao *et al.*, 2021 ; Chandola *et al.*, 2009). Les revues récentes confirment la prédominance des approches supervisées, tout en soulignant le manque d'études non supervisées en conditions réelles d'élevage (Qiao *et al.*, 2021 ; O'Leary *et al.*, 2020). Une revue récente de la détection automatisée par intelligence artificielle confirme cette dynamique tout en pointant des freins persistants : hétérogénéité des protocoles, dépendance aux étiquettes et validation encore limitée en conditions réelles (Siachos *et al.*, 2024). Les approches récentes par vision et apprentissage profond atteignent de bonnes performances sur vidéo (Myint *et al.*, 2024), mais supposent une infrastructure caméra et des données étiquetées, deux conditions absentes du corpus accéléromètre non étiqueté utilisé ici.

La diversité de ces approches peut être organisée selon trois dimensions complémentaires : *la source de*

données, la stratégie analytique et la nature de la sortie. Une telle lecture est importante, car elle évite de comparer directement des travaux qui ne visent pas le même objectif. Un modèle supervisé de classification binaire à partir d'images et un système d'alerte basé sur des capteurs d'activité n'ont ni les mêmes contraintes de données, ni le même niveau d'interprétabilité, ni le même usage en ferme.

La Figure 1.3 synthétise cette organisation en trois axes : la source de données (de l'observation visuelle aux accéléromètres portés), la stratégie analytique (règles et seuils, modèles supervisés, détection d'anomalies non supervisée, approches hybrides) et la sortie opérationnelle (du score locomoteur à l'alerte nécessitant une vérification). Le présent travail se positionne dans la branche non supervisée et hybride, encadrée en vert sur la figure.




Figure 1.3 Taxonomie des approches de détection automatisée.

Du point de vue de la stratégie analytique, les méthodes de détection se déclinent classiquement en deux familles :

- (a) *Modèles supervisés* : lorsque des labels fiables et suffisamment représentatifs sont disponibles. Ces approches peuvent atteindre de bonnes performances de classification (Van Hertem *et al.*, 2014; Viazzi *et al.*, 2013), mais leur dépendance aux labels limite leur déployabilité dans des contextes où l'étiquetage est incomplet ou incertain ;
- (b) *Détection d'anomalies et règles expertes* : lorsque les labels sont partiels ou absents. Ces approches ne nécessitent pas d'exemples positifs pour l'entraînement et sont donc mieux adaptées aux situations réelles où la boiterie n'est pas systématiquement diagnostiquée et enregistrée.

Dans le corpus étudié, la supervision clinique exhaustive n'est pas disponible. Cette contrainte motive une architecture qui combine des mesures de déviation et des règles temporelles explicites (Chandola *et al.*,

2009 ; Palma *et al.*, 2025). L'étude de Michelena (2025) compare plusieurs détecteurs non supervisés sur un autre usage bovin, la détection des chaleurs ; elle soutient l'intérêt d'une comparaison empirique des algorithmes, mais ne fournit pas de preuve sur la boiterie.

1.3.1 Isolation Forest

L'algorithme Isolation Forest (IF), proposé par Liu *et al.* (Liu *et al.*, 2008), repose sur le principe que les anomalies sont plus faciles à isoler que les points normaux dans un espace de variables. Son échantillonnage et ses arbres aléatoires permettent de traiter des jeux tabulaires sans modèle explicite de la distribution normale. Son implémentation dans scikit-learn (Pedregosa *et al.*, 2011) fournit ici un comparateur ponctuel reproductible ; elle ne modélise toutefois pas directement la direction ni la durée d'un changement.

La Figure 1.4 illustre le principe fondamental d'IF : une anomalie (point rouge) est isolée en seulement deux coupures aléatoires, tandis que les points normaux (cluster bleu) nécessitent de nombreuses partitions supplémentaires. Le score d'anomalie est inversement proportionnel au nombre de coupures.




Figure 1.4 Principe d'Isolation Forest.

1.3.2 Local Outlier Factor

Le Local Outlier Factor (LOF), proposé par Breunig *et al.* (Breunig *et al.*, 2000), estime la densité locale de chaque point par rapport à celle de ses voisins. Il vise ainsi des points rares dans leur voisinage, tandis qu'IF repose sur leur facilité d'isolation globale. Le coût de LOF dépend notamment de la recherche des voisins et de la dimension des données. Dans ce mémoire, il sert de second comparateur non supervisé ; aucune supériorité générale ne lui est attribuée a priori.

1.3.3 Comparaison synthétique IF et LOF

Le Tableau 1.3 synthétise les différences fondamentales entre les deux détecteurs utilisés dans ce projet.

Tableau 1.3 Comparaison des propriétés d'Isolation Forest et de Local Outlier Factor.

Propriété	Isolation Forest	Local Outlier Factor
Principe	Isolabilité par partitions	Densité locale relative
Type d'anomalie ciblée	Globale (isolée dans l'espace)	Locale (faible densité relative)
Référence fondatrice	Liu <i>et al.</i> (2008)	Breunig <i>et al.</i> (2000)
Dépendance principale	Nombre d'arbres et contamination	Nombre de voisins et contamination
Limite pour ce projet	Ne modélise pas la persistance	Ne modélise pas la persistance
Paramètres critiques	contamination, n_estimators	n_neighbors, contamination

IF fournit un comparateur fondé sur l'isolation globale, tandis que LOF apporte un contraste fondé sur la densité locale. La sortie principale du mémoire repose sur les détecteurs temporels décrits au Chapitre 2.

1.3.4 Choix méthodologique et travaux directement pertinents

La revue présentée ici est narrative et ciblée ; elle ne constitue ni une revue systématique ni une méta-analyse. Les travaux ont été retenus parce qu'ils éclairent directement l'une des décisions du projet : nature indirecte des signaux comportementaux, absence de labels cliniques dans le corpus principal, intérêt d'une référence individuelle, nécessité d'une évaluation temporelle et exigence d'interprétabilité.

Les modèles supervisés et les réseaux profonds peuvent exploiter des motifs complexes lorsque des signaux suffisamment riches et des labels contemporains sont disponibles (Van Hertem *et al.*, 2014 ; Balasso *et al.*, 2023). Ces conditions ne sont pas réunies ici : les variables IceQube sont déjà agrégées par intervalles de 15 minutes et le corpus principal ne comporte pas de diagnostic locomoteur synchronisé. Une classification

clinique supervisée ne serait donc pas défendable. Les méthodes non supervisées restent utiles comme points de comparaison, mais elles ne résolvent pas à elles seules la direction ni la persistance d'un changement. Des travaux récents transposent la détection d'anomalies non supervisée à des séries capteurs d'élevage bruitées (Kakar *et al.*, 2024), ce qui conforte l'intérêt d'approches sans étiquettes ; ils restent toutefois orientés vers la reconstruction de signaux plutôt que vers une baisse comportementale directionnelle, persistante et individualisée comme celle que cible HYPO.

Le Tableau 1.4 résume les travaux les plus directement reliés aux choix méthodologiques. Il ne compare pas leurs performances numériques, car les capteurs, les définitions de cas et les unités statistiques diffèrent.

Tableau 1.4 Travaux directement reliés aux choix méthodologiques.

Travail	Constat utile	Conséquence pour ce mémoire
Alsaad <i>et al.</i> (2019)	Les systèmes automatiques reposent sur des modalités et des protocoles hétérogènes.	Limiter la sortie à une alerte comportementale et documenter le protocole complet.
O'Leary <i>et al.</i> (2020)	Les variables accélérométriques associées à la boiterie varient selon le capteur et le protocole.	Éviter une signature universelle et conserver plusieurs familles de signaux.
Lavrova <i>et al.</i> (2023)	Une étude multi-fermes combine activité, couchage, production et caractéristiques individuelles.	Comparer chaque vache à sa propre référence et reconnaître l'intérêt futur de variables contextuelles.
Balasso <i>et al.</i> (2023)	Les signaux accélérométriques bruts permettent de modéliser des motifs comportementaux complexes.	Ne pas transposer ces capacités à des agrégats de 15 minutes qui ne contiennent plus la dynamique fine de la démarche.
Palma <i>et al.</i> (2025)	Le déploiement de l'intelligence artificielle en élevage dépend de la qualité des données, de l'intégration et de l'usage.	Privilégier une sortie traçable, interprétable et destinée à une vérification humaine.

Ces travaux motivent une architecture classique, individualisée et temporelle. IF et LOF sont conservés comme comparateurs ponctuels de familles différentes ; le résultat principal repose toutefois sur une accu-

mulation directionnelle des baisses et sur la concordance de plusieurs signaux. L'apprentissage profond n'est pas rejeté en général : il est simplement hors de portée des données agrégées et non étiquetées utilisées dans ce mémoire.

1.4 Capteurs et variables comportementales

Avant d'aborder l'hétérogénéité des protocoles, cette section poursuit un double objectif : situer d'abord brièvement les grandes familles de capteurs disponibles pour la détection de boiterie, puis décrire le capteur effectivement retenu dans ce projet (IceQube) ainsi que les variables comportementales qu'il produit. Les systèmes de surveillance comportementale reposent sur plusieurs familles de capteurs, dont les caractéristiques conditionnent directement les variables disponibles et les performances atteignables.

Le Tableau 1.5 présente les principales technologies et leurs caractéristiques opérationnelles. On distingue trois grandes familles : les capteurs portés par l'animal, tels que les accéléromètres, les podomètres et les colliers ; les capteurs intégrés à l'infrastructure, comme les tapis de pesée et les systèmes de traite ; et les systèmes sans contact, comme les caméras et la vision par ordinateur. Les accéléromètres portés constituent la technologie la plus étudiée dans la littérature récente (O'Leary *et al.*, 2020 ; Alsaad *et al.*, 2019).

Tableau 1.5 Principales familles de capteurs étudiées.

Technologie	Variables mesurées	Avantages	Limites	Études repr.
Accéléromètre (patte/collier)	Activité, pas, transitions couché/debout, durée couchage	Continu, individuel, coût modéré	Dérive, position variable	Alsaad et al. (2012); Balasso et al. (2023)
Podomètre	Nombre de pas, distance parcourue	Simple, robuste	Signal limité, faible résolution	Flower et Weary (2006); Mazrier et al. (2006)
Passerelle sensible à la pression	Pressions plantaires et paramètres spatio-temporels de la démarche	Objectif, quantitatif	Infrastructure fixe, coût élevé	Maertens et al. (2011)
Vision par ordinateur	Posture, arc du dos, démarche	Sans contact, riche en information	Sensible aux conditions, calibration	Qiao et al. (2021)
Système de traite automatisé	Production laitière, conductivité, fréquentation	Déjà installé, données continues	Signal indirect pour la boiterie	Lavrova et al. (2023); Van Hertem et al. (2013)

Dans le cadre de ce mémoire, les données proviennent de capteurs IceQube (IceRobotics Ltd, Édimbourg, Royaume-Uni), des accéléromètres tri-axiaux conçus spécifiquement pour le suivi comportemental des vaches laitières. La Figure 1.5 montre la représentation schématique du capteur IceQube, dont le boîtier étanche contient l'accéléromètre tri-axial et se fixe à la patte par un bracelet en plastique muni d'une boucle et de trous d'ajustement. La Figure 1.6 illustre son positionnement sur le métatarse de la patte arrière; les axes x , y , z de l'accéléromètre permettent de distinguer la position debout (patte verticale, $\vec{g}$ aligné avec z) de la position couchée (patte horizontale).




Figure 1.5 Schéma du capteur IceQube.




Figure 1.6 Positionnement du capteur IceQube.

Le capteur se fixe au métatarse d'une patte arrière par un bracelet à boucle. L'accéléromètre interne mesure l'accélération sur trois axes. La composante gravitationnelle contribue à distinguer la position couchée de la position debout, tandis que les variations d'accélération alimentent les indicateurs d'activité. L'algorithme propriétaire agrège les mesures brutes ; le présent projet exploite des intervalles de 15 minutes. Cette résolution est un choix analytique du mémoire et non une fréquence cliniquement optimale démontrée. Des études de validation de capteurs portés rapportent une forte concordance entre certaines mesures de posture et l'observation directe. Alsaad *et al.* (2012) rapportent une forte concordance entre les mesures d'accéléromètres de patte et l'observation directe pour la classification couché/debout, tandis que Blackie *et al.* (2011) montrent que ces mesures permettent de caractériser les différences de comportement couché associées à la boiterie.

Chaque intervalle de 15 minutes génère sept colonnes de données, dont cinq sont utilisées dans la chaîne de traitement :

- *Steps* : nombre de pas détectés par l'accéléromètre ;
- *Motion Index* : indice synthétique d'activité locomotrice (unité propriétaire IceRobotics, dérivée des variations d'accélération) ;
- *Lying Time* : durée cumulée en position couchée (en minutes, bornée à 15) ;
- *Standing Time* : durée cumulée en position debout (en minutes, bornée à 15) ;
- *Transitions* : nombre total de changements de posture couché↔debout.

Les colonnes supplémentaires (*Transitions Up* et *Transitions Down*) détaillent la direction des transitions mais ne sont pas exploitées directement par la chaîne de traitement, qui utilise leur somme.

Les données agrégées sont stockées dans la mémoire interne du capteur, puis récupérées périodiquement. Elles sont accessibles via la plateforme web CowAlert (IceRobotics), qui offre une interface de visualisation en ligne, et peuvent être exportées au format tabulaire (CSV), directement exploitable par la chaîne de traitement décrite dans ce mémoire.

Le modèle IceTag, prédécesseur de l'IceQube, fournit des variables similaires (pas, temps couché, transitions) et a été utilisé dans plusieurs travaux sur le comportement et la locomotion bovins (Beer *et al.*, 2016 ; Alsaad *et al.*, 2012). Le choix de l'IceQube est d'abord déterminé par la disponibilité du corpus. Il est cohérent avec la place importante des accéléromètres portés dans la littérature sur la surveillance locomotrice (O'Leary *et al.*, 2020 ; Bewley et Schutz, 2008).

Ito *et al.* (2010) montrent que les vaches boiteuses modifient significativement leur comportement de couchage (durée allongée, fréquence de transitions réduite), ce qui justifie l'inclusion de ces variables dans la chaîne de traitement. Nechanitzky *et al.* (2016) montrent également que des lésions de la corne sont associées à des changements de comportement mesurables. Ces résultats justifient l'étude de signaux comportementaux, sans établir à eux seuls un délai universel de détection préclinique.

1.5 Hétérogénéité des protocoles : un obstacle à la comparaison

Les revues spécialisées sur la détection automatisée de boiterie convergent vers une limite récurrente : l'hétérogénéité des protocoles. Le type de capteur, sa position sur l'animal, la définition opérationnelle de la boiterie, la taille des cohortes et l'horizon d'évaluation varient fortement d'une étude à l'autre, ce qui complique la comparaison directe des performances publiées, comme le soulignent les travaux de O'Leary *et al.* (2020) et de Alsaad *et al.* (2019).

Les travaux représentatifs du Tableau 1.4 montrent pourquoi les performances numériques ne doivent pas être juxtaposées sans précaution : les définitions cliniques, les populations, les modalités de capteurs, les découpages d'évaluation et les unités statistiques diffèrent. La présente section examine donc les protocoles plutôt qu'un classement de sensibilités. La revue d'O'Leary et al. (O'Leary *et al.*, 2020) sur les accéléromètres pour la détection de boiterie confirme cette dispersion et souligne l'absence de standardisation dans les protocoles d'évaluation. Alsaad et al. (Alsaad *et al.*, 2019) soulignent en particulier l'absence de véritables études de longue durée ayant abouti à un système d'alerte précoce valide de bout en bout.

Une étude longitudinale menée dans six fermes allemandes combine activité, couchage, production laitière et caractéristiques individuelles dans un modèle à effets mixtes (Lavrova *et al.*, 2023). Elle illustre l'intérêt d'informations hétérogènes, mais son protocole supervisé et ses données contextuelles diffèrent de ceux du présent mémoire.

Enfin, la qualité de la mesure amont reste déterminante : l'échantillonnage, l'édition des épisodes et la représentation des comportements influencent directement la fiabilité des variables dérivées (Ledgerwood *et al.*, 2010 ; Balasso *et al.*, 2023).

Concrètement, l'hétérogénéité des protocoles se manifeste sur au moins cinq dimensions :

1. *Définition du cas* : classe clinique, score locomoteur seuil ou probabilité de boiterie selon les études, d'où des phénomènes mesurés et des sensibilités difficilement comparables ;
2. *Instrumentation* : position du capteur (patte (Alsaad *et al.*, 2012 ; Thorup *et al.*, 2015), collier (Van Herrem *et al.*, 2013), vision dorsale (Viazzi *et al.*, 2013)), fréquence d'échantillonnage et signaux contextuels varient, produisant des variables de nature différente ;
3. *Granularité analytique* : prédiction instantanée, journalière, par épisode ou par vache, avec des exigences de précision temporelle très différentes ;
4. *Objectif métier* : classification clinique, alerte précoce, filtrage ou score de risque, chaque objectif imposant des coûts d'erreur différents ;
5. *Évaluation* : sensibilité, spécificité, AUC, taux d'alertes, IoU ou robustesse inter-fermes, un même système paraissant excellent ou médiocre selon la métrique.

Autrement dit, deux articles peuvent rapporter une "bonne performance" tout en répondant à des problèmes différents. Cette observation justifie le choix de consacrer un chapitre entier aux protocoles de validation et à leurs artefacts, plutôt que de se limiter à un score unique agrégé.

1.6 Détection temporelle de changements persistants

La boiterie n'est pas nécessairement représentée par un point extrême isolé. Les changements rapportés dans les signaux portés concernent souvent une tendance, une rupture ou une modification persistante par rapport au comportement habituel de l'animal (Alsaad et al., 2019 ; Paudyal et al., 2021). Cette structure temporelle favorise les méthodes capables d'accumuler une évidence unilatérale plutôt que de classer indépendamment chaque intervalle.

Les sommes cumulées proposées par Page (1954) constituent une famille classique de détection de changement. Appliquées à une combinaison de déficits normalisés, elles permettent d'oublier les fluctuations brèves, d'accumuler une baisse soutenue et de déclencher une alerte lorsque l'évidence franchit un seuil. Dans un contexte bovin, cette logique doit être associée à une période de référence individuelle, au cycle journalier, à la qualité des données et à la concordance de plusieurs familles de signaux. Elle reste toutefois une détection comportementale : seule une validation avec examens locomoteurs et diagnostics contemporains peut établir la relation clinique.

1.7 Synthèse critique

La littérature et les guides pratiques indiquent trois exigences pour une solution de surveillance associée au risque de boiterie :

1. *Réactivité opérationnelle* : repérer des changements persistants assez tôt pour prioriser l'observation ;
2. *Maîtrise de la charge d'alerte* : limiter les notifications sans suite opérationnelle et la fatigue d'alerte, qui dégradent rapidement la confiance des utilisateurs (Rutten et al., 2013) ;
3. *Interprétabilité* : fournir des raisons explicites utiles à la vérification pour chaque alerte, afin de faciliter la prise de décision terrain.

En pratique, les méthodes purement pilotées par les données peuvent manquer d'explicabilité pour l'opérateur, tandis que les approches purement à règles peuvent manquer de flexibilité face à la variabilité inter-animaux. Un compromis robuste consiste à coupler détection d'anomalies et contraintes métier explicites. Ce couplage cumule la capacité de généralisation des algorithmes non supervisés et des gardes-fous interprétables. La littérature récente confirme cette orientation : les systèmes d'élevage de précision les plus prometteurs combinent des signaux hétérogènes avec des logiques de décision interprétables, plutôt que de s'appuyer sur un modèle unique en boîte noire (Palma et al., 2025 ; Michelena et al., 2025).

L'hétérogénéité des protocoles évoquée à la section précédente a une conséquence directe sur l'évaluation des systèmes : de nombreux travaux comparent des capteurs, des fermes, des labels et des définitions de cas différents, ce qui complique l'appréciation d'une chaîne déployable de bout en bout. Dans ce contexte, il existe une place claire pour des contributions moins théoriques mais plus systémiques : une chaîne reproductible, une validation explicite sur plusieurs niveaux et une traçabilité des artefacts expérimentaux.

La revue de littérature conduit donc à un enseignement central : la difficulté n'est pas seulement de proposer un détecteur performant, mais de construire une chaîne de décision cohérente, reproductible et défendable du point de vue métier. Une telle exigence justifie la structure du présent mémoire, qui traite l'algorithme, les règles métier, l'interface et la validation comme un ensemble cohérent plutôt que comme des blocs séparés.

1.8 Positionnement du mémoire

Le présent mémoire retient d'abord une approche temporelle directionnelle orientée vers les baisses d'activité, puis examine une extension bidirectionnelle. Cette hiérarchie reflète le niveau de preuve : la branche HYPO est soumise à une validation attribuable, une ablation et une analyse de sensibilité complètes ; la branche d'instabilité teste une hypothèse complémentaire qui reste exploratoire. La contribution relève de l'ingénierie scientifique : construire une chaîne reproductible qui compare chaque vache à sa propre période de référence et évaluer honnêtement ce que permettent des données d'activité non étiquetées. Concrètement, le mémoire livre :

1. une branche HYPO évaluée sur 44 événements postérieurs à la période de référence, avec exécution propre de référence, ablation contre IF et LOF et analyse OFAT de vingt variantes ;
2. une branche d'instabilité exploratoire et cinq stratégies de fusion, dont une règle hiérarchique séparant surveillance et notification de vérification ;
3. une campagne étendue de 132 événements incluant contrôles brefs et facteurs confondants ;
4. une évaluation du temps d'exécution de la chaîne complète sur les 28 vaches ;
5. une analyse complémentaire IceTag-SLS synchronisée, explicitement interprétée comme exploratoire et non concluante ;
6. une traçabilité par tests et artefacts tabulaires reproductibles.

La portée reste clairement délimitée : la sortie est une alerte de dégradation comportementale à vérifier, et non une classification ou un diagnostic vétérinaire de boiterie. Cette distinction est fondamentale et

cohérente avec les recommandations de la littérature (Alsaad *et al.*, 2019).

Le chapitre suivant détaille donc les données utilisées, les transformations appliquées aux signaux capteurs, le choix des variables et le protocole expérimental retenu. L'objectif n'est pas seulement de décrire une implémentation, mais de montrer comment la revue précédente se traduit en décisions méthodologiques explicites.

CHAPITRE 2

DONNÉES ET MÉTHODOLOGIE

Ce chapitre définit les données, la branche HYPO, son protocole principal de validation et l'extension bi-directionnelle exploratoire. La sortie étudiée est une alerte comportementale à vérifier sur le terrain. Les termes de sensibilité et de faux positif cliniques ne sont pas employés pour la validation synthétique, faute d'étalon vétérinaire.

2.1 Plan d'étude

L'étude comporte trois niveaux. Le premier valide HYPO sur 44 événements et le compare à trois variantes IF/LOF. Le deuxième étend la campagne à 132 scénarios pour explorer INSTABILITÉ et cinq règles de fusion. À chaque niveau, un scénario est injecté dans une copie distincte de la période future, puis comparé à l'exécution propre de la même vache. Le troisième niveau est une analyse observationnelle sur une cohorte IceTag-SLS de l'hiver 2019. Il utilise des mesures strictement antérieures au score locomoteur et ne sert pas à régler le système. La Figure 2.1 schématise ces trois niveaux.




Figure 2.1 Plan d'étude.

2.2 Corpus principal IceQube 2023

Le fichier `data/brut.csv` provient de la ferme du campus Macdonald de l'Université McGill. Il contient 37 839 mesures de 28 vaches entre le 1^{er} octobre et le 11 novembre 2023. Les variables sont agrégées à une résolution nominale de quinze minutes. Le Tableau 2.1 en décrit les caractéristiques vérifiées.

Tableau 2.1 Caractéristiques vérifiées du corpus IceQube 2023.

Caractéristique	Valeur
Vaches	28
Lignes	37 839
Résolution nominale	15 minutes
Période	1 octobre–11 novembre 2023
Lignes par vache, médiane	564
Lignes par vache, étendue	244–2 474
Doublons vache–temps	0

2.2.1 Variables disponibles

Les variables utilisées sont les pas, le *Motion Index*, le temps couché, le temps debout, les transitions et leur décomposition en levers et couchers (Tableau 2.2). Elles décrivent la quantité de mouvement et la posture ; elles ne mesurent ni l'asymétrie de démarche, ni la douleur, ni une lésion du pied (Alsaad *et al.*, 2019 ; O'Leary *et al.*, 2020). Leur portée clinique est donc indirecte.

Tableau 2.2 Variables brutes du corpus IceQube 2023.

Variable	Interprétation
<i>Steps</i>	Nombre de pas dans l'intervalle.
<i>Motion Index</i>	Intensité agrégée du mouvement mesuré par le capteur.
<i>Lying Time</i>	Temps couché dans l'intervalle.
<i>Standing Time</i>	Temps debout dans l'intervalle.
<i>Transitions</i>	Nombre total de transitions posturales.
<i>Transitions Up/Down</i>	Décomposition en levers et couchers.

2.2.2 Statistiques descriptives et variabilité inter-individuelle

Les distributions sont fortement asymétriques (Tableau 2.3) : la médiane des pas et des transitions par intervalle est nulle, tandis que les maxima sont élevés. Cette structure écarte une normalisation gaussienne globale et motive des comparaisons robustes propres à chaque vache et à chaque créneau horaire (Leys

et al., 2013).

Tableau 2.3 Statistiques descriptives des variables de mouvement (par intervalle de 15 min).

Variable	Moyenne	Écart-type	Médiane	Maximum
Pas	4,0	15,4	0	387
<i>Motion Index</i>	25,5	103,7	5	3 351
Transitions	0,16	0,40	0	6

La variabilité entre vaches est considérable (Tableau 2.4). La moyenne de pas par intervalle varie de 0,0 à 11,1 selon l'animal, et le coefficient de variation inter-vache atteint 0,50 pour les pas, 0,40 pour le *Motion Index* et 0,41 pour les transitions. Cette hétérogénéité interdit un seuil commun à tout le troupeau et justifie le recours à une référence *individuelle*, propre à chaque vache.

Tableau 2.4 Variabilité inter-individuelle des principales variables (moyenne par vache).

Variable	Moyenne/vache min	Moyenne/vache max	CV inter-vache
Pas	0,0	11,1	0,50
<i>Motion Index</i>	4,0	57,4	0,40
Transitions	0,00	0,31	0,41

2.2.3 Choix de la résolution temporelle

L'agrégation à quinze minutes est conservée comme résolution nominale. Une résolution plus fine multiplie le bruit et les intervalles vides sans ajouter d'information comportementale exploitable à l'échelle d'un épisode de plusieurs heures ; une résolution plus grossière masque les transitions posturales. Quinze minutes offrent un compromis entre stabilité du signal et granularité suffisante pour la persistance recherchée par les deux branches.

2.2.4 Contrôles d'intégrité et admissibilité

Le chargement impose des dates interprétables, des identifiants non vides et des variables numériques non négatives ; les durées posturales sont converties en minutes et la couverture de chaque intervalle est

conservée. Les données originales ne sont jamais modifiées par la validation : chaque injection opère sur une copie en mémoire.

La durée des séries est bimodale : seize vaches possèdent moins de quatorze jours de mesures et douze une série longue. Une vache est admissible à la validation synthétique si sa durée atteint quatorze jours, si une période future existe après la période de référence et si les pas, le *Motion Index* et les transitions y sont informatifs. Onze vaches satisfont ces conditions ; les 28 restent utilisables dans l'interface, l'effectif de onze ne concernant que le protocole expérimental. La Figure 2.2 montre la durée disponible par vache et distingue les onze vaches admissibles, en vert, des dix-sept autres, en gris ; le trait pointillé marque le seuil de quatorze jours. Seize des vaches grises restent sous ce seuil, faute d'une durée suffisante. Une barre grise le dépasse pourtant : cette vache atteint la durée requise, mais ne fournit pas de signaux informatifs dans sa période future, ce qui ramène l'effectif admissible à onze.




Figure 2.2 Admissibilité des vaches.

2.2.5 Traçabilité et provenance des données

La provenance du corpus a été vérifiée en confrontant ses valeurs à celles du système commercial CowAlert (IceRobotics), qui restitue les mêmes mesures IceQube. Pour les cinq vaches dont les mesures ont pu être relevées depuis ce système, les deux sources sont alignées un à un sur le couple (vache, début d'intervalle), après vérification de l'absence de doublons. Sur les 7 631 intervalles communs parmi 7 823 lignes CowAlert (97,5 %), les pas, le *Motion Index* et les transitions *coïncident exactement* (corrélation de 1,0, valeurs identiques). Le corpus reflète donc les mesures restituées par le système officiel pour ces animaux. Cette vérification porte sur cinq des vingt-huit vaches ; le fichier source est confidentiel et n'est pas diffusé, seules les corrélations agrégées étant rapportées.

2.2.6 Variables dérivées

Pour chaque variable brute, la chaîne de traitement construit une famille de variables dérivées (Tableau 2.5) : des agrégats par intervalle, leurs transformations logarithmiques pour atténuer l'asymétrie, un z-score robuste global et un z-score robuste glissant (centrage par la médiane, échelle par l'écart absolu médian) et un indicateur de couverture. Ces variables alimentent principalement les comparateurs Isolation Forest et Local Outlier Factor ainsi que les règles de cohérence ; les deux branches temporelles, elles, raisonnent directement sur des ratios à la référence individuelle.

Tableau 2.5 Familles de variables dérivées par variable comportementale brute.

Famille	Description
Agrégats	Somme et moyenne par intervalle de quinze minutes.
Transformations log	$\log(1 + x)$ sur la somme et la moyenne.
Z-score robuste global	Centrage par la médiane, échelle par l'écart absolu médian (MAD).
Z-score robuste glissant	Même principe sur une fenêtre mobile de 24 intervalles.
Couverture	Rapport entre échantillons observés et attendus par intervalle.

2.3 Cohorte IceTag-SLS de l'hiver 2019

Cette cohorte provient du même campus, mais d'une période et d'un dispositif différents. Le SLS est la somme de quatre composantes binaires et varie de 0 à 4. L'analyse retient le score du 12 mars 2019 et les données capteurs strictement antérieures. Une vache doit avoir une période de référence suffisante et au moins 70 % de couverture dans les sept jours précédents. Quatorze vaches sont évaluable : deux ont un

SLS de 0, neuf un SLS de 1 et trois un SLS de 2. Aucun SLS de 3 ou 4 n'est observé. Le seuil $SLS \geq 2$ constitue une séparation exploratoire, non un diagnostic imposé par le protocole source.

2.4 Période de référence individuelle et contrôle de qualité

Chaque série est triée chronologiquement. Les 60 % premiers intervalles admissibles constituent la période de référence; les 40 % suivants forment la période future. Les médianes de référence sont calculées pour le même créneau horaire, avec repli sur la médiane globale de la vache. Une deuxième référence est la valeur du jour précédent. Selon le signal, la comparaison la plus prudente entre ces deux références est retenue. Les sorties sont forcées à zéro pendant la période de référence et un intervalle dont la couverture est inférieure à 25 % ne peut devenir candidat.

2.5 Branche HYPO : baisse comportementale persistante

La branche HYPO cible la signature comportementale la mieux documentée de la boiterie : une réduction de l'activité locomotrice (pas, mouvement, transitions) accompagnée d'une augmentation du temps couché (Ito *et al.*, 2010; Blackie *et al.*, 2011; Chapinal *et al.*, 2011). C'est cette direction de changement, et non un écart quelconque, que le détecteur recherche.

Les pas, le *Motion Index*, les transitions et les temps posturaux sont cumulés sur douze heures. Pour les trois familles d'activité, le déficit est $d_j(t) = \max(0, 1 - r_j(t))$, où $r_j(t)$ est le ratio à la référence individuelle. Le changement postural combine l'excès de temps couché et le déficit de temps debout. Le score est

$$S_H(t) = 0,30d_{pas} + 0,30d_{MI} + 0,20d_{transitions} + 0,20d_{posture}.$$

Un candidat exige $S_H \geq 0,12$, au moins trois familles concordantes, l'implication des pas ou du *Motion Index*, une couverture suffisante et une position dans la période future. Une baisse progressive mesurée sur six heures renforce l'évidence. Le CUSUM, somme cumulée unilatérale de Page (Page, 1954), est défini par $C_t = \max(0, C_{t-1} + e_t - 0,07)$. Un épisode exige une persistance sur six heures et $C_t \geq 1,20$. Deux notifications HYPO sont espacées d'au moins 24 heures. L'algorithme 2.3 résume cette logique de détection pour une vache.

Algorithme : Détection HYPO d'une baisse comportementale persistante (par vache)

Entrée : intervalles X d'une vache, période de référence individuelle, paramètres θ

Sortie : épisodes, départs et notifications (alerte à vérifier, non diagnostique)

1. *Référence individuelle :*

Pour chaque famille (pas, *Motion Index*, transitions, posture), médiane de la période de référence par créneau horaire, avec repli sur la médiane globale de la vache.

2. *Pour chaque intervalle t de la période surveillée :*

Totaux glissants sur 12 h, puis ratio $r_j(t)$ à la référence (créneau et veille, comparaison prudente)

Déficits $d_j(t) = \max(0, 1 - r_j(t))$ (posture : excès de temps couché et déficit de temps debout)

Score $S_H(t) = 0,30 d_{pas} + 0,30 d_{MI} + 0,20 d_{transitions} + 0,20 d_{posture}$

Candidat si $S_H \geq 0,12$, au moins trois familles concordantes, pas ou *Motion Index* impliqués, et couverture suffisante

Évidence $e_t \leftarrow S_H + 0,35$ (baisse sur 6 h) si candidat, sinon 0

CUSUM $C_t \leftarrow \max(0, C_{t-1} + e_t - 0,07)$

3. *Épisode et notification :*

Épisode si persistance du candidat sur 6 h et $C_t \geq 1,20$

Notifier au début d'un épisode, avec un délai réfractaire de 24 h

Figure 2.3 Pseudocode de la détection HYPO.

La Figure 2.4 illustre ce mécanisme sur une vache, en comparant l'exécution injectée à l'exécution propre de la même vache.




Figure 2.4 Détection attribuable au niveau de l'événement, pour une vache et une dégradation graduelle injectée après la période de référence. En haut, le score comportemental $S_H(t)$ de l'exécution injectée s'élève au-dessus du seuil de candidat et de l'exécution propre pendant la fenêtre injectée, puis redescend une fois l'événement terminé. En bas, l'épisode détecté de l'exécution injectée se superpose à la fenêtre réelle (bonne localisation temporelle), alors que l'exécution propre ne produit pas le même épisode au même endroit : seule la part attribuable à l'injection est créditée.

2.6 Branche INSTABILITÉ : mouvement disproportionné et posture fragmentée

La branche INSTABILITÉ ne recherche pas une hausse globale d'activité. Elle calcule quatre familles sur une fenêtre de trois heures : mouvement relatif aux pas, transitions relatives aux pas, transitions relatives au temps postural et volatilité de la fraction couchée. Les hausses des quatre familles sont pondérées respectivement par 0,35, 0,30, 0,20 et 0,15.

Un candidat exige un score d'au moins 0,18, deux familles, dont le mouvement relatif et au moins une corroboration par transitions, fragmentation ou posture. Chaque changement familial doit atteindre 20 %. Une hausse coordonnée des pas et du *Motion Index* d'au moins 15 %, avec un écart inférieur à 20 % et sans fragmentation, est filtrée comme activité générale. Le CUSUM utilise une dérive de 0,06 et un seuil de 0,70. La persistance est de deux heures et le délai réfractaire de douze heures.

Les paramètres de la branche INSTABILITÉ sont des choix techniques exploratoires. Ils ont été définis avant la campagne complète puis soumis à une analyse de sensibilité. Ils ne sont pas présentés comme des seuils physiologiques ou cliniquement optimaux.

2.7 Fusion des branches

Cinq stratégies sont comparées sur les mêmes événements :

1. **HYPO** : seule la branche HYPO produit la sortie ;
2. **INSTABILITÉ** : seule l'instabilité produit la sortie ;
3. **OU** : toute branche active peut notifier ;
4. **HIÉRARCHIQUE** : l'hypoactivité, la convergence ou une séquence produit une alerte de vérification ; l'instabilité isolée reste en surveillance ;
5. **SÉQUENTIELLE** : une alerte exige une instabilité suivie d'une hypoactivité entre 24 et 72 heures plus tard.

La fusion hiérarchique est la configuration de référence de l'extension exploratoire. Sa période réfractaire est de douze heures. Une priorité 1 correspond à une surveillance d'instabilité, une priorité 2 à une hypoactivité et une priorité 3 à une convergence ou une séquence. Elle n'est pas présumée supérieure à HYPO : cette comparaison fait partie des résultats. Le Tableau 2.6 consigne les paramètres de référence des deux branches.

Tableau 2.6 Paramètres de référence des deux branches.

Paramètre	HYPO	INSTABILITÉ
Agrégation	12 h	3 h
Persistance	6 h	2 h
Délai réfractaire	24 h	12 h
Seuil de score	0,12	0,18
Dérive CUSUM	0,07	0,06
Seuil CUSUM	1,20	0,70
Familles minimales	3	2
Couverture minimale	25 %	25 %

2.8 Validation technique principale du module HYPO

Trois profils graduels et un contrôle bref sont appliqués à chacune des onze vaches admissibles, soit 44 événements. Les profils léger, modéré et marqué diminuent de façon progressive les pas, le mouvement et les transitions, puis transfèrent une part du temps debout vers le temps couché pendant respectivement 36, 48 et 60 heures. Le contrôle dure trois heures et ne devrait pas former un épisode persistant. Chaque événement est placé dans une copie indépendante des données, strictement après le début de la période future. L'exécution propre de la même vache est soustraite lors du calcul des métriques attribuables.

L'ablation applique cinq variantes aux mêmes fenêtres : (A) HYPO temporel multivarié ; (B) Isolation Forest suivi des règles de persistance ; (C) Isolation Forest ponctuel ; (D) LOF suivi des règles ; et (E) un comparateur pédométrique restreint au seul canal des pas. Les comparaisons appariées sont calculées après agrégation par vache. Une analyse OFAT conserve les mêmes onze vaches, les mêmes fenêtres et la même graine, puis modifie séparément dix paramètres autour de la référence. Elle évalue une robustesse locale et ne sélectionne pas une nouvelle configuration.

2.9 Extension bidirectionnelle et contrôles de confusion

Douze scénarios sont appliqués à chacune des onze vaches admissibles, soit 132 événements. Chaque scénario est injecté dans une copie indépendante des données, strictement après le début de la période future. L'enveloppe est progressive, avec montée, plateau et retour. La somme des temps couché et debout est conservée. Le Tableau 2.7 décrit ces douze scénarios.

Tableau 2.7 Scénarios de la validation technique.

Famille	Nombre	Rôle
Hypoactivité légère, modérée, marquée	33	Baisse progressive de plusieurs signaux sur 24 à 48 h.
Instabilité légère, modérée, marquée	33	Mouvement relatif, transitions et posture sur 8 à 16 h.
Instabilité puis hypoactivité	11	Séquence séparée par 24 h.
Pic capteur, exercice bref, manipulation	33	Contrôles brefs qui doivent être rejetés.
Activité de type œstrus	11	Confondant d'hyperactivité coordonnée.
Hypoactivité non locomotrice	11	Confondant causal indiscernable avec les capteurs seuls.

L'amplitude modérée des pas atteint 29 %, valeur ancrée sur un ordre de grandeur publié autour d'un parage thérapeutique (Paudyal *et al.*, 2021). Les amplitudes des autres signaux sont des hypothèses de test et non des estimations cliniques.

2.10 Métriques et analyses de sensibilité

2.10.1 Recouvrement temporel (IoU)

La localisation d'un épisode est mesurée par l'intersection sur l'union (*Intersection over Union*, IoU), une métrique issue de la détection d'objets en vision par ordinateur (Everingham *et al.*, 2010), entre la fenêtre injectée et l'épisode prédit :

$$\text{IoU} = \frac{|\text{injecté} \cap \text{prédit}|}{|\text{injecté} \cup \text{prédit}|},$$

exprimée en nombre d'intervalles de quinze minutes. Une valeur de 1 indique une superposition parfaite et une valeur de 0 une absence de chevauchement. Le seuil $\text{IoU} \geq 0,20$ retient les épisodes raisonnablement localisés ; il est nettement plus strict que le simple recouvrement, qui ne compte qu'un chevauchement non nul.

2.10.2 Métriques attribuables et unité statistique

Une détection est attribuable seulement si l'exécution injectée ajoute un intervalle ou un départ absent de l'exécution propre. Pour HYPO, les résultats distinguent nouveau départ, couverture attribuable, $\text{IoU} \geq 0,20$, meilleur IoU, délai et notifications de fond. Pour l'extension, ils ajoutent les taux de surveillance, de contrôle et de confusion. Les synthèses inférentielles utilisent la vache comme unité ; les lignes de quinze minutes ne sont jamais des sujets indépendants.

Cette dépendance se quantifie. En estimant l'autocorrélation des séries par vache, on obtient un temps d'autocorrélation intégré τ et une taille d'échantillon effective $n_{\text{eff}} = n/\tau$. Au grain brut de quinze minutes, τ vaut de l'ordre d'une heure pour l'activité, de sorte que les 36 879 mesures ne représentent déjà qu'environ dix mille observations indépendantes. Surtout, comme HYPO décide sur des totaux glissants de douze heures, deux fenêtres voisines partagent presque toutes leurs données et le temps de corrélation au niveau de la décision atteint environ huit heures : chaque vache n'apporte alors qu'une quinzaine de points de décision indépendants, soit de l'ordre du millier sur l'ensemble du corpus. Ce constat justifie quantitativement le choix de la vache comme unité de rééchantillonnage et le caractère conservateur des intervalles de confiance. Le calcul est reproductible par `scripts/compute_correlation_time.py`.

La détection peut aussi se résumer, au niveau de l'événement, par un F1 : les 33 dégradations graduelles sont les positifs attendus et les 11 contrôles brefs les négatifs attendus. Un vrai positif est un événement graduel détecté de façon attribuable, un faux positif un contrôle bref alerté à tort, un faux négatif un événement graduel manqué et un vrai négatif un contrôle correctement rejeté ; le F1 est la moyenne harmonique de la précision et du rappel correspondants. Cette synthèse reste complémentaire : elle n'intègre ni la charge de fond ni la qualité fine de localisation.

La sélection descriptive des fusions impose trois conditions de portée : détection des scénarios de vérification d'au moins 60 %, surveillance de l'instabilité d'au moins 50 % et IoU_{20} d'au moins 20 %. Une fonction d'utilité secondaire récompense la détection et pénalise fortement les contrôles, les confondants et la charge de fond. Ses poids sont des choix d'ingénierie ; elle ne représente pas une utilité clinique validée.

L'analyse OFAT principale modifie vingt fois, une valeur à la fois, dix paramètres de HYPO. Une analyse plus restreinte modifie ensuite l'agrégation, la persistance et les seuils de la branche INSTABILITÉ. Les deux analyses servent à détecter une dépendance excessive aux valeurs de référence, non à optimiser les paramètres

sur les événements évalués.

Deux analyses exploratoires complètent ce dispositif sans modifier la configuration principale. La première estime, uniquement sur la période de référence de chaque vache, un facteur proportionnel à l'écart-type de son score, puis réexécute la campagne avec un seuil individualisé. La seconde fait varier le seuil de score HYPO de 0,04 à 0,20, en conservant les mêmes vaches, fenêtres, injections et autres paramètres. Elle décrit conjointement la réponse aux événements graduels et la charge produite par les exécutions propres. Ces analyses ont été ajoutées après la validation principale : elles servent à examiner des hypothèses et non à sélectionner rétrospectivement une nouvelle valeur de seuil.

2.11 Analyse SLS

La configuration hiérarchique est appliquée sans consulter les scores. La mesure principale est le nombre de notifications dans les sept jours précédant le 12 mars 2019. Sont également rapportées la fraction du temps en épisode, la surveillance d'instabilité et le score maximum. Les comparaisons utilisent l'AUC descriptive, le test de Mann-Whitney et la corrélation de Spearman au niveau de la vache. Avec seulement trois SLS ≥ 2 , ces mesures restent exploratoires.

2.12 Reproductibilité

Les configurations et les sorties sont exportées en CSV. Les tests vérifient le placement postérieur à la période de référence, la conservation posturale, la fusion et les contrats de sortie. L'Annexe A fournit les commandes de reproduction. Cette démarche rejoint les recommandations sur la reproductibilité en apprentissage automatique et la gestion FAIR des données (Pineau *et al.*, 2021; Wilkinson *et al.*, 2016).

CHAPITRE 3

ARCHITECTURE ET IMPLÉMENTATION

Ce chapitre relie la méthodologie au code exécuté. Le noyau HYPO, son évaluation principale, l'extension bidirectionnelle et l'interface sont séparés afin qu'une modification de présentation ne change pas silencieusement les résultats (Sculley *et al.*, 2015 ; Amershi *et al.*, 2019 ; Breck *et al.*, 2017).

3.1 Organisation du logiciel

Le Tableau 3.1 récapitule les modules qui produisent les sorties du mémoire.

Tableau 3.1 Modules qui produisent les sorties du mémoire.

Module	Responsabilité
<code>core/io.py</code>	Chargement, noms de colonnes et types temporels.
<code>core/features.py</code>	Agrégation à quinze minutes, couverture et variables dérivées.
<code>core/early_warning.py</code>	Branche HYPO, période de référence, score, CUSUM et persistance.
<code>core/hybrid_warning.py</code>	Branche INSTABILITÉ et cinq règles de fusion.
<code>core/pipeline.py</code>	Orchestration vache par vache et sortie troupeau.
<code>core/model_if.py</code>	Isolation Forest conservé comme comparateur visuel.
Campagne HYPO	Validation principale après la période de référence.
Ablation HYPO	Comparaison contre IF, LOF et le comparateur pédométrique.
Sensibilité HYPO	Analyse OFAT des paramètres sans sélection de nouvelle configuration.
<code>scripts/per_cow_calibration.py</code>	Test exploratoire d'un seuil individualisé.
<code>scripts/detection_</code>	
<code>background_curve.py</code>	Courbe descriptive détection-charge.
Profils de l'extension bidirectionnelle	Douze scénarios synthétiques et contrôles.
Campagne de l'extension bidirectionnelle	Injections après la période de référence et métriques attribuables.
Sensibilité de la fusion	Comparaison des fusions et sensibilité technique.
Analyse IceTag-SLS synchronisée	Cohorte et mesures SLS.
<code>app.py, ui/</code>	Interface Streamlit de priorisation.
<code>tests/</code>	Tests unitaires, invariants et non-régression.

Les fichiers du dossier `scripts/` servent aux tâches reproductibles de soutien : génération des figures, orchestration de la validation HYPO et mesure de performance. Ils n'introduisent pas une logique de détection parallèle. Le script `run_hypo_module_validation.py` produit les artefacts de la campagne principale et de l'ablation; `benchmark_performance.py` chronomètre la chaîne de traitement complète; et un script dédié produit les figures de l'extension. Les scripts `per_cow_calibration.py` et `detection_background_curve.py` réutilisent la campagne HYPO sans introduire de nouvelle logique d'alerte. La Figure 3.1 schématise cette organisation.




Figure 3.1 Architecture du système.

3.2 Flux de traitement

Pour une vache, `run_pipeline_one_cow` effectue les opérations suivantes :

1. normaliser les mesures et construire les intervalles;
2. matérialiser la séparation entre la période de référence et la période future;
3. exécuter le comparateur Isolation Forest;
4. calculer la branche HYPO;
5. calculer la branche INSTABILITÉ;
6. appliquer la fusion choisie et espacer les notifications;
7. retourner les scores, épisodes, départs, notifications, types et priorités.

La chaîne appliquée au troupeau répète ce traitement sans partager de période de référence entre les vaches.

3.3 Implémentation des deux persistances

La persistance n'est pas appliquée après une fusion brute. Chaque branche construit d'abord ses propres candidats, son propre CUSUM et son propre épisode. Cette décision évite qu'une instabilité courte doive durer six heures pour être reconnue ou qu'une baisse lente soit déclenchée par deux heures de fluctuation. La fusion reçoit donc deux séries d'épisodes déjà stabilisées.

Dans la branche HYPO, une fenêtre glissante de six heures doit contenir au moins 45 % de candidats et le CUSUM doit franchir 1,20. Dans la branche INSTABILITÉ, la proportion minimale est de 50 % sur deux heures et le CUSUM doit franchir 0,70. Ces règles sont déterministes et testées séparément.

3.4 Fusion hiérarchique

La fusion hiérarchique est volontairement asymétrique. Une instabilité seule indique une situation à surveiller, mais ne déclenche pas automatiquement une vérification prioritaire. Une hypoactivité produit une notification de vérification. La priorité augmente lorsque les deux branches convergent ou lorsqu'un départ HYPO est précédé d'un départ INSTABILITÉ dans la fenêtre de 72 heures. Cette architecture empêche un simple pic de *Motion Index* de devenir une notification de vérification.

L'algorithme 3.2 formalise cette logique de fusion pour une vache donnée.

Algorithme : Fusion hiérarchique des branches HYPO et INSTABILITÉ (par vache)
Entrée : intervalles X d'une vache, période de référence individuelle, paramètres θ
Sortie : type d'alerte, priorité et notifications (alerte à vérifier, non diagnostique)
1. <i>Détection des deux branches :</i>
hypo $\leftarrow$ DétecterHypo(X , référence, persistance = 6 h) (baisse d'activité persistante)
instab $\leftarrow$ DétecterInstabilité(X , référence, persistance = 2 h) (mouvement disproportionné aux pas)
2. <i>Fusion par priorité décroissante :</i>
Si hypo et instab récente (≤ 72 h) : priorité $\leftarrow 3$, type $\leftarrow$ SEQUENCE
Sinon si hypo et instab : priorité $\leftarrow 3$, type $\leftarrow$ MIXTE
Sinon si hypo : priorité $\leftarrow 2$, type $\leftarrow$ HYPO
Sinon si instab : priorité $\leftarrow 1$, type $\leftarrow$ SURVEILLANCE (à surveiller, sans vérification prioritaire)
3. <i>Notification :</i>
Émettre une notification seulement si priorité ≥ 2
Respecter un délai réfractaire de fusion de 12 h entre notifications

Figure 3.2 Pseudocode de la fusion hiérarchique des deux branches.

3.5 Comparateurs Isolation Forest et Local Outlier Factor

Deux détecteurs d'anomalies non supervisés sont conservés comme points de comparaison. Ils ne produisent pas la notification principale : ils situent le détecteur temporel par rapport à des familles d'algorithmes répandues et fournissent des points de comparaison reproductibles.

3.5.1 Isolation Forest

Isolation Forest isole les observations rares en construisant des arbres de partition aléatoire : un point anormal, plus facile à séparer du reste, présente une profondeur moyenne d'isolation plus faible (Liu *et al.*, 2008). Les variables dérivées sont d'abord mises à l'échelle par un `RobustScaler` (intervalle inter-quantile 10–90), qui résiste aux distributions fortement asymétriques des signaux d'activité. Le modèle est ajusté sur la période de référence de chaque vache, puis appliqué à l'ensemble de sa série, de sorte qu'il décrive l'écart d'un intervalle par rapport au comportement individuel appris. Les hyperparamètres figés sont rassemblés au Tableau 3.2.

Tableau 3.2 Hyperparamètres figés d'Isolation Forest (comparateur).

Hyperparamètre	Valeur	Rôle
Nombre d'arbres	800	Stabilité du score d'isolation
Variables par arbre	0,80	Décorrélation des arbres
Échantillonnage	<i>bootstrap</i>	Diversité des sous-ensembles
Contamination	0,06	Fraction supposée d'anomalies
Graine aléatoire	42	Reproductibilité exacte
Mise à l'échelle	<code>RobustScaler</code> 10–90	Robustesse à l'asymétrie
Ajustement	période de référence	Référence propre à chaque vache

Les sorties `if_score` et `if_anomaly_point`, ainsi que des colonnes de compatibilité `pred_lameness_*`, restent disponibles. Elles alimentent l'ablation du Chapitre 4 et l'affichage, sans jamais définir la conclusion. Par construction, Isolation Forest repère un écart *ponctuel* dans n'importe quelle direction ; il ne modélise ni la référence horaire individuelle, ni la *direction*, ni la *persistance* d'une dégradation, qui sont précisément les propriétés recherchées par la branche HYPO.

3.5.2 Local Outlier Factor

Local Outlier Factor compare la densité locale d'un point à celle de ses voisins : une densité nettement plus faible que le voisinage signale une anomalie locale (Breunig *et al.*, 2000). Il est exécuté en mode nouveauté dans le module d'ablation, avec les mêmes indices d'entraînement et la même normalisation robuste que la comparaison Isolation Forest, afin que l'écart mesuré reflète l'algorithme et non un changement de protocole. Sa complexité quadratique dans le cas général le rend moins apte au passage à l'échelle, mais il peut capter des structures locales que les méthodes globales manquent. Le Tableau 1.3 du Chapitre 1 résume leurs propriétés respectives.

3.6 Implémentation des validations

Le module de campagne HYPO sélectionne les vaches admissibles, exécute une référence propre et injecte les quatre profils de la campagne HYPO. Le module d'ablation réutilise les mêmes fenêtres pour les cinq variantes. Le module d'extension bidirectionnelle étend ensuite le protocole aux douze scénarios bidirectionnels. Le harnais garantit trois propriétés : un placement reproductible des perturbations, une attribution stricte de l'effet à l'injection, et le rejet de toute campagne mal formée.

3.6.1 Génération déterministe

La graine d'une vache et d'un scénario est dérivée par SHA-256, indépendamment de la variable d'environnement de hachage de Python ; deux exécutions produisent donc exactement les mêmes injections. La position des profils est tournée entre les vaches pour ne pas associer systématiquement une intensité à une période particulière. La fonction d'injection renvoie une copie modifiée de la série et une table décrivant la fenêtre, les changements cibles et la raison de conception, sans jamais altérer le fichier source.

3.6.2 Exécution de référence et attribution

Chaque vache est aussi exécutée *sans* injection. Les nouveaux débuts de la série injectée sont comparés aux débuts de cette référence avec une tolérance temporelle, et pour la couverture comme pour l'IoU, le masque d'épisode de référence est soustrait intervalle par intervalle du masque injecté. Cette étape est indispensable : elle empêche de créditer une injection lorsqu'une alerte identique aurait été produite par les données originales, et c'est elle qui rend les métriques *attribuables* (Section 2.5 du Chapitre 2).

3.6.3 Contrôles bloquants

Avant tout calcul de résultat, le protocole vérifie l'unicité des identifiants d'événement, leur non-chevauchement, leur placement strictement après la période de référence, la disponibilité des signaux, la non-négativité des mesures, la conservation du temps postural total et l'absence d'écriture dans le fichier source. Une campagne qui échoue à l'un de ces contrôles n'alimente pas le manuscrit. La comparaison des fusions réutilise exactement les mêmes vaches et les mêmes scénarios, de sorte que les écarts entre variantes ne tiennent qu'à la règle de fusion.

3.7 Évaluation du temps d'exécution

L'évaluation reconstruit les variables, exécute le comparateur Isolation Forest, les règles IF comparatives, HYPO, INSTABILITÉ et la fusion hiérarchique. Chaque étape est chronométrée avec une horloge monotone. Cinq répétitions sont effectuées sur les 28 vaches et la concaténation des sorties intervalle est incluse. Le résultat canonique est la médiane des cinq durées ; les valeurs minimale et maximale sont conservées pour rendre visible la variabilité de la machine. Ce test documente la faisabilité du prototype sur l'ordinateur utilisé, non un temps garanti en production.

3.8 Technologies et dépendances

Le Tableau 3.3 présente les principales dépendances figées dans `requirements.txt`. Les versions exactes servent à reconstruire l'environnement et à garantir la reproductibilité numérique ; elles ne constituent pas un résultat scientifique. Les comparateurs Isolation Forest et Local Outlier Factor proviennent de `scikit-learn` (Pedregosa *et al.*, 2011), les tests statistiques de `SciPy` (Virtanen *et al.*, 2020), et l'interface de `Streamlit` ; la manipulation des données et le calcul numérique reposent sur `pandas` (McKinney, 2010) et `NumPy` (Harris *et al.*, 2020).

Tableau 3.3 Principales technologies de la version reproductible.

Composant	Version	Rôle principal
Python	3.10 ou ultérieur	Langage d'exécution
pandas	2.3.3	Manipulation des données tabulaires
NumPy	2.3.5	Calcul numérique
scikit-learn	1.7.2	Comparateurs IF et LOF
SciPy	1.16.2	Tests et statistiques descriptives
statsmodels	0.14.5	Compléments statistiques
Streamlit	1.51.0	Interface interactive
Plotly	6.3.0	Tracés interactifs de l'interface
pytest	8.4.2	Tests automatisés

3.9 Interface Streamlit

L'interface est un outil de lecture et de priorisation. Elle charge par défaut `data/brut.csv` et accepte un CSV importé. La vue individuelle présente les signaux, les épisodes et les notifications. La vue troupeau ordonne les animaux à vérifier, tandis que la carte thermique permet une comparaison journalière. Isolation Forest reste présenté comme comparateur ; il ne constitue pas la notification principale.

3.9.1 Niveaux de priorité et action associée

L'interface traduit la sortie de fusion en trois niveaux de priorité qui orientent l'effort de vérification, sans jamais affirmer un diagnostic (Tableau 3.4). Seules les priorités 2 et 3 produisent une notification de vérification ; la priorité 1 reste un signal de surveillance. Ce classement remplace une échelle de risque clinique : il ordonne les animaux à observer, il ne quantifie pas une probabilité de boiterie.

Tableau 3.4 Niveaux de priorité de l'interface et action de vérification associée.

Priorité	Condition	Action suggérée
3	Convergence HYPO + INSTABILITÉ, ou séquence instabilité→hypoactivité	Vérification rapprochée, observation locomotrice
2	Hypoactivité persistante (HYPO)	Vérification à planifier
1	Instabilité isolée	Surveillance, sans alerte de vérification

Les Figures 3.3 à 3.7 illustrent les principales vues de l'interface. Les marqueurs affichés dans la vue individuelle signalent une vérification à effectuer ; ils ne confirment pas une boiterie. Les vues de troupeau servent uniquement à ordonner les animaux et les journées à examiner.




Figure 3.3 Analyse individuelle du tableau de bord.




Figure 3.4 Signaux de la vache 8116.

Animaux à vérifier en priorité




Figure 3.5 Animaux à vérifier en priorité.

Classement du troupeau par priorité de vérification




Figure 3.6 Classement du troupeau.

Comparaison inter-animaux (vue journalière)

Carte thermique des alertes journalières




Figure 3.7 Alertes journalières par animal.

3.10 Tests et traçabilité

La suite automatisée contient 98 tests. Elle couvre le chargement, les variables dérivées, les deux détecteurs, les cinq fusions, les injections, les contrôles après la période de référence, l'analyse de sensibilité, l'analyse SLS et le démarrage de Streamlit. Les résultats sont écrits dans des fichiers tabulaires dont la provenance est explicite. Le succès des tests atteste la cohérence logicielle, pas la validité clinique.

Chaque résultat suit un cycle de vie traçable : une commande de reproduction exécute un module de validation, qui écrit des fichiers CSV et JSON ; un manifeste SHA-256 fige ces sorties ; et un script dédié les transforme en figures du manuscrit. Aucun résultat n'est saisi à la main. Une modification du code, des données ou des paramètres impose donc une nouvelle exécution et un nouveau manifeste, de sorte que le PDF seul ne constitue jamais la trace de référence de l'expérience. La Figure 3.8 illustre cette chaîne.




Figure 3.8 Chaîne de reproductibilité.

Le manifeste ferme la chaîne en rendant toute modification d'un artefact détectable. Il atteste l'identité des fichiers reproduits, mais ne remplace ni les contrôles méthodologiques ni une validation clinique.

CHAPITRE 4

VALIDATION ET RÉSULTATS

Ce chapitre présente les preuves techniques du système en partant du résultat le plus solide : la branche HYPO. La première partie montre sa réponse à des dégradations graduelles, son avantage sur les comparateurs IF/LOF et sa stabilité locale par OFAT. La deuxième partie examine l'extension INSTABILITÉ et les règles de fusion sur une campagne plus large. Les pourcentages décrivent la réponse du logiciel à des scénarios contrôlés ; ils ne sont pas des performances cliniques. Le Tableau 4.1 rassemble les clés de lecture mobilisées tout au long du chapitre.

Tableau 4.1 Clés de lecture du chapitre.

Élément	Interprétation
Onze vaches	Seules onze des 28 vaches possèdent une période future suffisamment longue, les signaux requis et une couverture compatible avec toutes les campagnes.
Injections après la période de référence	Elles commencent après les 60 % réservés à la construction de la référence ; les données injectées ne peuvent donc pas influencer cette référence.
Attribution	Une alerte est attribuable seulement si elle apparaît avec l'injection et non dans l'exécution propre de la même vache et de la même période.
Couverture	Au moins un intervalle attribuable recouvre la fenêtre injectée.
Nouveau départ	Un épisode absent de l'exécution propre commence dans la fenêtre ; ce critère est plus exigeant qu'un simple recouvrement.
IoU20	Le recouvrement temporel entre l'épisode attribuable et l'événement atteint au moins 0,20 ; il renseigne la localisation, pas la validité clinique.
Charge de fond	Les notifications hors fenêtres injectées sur des données non étiquetées ; sans diagnostic exhaustif, elles ne peuvent pas être appelées faux positifs.
Hypoactivité non locomotrice	Neuf alertes sur onze montrent que les signaux disponibles ne permettent pas d'identifier la cause d'une baisse persistante.

4.1 Intégrité des protocoles

Onze vaches satisfont les critères de durée et de signaux informatifs. La campagne HYPO comprend quatre événements indépendants par vache, soit 44 événements. La campagne étendue comprend douze scénarios

rios par vache, soit 132 événements. Tous commencent après la séparation chronologique, utilisent des identifiants et des fenêtres physiques distincts et sont comparés à une exécution propre de la même vache. Les injections ne modifient pas le fichier brut, les variables restent non négatives et le temps postural total est conservé. Le Tableau 4.2 récapitule les contrôles automatiques correspondants.

Tableau 4.2 Contrôles automatiques communs aux campagnes techniques.

Contrôle	Résultat
Colonnes requises présentes et campagnes non vides	Conforme
Identifiants et fenêtres physiques uniques	Conforme
Fenêtres non chevauchantes dans la campagne HYPO	Conforme
Injections strictement postérieures à la période de référence	Conforme
Signaux sources informatifs et couverture admissible	Conforme
Non-négativité et conservation du temps postural	Conforme
Exécution propre utilisée pour l'attribution	Conforme

4.2 Validation technique principale du module HYPO

4.2.1 Résultats attribuables par profil

Le Tableau 4.3 présente séparément le nouveau départ, la couverture attribuable et la localisation IoU20. Les trois profils graduels sont les cas techniques attendus positifs ; la variation brève isolée est le contrôle attendu négatif.

Tableau 4.3 Résultats attribuables du module HYPO.

Profil	<i>n</i>	Nouveau départ	Couverture	IoU20	IoU moyen
Graduel léger	11	45,5 %	72,7 %	27,3 %	0,087
Graduel modéré	11	63,6 %	90,9 %	36,4 %	0,192
Graduel marqué	11	63,6 %	100,0 %	54,5 %	0,269
Variation brève isolée	11	0,0 %	0,0 %	0,0 %	0,000

Sur les 33 dégradations graduelles, un nouvel épisode apparaît dans 19 cas, soit 57,6 %. Après soustraction de l'exécution propre, un intervalle ajouté recouvre la fenêtre dans 29 cas sur 33, soit 87,9 %, et 13 cas

atteignent $IoU \geq 0,20$, soit 39,4 %. L' IoU attribuable moyen est de 0,183 et le délai médian de nouveau départ de 20,75 heures. Les intervalles de confiance à 95 %, obtenus par bootstrap regroupé par vache (Efron et Tibshirani, 1993; Field et Welsh, 2007) (10 000 rééchantillonnages, l'unité étant la vache), sont [78,8 ; 97,0] pour la couverture, [42,4 ; 75,8] pour le nouveau départ et [24,2 ; 54,5] pour l' IoU_{20} . Leur largeur reflète l'effectif de onze vaches et invite à interpréter la valeur ponctuelle avec prudence. Ces indicateurs ne sont pas interchangeables : la couverture montre une réponse dans la fenêtre, tandis que le nouveau départ vérifie qu'un épisode distinct a réellement commencé.

Le contrôle bref n'engendre aucun départ ni intervalle attribuable. Sur les exécutions propres et uniquement pendant la période future, HYPO produit en moyenne 0,402 notification par vache-jour ; le 90^e percentile entre vaches est de 0,491. Cette quantité mesure une charge de fond, pas un taux de faux positifs, car les données propres ne possèdent pas d'annotation clinique exhaustive.

4.2.2 Typologie des modes de défaillance

Le Tableau 4.4 décompose les résultats actuels en modes d'échec, sans reprendre les fréquences d'un protocole antérieur. Sur les 33 dégradations graduelles, quatre ne produisent aucun recouvrement attribuable et seize sont recouvertes sans localisation suffisante ; sur les vingt-neuf recouvertes, dix n'ouvrent aucun nouveau départ par rapport à l'exécution propre. Du côté des contrôles, les variations brèves sont rejetées, mais l'hypoactivité non locomotrice déclenche neuf alertes sur onze. Parmi les 33 instabilités pures, 22 sont repérées par la branche de surveillance et aucune ne produit un épisode nécessitant une vérification de la fusion. Ces fréquences sont régénérées par le script `scripts/compute_failure_modes.py`.

Tableau 4.4 Modes de défaillance observés.

Mode	Fréquence
Graduel non détecté (aucun recouvrement attribuable)	4 / 33
Graduel recouvert mais mal localisé ($IoU < 0,20$)	16 / 33
Graduel recouvert sans nouveau départ	10 / 29
Confusion avec une hypoactivité non locomotrice	9 / 11
Instabilité pure repérée en surveillance	22 / 33
Instabilité pure produisant un épisode de vérification	0 / 33
Contrôle bref alerté à tort	0 / 11

Cette typologie oriente les priorités : la localisation temporelle et la séparation causale avec les hypoactivités non locomotrices sont les deux limites dominantes, tandis que les pics brefs sont rejetés dans les conditions testées.

4.2.3 Robustesse locale des paramètres HYPO

L'analyse OFAT comprend la référence et vingt variantes dans lesquelles un seul des dix paramètres est modifié. Les 924 évaluations événement–configuration rejettent toutes le contrôle bref. Sur les profils progressifs, 12 variantes sur 20 reproduisent exactement le taux de nouveaux départs de la référence et 15 restent dans un écart maximal de 6,1 points. Pour IoU20, 15 variantes restent dans un écart maximal de 3,0 points. Sur l'ensemble des valeurs testées, le taux de nouveaux départs varie de 45,5 à 66,7 %, la couverture de 63,6 à 90,9 %, IoU20 de 27,3 à 45,5 %, le délai médian de 15,5 à 24,5 heures et le fond de 0,187 à 0,553 notification par vache-jour.

La Figure 4.1 représente l'amplitude maximale de ces écarts. Elle mesure une influence locale des paramètres, et non une amélioration ni une optimisation de la configuration de référence. Le Tableau 4.5 en détaille les plages signées pour les paramètres les plus structurants.




Figure 4.1 Sensibilité locale des paramètres HYPO.

Tableau 4.5 Plages d'écarts signés pour les paramètres HYPO les plus structurants.

Paramètre	Valeurs testées	Δ départ (pp)	Δ couverture (pp)	Δ IoU20 (pp)	Δ fond (/vache-jour)
Familles concordantes	2; 4	-12,1 à 0,0	-24,2 à +3,0	-12,1 à +3,0	-0,214 à +0,107
Agrégation	6; 24 h	-9,1 à +9,1	-18,2 à 0,0	-12,1 à -3,0	-0,098 à +0,152
Baisse d'activité	5; 15 %	-9,1 à -9,1	-9,1 à +3,0	-6,1 à -3,0	-0,036 à +0,027
Persistance	3; 12 h	-6,1 à 0,0	0,0 à 0,0	-3,0 à +6,1	-0,054 à +0,080

Le nombre de familles et la fenêtre d'agrégation sont les choix les plus influents. Les paramètres CUSUM et de couverture ont peu d'effet dans les plages testées. Cette stabilité locale rend la configuration reproductible et techniquement défendable, mais ne démontre ni son optimalité ni sa validité physiologique.

4.2.4 Calibration individuelle exploratoire

Une calibration simple a été testée pour répondre à la variabilité du fond entre vaches. Pour chaque animal, le seuil de 0,12 est multiplié par le rapport entre l'écart-type de son score pendant la période de référence et la médiane de ces écarts-types. Les facteurs, estimés sans utiliser la période future, restent compris entre 0,98 et 1,03. La procédure ne modifie ni le fond moyen (0,402 notification par vache-jour), ni son coefficient de variation inter-vache (0,244), ni la couverture attribuable (87,9 %). Le taux de nouveaux départs passe de 57,6 à 60,6 %, mais IoU20 diminue de 39,4 à 33,3 %. Cette calibration n'apporte donc aucun gain opérationnel et dégrade la localisation ; elle n'est pas retenue. Ce résultat nul ne démontre pas qu'aucune calibration individualisée soit possible, seulement que la dispersion du score de référence n'est pas une base utile dans cette campagne.

4.2.5 Compromis entre réponse technique et charge de fond

Le seuil de score est ensuite parcouru de 0,04 à 0,20 sans modifier les autres paramètres. Les neuf configurations rejettent les onze variations brèves. Entre 0,04 et 0,12, la couverture, les nouveaux départs et IoU20 restent respectivement à 87,9 %, 57,6 % et 39,4 %, tandis que le fond diminue légèrement de 0,419 à 0,402 notification par vache-jour. À 0,20, le fond atteint 0,330, mais la couverture et IoU20 baissent à 78,8 % et 30,3 %.

Le point 0,14 atteint 45,5 % à IoU20 avec un fond de 0,375 et les mêmes taux de couverture et de nouveaux départs que la référence. Il ne constitue toutefois pas un nouvel optimum : il a été observé sur le même ensemble qui sert à évaluer la configuration. Le seuil de 0,12 reste donc inchangé ; 0,14 devient seulement une hypothèse à tester après sélection sur un jeu de développement indépendant.

Dans la Figure 4.2, la ligne pointillée repère le seuil de référence de 0,12, conservé malgré le résultat ponctuel observé à 0,14.




Figure 4.2 Compromis détection-charge de fond.

4.2.6 Ablation contre IF, LOF et comparateur pédométrique

Les cinq variantes sont évaluées sur les mêmes 44 fenêtres. La colonne de détection attribuable retient ici le critère de nouveau départ, c'est-à-dire l'apparition d'un épisode absent de l'exécution propre. La cinquième variante, le comparateur pédométrique, restreint le détecteur au seul canal des pas, à la manière d'un podomètre. Le Tableau 4.6 rapporte les métriques attribuables des cinq variantes.

Tableau 4.6 Ablation attribuable du module HYPO sur les mêmes événements. Le F1 événementiel oppose les 33 dégradations graduelles (positifs) aux 11 contrôles brefs (négatifs), sur le critère de nouveau départ attribuable.

Variante	Nouv. départ	IoU20	IoU moyen	Fond/vache-jour	F1
A. HYPO temporel multivarié	43,2 %	29,5 %	0,137	0,402	0,73
B. IF + règles de persistance	15,9 %	0,0 %	0,004	0,152	0,35
C. IF ponctuel	13,6 %	0,0 %	0,002	7,658	0,31
D. LOF + règles	15,9 %	0,0 %	0,005	0,107	0,35
E. Comparateur pédométrique (pas seuls)	27,3 %	31,8 %	0,141	0,518	0,53

La dernière colonne résume détection et rejet des contrôles en un F1 événementiel : HYPO atteint 0,73 (IC95 par vache [0,60 ; 0,86]), nettement au-dessus d'IF et de LOF (au plus 0,35). Comme aucun contrôle n'est alerté (précision de 1,0), ce F1 ne fait toutefois que réexprimer le rappel et n'intègre pas la charge de

fond : avec la couverture attribuable, plus permissive que le nouveau départ, le comparateur pédométrique passerait même devant HYPO sur ce seul résumé, au prix d'un fond bien plus élevé. Le F1 reste donc un complément des métriques décomposées et de la charge de fond, qui demeurent privilégiées.

Après agrégation par vache, HYPO obtient un IoU supérieur à B, C et D ($p = 0,00098$ pour les trois comparaisons appariées de Wilcoxon (Wilcoxon, 1945)). Son recouvrement est également supérieur à B et D ($p = 0,04297$) et à C ($p = 0,01562$). L'avantage est aussi de *taille* : l'écart d'IoU attribuable moyen par vache vis-à-vis des comparateurs IF et LOF est d'environ 0,13 (IC95 [0,106 ; 0,161] contre B, [0,107 ; 0,163] contre C, [0,103 ; 0,161] contre D, tous excluant zéro), avec une corrélation rang-bisériale appariée (Kerby, 2014) de +1,00 : les onze vaches favorisent HYPO. La supériorité ne tient donc pas à quelques animaux.

La cinquième variante isole, elle, le rôle de la combinaison de plusieurs signaux. Le comparateur pédométrique (E) reprend exactement la machinerie temporelle de HYPO (même période de référence individuelle par créneau horaire, même cumul CUSUM et même persistance), mais restreint la détection au seul canal des pas, à la manière du comptage d'activité d'un podomètre (Alsaad et al., 2012); la cohérence entre familles, qu'un canal unique ne peut satisfaire, y est relâchée pour ne pas le désavantager. Partageant cette machinerie, E *localise* les épisodes aussi précisément que le détecteur complet : l'écart d'IoU attribuable par vache n'est que de $-0,004$ (IC95 [$-0,032$; $0,022$], $p = 0,966$, six vaches sur onze le favorisant légèrement), là où les comparateurs IF et LOF s'effondrent à un IoU quasi nul. Sa faiblesse est ailleurs : restreint aux pas, il ouvre moins de nouveaux départs attribuables (27,3 contre 43,2 %; tendance en faveur de HYPO, $p = 0,0625$ sur onze vaches, sans atteindre le seuil de significativité) et laisse passer davantage de fond (0,518 contre 0,402 notification par vache-jour, soit près d'un tiers de plus). Ce que l'architecture fondée sur plusieurs signaux apporte n'est donc pas une meilleure localisation, mais un meilleur compromis entre déclenchement attribuable et charge de fond : c'est la cohérence entre familles, et non la seule machinerie temporelle, qui resserre ce compromis. Ce constat rejoint la limite connue des approches strictement podométriques, dont la sensibilité dépend du seul comptage de pas (Alsaad et al., 2012; O'Leary et al., 2020).

L'ablation soutient donc l'apport de la direction du changement, de la cohérence entre signaux et de la persistance. Elle ne résout pas la charge opérationnelle, qui reste supérieure à celle des variantes B et D.

4.2.7 Temps d'exécution

L'évaluation complète inclut les variables, IF, les règles IF comparatives, HYPO, INSTABILITÉ, la fusion et la concaténation des sorties. Sur les 28 vaches et 37 839 lignes, la médiane de cinq répétitions est de 10,64 secondes, avec une étendue de 10,58 à 10,83 secondes et un débit médian de 3 557 lignes par seconde. Dans le temps instrumenté, IF représente 82,8 %, les variables 8,2 %, HYPO+INSTABILITÉ+fusion 6,4 % et les règles IF comparatives 2,5 %. L'extension hybride ajoute donc un coût mesurable mais secondaire par rapport au comparateur IF. Ces valeurs décrivent la machine de test et ne constituent pas un test de charge en ferme.

4.3 Extension bidirectionnelle exploratoire

4.3.1 Comparaison des règles de fusion

Le Tableau 4.7 compare les cinq stratégies sur 132 scénarios. La colonne "vérification" regroupe les trois scénarios HYPO et la séquence. La surveillance mesure le recouvrement des trois instabilités. Les facteurs confondants regroupent l'activité de type œstrus et l'hypoactivité non locomotrice.

Tableau 4.7 Comparaison exploratoire des règles de fusion sur 132 événements.

Configuration	Vérification (%)	Surveillance instabilité (%)	Confondants alertés (%)	IoU20 (%)	Fond /vache-jour
HYPO	61,4	66,7	40,9	29,5	0,446
INSTABILITÉ	38,6	66,7	0,0	0,0	0,875
OU	65,9	66,7	31,8	11,4	0,982
HIÉRARCHIQUE	72,7	66,7	40,9	29,5	0,571
SÉQUENTIELLE	56,8	66,7	36,4	0,0	0,366

Dans cette comparaison, toutes les sorties fusionnées utilisent un délai réfractaire commun de douze heures. Le fond HYPO de 0,446 diffère donc du 0,402 de la validation principale, où la notification propre à HYPO est espacée de 24 heures. Les valeurs ne doivent pas être comparées comme si seul l'algorithme avait changé.

La fusion hiérarchique augmente la couverture des scénarios de vérification par rapport à HYPO seul, conserve IoU20 à 29,5 %, mais élève le fond de 0,446 à 0,571. Sa fonction d'utilité technique reste négative

(−0,088), car les pénalités de confusion et de charge sont importantes. Elle est retenue comme configuration représentative de l'extension, non comme remplacement démontré de HYPO. La Figure 4.3 compare les cinq règles de fusion.




Figure 4.3 Comparaison des règles de fusion.

4.3.2 Résultats par scénario

La fusion hiérarchique couvre 45,5 % des hypoactivités légères, 72,7 % des modérées et 81,8 % des marquées. L'instabilité légère, modérée et marquée est observée en surveillance dans respectivement 45,5 %, 54,5 % et 100,0 % des cas. La séquence synthétique instabilité-hypoactivité est alertée dans 90,9 % des cas. Le Tableau 4.8 détaille ces réponses par scénario, que la Figure 4.4 représente visuellement.

Tableau 4.8 Réponse de la fusion hiérarchique par scénario.

Scénario	<i>n</i>	Alerte de vérification (%)	Surveillance (%)
Hypoactivité légère	11	45,5	0,0
Hypoactivité modérée	11	72,7	18,2
Hypoactivité marquée	11	81,8	54,5
Instabilité légère	11	9,1	45,5
Instabilité modérée	11	9,1	54,5
Instabilité marquée	11	18,2	100,0
Instabilité puis hypoactivité	11	90,9	81,8
Contrôles brefs regroupés	33	0,0	0,0
Activité de type œstrus	11	0,0	0,0
Hypoactivité non locomotrice	11	81,8	0,0




Figure 4.4 Réponse par scénario contrôlé.

Parmi les scénarios de vérification, 29,5 % atteignent IoU20. Le délai médian est de 19,875 heures. Le fond hiérarchique est de 0,571 notification par vache-jour, avec une étendue de 0,295 à 0,884 entre vaches. Aucun des 33 contrôles brefs ne produit de nouveau départ de vérification ou de surveillance. Par ailleurs, l'alerte de neuf hypoactivités non locomotrices sur onze démontre une limite d'identifiabilité : des causes différentes peuvent produire la même forme sur les capteurs disponibles.

4.3.3 Sensibilité des paramètres INSTABILITÉ

Trois variantes proches sont comparées à la référence. La détection des scénarios de vérification reste entre 72,7 et 75,0 %, tandis que la surveillance varie de 54,5 à 66,7 % et le fond de 0,518 à 0,571 notification par vache-jour. Une persistance de trois heures réduit la surveillance et augmente les confusions ; une agrégation de quatre heures réduit également la surveillance. Cette analyse soutient la stabilité locale de l'extension, mais elle est beaucoup moins complète que l'OFAT de HYPO et ne valide pas les seuils physiologiquement.

4.4 Concordance observationnelle avec les scores SLS

Quatorze vaches sont évaluables. Les trois vaches $SLS \geq 2$ appartiennent toutes au groupe *Exercice* ; aucune vache du groupe sans exercice n'atteint ce seuil. Dans les sept jours précédant le score, la fusion hiérarchique produit en moyenne 6,67 notifications chez les trois vaches $SLS \geq 2$, contre 4,45 chez les onze autres. L'AUC

exploratoire est 0,924, le test de Mann-Whitney donne $p = 0,031$ et la corrélation de Spearman vaut $\rho = 0,504$ avec $p = 0,066$. Chaque point de la Figure 4.5 représente une vache ; l'effectif de trois animaux dans le groupe $SLS \geq 2$ impose une interprétation prudente.




Figure 4.5 Notifications précédant le score SLS.

Les mesures secondaires sont moins séparatrices : l'AUC de la fraction du temps en épisode est 0,712, celle du score maximum 0,606 et celle de la surveillance d'instabilité 0,348. La charge future atteint environ 0,755 notification par vache-jour. L'ensemble forme un signal de concordance intéressant, mais l'effectif réduit et l'entrelacement complet avec le traitement *Exercise* limitent son interprétation.

4.5 Inspection visuelle ciblée

La Figure 4.6 montre quatre situations de la vache 8081 après le gel des paramètres. L'hypoactivité modérée produit un épisode de vérification ; l'instabilité modérée reste au niveau de surveillance ; le pic capteur isolé est rejeté ; et l'hypoactivité non locomotrice produit une alerte comparable à celle d'une baisse locomotrice. Les zones grises représentent les fenêtres injectées et les zones rouges les épisodes de vérification. Dans chaque panneau, les trois signaux sont normalisés séparément par leur maximum sur la fenêtre affichée afin de conserver tous les pics. Cette inspection vérifie la cohérence technique des sorties ; elle ne constitue pas une adjudication clinique.




Figure 4.6 Inspection visuelle de scénarios représentatifs.

4.6 Correspondance entre objectifs et résultats

Le Tableau 4.9 vérifie qu'aucun objectif annoncé dans l'introduction ne reste sans résultat et qu'aucun résultat principal n'est introduit sans objectif préalable.

Tableau 4.9 Correspondance entre objectifs et résultats.

Obj.	Attente	Résultat principal	Statut
1	Référence individuelle et chronologique	Séparation 60/40, référence par vache et créneau, contrôles d'intégrité conformes.	Réalisé
2	Détection HYPO persistante	87,9 % de couverture attribuable et 39,4 % à IoU20 sur 33 profils graduels.	Réalisé
3	Ablation et sensibilité HYPO	Supériorité sur IF/LOF pour l'IoU; OFAT de vingt variantes; compromis avec le comparateur pédométrique explicité.	Réalisé
4	Explorer INSTABILITÉ et les fusions	Surveillance de 22/33 instabilités; aucune supériorité de la fusion sur HYPO.	Exploratoire
5	Contrôles, confondants, fond et coût	Contrôles brefs rejetés, 9/11 hypoactivités non locomotrices alertées, fond HYPO de 0,402 et temps médian de 10,64 s.	Réalisé
6	Confrontation IceTag-SLS	Association exploratoire sur 14 vaches, mais trois cas $SLS \geq 2$ entièrement confondus avec le groupe <i>Exercise</i> .	Non concluant

4.7 Synthèse

La validation principale établit que HYPO transforme des baisses graduelles injectées après la période de référence en épisodes attribuables, mieux localisés que ceux des comparateurs IF et LOF. Le contrôle bref est rejeté, l'ablation favorise HYPO chez les onze vaches, et l'OFAT montre que la conclusion ne dépend pas d'un seul seuil isolé. Le comparateur pédométrique localise de façon proche, mais recouvre moins d'événements et produit plus de fond. L'extension bidirectionnelle ajoute une surveillance utile des instabilités et récupère les séquences synthétiques. Elle apporte une lecture complémentaire du comportement, tout en gardant HYPO comme résultat principal parce qu'elle n'améliore pas IoU20 et augmente la charge de fond.

CHAPITRE 5

DISCUSSION ET LIMITES

5.1 Réponse à la question principale

L'apport central du mémoire est de montrer qu'une alerte comportementale peut être construite autour d'une trajectoire individuelle plutôt qu'autour de points anormaux isolés. HYPO combine direction du changement, cohérence entre signaux et persistance temporelle ; cette combinaison produit des épisodes plus cohérents avec les dégradations graduelles que les comparateurs IF et LOF. Après soustraction de l'exécution propre, HYPO couvre 29 des 33 événements graduels et atteint IoU20 dans 13 cas. Cette preuve établit la capacité du système à transformer une dégradation contrôlée en priorité de vérification localisée.

Le taux de nouveaux départs de 57,6 % nuance la couverture de 87,9 %. Une partie de la réponse prolonge un épisode déjà actif au lieu d'en créer un. Le délai médian de 20,75 heures montre également que le terme *précoce* doit être interprété relativement à des dégradations de 36 à 60 heures, et non comme une réaction immédiate.

Cette nuance n'annule pas le résultat principal. Elle précise plutôt l'usage réaliste du système : prioriser une vérification lorsque plusieurs familles de signaux se dégradent de façon persistante, avec une traçabilité suffisante pour expliquer pourquoi une vache remonte dans le classement.

5.2 Niveau de preuve des principales conclusions

Le Tableau 5.1 associe à chaque conclusion son niveau de preuve.

Tableau 5.1 Portée des conclusions principales.

Niveau	Conclusion permise	Conclusion non permise
Démonstré technique- ment	HYPO réagit à des baisses graduelles après la période de référence et localise mieux ces scénarios que les comparateurs IF/LOF.	HYPO constitue un détecteur clinique ou distingue la cause de la dégradation.
Soutenu mais limité	La persistance, la direction et la cohérence entre signaux améliorent le compromis entre recouvrement et charge de fond dans cette campagne.	Les paramètres constituent un optimum physiologique ou sont transférables à une autre ferme sans réévaluation.
Exploratoire	INSTABILITÉ peut produire une sortie de surveillance distincte et la fusion peut représenter une séquence synthétique.	L'instabilité précède habituellement une boiterie réelle.
Non démontré	Aucune	Sensibilité, spécificité, valeur prédictive ou bénéfice clinique.

5.3 Apport de l'ablation et de l'OFAT

L'ablation apporte un résultat méthodologique important : la quantité de points anormaux n'est pas le critère décisif. IF ponctuel produit 7,658 départs par vache-jour, mais aucun événement à IoU20. IF et LOF suivis de persistance réduisent la charge, sans localiser les fenêtres avec IoU20. HYPO atteint un IoU attribuable moyen de 0,137 et 29,5 % à IoU20 sur les quatre profils. La direction du changement, la cohérence entre familles et l'accumulation temporelle constituent donc les éléments les mieux soutenus par l'expérience. C'est ce point qui rend HYPO plus défendable qu'une simple accumulation d'anomalies ponctuelles.

L'analyse OFAT montre que les conclusions ne reposent pas sur une valeur unique de chaque seuil. Elle identifie toutefois deux choix structurants : l'agrégation et le nombre de familles concordantes. Exiger quatre familles réduit fortement la couverture et le fond ; n'en exiger que deux augmente la charge. Une agrégation courte réagit plus vite mais localise moins bien, tandis qu'une agrégation longue perd des événements. Les valeurs de référence constituent un compromis documenté, pas un optimum. Modifier les seuils après lecture de cette analyse aurait transformé une étude de robustesse en sélection sur les données d'évaluation ; aucun réglage a posteriori n'a donc été effectué.

La tentative de calibration par la dispersion du score propre à chaque période de référence confirme ce principe de prudence. Elle ne réduit ni le fond moyen ni sa variabilité, et diminue IoU20 de 39,4 à 33,3 %. Elle est donc rejetée. La courbe détection-charge montre par ailleurs qu'un seuil de 0,14 paraît favorable sur cette campagne, mais l'adopter après observation des mêmes événements introduirait un biais de sélection. Le résultat sert à formuler une hypothèse de développement ultérieur, non à améliorer rétroactivement la performance annoncée.

5.4 Portée de l'extension bidirectionnelle

L'extension répond à une question secondaire : peut-on représenter une instabilité courte sans l'assimiler automatiquement à une alerte de vérification ? L'architecture y répond sur le plan logiciel grâce à deux persistances indépendantes et à une sortie de surveillance. Les contrôles brefs et l'activité coordonnée de type œstrus sont rejetés dans la campagne synthétique, et la séquence instabilité-hypoactivité est récupérée dans 90,9 % des cas.

Les profils d'instabilité et leur chronologie restent des hypothèses de test, mais la branche apporte une sortie utile pour distinguer surveillance et vérification. La fusion hiérarchique augmente la couverture des scénarios de vérification de 61,4 à 72,7 % par rapport à HYPO seul dans la campagne étendue. En contrepartie, elle n'améliore pas IoU20 et augmente le fond de 0,446 à 0,571 notification par vache-jour. Son intérêt actuel est donc de structurer une hypothèse et une interface de surveillance, tandis que HYPO reste la méthode principale.

5.5 Contrôles et facteurs confondants

Le rejet des 33 contrôles brefs vérifie qu'un pic capteur, deux heures d'exercice synthétique ou une manipulation d'une heure ne suffisent pas dans les conditions testées. Cette réussite dépend de la représentation choisie et ne garantit pas le rejet de tous les événements réels de même nature.

La confusion avec l'hypoactivité non locomotrice est la limite centrale. Neuf scénarios sur onze sont alertés, car leur forme est volontairement identique à une dégradation locomotrice sur les signaux disponibles. Aucun réglage temporel ne peut entièrement séparer deux causes qui produisent les mêmes observations. La température, l'ingestion, la production laitière, les traitements, le vêlage ou un examen clinique sont nécessaires pour améliorer la spécificité causale.

5.6 Charge opérationnelle et performance

Le fond de 0,402 notification par vache-jour pour HYPO et de 0,571 pour la fusion hiérarchique demeure élevé pour un grand troupeau. Ces valeurs ne sont pas des taux de faux positifs : une donnée propre peut contenir une dégradation réelle non annotée. Elles indiquent néanmoins une fatigue d'alerte potentielle. Un déploiement devrait regrouper les alertes par épisode, limiter les répétitions, prioriser les trajectoires persistantes et enregistrer le résultat de la vérification humaine.

Le temps médian de 10,64 secondes pour 28 vaches montre que le prototype est techniquement exécutable sur le corpus étudié. IF représente la majeure partie du coût, tandis que le calcul HYPO+INSTABILITÉ+fusion représente 6,4 % du temps instrumenté. Ce résultat ne préjuge pas de la latence en ferme, du stockage continu ou de la concurrence entre utilisateurs.

5.7 Portée de l'analyse SLS

L'analyse IceTag-SLS apporte un résultat encourageant : le nombre de notifications dans les sept jours précédant le score est plus élevé chez les trois vaches $SLS \geq 2$, avec une AUC exploratoire de 0,924. Le test de Mann-Whitney est favorable, tandis que le score maximal et la surveillance d'instabilité séparent moins bien les groupes. Cette concordance reste limitée par l'effectif et par le fait que les trois animaux $SLS \geq 2$ appartiennent au groupe *Exercise* ; elle sert donc à appuyer la faisabilité de l'analyse synchronisée, pas à régler les seuils.

5.8 Mise en perspective avec la littérature

Les résultats s'accordent avec la signature comportementale la mieux établie de la boiterie : une réduction de l'activité locomotrice et une augmentation du temps couché (Ito *et al.*, 2010 ; Blackie *et al.*, 2011 ; Chapin *et al.*, 2011). La branche HYPO cible précisément cette direction. Les revues soulignent toutefois que les variables utiles et leurs amplitudes dépendent du capteur, du protocole et du contexte (O'Leary *et al.*, 2020 ; Alsaad *et al.*, 2019). La référence propre à chaque vache est donc un choix méthodologique prudent pour absorber une partie de l'hétérogénéité observée ; elle ne constitue pas, à elle seule, une preuve de spécificité clinique.

Ce choix d'une référence propre à chaque vache, et à chaque créneau horaire, répond à une structure de variance précise : chez la vache laitière, l'activité varie davantage entre individus (âge, rang de lactation,

stade, tempérament) et selon le rythme circadien lié à la traite et à l'alimentation qu'au sein d'une même journée pour un même animal. Un seuil de population serait donc dominé par l'identité de la vache et l'heure, plutôt que par son changement propre. En normalisant chaque animal par sa médiane horaire de référence, HYPO retire cette variance de nuisance dominante et rend comparable, d'une vache à l'autre, l'ampleur d'une dégradation relative.

L'agitation, les reports de poids et les changements posturaux peuvent être observés lors d'un inconfort, mais les agrégats IceQube ne mesurent ni l'appui relatif des membres ni la démarche. Une hausse de mouvement ou de transitions reste en outre compatible avec l'œstrus, l'exercice, une manipulation ou un artefact. C'est pourquoi la branche INSTABILITÉ filtre l'activité coordonnée et demeure exploratoire. Enfin, les performances rapportées varient fortement d'une étude à l'autre (O'Leary *et al.*, 2020 ; Qiao *et al.*, 2021), ce qui rappelle qu'aucune signature unique n'est pleinement fiable sur ces capteurs et conforte le cadrage en alerte non diagnostique.

5.9 Comparaison avec les systèmes commerciaux

Plusieurs systèmes commerciaux fondés sur des podomètres et des accéléromètres d'activité sont déployés en élevage. Leur logique interne et leurs protocoles d'évaluation ne sont pas toujours décrits avec le niveau de détail nécessaire à une comparaison indépendante (Rutten *et al.*, 2013 ; Stangaferro *et al.*, 2016). Le présent travail se distingue par un code auditable, des paramètres figés, un protocole explicite et un manifeste d'intégrité. Il ne revendique aucune performance supérieure à ces systèmes, faute d'étalon et de protocole communs.

5.10 Implications pratiques pour l'éleveur

À l'échelle d'un troupeau, le système se positionne comme un outil de priorisation, non d'alarme. La charge de fond mesurée (0,402 notification par vache-jour pour HYPO) reste trop élevée pour une vérification systématique ; un déploiement réaliste afficherait plutôt chaque jour les quelques animaux les plus anormaux, à partir du classement de l'interface. Le bénéfice attendu est d'orienter plus tôt l'attention humaine vers des vaches dont le comportement dérive, le coût étant le temps de vérification et le risque de fatigue d'alerte. Cette forme de tri correspond mieux à la charge observée qu'une alarme binaire envoyée pour chaque notification.

5.11 Forces et limites

Le Tableau 5.2 synthétise les forces et les limites du système.

Tableau 5.2 Forces et limites du travail.

Forces	Limites
Séparation temporelle stricte et exécution propre de référence.	Absence de labels cliniques dans le corpus principal.
Profils graduels, multivariés et physiquement contraints.	Amplitudes partiellement hypothétiques.
Ablation sur les mêmes événements et agrégation par vache.	Onze vaches seulement dans les campagnes.
OFAT de vingt variantes pour HYPO.	Aucune interaction entre paramètres ni jeu de développement indépendant.
Contrôles brefs et facteurs confondants explicites.	Hypoactivité locomotrice et non locomotrice non identifiables avec ces seuls signaux.
Évaluation du temps d'exécution de la chaîne complète et artefacts reproductibles.	Temps mesuré sur une seule machine et un seul corpus.
Analyse SLS fondée sur des mesures antérieures au score.	Trois $SLS \geq 2$, tous dans le groupe <i>Exercise</i> .

5.12 Menaces à la validité

L'analyse suit la typologie classique des menaces à la validité en recherche empirique (Shadish *et al.*, 2002; Wohlin *et al.*, 2012).

5.12.1 Validité de construit

Les injections représentent des changements de comportement, non des cas de boiterie. Les capteurs ne mesurent pas directement la douleur, la lésion ou l'asymétrie de démarche. Le seuil IoU20 est une convention technique et ne possède pas de signification clinique.

5.12.2 Validité interne

La séparation chronologique et la soustraction de l'exécution propre réduisent la fuite et l'attribution erronée. Plusieurs scénarios proviennent toutefois de la même vache ; l'unité indépendante reste donc la vache. La graine unique améliore la traçabilité, mais ne mesure pas toute la variabilité possible du placement des événements.

5.12.3 Validité externe

Le corpus principal provient d'une ferme et d'une période. Les différences de logement, de sol, de saison, de conduite et de capteur peuvent modifier les distributions. La cohorte SLS provient du même site et ne constitue pas une validation inter-fermes.

5.12.4 Validité statistique

Les proportions synthétiques sont descriptives. Les tests d'ablation utilisent onze paires au niveau vache, ce qui respecte la structure mais limite la puissance. Les analyses OFAT et INSTABILITÉ examinent plusieurs variantes sans jeu de test indépendant. Les AUC et valeurs de p de l'analyse SLS sont fragiles en raison du petit effectif et de la multiplicité. La calibration individuelle et la courbe détection-charge sont des analyses exploratoires postérieures à la validation principale ; aucune valeur observée dans ces analyses n'est utilisée pour remplacer la configuration de référence.

5.13 Usage prévu et implications éthiques

L'usage défendable est un tri des animaux à observer. Une notification signifie que plusieurs dimensions du comportement ont changé de manière persistante par rapport à sa période de référence ; elle ne signifie pas que la vache soit boiteuse. Une vérification doit inclure l'observation locomotrice, l'examen du pied si nécessaire et une consultation vétérinaire selon le contexte. L'absence d'alerte ne garantit pas l'absence de douleur et le système ne doit automatiser ni traitement ni réforme.

La gouvernance des données mérite d'être explicitée en vue d'un déploiement. Les droits de propriété et d'usage ne peuvent pas être présumés : ils doivent être définis entre l'exploitation, le fournisseur technologique et les chercheurs, avec des règles explicites de consentement et de confidentialité (Wolfert *et al.*,

2017 ; Carbonell, 2016). Dans ce travail, l'extraction CowAlert demeure locale, est exclue des artefacts diffusables et ne sert qu'au contrôle de provenance ; seules des sorties agrégées et leurs empreintes d'intégrité sont conservées dans la chaîne reproductible. Un système déployé devrait documenter la finalité, les droits d'accès, la sécurité, la durée de conservation et l'audit des données, et garantir qu'une alerte n'entraîne aucune décision automatique de traitement ou de réforme.

5.14 Travaux nécessaires avant une revendication clinique

Une validation clinique devrait réunir des scores locomoteurs datés, plusieurs évaluateurs, des examens des pieds ou diagnostics vétérinaires et les données capteurs des jours précédents. Le développement et le test devraient être séparés par vache, période et, idéalement, ferme. Des contrôles réels doivent inclure œstrus, exercice, manipulation, vêlage, chaleur et maladies non locomotrices. Les seuils pourraient alors être optimisés sur le jeu de développement, puis gelés avant le test.

5.15 Bilan

Le module HYPO constitue le résultat technique principal : il est mieux étayé que les comparateurs ponctuels, mais sa localisation et sa charge restent imparfaites. L'extension bidirectionnelle organise une hypothèse complémentaire et révèle ses propres compromis sans masquer le résultat négatif sur les confondants. Cette séparation entre preuve principale et exploration rend l'ensemble plus cohérent et plus directement exploitable pour un usage de priorisation en ferme.

CONCLUSION

Synthèse

Ce mémoire atteint son objectif principal : produire une chaîne reproductible qui transforme des mesures IceQube indirectes en priorités de vérification locomotrice. Le résultat central est la branche HYPO, qui recherche une réduction persistante et concordante des pas, du mouvement, des transitions et de la posture par rapport à la période de référence individuelle. Une extension exploratoire ajoute une branche INSTABILITÉ et une fusion hiérarchique qui distingue surveillance et notification de vérification.

Résultats principaux

Sur 33 dégradations graduelles injectées après la période de référence, HYPO produit une couverture attribuable dans 87,9 % des cas, un nouveau départ dans 57,6 % et IoU20 dans 39,4 %. Le contrôle bref est rejeté et le fond atteint 0,402 notification par vache-jour. Dans l'ablation, HYPO atteint 29,5 % à IoU20, contre 0 % pour les trois comparateurs IF/LOF. L'analyse OFAT montre que l'agrégation et le nombre de familles concordantes structurent principalement le compromis. Ces résultats soutiennent l'intérêt d'une détection temporelle individualisée plutôt qu'une décision fondée sur des anomalies ponctuelles.

Sur la campagne étendue de 132 scénarios, la fusion hiérarchique couvre 72,7 % des scénarios de vérification, 66,7 % des instabilités en surveillance et 90,9 % des séquences. Elle ne dépasse cependant pas HYPO sur toutes les dimensions : IoU20 reste à 29,5 %, le fond passe de 0,446 à 0,571 et 40,9 % des facteurs confondants sont alertés. L'extension constitue donc un résultat mitigé, non une preuve de supériorité. La chaîne de traitement complète traite le corpus en 10,64 secondes en médiane sur cinq répétitions.

Portée et usage

Les résultats convergent vers un usage clair : prioriser l'observation des animaux dont le comportement se dégrade de façon persistante. La cohorte IceTag-SLS va dans le même sens, avec davantage de notifications chez les trois vaches $SLS \geq 2$, mais ces trois cas appartiennent tous au groupe *Exercise*. La limite centrale reste donc causale : 81,8 % des hypoactivités non locomotrices sont alertées. Les capteurs reconnaissent une forme comportementale sans identifier son origine, ce qui impose une vérification terrain.

Contributions

Le travail fournit une validation attribuable de HYPO avec intervalles de confiance, une ablation et ses tailles d'effet, une analyse OFAT, une courbe détection-charge, une tentative de calibration individuelle rapportée malgré son résultat négatif, une extension bidirectionnelle avec contrôles de confusion, une évaluation du temps d'exécution, une analyse SLS synchronisée, une interface de priorisation et des artefacts reproductibles. Sa contribution méthodologique est double : proposer un détecteur temporel interprétable et montrer comment évaluer ce type d'outil sans confondre résultats techniques, hypothèses exploratoires et affirmations cliniques non démontrées.

Disponibilité

Le code source, les paramètres figés, les douze profils d'injection et les scripts d'évaluation sont versionnés, avec un manifeste d'intégrité SHA-256 des sorties (Annexe A). Les données capteurs brutes ne peuvent être diffusées pour des raisons de confidentialité, mais la procédure de reproduction et les artefacts documentés permettent de rejouer intégralement la démarche, des injections jusqu'aux figures du manuscrit.

Perspectives

La prochaine étape est une validation longitudinale avec scores locomoteurs, examens des pieds, causes non locomotrices et métadonnées de contexte. Une séparation stricte entre jeu de développement et jeu de test permettra de régler les seuils sans optimisme. Des signaux de démarche ou d'asymétrie seraient plus proches du construit clinique que la seule quantité de mouvement. Enfin, la charge de vérification devra être évaluée avec les utilisateurs afin de définir un compromis acceptable en ferme.

ANNEXE A

REPRODUCTIBILITÉ ET CONTRÔLES COMPLÉMENTAIRES

Cette annexe recense les commandes et artefacts qui soutiennent les résultats du mémoire. Les commandes sont exécutées depuis la racine du dépôt reproductible.

A.1 Environnement

```
python -m venv .venv
source .venv/bin/activate
python -m pip install --upgrade pip
python -m pip install -r requirements.txt
```

L'environnement effectivement utilisé peut aussi être appelé avec le chemin absolu de son interpréteur Python. Les résultats ne doivent pas être mélangés avec des artefacts produits par une autre configuration du code.

A.2 Commandes de reproduction

La reproduction complète suit six étapes, dans l'ordre :

1. préparer l'environnement et placer `data/brut.csv` dans le projet ;
2. exécuter la validation et l'ablation du module HYPO ;
3. exécuter l'analyse OFAT, la calibration exploratoire et la courbe détection-charge de HYPO ;
4. exécuter la comparaison exploratoire des fusions, puis l'évaluation du temps d'exécution ;
5. exécuter l'analyse IceTag-SLS et régénérer les figures ;
6. régénérer puis vérifier le manifeste SHA-256.

Les commandes correspondantes sont détaillées ci-dessous.

A.2.1 Validation et ablation du module HYPO

```
python scripts/run_hypo_module_validation.py \
--output-dir data/validation/hypo_module
```

Cette commande régénère les 44 événements, les contrôles du protocole, le résumé par profil, l'ablation et les tests appariés regroupés par vache.

A.2.2 Typologie des modes de défaillance

```
python scripts/compute_failure_modes.py
```

Cette commande relit les sorties événementielles de HYPO et de la fusion hiérarchique, puis écrit les fréquences du Tableau 4.4 dans `hypo_module/failure_modes.csv`. Elle ne relance pas les détecteurs.

A.2.3 Analyse OFAT du module HYPO

```
python -m validation_hypo.sensitivity \  
    --output-dir data/validation/hypo_module/parameter_sensitivity
```

La référence et les vingt variantes utilisent les mêmes onze vaches, les mêmes fenêtres et la même graine. L'analyse ne sélectionne pas de nouvelle configuration.

A.2.4 Traçabilité des données (provenance CowAlert)

```
python scripts/cowalert_provenance.py
```

Cette commande confronte `data/brut.csv` à l'extraction `data/cowalert_export.csv` relevée depuis le système CowAlert, et écrit les corrélations et la proportion d'intervalles appariés dans `hypo_module/cowalert_provenance.csv`. Le fichier source est confidentiel, demeure local et n'est pas versionné.

A.2.5 Intervalles de confiance et tailles d'effet

```
python scripts/compute_bootstrap_ci.py
```

Ce script recalcule, à graine fixée, les intervalles de confiance à 95 % des métriques attribuables (bootstrap regroupé par vache, 10 000 rééchantillonnages) et les tailles d'effet de l'ablation, puis les écrit dans `hypo_module/bootstrap_ci.csv`.

A.2.6 Calibration individuelle et courbe détection-charge

```
python scripts/per_cow_calibration.py  
python scripts/detection_background_curve.py
```

La première commande estime les facteurs uniquement sur la période de référence et conserve le résultat négatif de l'expérience. La seconde réexécute neuf seuils de score sur les mêmes fenêtres, écrit le tableau complet et produit la Figure 4.2. Aucune des deux commandes ne remplace la configuration de référence.

A.2.7 Comparaison exploratoire des fusions

```
python -m validation_hybrid.sensitivity \  
    --output-dir data/validation/hybrid_refined_full
```

Cette commande exécute les cinq règles de fusion et quatre configurations de sensibilité sur les mêmes onze vaches et les mêmes douze scénarios.

A.2.8 Évaluation du temps d'exécution

```
python scripts/benchmark_performance.py \  
    --input data/brut.csv \  
    --output-root data/performance \  
    --fractions 1.0 --repeats 5 --collect-output \  
    --canonical-json data/validation/performance_full_corpus.json
```

Le fichier canonique retient la médiane des cinq exécutions complètes et les temps par étape.

A.2.9 Analyse IceTag-SLS

```
python -m validation_hybrid.mcgill_sls_validation
```

Le répertoire source `mcgill_iot_cattle` doit être disponible selon le chemin documenté dans le module. Aucune observation postérieure au 12 mars 2019 n'est utilisée.

A.2.10 Figures du manuscrit

```
python scripts/plot_parameter_sensitivity.py \  
    --summary data/validation/hypo_module/parameter_sensitivity/\  
parameter_sensitivity_summary.csv \  
    --pdf memoire/figures/hypo_parameter_sensitivity_effects.pdf \  
    --png memoire/figures/hypo_parameter_sensitivity_effects.png  
python scripts/plot_manuscript_results.py  
python scripts/plot_cow_admissibility.py  
python scripts/audit_manuscript_numbers.py  
python scripts/update_validation_manifest.py  
shasum -a 256 -c data/validation/validation_artifacts.sha256
```

Le premier script représente l'OFAT de HYPO. Le second lit les CSV finaux et régénère les figures de fusion, de scénarios et de SLS; il reconstruit également quatre trajectoires représentatives pour l'inspection visuelle. Le script d'audit compare 95 valeurs empiriques du manuscrit à leurs CSV ou JSON sources. Les deux dernières commandes reconstruisent le manifeste des artefacts scientifiques puis en vérifient chaque empreinte.

A.2.11 Tests et interface

```
pytest -q  
python -m streamlit run app.py
```

L'interface est ensuite accessible à <http://localhost:8501>. Les tests vérifient la cohérence logicielle, non la validité clinique.

A.2.12 Compilation

```
cd memoire  
latexmk -pdf -interaction=nonstopmode -halt-on-error main.tex
```

A.3 Artefacts principaux

Le Tableau A.1 liste les artefacts qui soutiennent les résultats.

Tableau A.1 : Artefacts qui soutiennent les résultats.

Fichier	Contenu
hypo_module/events_primary.csv	44 événements de la validation principale HYPO.
hypo_module/protocol_checks.csv	Contrôles automatiques de la campagne HYPO.
hypo_module/detection_summary.csv	Résultats attribuables par profil.
hypo_module/ablation_primary.csv	Sorties des cinq variantes sur les mêmes fenêtres.
hypo_module/ablation_summary.csv	Résumé de l'ablation HYPO, IF, LOF et pédométrique.
hypo_module/ablation_tests_by_cow.csv	Tests appariés après agrégation par vache.
hypo_module/parameter_sensitivity/parameter_sensitivity_summary.csv	OFAT des dix paramètres HYPO.
hypo_module/bootstrap_ci.csv	IC95 (bootstrap par vache) et tailles d'effet de l'ablation.
hypo_module/failure_modes.csv	Fréquences reproductibles des modes de défaillance.
hypo_module/per_cow_calibration.csv	Comparaison agrégée avant et après calibration.
hypo_module/per_cow_calibration_by_cow.csv	Facteurs et charges de fond par vache.
hypo_module/cowalert_provenance.csv	Concordance IceQube-CowAlert (corrélations, identité).
hypo_module/detection_background_curve/detection_background_curve.csv	Neuf points de la courbe détection-charge.
manuscript_number_audit.csv	Correspondance entre 95 valeurs du manuscrit et leurs artefacts sources.
performance_full_corpus.json	Médiane et décomposition du temps d'exécution de la chaîne complète.

Fichier	Contenu
hybrid_refined_full/comparison_summary.csv	Comparaison des fusions et variantes de sensibilité.
hybrid_refined_full/events_fusion_hierarchical.csv	132 évaluations de la fusion hiérarchique exploratoire.
hybrid_refined_full/events_fusion_hypo_only.csv	Résultats de la branche HYPO seule.
hybrid_refined_full/events_fusion_instability_only.csv	Résultats de la branche INSTABILITÉ seule.
hybrid_refined_full/events_fusion_or.csv	Résultats de la fusion OU.
hybrid_refined_full/events_fusion_sequential_24_72h.csv	Résultats de la fusion séquentielle.
hybrid_refined_full/events_parameter_sensitivity_*.csv	Évaluations des variantes de paramètres.
mcgill_sls/mcgill_cohort_all_variants.csv	Cohorte SLS et sorties des cinq fusions.
mcgill_sls/mcgill_exclusions.csv	Motifs d'exclusion et couverture.
mcgill_sls/mcgill_metrics.csv	AUC, Mann-Whitney et Spearman.
mcgill_sls/mcgill_summary.json	Protocole et synthèse de l'analyse SLS.
memoire/figures/manual_review.png	Planche reproductible de l'inspection visuelle ciblée.

Sauf pour la planche d'inspection, les chemins du tableau sont relatifs à `data/validation/`.

A.4 Amplitudes des profils d'injection

Les Tableaux A.2 et A.3 donnent les changements relatifs appliqués aux signaux bruts. Les amplitudes des trois baisses sont communes aux deux campagnes, mais leurs durées diffèrent : 36 à 60 heures dans la validation principale HYPO, contre 24 à 48 heures dans l'extension bidirectionnelle. Les modifications suivent une enveloppe progressive. Seule l'amplitude modérée des pas (−29 %) est ancrée sur un ordre de gran-

deur publié (Paudyal *et al.*, 2021) ; les autres valeurs sont des hypothèses de test et non des estimations cliniques.

Tableau A.2 Profils de la validation principale HYPO.

Profil	Durée	Pas	Mouvement	Transitions	Posture
Graduel léger	36 h	−12 %	−10 %	−12 %	+3 %
Graduel modéré	48 h	−29 %	−25 %	−25 %	+7 %
Graduel marqué	60 h	−42 %	−38 %	−40 %	+12 %
Variation brève	3 h	+15 %	.	.	.

Tableau A.3 Profils bidirectionnels et contrôles de confusion.

Profil	Durée	Pas	Mouvement	Transitions	Posture/osc.
<i>Hypoactivité de l'extension</i>					
Léger	24 h	−12 %	−10 %	−12 %	+3/ . %
Modéré	36 h	−29 %	−25 %	−25 %	+7/ . %
Marqué	48 h	−42 %	−38 %	−40 %	+12/ . %
<i>Instabilité (hausse disproportionnée aux pas)</i>					
Léger	8 h	0 %	+25 %	+30 %	+6/ + 8 %
Modéré	12 h	+5 %	+45 %	+50 %	+10/ + 12 %
Marqué	16 h	+8 %	+65 %	+70 %	+15/ + 18 %
<i>Contrôles et confondants</i>					
Pic capteur	15 min	.	+200 %	.	.
Exercice bref	2 h	+45 %	+45 %	+45 %	./+5 %
Activité de type œstrus	6 h	+40 %	+40 %	+40 %	./+10 %
Hypoactivité non locomotrice	24 h	−30 %	−28 %	−25 %	+8/ . %
Manipulation	1 h	+10 %	+55 %	+70 %	+18/ + 20 %

Dans la dernière colonne du Tableau A.3, la première valeur est le transfert ou l'oscillation posturale et la seconde l'oscillation générale appliquée aux signaux. Un point (.) indique l'absence de modification correspondante.

Le profil séquentiel enchaîne une instabilité (+50 % de mouvement, +55 % de transitions, +12/ + 14 % de posture/oscillation sur 12 h), un délai de 24 h, puis une hypoactivité (−32 % de pas, −28 % de mouvement, −30 % de transitions et +8 % de transfert postural sur 36 h).

A.5 Invariants des injections

1. chaque scénario est injecté dans une copie distincte des données ;
2. le début est strictement postérieur à la période de référence ;
3. les pas, le mouvement et les transitions restent non négatifs ;
4. le temps couché plus le temps debout est conservé ;
5. les enveloppes sont progressives et ne contiennent pas d'alternance extrême ;
6. l'exécution propre de la même vache sert de référence d'attribution ;
7. le fichier `data/brut.csv` n'est jamais modifié.

A.6 Unité statistique

Les 132 lignes événementielles ne représentent pas 132 animaux indépendants. Elles sont regroupées dans onze vaches. Les résultats par scénario sont descriptifs ; toute comparaison inférentielle doit agréger préalablement par vache. Dans l'analyse SLS, chaque vache fournit une seule valeur par mesure sur la fenêtre de sept jours.

La campagne HYPO comporte 44 événements mais repose sur les mêmes onze vaches. Les tests de l'ablation utilisent donc les moyennes par vache, jamais les 44 lignes comme observations indépendantes.

A.7 Variabilité inter-vache du fond

Le taux de fond agrégé (0,402 notification par vache-jour pour HYPO) masque une variabilité individuelle importante. Sur les onze vaches admissibles (45 notifications, 112 vaches-jours), le taux varie de 0,197 à 0,590 selon l'animal, soit un facteur d'environ trois (Tableau A.4).

Tableau A.4 Distribution du fond de notifications HYPO par vache (campagne principale).

Groupe	<i>n</i> vaches	Notifications (≈ 10 j)	Taux/vache-jour
Stable ($\leq 0,30$)	2	2-3	0,197-0,295
Intermédiaire (0,30-0,45)	6	4	0,389-0,393
Active ($> 0,45$)	3	5-6	0,491-0,590
Ensemble	11	45 (total)	0,402 (agrégé)

Cette dispersion décrit une hétérogénéité de charge, mais elle ne démontre pas que le niveau d'activité moyen en est la cause. Une calibration simple fondée sur la dispersion du score de période de référence a été testée sans réduire le fond ni son coefficient de variation, et elle a dégradé IoU20. Elle n'est donc pas retenue. Une méthode future devrait être définie sur un jeu de développement distinct avant d'être évaluée. Ces chiffres décrivent une charge opérationnelle et ne constituent pas un taux de faux positifs, faute de labels cliniques.

A.8 Intégrité des fichiers

Le fichier `data/validation/validation_artifacts.sha256` contient les empreintes SHA-256 des sorties qui alimentent ce mémoire : validation attribuable, ablation, analyses exploratoires, temps d'exécution, comparaison des fusions et concordance IceTag-SLS. Les chemins y sont relatifs à la racine du projet. Après une reproduction, la commande suivante vérifie le manifeste :

```
shasum -a 256 -c data/validation/validation_artifacts.sha256
```

Toute modification des scripts, des données, des paramètres ou de l'environnement exige une nouvelle exécution et un nouveau manifeste. Le PDF seul ne constitue pas une trace suffisante de l'expérience.

A.9 Règles d'interprétation

Les formulations suivantes sont exclues des conclusions :

- appeler “sensibilité clinique” le taux de détection des injections ;
- appeler “faux positifs” les notifications produites sur des données sans labels ;
- interpréter une instabilité isolée comme une boiterie précoce confirmée ;
- attribuer l'association SLS au système sans mentionner le groupe *Exercise* ;
- présenter les paramètres techniques comme des seuils physiologiques optimaux ;
- remplacer le seuil de référence par 0,14 à partir de la courbe descriptive, sans jeu de développement indépendant ;
- comparer directement 87,9 % de couverture HYPO et 72,7 % de détection nécessitant une vérification dans l'extension hybride, car les critères et les ensembles de scénarios diffèrent ;

- attribuer l'écart entre 0,402 et 0,446 au seul algorithme, car le délai réfractaire passe de 24 à 12 heures dans la comparaison des fusions ;
- traiter les intervalles de quinze minutes comme des sujets indépendants.

Ces règles font partie du protocole de reproductibilité : reproduire les calculs sans en respecter la portée conduirait à une conclusion scientifiquement différente.

BIBLIOGRAPHIE

- Sprecher, D. J., Hostetler, D. E. et Kaneene, J. B. (1997). A lameness scoring system that uses posture and gait to predict dairy cattle reproductive performance. *Theriogenology*, 47(6), 1179–1187.
[http://dx.doi.org/10.1016/S0093-691X\(97\)00098-8](http://dx.doi.org/10.1016/S0093-691X(97)00098-8)
- Chapinal, N., de Passillé, A. M., Pastell, M., Hänninen, L., Munksgaard, L. et Rushen, J. (2011). Measurement of acceleration while walking as an automated method for gait assessment in dairy cattle. *Journal of Dairy Science*, 94(6), 2895–2901.
<http://dx.doi.org/10.3168/jds.2010-3882>
- Whay, H. R., Main, D. C. J., Green, L. E. et Webster, A. J. F. (2003). Assessment of the welfare of dairy cattle using animal-based measurements : Direct observations and investigation of farm records. *Veterinary Record*, 153(7), 197–202. <http://dx.doi.org/10.1136/vr.153.7.197>
- Flower, F. C. et Weary, D. M. (2006). Effect of hoof pathologies on subjective assessments of dairy cow gait. *Journal of Dairy Science*, 89(1), 139–146.
[http://dx.doi.org/10.3168/jds.S0022-0302\(06\)72077-X](http://dx.doi.org/10.3168/jds.S0022-0302(06)72077-X)
- Green, L. E., Hedges, V. J., Schukken, Y. H., Blowey, R. W. et Packington, A. J. (2002). The impact of clinical lameness on the milk yield of dairy cows. *Journal of Dairy Science*, 85(9), 2250–2256.
[http://dx.doi.org/10.3168/jds.S0022-0302\(02\)74304-X](http://dx.doi.org/10.3168/jds.S0022-0302(02)74304-X)
- Bruijn, M. R. N., Hogeveen, H. et Stassen, E. N. (2010). Assessing economic consequences of foot disorders in dairy cattle using a dynamic stochastic simulation model. *Journal of Dairy Science*, 93(6), 2419–2432. <http://dx.doi.org/10.3168/jds.2009-2721>
- Bewley, J. M., Russell, R. A. et Borchers, M. R. (2015). Precision dairy monitoring opportunities and limitations. *Journal of Dairy Science*, 98(Supplement 2), 552. Abstract presented at the ADSA-ASAS Joint Annual Meeting, <http://dx.doi.org/10.3168/jds.2015-9538>
- Alsaad, M., Fadul, M. et Steiner, A. (2019). Automatic lameness detection in cattle. *The Veterinary Journal*, 246, 35–44. <http://dx.doi.org/10.1016/j.tvjl.2019.01.005>
- O'Leary, N., Byrne, D. T., O'Connor, A. et Shalloo, L. (2020). Invited review : Cattle lameness detection with accelerometers. *Journal of Dairy Science*, 103(5), 3895–3911.
<http://dx.doi.org/10.3168/jds.2019-17123>
- Rodrigues, R., Newsome, R., Green, M. et Huxley, J. (2017). Lameness in dairy cows : A debilitating disease or a disease of debilitated cattle ? a cross-sectional study of lameness prevalence and thickness of the digital cushion. *Journal of Dairy Science*, 100(7), 5603–5612.
<http://dx.doi.org/10.3168/jds.2016-12331>
- Cook, N. B. (2003). Prevalence of lameness among dairy cattle in wisconsin as a function of housing type and stall surface. *Journal of the American Veterinary Medical Association*, 223(9), 1324–1328.
<http://dx.doi.org/10.2460/javma.2003.223.1324>
- Merck Veterinary Manual (2024a). Lameness originating in the hoof in cattle.
<https://www.merckvetmanual.com/musculoskeletal-system/lameness-in-cattle/lameness-originating-in-the-hoof-in-cattle>. Consulté le 26 février 2026.

- Broom, D. M. (2017). *Animal Welfare in the European Union*. Rapport technique, European Parliament, Policy Department for Citizens' Rights and Constitutional Affairs. Study requested by the PETI Committee, PE 583.114.
- DairyNZ (2025a). Preventing and managing lameness guide. <https://www.dairynz.co.nz/media/hr2hwwq2/preventing-and-managing-lameness-guide-2025-v2.pdf>. Consulté le 26 février 2026.
- Merck Veterinary Manual (2024b). Overview of lameness in cattle. <https://www.merckvetmanual.com/musculoskeletal-system/lameness-in-cattle/overview-of-lameness-in-cattle>. Consulté le 26 février 2026.
- DairyNZ (2025b). Treating lameness. <https://www.dairynz.co.nz/animal/lameness/treating-lameness/>. Consulté le 26 février 2026.
- Pastell, M. E. et Kujala, M. (2007). A probabilistic neural network model for lameness detection. *Journal of Dairy Science*, 90(5), 2283-2292. <http://dx.doi.org/10.3168/jds.2006-267>
- Palma, O., Pla-Aragones, L. M., Mac Cawley, A. et Albornoz, V. M. (2025). Ai and data analytics in the dairy farms : A scoping review. *Animals*, 15(9), 1291. <http://dx.doi.org/10.3390/ani15091291>
- Michelena, A., Fontenla-Romero, O. et Calvo-Rolle, J. L. (2025). A review and future trends of precision livestock over dairy and beef cow cattle with artificial intelligence. *Logic Journal of the IGPL*, 33(4), jzae111. <http://dx.doi.org/10.1093/jigpal/jzae111>
- Flower, F. C. et Weary, D. M. (2009). Gait assessment in dairy cattle. *Animal*, 3(1), 87-95. <http://dx.doi.org/10.1017/S1751731108003194>
- AHDB (2025a). Mobility score sheet (48h for score 2). https://projectblue.blob.core.windows.net/media/Default/Research%20Papers/Dairy/ahdb_dairy_mobility_score_score_sheet__2_.pdf. Consulté le 26 février 2026.
- March, S., Brinkmann, J. et Winckler, C. (2007). Effect of training on the inter-observer reliability of lameness scoring in dairy cattle. *Animal Welfare*, 16(2), 131-133. <http://dx.doi.org/10.1017/S096272860003116X>
- AHDB (2025b). Mobility scoring for dairy cows. <https://ahdb.org.uk/knowledge-library/mobility-scoring-for-dairy-cows>. Consulté le 26 février 2026.
- Van Hertem, T., Viazzi, S., Steensels, M., Maltz, E., Antler, A., Alchanatis, V., Schlageter-Tello, A. A., Lokhorst, K., Romanini, E. C. B., Bahr, C., Berckmans, D. et Halachmi, I. (2014). Automatic lameness detection based on consecutive 3d-video recordings. *Biosystems Engineering*, 119, 108-116. <http://dx.doi.org/10.1016/j.biosystemseng.2014.01.009>
- Lavrova, A. I., Choucair, A., Palmi, A., Stock, K. F., Kammer, M., Querengasser, F. et Belik, V. (2023). Leveraging accelerometer data for lameness detection in dairy cows : A longitudinal study of six farms in germany. *Animals*, 13(23), 3681. <http://dx.doi.org/10.3390/ani13233681>
- Balasso, P., Taccioli, C., Serva, L., Magrin, L., Andrighetto, I. et Marchesini, G. (2023). Uncovering patterns in dairy cow behaviour : A deep learning approach with tri-axial accelerometer data. *Animals*, 13(11), 1886. <http://dx.doi.org/10.3390/ani13111886>

- Benaissa, S., Tuytens, F. A. M., Plets, D., de Pessemier, T., Trogh, J., Tanghe, E., Martens, L., Vandaele, L., Van Nuffel, A., Joseph, W. et Sonck, B. (2019). On the use of on-cow accelerometers for the classification of behaviours in dairy barns. *Research in Veterinary Science*, 125, 425–433. <http://dx.doi.org/10.1016/j.rvsc.2017.10.005>
- Qiao, Y., Kong, H., Clark, C., Lomax, S., Su, D., Eiffert, S. et Sukkarieh, S. (2021). Intelligent perception-based cattle lameness detection and behaviour recognition : A review. *Animals*, 11(11), 3033. <http://dx.doi.org/10.3390/ani11113033>
- Chandola, V., Banerjee, A. et Kumar, V. (2009). Anomaly detection : A survey. *ACM Computing Surveys*, 41(3), 1–58. <http://dx.doi.org/10.1145/1541880.1541882>
- Siachos, N., Neary, J. M., Smith, R. F. et Oikonomou, G. (2024). Automated dairy cattle lameness detection utilizing the power of artificial intelligence; current status quo and future research opportunities. *The Veterinary Journal*, 304, 106091. <http://dx.doi.org/10.1016/j.tvjl.2024.106091>
- Myint, B. B., Onizuka, T., Tin, P., Aikawa, M., Kobayashi, I. et Zin, T. T. (2024). Development of a real-time cattle lameness detection system using a single side-view camera. *Scientific Reports*, 14, 13734. <http://dx.doi.org/10.1038/s41598-024-64664-7>
- Viazzi, S., Bahr, C., Schlageter-Tello, A., Van Hertem, T., Romanini, C. E. B., Pluk, A., Halachmi, I., Lokhorst, C. et Berckmans, D. (2013). Analysis of individual classification of lameness using automatic measurement of back posture in dairy cattle. *Journal of Dairy Science*, 96(1), 257–266. <http://dx.doi.org/10.3168/jds.2012-5806>
- Michelena, A. (2025). Comparative analysis of unsupervised anomaly detection techniques for heat detection in dairy cattle. *Neurocomputing*, 618, 129088. <http://dx.doi.org/10.1016/j.neucom.2024.129088>
- Liu, F. T., Ting, K. M. et Zhou, Z.-H. (2008). Isolation forest. Dans *Proceedings of the 2008 Eighth IEEE International Conference on Data Mining*, 413–422. <http://dx.doi.org/10.1109/ICDM.2008.17>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. et Duchesnay, É. (2011). Scikit-learn : Machine learning in python. *Journal of Machine Learning Research*, 12, 2825–2830. Récupéré le 2026-06-13 de <https://jmlr.org/papers/v12/pedregosa11a.html>
- Breunig, M. M., Kriegel, H.-P., Ng, R. T. et Sander, J. (2000). Lof : Identifying density-based local outliers. *SIGMOD Record*, 29(2), 93–104. <http://dx.doi.org/10.1145/335191.335388>
- Kakar, J. K., Hussain, S., Kim, S. C. et Kim, H. (2024). TimeTector : A twin-branch approach for unsupervised anomaly detection in livestock sensor noisy data. *Sensors*, 24(8), 2453. <http://dx.doi.org/10.3390/s24082453>
- Alsaad, M., Niederhauser, J. J., Beer, G., Zehner, N., Schuepbach-Regula, G. et Steiner, A. (2012). Electronic detection of lameness in dairy cows through measuring pedometric activity and lying behavior. *Applied Animal Behaviour Science*, 142(3-4), 134–141. <http://dx.doi.org/10.1016/j.applanim.2012.10.001>

- Mazrier, H., Tal, S., Aizinbud, E. et Eitan, U. (2006). A field investigation of the use of the pedometer for the early detection of lameness in cattle. *Canadian Veterinary Journal*, 47(9), 883–886. PMID : 17017652.
- Maertens, W., Vangeyte, J., Baert, J., Jantuan, A., Mertens, K. C., De Campeneere, S., Pluk, A., Opsomer, G., Van Weyenberg, S. et Van Nuffel, A. (2011). Development of a real time cow gait tracking and analysing tool to assess lameness using a pressure sensitive walkway : The GAITWISE system. *Biosystems Engineering*, 110(1), 29–39.
<http://dx.doi.org/10.1016/j.biosystemseng.2011.06.003>
- Van Hertem, T., Maltz, E., Antler, A., Romanini, C. E. B., Viazzi, S., Bahr, C., Schlageter-Tello, A., Lokhorst, K., Berckmans, D. et Halachmi, I. (2013). Lameness detection based on multivariate continuous sensing of milk yield, rumination, and neck activity. *Journal of Dairy Science*, 96(7), 4286–4298.
<http://dx.doi.org/10.3168/jds.2012-6188>
- Blackie, N., Amory, J., Bleach, E. et Scaife, J. (2011). The effect of lameness on lying behaviour of zero grazed holstein dairy cattle. *Applied Animal Behaviour Science*, 134(3–4), 85–91.
<http://dx.doi.org/10.1016/j.applanim.2011.08.004>
- Beer, G., Alsaad, M., Starke, A., Schuepbach-Regula, G., Müller, H., Kohler, P. et Steiner, A. (2016). Use of extended characteristics of locomotion and feeding behavior for automated identification of lame dairy cows. *PLoS ONE*, 11(5), e0155796.
<http://dx.doi.org/10.1371/journal.pone.0155796>
- Bewley, J. M. et Schutz, M. M. (2008). An interdisciplinary review of body condition scoring for dairy cattle. *The Professional Animal Scientist*, 24(6), 507–529.
[http://dx.doi.org/10.15232/S1080-7446\(15\)30901-3](http://dx.doi.org/10.15232/S1080-7446(15)30901-3)
- Ito, K., von Keyserlingk, M. A. G., LeBlanc, S. J. et Weary, D. M. (2010). Lying behavior as an indicator of lameness in dairy cows. *Journal of Dairy Science*, 93(8), 3553–3560.
<http://dx.doi.org/10.3168/jds.2009-2951>
- Nechanitzky, K., Starke, A., Vidondo, B., Müller, H., Reckardt, M., Friedli, K. et Steiner, A. (2016). Analysis of behavioral changes in dairy cows associated with claw horn lesions. *Journal of Dairy Science*, 99(4), 2904–2914. <http://dx.doi.org/10.3168/jds.2015-10109>
- Ledgerwood, D. N., Winckler, C. et Tucker, C. B. (2010). Evaluation of data loggers, sampling intervals, and editing techniques for measuring the lying behavior of dairy cattle. *Journal of Dairy Science*, 93(11), 5129–5139. <http://dx.doi.org/10.3168/jds.2009-2945>
- Thorup, V. M., do Nascimento, O. F., Skjøth, F., Voigt, M., Rasmussen, M. D., Bennedsgaard, T. W. et Friggens, N. C. (2015). Lameness detection via leg-mounted accelerometers on dairy cows on four commercial farms. *Animal*, 9(10), 1704–1712.
<http://dx.doi.org/10.1017/S1751731115000890>
- Paudyal, S., Lombard, J. E., Melendez, P., Roman-Muniz, I. N., Callan, R. J., Maunsell, F. et Pinedo, P. (2021). Lying and stepping behaviors around corrective or therapeutic claw trimming. *JDS Communications*, 2(5), 282–288. <http://dx.doi.org/10.3168/jdsc.2020-0044>
- Page, E. S. (1954). Continuous inspection schemes. *Biometrika*, 41(1–2), 100–115.
<http://dx.doi.org/10.1093/biomet/41.1-2.100>

- Rutten, C. J., Velthuis, A. G. J., Steeneveld, W. et Hogeveen, H. (2013). Invited review : Sensors to support health management on dairy farms. *Journal of Dairy Science*, 96(4), 1928–1952.
<http://dx.doi.org/10.3168/jds.2012-6107>
- Leys, C., Ley, C., Klein, O., Bernard, P. et Licata, L. (2013). Detecting outliers : Do not use standard deviation around the mean, use absolute deviation around the median. *Journal of Experimental Social Psychology*, 49(4), 764–766. <http://dx.doi.org/10.1016/j.jesp.2013.03.013>
- Everingham, M., Van Gool, L., Williams, C. K. I., Winn, J. et Zisserman, A. (2010). The pascal visual object classes (voc) challenge. *International Journal of Computer Vision*, 88(2), 303–338.
<http://dx.doi.org/10.1007/s11263-009-0275-4>
- Pineau, J., Vincent-Lamarre, P., Sinha, K., Larivière, V., Beygelzimer, A., d'Alché Buc, F., Fox, E. et Larochelle, H. (2021). Improving reproducibility in machine learning research (a report from the neurips 2019 reproducibility program). *Journal of Machine Learning Research*, 22(164), 1–20.
<http://dx.doi.org/10.5555/3546258.3546422>
- Wilkinson, M. D., Dumontier, M., Aalbersberg, I. J., Appleton, G., Axton, M., Baak, A., Blomberg, N., Boiten, J.-W., da Silva Santos, L. B., Bourne, P. E. et al. (2016). The fair guiding principles for scientific data management and stewardship. *Scientific Data*, 3, 160018.
<http://dx.doi.org/10.1038/sdata.2016.18>
- Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F. et Dennison, D. (2015). Hidden technical debt in machine learning systems. Dans *Advances in Neural Information Processing Systems*, volume 28, 2503–2511.
- Amershi, S., Begel, A., Bird, C., DeLine, R., Gall, H., Kamar, E., Nagappan, N., Nushi, B. et Zimmermann, T. (2019). Software engineering for machine learning : A case study. Dans *Proceedings of the 41st International Conference on Software Engineering : Software Engineering in Practice*, 291–300.
<http://dx.doi.org/10.1109/ICSE-SEIP.2019.00042>
- Breck, E., Cai, S., Nielsen, E., Salib, M. et Sculley, D. (2017). The ml test score : A rubric for ml production readiness and technical debt reduction. Dans *Proceedings of IEEE International Conference on Big Data*, 1123–1132. <http://dx.doi.org/10.1109/BigData.2017.8258038>
- Virtanen, P., Gommers, R., Oliphant, T. E. et al. (2020). SciPy 1.0 : Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3), 261–272.
<http://dx.doi.org/10.1038/s41592-019-0686-2>
- McKinney, W. (2010). Data structures for statistical computing in Python. Dans *Proceedings of the 9th Python in Science Conference*, 56–61. <http://dx.doi.org/10.25080/Majora-92bf1922-00a>
- Harris, C. R., Millman, K. J., van der Walt, S. J. et al. (2020). Array programming with NumPy. *Nature*, 585(7825), 357–362. <http://dx.doi.org/10.1038/s41586-020-2649-2>
- Efron, B. et Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. New York : Chapman & Hall/CRC.
- Field, C. A. et Welsh, A. H. (2007). Bootstrapping clustered data. *Journal of the Royal Statistical Society : Series B (Statistical Methodology)*, 69(3), 369–390.
- Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), 80–83.
<http://dx.doi.org/10.2307/3001968>

- Kerby, D. S. (2014). The simple difference formula : An approach to teaching nonparametric correlation. *Comprehensive Psychology*, 3, 11.IT.3.1. <http://dx.doi.org/10.2466/11.IT.3.1>
- Stangaferro, M. L., Wijma, R., Caixeta, L. S., Al-Abri, M. A. et Giordano, J. O. (2016). Use of rumination and activity monitoring for the identification of dairy cows with health disorders. *Journal of Dairy Science*, 99(9), 7395–7410. <http://dx.doi.org/10.3168/jds.2016-10907>
- Shadish, W. R., Cook, T. D. et Campbell, D. T. (2002). *Experimental and Quasi-Experimental Designs for Generalized Causal Inference*. Boston, MA : Houghton Mifflin.
- Wohlin, C., Runeson, P., Höst, M., Ohlsson, M. C., Regnell, B. et Wesslén, A. (2012). *Experimentation in Software Engineering*. Springer. <http://dx.doi.org/10.1007/978-3-642-29044-2>
- Wolfert, S., Ge, L., Verdouw, C. et Bogaardt, M.-J. (2017). Big data in smart farming – a review. *Agricultural Systems*, 153, 69–80. <http://dx.doi.org/10.1016/j.agsy.2017.01.023>
- Carbonell, I. M. (2016). The ethics of big data in agriculture. *Internet Policy Review*, 5(1). <http://dx.doi.org/10.14763/2016.1.405>