

UNIVERSITÉ DU QUÉBEC À MONTRÉAL

DÉTECTION DE BOITERIE BOVINE PROBABLE À PARTIR DE DONNÉES CAPTEURS

MÉMOIRE

PRÉSENTÉ

COMME EXIGENCE PARTIELLE

DE LA MAÎTRISE EN INFORMATIQUE

CONCENTRATION : SYSTÈMES ÉLECTRONIQUES

PAR

ALIOU BARRY

JUIN 2026

*À la mémoire de mon père,
dont l'exemple, les valeurs et la confiance
continuent de guider chacun de mes pas.*

*À ma mère,
pour son courage et sa force inébranlable
depuis son départ.*

*Ce travail est le fruit
de tout ce qu'ils m'ont transmis.*

REMERCIEMENTS

Je tiens à exprimer ma profonde gratitude envers mon directeur de recherche, le professeur Abdoulaye Baniré Diallo, pour son encadrement scientifique rigoureux, sa confiance et sa disponibilité tout au long de ce projet. Ses conseils méthodologiques et sa vision ont été déterminants dans l'aboutissement de ce mémoire.

Je remercie sincèrement mon codirecteur, Zakaria El Alaoui Ismaili, pour son accompagnement, ses retours constructifs et son expertise qui ont enrichi ce travail à chaque étape.

Ce mémoire a été réalisé au sein du Laboratoire de bio-informatique de l'UQAM, un environnement de recherche stimulant et collaboratif. Je remercie l'ensemble des membres du laboratoire pour les échanges scientifiques et le soutien quotidien.

Je tiens également à remercier l'équipe du projet Well-E, regroupant des chercheurs de l'UQAM et de McGill, pour le cadre applicatif et les données qui ont rendu ce travail possible.

Un merci particulier à mes collègues François Gonothé Touré et Armand Bandiang Massoua, pour leur camaraderie, les discussions enrichissantes et l'entraide qui ont ponctué ces années de maîtrise.

Je remercie les membres du jury pour le temps consacré à l'évaluation de ce mémoire et pour leurs commentaires constructifs.

Enfin, je remercie ma famille et mes proches pour leur soutien indéfectible et leurs encouragements constants.

TABLE DES MATIÈRES

TABLE DES FIGURES	x
LISTE DES TABLEAUX	xii
Liste des acronymes et abréviations	xvi
Liste des symboles	xix
RÉSUMÉ	xx
ABSTRACT	xxi
INTRODUCTION	1
CHAPITRE 1 CONTEXTE ET REVUE DE LITTÉRATURE	5
1.1 Cadre général	5
1.1.1 Impact économique	5
1.1.2 Étiologie et facteurs de risque	6
1.1.3 Importance de la détection précoce.....	7
1.2 Approches conventionnelles : observation et notation locomotrice	7
1.2.1 Lecture opérationnelle du score locomoteur	8
1.3 Approches basées sur des capteurs et apprentissage	9
1.3.1 Isolation Forest	11
1.3.2 Local Outlier Factor	11
1.3.3 Comparaison synthétique IF et LOF.....	12
1.3.4 Comparaison systématique des méthodes de détection d'anomalies	12
1.3.5 Protocole de sélection des études.....	15
1.3.6 Travaux représentatifs et implications pour ce mémoire	15
1.3.7 Apprentissage profond versus approches classiques	17
1.4 Technologies capteurs pour la détection de boiterie	18

1.5	Hétérogénéité des protocoles : un obstacle à la comparaison	21
1.6	Synthèse critique	25
1.7	Positionnement du mémoire	26
CHAPITRE 2 DONNÉES ET MÉTHODOLOGIE		27
2.1	Corpus de données capteurs	27
2.1.1	Vérification de l'intégrité des données	27
2.1.2	Qualité des données et critères de filtrage	31
2.1.3	Variabilité inter-individuelle	32
2.1.4	Choix de la résolution temporelle	33
2.1.5	Corpus complémentaire : ferme du campus Macdonald (automne 2019)	33
2.2	Architecture du pipeline	35
2.3	Détection et règles métier	38
2.3.1	Normalisation robuste	39
2.3.2	Stratégie d'entraînement par vache	39
2.4	Métriques d'évaluation	40
2.4.1	Intersection over Union (IoU)	40
2.5	Protocole d'injection	41
CHAPITRE 3 ARCHITECTURE ET IMPLÉMENTATION		43
3.1	Architecture logicielle	43
3.2	Choix d'implémentation	45
3.2.1	Façades publiques et composantes internes	45
3.2.2	Source unique de vérité pour les paramètres	45
3.2.3	Séparation logique / présentation	46

3.2.4	Flux de données détaillé	46
3.2.5	Diagramme de séquence d'une exécution de validation	46
3.3	Stratégie de tests et qualité.....	47
3.4	Détail algorithmique : Isolation Forest	48
3.4.1	Pseudocode du pipeline complet	50
3.4.2	Détail de la logique d'alerte (mode MIX)	51
3.5	Détail algorithmique : Local Outlier Factor (comparaison)	51
3.5.1	Comparaison de complexité algorithmique	52
3.6	Technologies et dépendances	52
3.7	Interface interactive de visualisation	53
3.7.1	Score de risque de boiterie (LRS)	56
3.7.2	Séparation interface et logique scientifique	58
3.8	Traçabilité	58
3.8.1	Cycle de vie d'un artefact expérimental	58
3.9	Reproductibilité et science ouverte	59
CHAPITRE 4 VALIDATION ET RÉSULTATS		61
4.1	Protocole de validation	61
4.1.1	Validation manuelle	61
4.1.2	Validation robuste	62
4.1.3	Configuration finale retenue	62
4.2	Résultats	63
4.2.1	Validation manuelle v2.1 (configuration finale)	63
4.2.2	Validation robuste et configuration finale	68

4.2.3	Comparaison v4, v5.1 et v5.2	75
4.2.4	Ablation et comparaison IF versus LOF	77
4.2.5	Validation exploratoire IF versus LOF (protocole v4)	83
4.2.6	Analyse des modes de défaillance	85
4.2.7	Stabilité inter-seeds	87
4.2.8	Sensibilité locale autour de la configuration retenue	88
4.2.9	Performance, scalabilité et intégrité	90
4.2.10	Analyse de la variabilité inter-vache	91
4.3	Positionnement par rapport à la littérature	92
4.3.1	Distribution des recouvrements temporels	93
4.3.2	Gel des seuils et traçabilité de la décision	93
4.4	Validation exploratoire sur le corpus complémentaire IceTag 2019	93
4.4.1	Portabilité technique	94
4.4.2	Concordance avec les scores cliniques SLS	94
4.4.3	Interprétation	95
4.4.4	Limites et portée	96
4.4.5	Synthèse du chapitre	96
CHAPITRE 5	DISCUSSION ET LIMITES	98
5.1	Points forts de l'approche	98
5.1.1	Positionnement méthodologique clair	98
5.1.2	Architecture hybride IF + règles métier	98
5.1.3	Profondeur de validation	98
5.1.4	Honnêteté de l'ablation	98

5.2	Limites	99
5.2.1	Absence de labels cliniques exhaustifs	99
5.2.2	Cas borderline encore fragiles	99
5.2.3	Dépendance aux seuils	100
5.2.4	Généralisation à confirmer	100
5.2.5	Biais potentiels du corpus	101
5.3	Menaces à la validité	102
5.4	Spécificité de la détection et diagnostic différentiel	103
5.4.1	Ce que détecte réellement le pipeline	103
5.4.2	Confondants cliniques et mécanismes de mitigation	104
5.4.3	Positionnement clinique : outil de priorisation, pas de diagnostic	105
5.4.4	Limites assumées	105
5.5	Mise en perspective avec la littérature	105
5.6	Comparaison avec les systèmes commerciaux	107
5.7	Implications pratiques pour l'éleveur	107
5.7.1	Analyse coût-bénéfice	109
5.7.2	Architecture opérationnelle de bout-en-bout	110
5.8	Perspectives de déploiement	112
5.8.1	Retour sur la validation exploratoire IceTag 2019	113
5.9	Considérations d'usage et éthique	113
5.9.1	Responsabilité algorithmique et bien-être animal	113
5.9.2	Confiance et adoption	114
5.9.3	Protection des données	114

CONCLUSION..... 117

ANNEXE A DÉTAILS DE VALIDATION ET REPRODUCTIBILITÉ 121

BIBLIOGRAPHIE 129

TABLE DES FIGURES

Figure 1.1	Étiologie multifactorielle de la boiterie bovine.	6
Figure 1.2	Seuil opérationnel du score locomoteur.....	8
Figure 1.3	Taxonomie simplifiée des approches de détection automatisée de boiterie.....	10
Figure 1.4	Principe d'isolation des anomalies dans Isolation Forest.	11
Figure 1.5	Représentation schématique du capteur IceQube.	20
Figure 1.6	Positionnement du capteur IceQube sur la patte arrière.	20
Figure 1.7	Matrice de couverture des travaux représentatifs en détection de boiterie bovine.....	24
Figure 2.1	Distribution des <i>Steps</i> sur l'ensemble du corpus.	29
Figure 2.2	Distribution du nombre de bins par vache dans le corpus.	30
Figure 2.3	Illustration schématique du suivi de couverture temporelle hebdomadaire (échantillon de 7 vaches, oct.–nov. 2023).	30
Figure 2.4	Architecture du pipeline de détection de boiterie probable.	35
Figure 2.5	Processus d'extraction de <i>features</i> pour une variable brute.	37
Figure 2.6	Mécanisme de persistance et de cooldown.	39
Figure 2.7	Illustration du calcul d'IoU entre un épisode injecté et un épisode prédit.	41
Figure 3.1	Diagramme de dépendances entre les composantes du pipeline.	44
Figure 3.2	Flux de données détaillé à travers les quatre étapes du pipeline.....	46
Figure 3.3	Diagramme de séquence d'une exécution de validation.....	47
Figure 3.4	Pseudocode du pipeline de détection de boiterie probable.	50
Figure 3.5	Comparaison des complexités théoriques IF vs LOF.	52

Figure 3.6	Onglet « Analyse individuelle » du dashboard.....	55
Figure 3.7	Vue « Classement troupeau » du dashboard.	55
Figure 3.8	Vue « Animaux à risque » du dashboard.....	56
Figure 3.9	Carte de chaleur des alertes quotidiennes par animal.	56
Figure 3.10	Cycle de vie d'un artefact expérimental.....	59
Figure 4.1	Chronologie des 8 alertes de la vache 8081 (20 oct au 8 nov 2023).....	67
Figure 4.2	Profil de la configuration finale sur les quatre dimensions clés.....	69
Figure 4.3	Pouvoir discriminant du score <code>if_anom_k_max</code>	70
Figure 4.4	Importance des <i>features</i> de l'Isolation Forest via les valeurs de Shapley (vache 8081, 1000 bins).	72
Figure 4.5	Calibration du score <code>if_anom_k_max</code>	74
Figure 4.6	Progression de l'exploration : configurations testées (bleu) et validées GO (vert) par campagne robuste.	76
Figure 4.7	Comparaison des quatre variantes d'ablation sur les métriques de détection.....	78
Figure 4.8	Comparaison IF vs LOF au niveau événement (protocole v4, 288 exécutions).	85
Figure 4.9	Analyse de sensibilité locale autour de la configuration finale.	88
Figure 4.10	Scalabilité du pipeline.....	91
Figure 4.11	Décomposition du temps cœur du pipeline sur 28 vaches.....	91
Figure 5.1	Profil radar du système sur six dimensions d'évaluation.	115
Figure 5.2	Positionnement du système dans le flux décisionnaire d'un élevage.	115
Figure A.1	Distribution des <code>best_iou</code> par scénario d'injection (campagne v5.2).	128

LISTE DES TABLEAUX

Tableau 1.1	Composantes du coût économique de la boiterie par cas clinique.	5
Tableau 1.2	Lecture clinique et opérationnelle simplifiée du score locomoteur.	9
Tableau 1.3	Comparaison des propriétés d'Isolation Forest et de Local Outlier Factor.....	12
Tableau 1.4	Comparaison systématique de dix méthodes de détection d'anomalies et de classification.	13
Tableau 1.5	Synthèse de travaux représentatifs sur la détection automatisée de boiterie bovine.	16
Tableau 1.6	Comparaison des approches d'apprentissage profond et classiques pour la détection de boiterie bovine.	17
Tableau 1.7	Technologies capteurs utilisées dans la détection de boiterie bovine.	19
Tableau 1.8	Synthèse quantitative de travaux représentatifs en détection de boiterie bovine.....	22
Tableau 2.1	Description du corpus de données capteurs.	28
Tableau 2.2	Statistiques descriptives des variables comportementales brutes.....	28
Tableau 2.3	Variables comportementales brutes disponibles dans le corpus.....	31
Tableau 2.4	Variabilité inter-individuelle des principales variables comportementales.....	32
Tableau 2.5	Comparaison des résolutions temporelles candidates pour l'agrégation capteur.	33
Tableau 2.6	Description du corpus complémentaire McGill IceTag (automne 2019).	34
Tableau 2.7	Distribution des 30 vaches du corpus McGill par groupe clinique.	34
Tableau 2.8	Familles de <i>features</i> dérivées pour chaque variable comportementale brute.	36
Tableau 2.9	Configuration finale du pipeline, gelée après validation.	38
Tableau 2.10	Métriques d'évaluation utilisées dans les protocoles de validation.....	40
Tableau 2.11	Profils d'injection utilisés dans les validations manuelles et robustes.	42

Tableau 3.1	Composantes fonctionnelles du système de détection.....	43
Tableau 3.2	Principes de conception logicielle appliqués au pipeline de détection et leur justification pratique.	44
Tableau 3.3	Stratégie de tests du projet.	48
Tableau 3.4	Hyperparamètres d'Isolation Forest	49
Tableau 3.5	Principales technologies et dépendances du projet.	52
Tableau 3.6	Comparaison des frameworks candidats pour la détection d'anomalies.	53
Tableau 3.7	Niveaux d'alerte définis par le Lameness Risk Score (LRS) et plans d'action associés.	57
Tableau 3.8	Types d'artefacts produits par le pipeline et leur rôle dans la traçabilité.	59
Tableau 4.1	Vue d'ensemble des protocoles de validation.	61
Tableau 4.2	Seuils GO/NO-GO utilisés pour la validation robuste scenario-aware.	62
Tableau 4.3	Configuration finale retenue (figée dans <code>core/config.py</code>). Tous les résultats des sections suivantes utilisent ces valeurs.	63
Tableau 4.4	Distribution des alertes naturelles (baseline) avant injection. Les vaches sont regroupées par niveau d'activité d'alerte.	64
Tableau 4.5	Design des trois événements injectés dans la validation manuelle v2.1.	65
Tableau 4.6	Résultats de la validation manuelle v2.1 sur la configuration finale.	65
Tableau 4.7	Chronologie des alertes sur la vache 8081 après injection.	66
Tableau 4.8	Impact avant/après injection sur les notifications du troupeau.....	67
Tableau 4.9	Métriques de la configuration finale sur la validation robuste v5.1.	68
Tableau 4.10	Front de Pareto des configurations GO sur v5.1.	69
Tableau 4.11	Comparaison des campagnes robustes : exploration et stabilité.	75
Tableau 4.12	Performance par scénario d'injection à travers les trois campagnes robustes.	77

Tableau 4.13	Synthèse de l'ablation élargie (90 cas par variante).	77
Tableau 4.14	Intervalle de confiance à 95 % sur l'ablation élargie.	78
Tableau 4.15	Ablation par profil d'injection (30 cas par cellule).	79
Tableau 4.16	Tests statistiques appariés (McNemar + Wilcoxon) sur les 90 cas d'ablation.....	80
Tableau 4.17	Comparaison appariée de A (IF + règles) avec la baseline Alsaaod.	82
Tableau 4.18	Comparaison IF vs LOF au niveau événement sur le protocole v4 (288 exécutions).	83
Tableau 4.19	Analyse appariée IF vs LOF sur l'ablation étendue (90 cas).	83
Tableau 4.20	Analyse appariée IF vs LOF sur le protocole v4 (96 paires par scénario).	84
Tableau 4.21	Modes de défaillance identifiés lors des validations.....	86
Tableau 4.22	Stabilité inter-seeds de la configuration finale (validation robuste v5.1).....	87
Tableau 4.23	Sensibilité locale : écarts par rapport à la baseline retenue.....	89
Tableau 4.24	Benchmark de performance du pipeline complet selon la fraction du corpus.	90
Tableau 4.25	Positionnement du système proposé par rapport aux travaux publiés.	92
Tableau 4.26	Résultats du pipeline gelé sur les 30 vaches du corpus complémentaire IceTag 2019.	95
Tableau 5.1	Synthèse des forces et limites du système proposé.	99
Tableau 5.2	Confondants potentiels et mécanismes de mitigation par le pipeline.	104
Tableau 5.3	Comparaison du système proposé avec des solutions commerciales de suivi comportemental bovin.	107
Tableau 5.4	Scénario de journée type pour un élevage de 100 vaches.	108
Tableau 5.5	Estimation indicative du coût-bénéfice du système pour différentes tailles de troupeau.	109
Tableau 5.6	Budget de latence du système de bout-en-bout (100 vaches, fréquence 15 min, capteurs IceQube).	110

Tableau 5.7	Matrice de responsabilités pour le workflow de détection.	111
Tableau 5.8	Conditions de déploiement opérationnel et statut dans le projet actuel.....	113
Tableau A.1	Grille de paramètres explorée dans les validations robustes. Les colonnes v4/v5 . 1/v5 . 2 donnent le nombre de valeurs testées pour chaque paramètre; le nombre de configurations est le <i>produit</i> de ces comptes.	121
Tableau A.2	Multiplicateurs d'injection pour le profil detectable_strong.	123
Tableau A.3	Multiplicateurs d'injection pour les quatre profils.....	123
Tableau A.4	Artefacts produits par chaque campagne de validation.	124
Tableau A.5	Distribution des fausses notifications par vache sur la période d'étude.....	127

LISTE DES ACRONYMES ET ABRÉVIATIONS

AUC-PR	<i>Area Under the Precision-Recall Curve</i> : aire sous la courbe précision/rappel
AUC-ROC	<i>Area Under the ROC Curve</i> : aire sous la courbe ROC (taux vrais positifs vs faux positifs)
Brier	<i>Brier score</i> : erreur quadratique moyenne entre probabilités prédites et issues observées
CSV	<i>Comma-Separated Values</i> : format de fichier tabulaire
DL	<i>Deep Learning</i> : apprentissage profond
ECE	<i>Expected Calibration Error</i> : erreur de calibration espérée, moyenne pondérée des écarts entre fiabilité et précision sur les bins de scores
FAIR	<i>Findable, Accessible, Interoperable, Reusable</i> : principes directeurs pour la gestion des données scientifiques
FN	<i>False Negative</i> : faux négatif
FP	<i>False Positive</i> : faux positif
GO	Verdict positif : la configuration satisfait tous les critères de validation
IF	<i>Isolation Forest</i> : algorithme de détection d'anomalies par isolation
IoU	<i>Intersection over Union</i> : métrique de recouvrement temporel
JSON	<i>JavaScript Object Notation</i> : format d'échange de données
LOCO	<i>Leave-One-Cow-Out</i> : protocole de validation laissant une vache hors de l'apprentissage à chaque itération
LOF	<i>Local Outlier Factor</i> : détecteur d'anomalies basé sur la densité locale
MAD	<i>Median Absolute Deviation</i> : écart absolu médian
McNemar	Test statistique apparié pour comparer deux classifieurs sur les mêmes échantillons (version exacte avec loi binomiale pour faibles effectifs)
MCE	<i>Maximum Calibration Error</i> : écart maximal entre fiabilité et précision sur les bins de scores
MI	<i>Motion Index</i> : indice de mouvement mesuré par le capteur
MIX	Mode de cohérence multi-signaux (IF + z-scores + pic MI)

ML	<i>Machine Learning</i> : apprentissage automatique
MM7	Moyenne mobile sur 7 périodes
NMS	<i>Non-Maximum Suppression</i> : suppression des notifications redondantes
NO-GO	Verdict négatif : la configuration échoue à au moins un critère de validation
PLF	<i>Precision Livestock Farming</i> : élevage de précision
RACI	<i>Responsible, Accountable, Consulted, Informed</i> : matrice d'attribution des rôles dans un workflow opérationnel
SHA	<i>Secure Hash Algorithm</i> : algorithme de hachage cryptographique
SHAP	<i>SHapley Additive exPlanations</i> : méthode d'attribution d'importance basée sur les valeurs de Shapley issues de la théorie des jeux
UTAUT	<i>Unified Theory of Acceptance and Use of Technology</i> : modèle d'acceptation technologique
Wilcoxon	Test des rangs signés de Wilcoxon : test non paramétrique apparié pour comparer deux échantillons sur une métrique continue

Termes techniques

Bin	Intervalle temporel discret (15 minutes par défaut) servant d'unité d'analyse
Boiterie	Altération de la locomotion chez les bovins, se traduisant par une démarche asymétrique ou un appui réduit sur un ou plusieurs membres
Contamination	Fraction attendue d'anomalies dans le jeu de données ; hyperparamètre principal d'Isolation Forest (fixé à 0.06)
Cooldown	Période minimale d'espacement entre deux notifications consécutives pour une même vache (fixé à 12 heures)
Cow-day	Unité de normalisation : un jour d'observation pour une vache ; sert de dénominateur pour le taux de fausses notifications
Feature	Variable calculée à partir des signaux bruts du capteur, servant d'entrée au modèle de détection
Injection	Modification contrôlée des signaux bruts d'une vache cible pour simuler un épisode de boiterie ou un bruit
Persistence	Règle métier exigeant qu'un nombre minimum de bins anomaux soit observé dans une fenêtre temporelle glissante avant de déclencher une alerte
Pipeline	Chaîne de traitement complète, depuis l'ingestion des données brutes jusqu'à l'émission des notifications
Seed	Graine aléatoire fixant le générateur pseudo-aléatoire pour assurer la reproductibilité
Z-score robuste	Mesure d'écart par rapport à la médiane, normalisée par la MAD : $z_i = (x_i - \tilde{\mu}) / (1.4826 \times \text{MAD})$

LISTE DES SYMBOLES

$s(x)$	Score d'anomalie d'un point x dans Isolation Forest
$h(x)$	Profondeur (nombre de coupures) nécessaire pour isoler x dans un arbre
$E[h(x)]$	Espérance de la profondeur d'isolation sur l'ensemble des arbres de la forêt
$c(n)$	Facteur de normalisation : profondeur moyenne d'isolation dans un arbre binaire de n observations
n	Nombre d'observations (bins temporels)
K	Nombre de bins dans la fenêtre de persistance : $\lceil \text{persist_hours} \times 60 / \text{interval_min} \rceil$
σ	Écart-type
$\tilde{\mu}$	Médiane d'un signal
z_i	Score z robuste (basé sur la MAD) pour le bin i
IoU	<i>Intersection over Union</i> : $\frac{ A \cap B }{ A \cup B }$, mesure de recouvrement temporel entre un épisode prédit A et une fenêtre d'injection B
S	Score de sélection pondéré pour le classement des configurations (éq. A.1)
$\overline{\text{IoU}_{20}}$	Taux moyen de détection avec $\text{IoU} \geq 0.20$
$\overline{\text{det}}$	Taux moyen de détection (recouvrement quelconque)
$\overline{\text{leak}}$	Taux moyen de fuite sur les scénarios non détectables
$\overline{\text{FN}}$	Taux moyen de fausses notifications par vache-jour
σ_{FN}	Écart-type des fausses notifications entre seeds

RÉSUMÉ

La boiterie est l'un des trois problèmes de santé les plus fréquents chez les vaches laitières, avec des prévalences de 20 à 55 % selon les études. Son coût économique (75 à 300+ USD par cas) et son impact sur le bien-être animal motivent le développement de systèmes de détection automatisée. Ce mémoire présente la conception, l'implémentation et la validation d'un système reproductible de détection de boiterie probable, à partir de données de capteurs comportementaux collectées sur 28 vaches pendant 41 jours, comme l'activité, les transitions posturales et la dynamique de mouvement. L'architecture proposée est modulaire : un *pipeline* en quatre étapes (chargement, extraction d'environ 50 variables dérivées, détection d'anomalies, application de règles métier) combine un détecteur d'anomalies non supervisé proposé (Isolation Forest) avec des règles métier explicites comme la persistance temporelle, la cohérence multi-signaux et l'espacement des notifications. L'implémentation comprend également un score continu de risque pour le classement des animaux et un tableau de bord interactif offrant à l'éleveur quatre vues complémentaires.

La validation du système proposé est conduite sur deux niveaux. Une validation manuelle par injections contrôlées confirme que les événements détectables sont récupérés avec un recouvrement temporel strict, tandis que les scénarios non détectables restent silencieux. Une validation robuste multi-configurations, avec plus de 9 500 exécutions et 336 paramétrisations, établit 100 % de détection sur les cas forts, une fuite nulle et un taux de fausses notifications limité à 0.105 par vache-jour. De plus, l'accord de décision entre deux campagnes successives atteint 91.7 %.

D'autre part, pour valider les choix d'architecture, une étude d'ablation portant sur 90 cas par variante compare quatre configurations du pipeline et montre que chaque composante est nécessaire : le détecteur seul manque de précision temporelle, tandis que les règles seules génèrent significativement plus de fausses alertes. Isolation Forest et Local Outlier Factor présentent en outre des profils complémentaires, ouvrant la perspective d'un ensemble hybride. Un *benchmark* de performance confirme enfin une scalabilité linéaire (≈ 0.6 seconde par vache).

La rigueur statistique est renforcée par des tests appariés (McNemar exact et Wilcoxon des rangs signés), des intervalles de confiance à 95 % par rééchantillonnage *bootstrap*, des courbes de sensibilité/spécificité et de précision/rappel, une analyse de l'importance des variables par valeurs de Shapley, ainsi qu'une calibration isotonique des scores (score de Brier = 0.087; erreur de calibration espérée = 0.015). Une matrice de responsabilités documente l'intégration du système dans le *workflow* de ferme.

Une validation exploratoire sur un corpus complémentaire de 30 vaches (même ferme, capteur IceTag, automne 2019) confirme la portabilité technique du pipeline et une cohérence partielle avec les scores cliniques locomoteurs disponibles pour 12 d'entre elles. L'ensemble constitue un cadre reproductible pour la détection non supervisée de boiterie probable, avec traçabilité par empreintes cryptographiques des artefacts.

Mots clés : boiterie bovine, données capteurs, détection d'anomalies, Isolation Forest, règles métier, validation robuste, reproductibilité, élevage de précision.

ABSTRACT

Lameness is one of the three most prevalent health issues in dairy cattle, affecting 20–55 % of herds depending on the study. Its economic cost (75–300+ USD per case) and welfare impact motivate the development of automated detection systems. This thesis presents the design, implementation and validation of a reproducible system for probable bovine lameness detection, using behavioral sensor data collected from 28 cows over 41 days, such as activity, postural transitions and movement dynamics. The proposed architecture is modular : a four-stage pipeline (loading, extraction of about 50 derived features, anomaly detection, application of business rules) combines a proposed unsupervised anomaly detector (Isolation Forest) with explicit business rules such as temporal persistence, multi-signal coherence and notification spacing. The implementation also includes a continuous risk score for ranking animals and an interactive dashboard offering four complementary views to the farmer.

Validation of the proposed system is conducted at two levels. A manual validation using controlled injections confirms that detectable events are recovered with strict temporal overlap, while undetectable scenarios remain silent. A robust multi-configuration validation, with more than 9,500 runs and 336 parameterizations, establishes 100 % detection on strong cases, zero leakage and a false notification rate limited to 0.105 per cow-day. Furthermore, decision agreement between two successive campaigns reaches 91.7 %.

To validate the architectural choices, an ablation study of 90 cases per variant compares four pipeline configurations and shows that each component is necessary : the detector alone lacks temporal precision, whereas rules alone generate significantly more false alerts. Isolation Forest and Local Outlier Factor further exhibit complementary profiles, opening the prospect of a hybrid ensemble. A performance benchmark finally confirms linear scalability (≈ 0.6 second per cow).

Statistical rigor is reinforced by paired tests (exact McNemar and Wilcoxon signed-rank), 95 % bootstrap confidence intervals, sensitivity/specificity and precision/recall curves, a Shapley-value feature importance analysis, and isotonic score calibration (Brier score = 0.087 ; expected calibration error = 0.015). A responsibility matrix also documents the integration of the system into the farm workflow.

An exploratory validation on a complementary cohort of 30 cows (same farm, IceTag sensor, fall 2019) confirms the technical portability of the pipeline and partial concordance with locomotor clinical scores available for 12 cows. The work constitutes a reproducible framework for unsupervised detection of probable lameness, with cryptographic-hash traceability of all artifacts.

Keywords: bovine lameness, sensor data, anomaly detection, Isolation Forest, business rules, robust validation, reproducibility, precision livestock farming.

INTRODUCTION

Motivations

La boiterie en élevage laitier constitue un enjeu majeur de bien-être animal et de performance technico-économique. À l'échelle mondiale, elle est considérée comme l'un des trois problèmes de santé les plus fréquents chez les vaches laitières, avec des prévalences estimées entre 20 % et 55 % selon les études et les régions (Whay *et al.*, 2003; Flower et Weary, 2006). Le coût économique est substantiel : les estimations publiées varient de 75 à plus de 300 USD par cas clinique, incluant des pertes de production laitière qui peuvent atteindre 270 à 574 kg par lactation, une dégradation de la fertilité, des augmentations de réformes anticipées et des coûts vétérinaires directs (Green *et al.*, 2002; Bruijnis *et al.*, 2010). Pour un troupeau de 100 vaches soumis à une prévalence de 25 %, la perte annuelle attribuable aux seuls cas incidents est estimée entre 1 900 et 7 500 USD. Au-delà de l'impact financier, la boiterie soulève un enjeu éthique de bien-être animal, la douleur associée étant reconnue comme l'une des principales sources de souffrance chronique chez les vaches laitières (Whay *et al.*, 2003).

Face à ces enjeux, l'élevage de précision (*Precision Livestock Farming*, PLF) propose d'automatiser le suivi comportemental des animaux à l'aide de capteurs portés et d'outils numériques (Palma *et al.*, 2025; Michelena *et al.*, 2025). Les podomètres et accéléromètres aujourd'hui répandus dans les élevages laitiers génèrent des séries temporelles continues à faible coût marginal, ouvrant la voie à des systèmes de détection précoce intégrés au *workflow* de ferme. Ce mémoire se positionne dans cette dynamique en proposant un système de détection de boiterie probable conçu pour être à la fois interprétable, reproductible et exploitable par l'éleveur.

Contexte et problématique

En pratique, l'identification précoce de la boiterie repose souvent sur des observations humaines, utiles mais sensibles à la charge de travail et à l'expérience des observateurs. La concordance inter-observateurs sur les grilles de *scoring* locomoteur varie significativement d'une étude à l'autre (Sprecher *et al.*, 1997; Flower et Weary, 2006), ce qui motive le recours à des capteurs comportementaux pour une détection plus continue et plus objective.

L'automatisation soulève cependant deux difficultés majeures. D'une part, les signaux des capteurs (activité, transitions posturales, dynamique de mouvement) sont bruyants et hétérogènes entre individus. D'autre part, un score d'anomalie n'est pas, à lui seul, une preuve clinique suffisante de boiterie ; et l'absence fréquente de labels cliniques synchronisés interdit de formuler le problème comme une tâche de classification supervisée standard (Alsaad *et al.*, 2019; O'Leary *et al.*, 2020).

La littérature reflète d'ailleurs cette difficulté : les performances rapportées varient de 22 % à 91 % de sensibilité selon les capteurs utilisés, les définitions cliniques retenues et les protocoles de validation (O'Leary *et al.*, 2020; González-García *et al.*, 2023), ce qui complique la comparaison directe entre travaux et la transposition d'une étude à l'autre. Plusieurs solutions commerciales déployées en élevage (CowManager, Heatime, IceQube) fonctionnent par ailleurs comme des boîtes noires propriétaires, rarement évaluées de manière indépendante (Rutten *et al.*, 2013), ce qui motive le développement d'approches ouvertes, documentées et auditable.

Ensemble, ces constats conduisent au problème de recherche suivant : *comment construire un système de détection de boiterie probable, interprétable et robuste, à partir de données capteurs comportementaux, sans prétendre au diagnostic clinique ?*

La réponse proposée repose sur une architecture hybride combinant un détecteur d'anomalies non supervisé (Isolation Forest) et des règles métier explicites, validée à travers un protocole en deux niveaux.

Objectif général et objectifs spécifiques

L'objectif général consiste à développer et valider une chaîne de traitement reproductible permettant de détecter des épisodes de boiterie probable à partir de données capteurs bovines, en combinant détection d'anomalies et règles métier interprétables. Cet objectif peut se décliner en cinq sous-objectifs spécifiques :

1. Concevoir un *pipeline* complet couvrant l'ensemble de la chaîne : ingestion, prétraitement, extraction de variables dérivées, détection d'anomalies et filtrage par règles métier.
2. Assurer l'interprétabilité opérationnelle des alertes via des règles explicites comme la persistance temporelle, la cohérence comportementale multi-sigaux et l'espacement des notifications.
3. Évaluer la robustesse du système selon deux protocoles complémentaires : validation manuelle par injections contrôlées et validation robuste multi-configurations.

4. Comparer le détecteur retenu (Isolation Forest) à une alternative non supervisée (Local Outlier Factor) dans une étude d'ablation élargie.
5. Garantir la traçabilité et la reproductibilité des résultats par tests automatisés, vérification d'intégrité et gel explicite des seuils.

Positionnement et portée

Le système proposé produit des *alertes de boiterie probable*. Il s'agit d'une aide à la décision pour le suivi d'élevage, et non d'un dispositif de diagnostic vétérinaire. Un tel positionnement est volontaire et cohérent avec les limites des données disponibles dans le cadre du mémoire, car le corpus ne dispose d'aucun étalon clinique (*gold standard*) vétérinaire synchronisé avec les enregistrements capteurs sur l'ensemble des animaux et des périodes d'observation.

La prudence adoptée ici est conforme aux recommandations de la littérature, qui souligne la nécessité de distinguer clairement entre systèmes de détection automatisée et outils diagnostiques validés cliniquement (Alsaad et al., 2019). Le système vise à signaler des déviations comportementales compatibles avec une boiterie, afin de prioriser une vérification terrain.

Méthodologie

La démarche méthodologique articule trois volets complémentaires. Premièrement, un pipeline de traitement modulaire en quatre étapes (chargement et filtrage des données, extraction d'environ 50 variables dérivées, détection d'anomalies par Isolation Forest, application de règles métier) transforme les signaux capteurs bruts en épisodes de boiterie probable assortis d'un score de risque continu. Deuxièmement, deux protocoles de validation complémentaires évaluent la robustesse du système : une validation manuelle par injections contrôlées (cas détectables, *borderline* et non-détectables) confirme la capacité du pipeline à récupérer les épisodes simulés, et une validation robuste multi-configurations explore systématiquement l'espace des hyperparamètres pour vérifier la stabilité de la calibration retenue. Troisièmement, une étude d'ablation compare quatre variantes du pipeline pour isoler la contribution de chaque composante, complétée par des tests statistiques appariés (McNemar exact et *Wilcoxon signed-rank*), des intervalles de confiance à 95 % par rééchantillonnage *bootstrap*, des courbes de sensibilité/spécificité et précision/rappel, ainsi qu'une calibration isotonique des scores. L'ensemble de la démarche s'appuie sur une traçabilité par

empreintes cryptographiques SHA-256 des artefacts expérimentaux, qui garantit la reproductibilité bit-à-bit des résultats.

Contributions du mémoire

Les contributions principales sont les suivantes :

1. une architecture logicielle modulaire et reproductible combinant Isolation Forest et règles métier explicites, couvrant toute la chaîne de détection depuis les données capteurs brutes jusqu'aux notifications interprétables ;
2. un protocole de validation en deux niveaux (manuelle et robuste) couplé à une étude d'ablation comparant quatre variantes du pipeline (règles seules, Isolation Forest seul, Isolation Forest + règles, *Local Outlier Factor* + règles), complétée par des tests statistiques appariés (McNemar exact, *Wilcoxon signed-rank*) pour établir la significativité des écarts ;
3. une comparaison à une *baseline* pédométrique historique (Alsaad 2012) et une calibration isotonique des scores, assorties d'intervalles de confiance à 95 % par bootstrap ;
4. une couche d'interprétabilité associant analyse SHAP, courbes sensibilité/spécificité et précision/rappel, ainsi qu'un *dashboard* Streamlit interactif rendant les alertes directement exploitables par l'utilisateur final ;
5. une matrice RACI pour l'intégration opérationnelle du système dans le workflow de ferme, complétée par des mécanismes de traçabilité par empreintes cryptographiques SHA-256 garantissant l'auditabilité des résultats.

Structure du mémoire

Le mémoire s'articule autour de cinq chapitres complétés par une conclusion. Le Chapitre 1 présente le contexte scientifique et la revue de littérature sur la détection de boiterie bovine. Le Chapitre 2 détaille les données, la méthodologie et les métriques d'évaluation. Le Chapitre 3 décrit l'architecture logicielle et les choix d'implémentation, incluant les détails algorithmiques d'Isolation Forest et de Local Outlier Factor. Le Chapitre 4 expose les protocoles de validation et les résultats expérimentaux. Le Chapitre 5 discute les forces, les limites et les implications pratiques du système. La conclusion ferme le mémoire et propose des perspectives de recherche.

CHAPITRE 1

CONTEXTE ET REVUE DE LITTÉRATURE

1.1 Cadre général

La boiterie bovine est un problème de santé majeur en élevage laitier, avec des conséquences directes sur le bien-être animal, la productivité et la rentabilité des exploitations. Des études épidémiologiques rapportent des prévalences allant de 20% à plus de 50% selon les régions, les systèmes d'élevage et les critères de diagnostic utilisés (Whay *et al.*, 2003; Cook, 2003). Les pathologies du pied, qu'elles soient infectieuses (*dermatite digitale, phlegmon interdigité*) ou non infectieuses (*ulcère de la sole, maladie de la ligne blanche*), constituent la cause la plus fréquente de boiterie chez les vaches laitières (Merck Veterinary Manual, 2024a; Flower et Weary, 2006).

1.1.1 Impact économique

L'impact économique de la boiterie est substantiel et multidimensionnel. Le Tableau 1.1 synthétise les principales composantes du coût *par cas clinique*, c'est-à-dire par épisode de boiterie diagnostiqué chez une vache au cours d'une lactation, d'après les estimations publiées dans la littérature.

Tableau 1.1 Composantes du coût économique de la boiterie par cas clinique.

Composante	Estimation	Source
Perte de production laitière	270–574 kg/lactation	Green <i>et al.</i> (2002)
Coût vétérinaire direct	25–90 USD/cas	Bruijn <i>et al.</i> (2010)
Dégradation de la fertilité	+30–50 jours ouverts	Green <i>et al.</i> (2002)
Réforme anticipée	75–300 USD/cas	Bruijn <i>et al.</i> (2010)
Coût total estimé	75–300+ USD/cas	

Quatre postes principaux composent le coût d'un cas clinique : la perte de production laitière (270 à 574 kg par lactation), liée à la baisse de l'ingestion et de l'activité ; le coût vétérinaire direct (25 à 90 USD par cas), qui inclut la consultation, le parage, les traitements et le matériel de soin ; la dégradation de la fertilité, mesurée par une hausse de 30 à 50 *jours ouverts*, soit l'intervalle entre le vêlage et la conception suivante, avec un décalage de la lactation suivante ; et la réforme anticipée (75 à 300 USD par cas), liée à la perte de

valeur résiduelle d'une vache écartée avant la fin de sa carrière productive. Ces postes se cumulent selon la sévérité et la chronicité de l'épisode. À l'échelle d'un troupeau de 100 vaches avec une prévalence de 25 %, le coût annuel cumulé est estimé entre 1 900 et 7 500 USD pour les seuls cas incidents. Au-delà de l'impact financier, la boiterie soulève un enjeu éthique de bien-être animal : la douleur associée est reconnue comme l'une des principales sources de souffrance chronique chez les vaches laitières (Whay *et al.*, 2003). Ces conséquences justifient une compréhension fine des mécanismes de boiterie, afin d'orienter la prévention, la détection et la prise en charge.

1.1.2 Étiologie et facteurs de risque

Les causes de la boiterie sont multifactorielles. La Figure 1.1 les organise en quatre catégories : causes directes infectieuses ou non infectieuses, et facteurs modulateurs environnementaux ou individuels. Les causes directes regroupent des affections bactériennes, comme la *dermatite digitale* ou le *phlegmon inter-digité*, et des lésions mécaniques, comme l'*ulcère de la sole* ou la *maladie de la ligne blanche*. Les facteurs environnementaux (sol, hygiène, humidité) modulent l'exposition, tandis que les facteurs individuels (parité, âge, stade de lactation) modulent la susceptibilité. Cette structure multifactorielle explique qu'aucun indicateur unique ne suffise et justifie une approche multi-signaux pour la détection précoce.




Figure 1.1 Étiologie multifactorielle de la boiterie bovine.

1.1.3 Importance de la détection précoce

La littérature sur la boiterie bovine souligne l'importance d'une détection précoce pour limiter la dégradation du bien-être animal et les impacts de production. Les ressources vétérinaires de référence et les guides techniques convergent sur deux idées : une surveillance régulière est indispensable, et la prise en charge doit être structurée et rapide selon la sévérité du cas (Merck Veterinary Manual, 2024b; DairyNZ, 2025b).

La détection précoce (score locomoteur 2 sur une échelle de 1 à 5) ouvre la voie au traitement des cas avant qu'ils ne deviennent chroniques. Les études montrent qu'un retard de traitement de quelques jours peut multiplier la durée de récupération et le coût associé (Green *et al.*, 2002). Des travaux récents utilisant des capteurs automatisés portés (podomètres et accéléromètres fixés à la patte ou au collier) confirment que les systèmes d'alerte précoce peuvent identifier des changements comportementaux deux à quatre jours avant la détection visuelle par l'éleveur (Chapinal *et al.*, 2010; Pastell *et al.*, 2009). En pratique, les éleveurs détectent souvent la boiterie à un stade avancé (score 3 ou plus), lorsque les signes sont visibles à l'œil nu mais que le pronostic est déjà moins favorable.

Des revues de synthèse en élevage de précision montrent aussi que la boiterie fait partie des cas d'usage les plus importants, mais également des plus difficiles à stabiliser, car les signaux disponibles restent indirects, multifactoriels et fortement dépendants du contexte d'élevage (Palma *et al.*, 2025; Michelena *et al.*, 2025).

1.2 Approches conventionnelles : observation et notation locomotrice

Les approches conventionnelles reposent principalement sur l'observation humaine et les grilles de notation locomotrice. La grille proposée par Sprecher *et al.* (1997) reste l'une des plus utilisées en pratique. Elle attribue un score de 1 (*normal*) à 5 (*sévèrement boiteux*) en se basant sur la posture du dos et la démarche (Flower *et al.*, 2006). La fiche opérationnelle de l'AHDB propose une grille complémentaire adaptée au contexte britannique et associe le score 2 à une intervention rapide, généralement dans les 48 heures (AHDB, 2025a).

Les approches conventionnelles restent pertinentes en élevage car elles sont simples à déployer et directement interprétables par les équipes terrain. Elles présentent toutefois plusieurs limites opérationnelles. La première tient à la subjectivité inter-observateurs : même avec des grilles standardisées, la concordance entre évaluateurs peut varier significativement (Flower et Weary, 2006; Schlageter-Tello *et al.*, 2014). La

deuxième concerne le temps requis : dans les grands troupeaux, l'observation systématique de chaque animal à chaque traite est difficile à maintenir. Enfin, les boiteries légères (score 2) sont souvent sous-détectées par l'observation visuelle, alors qu'elles représentent le stade où l'intervention est la plus efficace.

Pour dépasser ces limites, le recours à des signaux capteurs vient compléter la surveillance humaine, sans la remplacer.

1.2.1 Lecture opérationnelle du score locomoteur

Au-delà de sa fonction descriptive, l'évaluation locomotrice est aussi un outil de priorisation de l'intervention. En pratique, la zone la plus critique est le passage du score 1 (*normal*) au score 2 (*boiterie légère*) : c'est à ce stade que les signes deviennent suffisamment perceptibles pour justifier une action, tout en restant assez précoces pour espérer limiter l'installation d'une boiterie chronique. Cette logique explique pourquoi de nombreux systèmes automatisés ne cherchent pas directement à reproduire l'intégralité d'une note clinique, mais plutôt à signaler une *boiterie probable* suffisamment tôt pour déclencher une vérification sur le terrain.

La Figure 1.2 synthétise la lecture opérationnelle du score locomoteur : le passage vers le score 2 constitue la zone d'intérêt pour une alerte précoce, car il marque l'entrée dans une situation où l'observation humaine ou l'examen du pied devient prioritaire.




Figure 1.2 Seuil opérationnel du score locomoteur pour la détection précoce.

Le Tableau 1.2 précise la lecture clinique simplifiée et l'action associée à chaque score, d'après la grille de Sprecher *et al.* (1997) et les recommandations AHDB (AHDB, 2025b).

Tableau 1.2 Lecture clinique et opérationnelle simplifiée du score locomoteur.

Score	Lecture clinique simplifiée	Lecture opérationnelle
1	Dos plat en station et en marche.	Surveillance usuelle.
2	Dos plat à l'arrêt, légèrement arqué en marche.	Intervention rapide : zone clé pour la détection précoce.
3	Dos arqué en permanence.	Vérification prioritaire.
4	Atteinte locomotrice visible.	Prise en charge urgente.
5	Appui très limité.	Prise en charge immédiate.

La lecture par seuil transforme la notation locomotrice en problème d'alerte : il ne s'agit plus seulement de décrire une boiterie, mais de repérer l'entrée dans une zone d'intervention. Ce déplacement justifie le recours à des signaux capteurs et à des méthodes d'apprentissage capables de suivre les changements comportementaux dans le temps.

1.3 Approches basées sur des capteurs et apprentissage

Les approches basées sur des capteurs visent à détecter des déviations comportementales (activité, transitions, dynamique de mouvement) compatibles avec une boiterie probable. La littérature distingue trois familles principales : l'analyse de la démarche par vision par ordinateur (Van Hertem *et al.*, 2014; Lavrova *et al.*, 2023), la classification de comportements par accélérométrie (O'Leary *et al.*, 2020; Alsaad *et al.*, 2019; Ballasso *et al.*, 2023) et la détection d'anomalies sur des indicateurs dérivés (Qiao *et al.*, 2021; González-García *et al.*, 2023; Chandola *et al.*, 2009). Les revues récentes confirment la prédominance des approches supervisées, tout en soulignant le manque d'études non supervisées en conditions réelles d'élevage (Qiao *et al.*, 2021; González-García *et al.*, 2023).

La diversité de ces approches peut être organisée selon trois dimensions complémentaires : *la source de données*, *la stratégie analytique* et *la nature de la sortie*. Une telle lecture est importante, car elle évite de comparer directement des travaux qui ne visent pas le même objectif. Un modèle supervisé de classification binaire à partir d'images et un système d'alerte basé sur des capteurs d'activité n'ont ni les mêmes contraintes de données, ni le même niveau d'interprétabilité, ni le même usage en ferme.

La Figure 1.3 synthétise cette organisation en trois axes : la source de données (de l'observation visuelle aux

accéléromètres portés), la stratégie analytique (règles et seuils, modèles supervisés, détection d'anomalies non supervisée, approches hybrides) et la sortie opérationnelle (du score locomoteur à l'alerte actionnable). Le présent travail se positionne dans la branche non supervisée et hybride, encadrée en vert sur la figure.




Figure 1.3 Taxonomie simplifiée des approches de détection automatisée de boiterie.

Du point de vue de la stratégie analytique, les méthodes de détection se déclinent classiquement en deux familles :

- (a) *Modèles supervisés* : lorsque des labels fiables et suffisamment représentatifs sont disponibles. Ces approches peuvent atteindre de bonnes performances de classification (Van Hertem *et al.*, 2014; Viazzi *et al.*, 2013; Blackie *et al.*, 2011), mais leur dépendance aux labels limite leur déployabilité dans des contextes où l'étiquetage est incomplet ou incertain ;
- (b) *Détection d'anomalies et règles expertes* : lorsque les labels sont partiels ou absents. Ces approches ne nécessitent pas d'exemples positifs pour l'entraînement et sont donc mieux adaptées aux situations réelles où la boiterie n'est pas systématiquement diagnostiquée et enregistrée.

Dans un contexte applicatif réel, la supervision exhaustive est rarement disponible. Cette contrainte favorise les architectures hybrides combinant score algorithmique et règles métier interprétables (Chandola *et al.*, 2009; Palma *et al.*, 2025). Une telle orientation rejoint des travaux récents de comparaison d'algorithmes non supervisés sur données bovines, qui montrent que le choix de l'algorithme dépend du compromis visé entre sensibilité, stabilité et volume de faux positifs, plutôt que d'une supériorité universelle d'une méthode unique (Michelena, 2025).

1.3.1 Isolation Forest

L'algorithme Isolation Forest (IF), proposé par Liu et al. (Liu et al., 2008), repose sur le principe que les anomalies sont plus faciles à isoler que les points normaux dans un espace de *features*. Sa complexité quasi-linéaire en $O(n \log n)$ ¹ le rend particulièrement adapté aux applications où le volume de données croît avec la taille du troupeau. IF est largement utilisé dans les applications de détection d'anomalies en série temporelle, et son implémentation dans scikit-learn (bibliothèque Python de référence pour l'apprentissage automatique) (Pedregosa et al., 2011) en fait un choix pratique pour les systèmes de production.

La Figure 1.4 illustre le principe fondamental d'IF : une anomalie (point rouge) est isolée en seulement deux coupures aléatoires, tandis que les points normaux (cluster bleu) nécessitent de nombreuses partitions supplémentaires. Le score d'anomalie est inversement proportionnel au nombre de coupures.




Figure 1.4 Principe d'isolation des anomalies dans Isolation Forest.

1.3.2 Local Outlier Factor

Le Local Outlier Factor (LOF), proposé par Breunig et al. (Breunig et al., 2000), adopte une approche différente en estimant la densité locale de chaque point par rapport à ses voisins. Contrairement à IF qui mesure l'isolabilité globale, LOF détecte les anomalies locales, c'est-à-dire les points qui sont significativement moins denses que leur voisinage. Sa complexité en $O(n^2)$ dans le cas général le rend moins apte au passage à l'échelle, mais il peut capturer des structures que les méthodes globales manquent. Des travaux

1. La notation $O(\cdot)$ (dite « grand O ») décrit la façon dont le coût de calcul croît avec le nombre d'observations n : $O(n \log n)$ correspond à un coût quasi proportionnel à n , alors que $O(n^2)$ croît comme le carré de n et devient rapidement prohibitif pour de grands volumes de données.

récents sur données bovines confirment que LOF présente une sensibilité accrue aux anomalies de densité locale, ce qui peut être avantageux pour les perturbations comportementales subtiles (Michelena, 2025).

1.3.3 Comparaison synthétique IF et LOF

Le Tableau 1.3 synthétise les différences fondamentales entre les deux détecteurs utilisés dans ce projet.

Tableau 1.3 Comparaison des propriétés d'Isolation Forest et de Local Outlier Factor.

Propriété	Isolation Forest	Local Outlier Factor
Principe	Isolabilité par partitions	Densité locale relative
Type d'anomalie ciblée	Globale (isolée dans l'espace)	Locale (faible densité relative)
Complexité entraînement	$O(n \log n)$	$O(n^2)$ (cas général)
Complexité prédiction	$O(n)$	$O(n \cdot k)$
Sensibilité aux cas faibles	Modérée	Élevée
Robustesse bruit ambiant	Élevée	Modérée
Paramètres critiques	<code>contamination</code> , <code>n_estimators</code>	<code>n_neighbors</code> , <code>contamination</code>
Scalabilité troupeau	Compatible (>200 vaches)	Limitée (<50 vaches)

La comparaison éclaire le choix d'IF comme détecteur principal dans ce projet, car sa complexité quasi-linéaire et sa robustesse au bruit ambiant en font un candidat naturel pour un déploiement sur des troupeaux de taille variable. LOF est néanmoins conservé comme point de comparaison dans l'étude d'ablation (Chapitre 4), où sa sensibilité accrue aux cas faibles pourrait se révéler avantageuse sur certains profils d'injection.

1.3.4 Comparaison systématique des méthodes de détection d'anomalies

Au-delà de la comparaison binaire entre Isolation Forest et LOF, il est utile de situer ces deux algorithmes dans le paysage plus large des méthodes de détection d'anomalies et de classification applicables au domaine. Le Tableau 1.4 propose une comparaison systématique de dix approches, couvrant des méthodes non supervisées, supervisées et semi-supervisées. Les critères y sont évalués pour un déploiement en élevage de précision ; les notations sont les suivantes : n nombre d'observations, d nombre de *features*, h nombre

de neurones cachés, k nombre de voisins. Cette mise en perspective permet de justifier de manière plus rigoureuse le choix de l'algorithme principal retenu dans ce mémoire.

Les critères retenus pour la comparaison sont les suivants :

- la complexité algorithmique (notation O) ;
- le caractère supervisé ou non ;
- le niveau d'interprétabilité de la sortie ;
- la capacité native de gestion de données multimodales, c'est-à-dire des *features* de natures hétérogènes ;
- une référence fondatrice pour chaque méthode.

Une revue comparative récente de Goldstein et Uchida (2016) sur données multivariées confirme que le choix d'un détecteur d'anomalies dépend fortement du compromis entre scalabilité, robustesse au bruit et type de structure recherchée.

Tableau 1.4 Comparaison systématique de dix méthodes de détection d'anomalies et de classification.

Méthode	Compl.	Supervisé	Interprétable	Multimodal	Réf. clé
Isolation Forest	$O(n \log n)$	Non	Partiel	Oui	Liu <i>et al.</i> (2008)
Local Outlier Factor	$O(n^2)$	Non	Partiel	Oui	Breunig <i>et al.</i> (2000)
One-Class SVM	$O(n^2 - n^3)$	Non	Non	Oui	Schölkopf <i>et al.</i> (2001)
Autoencoder	$O(n \cdot d \cdot h)$	Non	Non	Oui	Sakurada et Yairi (2014)
DBSCAN	$O(n \log n)$	Non	Partiel	Oui	Ester <i>et al.</i> (1996)
k -NN anomaly	$O(n^2)$	Non	Oui	Non	Ramaswamy <i>et al.</i> (2000)
Random Forest (supervisé)	$O(n \log n)$	Oui	Oui	Oui	Breiman (2001)
Régression logistique	$O(n \cdot d)$	Oui	Oui	Oui	Cox (1958)
LSTM / RNN	$O(n \cdot h^2)$	Oui	Non	Oui	Hochreiter et Schmidhuber (1997)
Elliptic Envelope	$O(n \cdot d^2)$	Non	Oui	Oui	Rousseeuw et Van Driessen (1999)

Les autres méthodes du tableau se répartissent en familles complémentaires. Les approches par densité (DBSCAN, LOF) repèrent les points situés dans des zones peu denses de l'espace ; les méthodes à frontière (One-Class SVM, Elliptic Envelope) apprennent une enveloppe du comportement normal et signalent ce

qui en sort ; les approches neuronales (Autoencoder, LSTM) modélisent la normalité par reconstruction et détectent les écarts de reconstruction ; les méthodes par distance (k -NN) mesurent l'éloignement aux plus proches voisins ; enfin, les modèles supervisés (Random Forest, régression logistique) exigent des labels d'entraînement. Isolation Forest se distingue de l'ensemble par son principe d'isolation directe des anomalies, sans hypothèse préalable de densité ni de distance.

Plusieurs constats se dégagent de cette comparaison. Parmi les méthodes non supervisées, seuls Isolation Forest et DBSCAN offrent une complexité quasi-linéaire en $O(n \log n)$, ce qui les rend compatibles avec un passage à l'échelle sur des troupes de grande taille. Les approches supervisées (Random Forest, régression logistique, LSTM) peuvent atteindre de bonnes performances de classification, mais elles nécessitent des labels fiables et suffisamment représentatifs, une condition rarement satisfaite dans les contextes d'élevage réel (Alsaad *et al.*, 2019; O'Leary *et al.*, 2020).

Le choix d'Isolation Forest comme détecteur principal dans ce mémoire repose sur la convergence de cinq arguments :

1. *Fonctionnement non supervisé* : IF ne nécessite pas de labels positifs (cas de boiterie confirmés) pour l'entraînement, ce qui le rend directement applicable dans des contextes où le diagnostic clinique n'est pas systématiquement enregistré ;
2. *Scalabilité* : sa complexité en $O(n \log n)$ permet de traiter des volumes de données croissants sans dégradation significative du temps de calcul, contrairement aux approches en $O(n^2)$ comme LOF ou k -NN ;
3. *Interprétabilité partielle* : le score d'anomalie produit par IF est directement exploitable comme indicateur de sévérité et peut être combiné avec des seuils métier pour produire des alertes graduées et compréhensibles ;
4. *Performances établies sur données tabulaires* : la littérature démontre l'efficacité d'IF sur des jeux de données tabulaires multivariés, un profil cohérent avec les *features* agrégées extraites de capteurs comportementaux (Liu *et al.*, 2012; Goldstein et Uchida, 2016) ;
5. *Support natif dans scikit-learn* : l'implémentation de référence dans scikit-learn (Pedregosa *et al.*, 2011) garantit une intégration directe dans un pipeline Python de production, sans dépendance à des frameworks spécialisés.

1.3.5 Protocole de sélection des études

La présente revue couvre les travaux portant sur la détection automatisée de boiterie bovine par capteurs, publiés entre 1990 et 2025. La sélection a été conduite par consultation des bases Google Scholar, Web of Science et PubMed, avec les termes clés *dairy cattle lameness detection*, *bovine lameness accelerometer*, *anomaly detection livestock* et leurs équivalents francophones.

Critères d'inclusion :

- Études portant sur la détection ou la prédiction de la boiterie chez les bovins laitiers, y compris les revues de littérature qui synthétisent des données empiriques ;
- Utilisant des données de capteurs comportementaux (accéléromètres, podomètres, tapis de pesée, systèmes de traite automatisés) ou de vision par ordinateur ;
- Rapportant au moins un indicateur de performance quantitatif (sensibilité, spécificité, AUC, taux de faux positifs) ou présentant une comparaison systématique de méthodes ;
- Publiées en anglais ou en français, dans des revues à comité de lecture ou des actes de conférences indexées.

Critères d'exclusion :

- Études portant exclusivement sur des espèces autres que les bovins laitiers ;
- Articles sans validation empirique (éditoriaux, perspectives théoriques sans données) ;
- Travaux consacrés uniquement à l'étiologie, au traitement ou à la chirurgie podologique, sans composante de détection automatisée.

Les études retenues pour la synthèse quantitative (Tableau 1.8) ont été sélectionnées pour leur représentativité des grandes familles d'approches identifiées dans la taxonomie (Figure 1.3). Le présent mémoire se situe dans la branche capteurs comportementaux → détection d'anomalies → règles métier → alerte actionnable. La revue ne prétend pas à l'exhaustivité d'une méta-analyse systématique : elle vise à couvrir les travaux qui ont le plus directement influencé les décisions méthodologiques du présent projet, et à mettre en évidence la variabilité des protocoles qui complique les comparaisons directes de performance.

1.3.6 Travaux représentatifs et implications pour ce mémoire

Le Tableau 1.5 résume quelques travaux représentatifs couvrant des angles différents de la détection de boiterie : revues méthodologiques, études multi-fermes, apprentissage profond sur signaux accélérométriques

et comparaisons d’algorithmes non supervisés. L’objectif n’est pas de dresser un inventaire exhaustif, mais de mettre en évidence les lignes de force qui ont orienté les choix méthodologiques de ce mémoire.

Tableau 1.5 Synthèse de travaux représentatifs sur la détection automatisée de boiterie bovine.

Travail	Données	Approche	Apport principal	Leçon pour ce mémoire
O’Leary <i>et al.</i> (2020)	Revue d’accélérométrie	Revue ciblée	Accéléromètres utiles, mais protocoles très variables	Documenter capteurs, labels et métriques
Alsaad <i>et al.</i> (2019)	Revue de systèmes automatiques	Revue de littérature	Pas d’alerte précoce validée de bout en bout	Viser un système complet, pas un modèle isolé
Lavrova <i>et al.</i> (2023)	Six fermes ; activité, couchage, production	Modèle logistique à effets mixtes	Sensibilité accrue en combinant comportement et contexte	Privilégier des <i>features</i> agrégées hétérogènes
Balasso <i>et al.</i> (2023)	Accéléromètres tri-axiaux	Apprentissage profond	Capte des motifs comportementaux complexes	Plus de signal demande plus de labels et de calibration
Michelena (2025)	Données capteurs bovines	Comparaison non supervisée	Aucun algorithme universellement dominant	Évaluer le compromis sensibilité/stabilité/bruit
Palma <i>et al.</i> (2025)	Revue IA, élevage de précision	Scoping review	Difficultés de déploiement, transfert et adoption	Sortie interprétable et traçable pour le terrain

Deux enseignements structurent particulièrement ce mémoire. D’une part, la qualité du système ne peut pas être réduite à une seule métrique de détection : un outil utile en ferme doit concilier sensibilité, robustesse au bruit et lisibilité des alertes. D’autre part, la valeur scientifique ne réside pas uniquement dans le choix d’un algorithme, mais aussi dans la capacité à documenter un protocole reproductible, ses hypothèses et ses limites.

Avant de fixer définitivement le positionnement du mémoire, une dernière famille d'approches mérite d'être située, à savoir l'apprentissage profond, dont l'essor récent en élevage de précision soulève la question de sa pertinence face aux méthodes classiques pour la détection de boiterie.

1.3.7 Apprentissage profond versus approches classiques

L'émergence des réseaux de neurones profonds a renouvelé l'intérêt pour la détection automatisée de boiterie, notamment via les architectures convolutives (CNN) et récurrentes (LSTM) appliquées à des signaux accélérométriques bruts (Balasso *et al.*, 2023; Qiao *et al.*, 2021). Le Tableau 1.6 compare les deux familles d'approches sur les dimensions pertinentes pour un déploiement en élevage, en évaluant les critères dans le contexte d'un déploiement opérationnel avec labels partiels.

Tableau 1.6 Comparaison des approches d'apprentissage profond et classiques pour la détection de boiterie bovine.

Critère	Deep Learning (CNN/LSTM)	Classique (IF, LOF, seuils)
Besoin en labels	Élevé (milliers d'exemples étiquetés)	Faible à nul (aucun label positif requis)
Interprétabilité	Limitée (<i>features</i> apprises peu lisibles)	Élevée (z-scores, seuils, règles explicites)
Volume de données	Important (milliers de séquences par classe)	Modeste (centaines de bins par vache)
Complexité de déploiement	GPU et frameworks lourds (TensorFlow, PyTorch)	CPU et bibliothèques légères (scikit-learn)
Performances publiées	Se 80–92% avec labels (Balasso <i>et al.</i> , 2023)	Se 76–91% selon les études (Alsaad <i>et al.</i> , 2012; Chapinal <i>et al.</i> , 2010)
Adaptabilité inter-fermes	Ré-entraînement ou transfert requis	Adaptation native (modèle par vache)

Dans le contexte de ce mémoire, trois arguments justifient le choix d'une approche classique plutôt que profonde :

1. *Absence de supervision* : le corpus ne contient pas d'évaluation locomotrice synchronisée, ce qui exclut les approches supervisées standard. Les travaux de Beer *et al.* (2016) et Thorup *et al.* (2015) montrent que même les approches classiques supervisées nécessitent des campagnes de notation dédiées ;
2. *Exigence d'interprétabilité* : le système doit produire des alertes compréhensibles par les éleveurs, avec des raisons explicites (z-scores, persistance, cohérence multi-signaux). Les réseaux profonds, même performants, ne fournissent pas nativement ce niveau d'explicabilité (Rutten *et al.*, 2013) ;
3. *Contrainte de corpus* : avec 28 vaches sur 6 semaines, le volume de données est insuffisant pour entraîner un réseau profond sans surapprentissage. Les détecteurs d'anomalies comme IF fonctionnent avec des échantillons bien plus modestes (Liu *et al.*, 2008).

Privilégier les méthodes classiques ne signifie pas que l'apprentissage profond soit inadapté à la détection de boiterie en général. Les travaux de Balasso *et al.* (2023) et de Qiao *et al.* (2021) démontrent le potentiel de ces méthodes lorsque les conditions sont réunies (labels, volume, GPU). Cependant, dans le contexte opérationnel de ce mémoire, l'approche classique hybride est plus pragmatique et défendable.

1.4 Technologies capteurs pour la détection de boiterie

Avant d'aborder l'hétérogénéité des protocoles, cette section poursuit un double objectif : situer d'abord brièvement les grandes familles de capteurs disponibles pour la détection de boiterie, puis décrire le capteur effectivement retenu dans ce projet (IceQube) ainsi que les variables comportementales qu'il produit. Les systèmes de surveillance comportementale reposent sur plusieurs familles de capteurs, dont les caractéristiques conditionnent directement les variables disponibles et les performances atteignables.

Le Tableau 1.7 présente les principales technologies et leurs caractéristiques opérationnelles. On distingue trois grandes familles : les capteurs portés par l'animal, tels que les accéléromètres, les podomètres et les colliers ; les capteurs intégrés à l'infrastructure, comme les tapis de pesée et les systèmes de traite ; et les systèmes sans contact, comme les caméras et la vision par ordinateur. Les accéléromètres portés constituent la technologie la plus étudiée dans la littérature récente (O'Leary *et al.*, 2020; Alsaad *et al.*, 2019).

Tableau 1.7 Technologies capteurs utilisées dans la détection de boiterie bovine.

Technologie	Variables mesurées	Avantages	Limites	Études repr.
Accéléromètre (patte/collier)	Activité, pas, transitions couché/debout, durée couchage	Continu, individuel, coût modéré	Dérive, position variable	Alsaad et al. (2012); Balasso et al. (2023)
Podomètre	Nombre de pas, distance parcourue	Simple, robuste	Signal limité, faible résolution	Flower et Weary (2006); Mazrier et al. (2006)
Tapis de pesée	Distribution du poids entre les pieds	Objectif, quantitatif	Infrastructure fixe, coût élevé	Alsaad et al. (2012); Hempel et al. (2019)
Vision par ordinateur	Posture, arc du dos, démarche	Sans contact, riche en information	Sensible aux conditions, calibration	Qiao et al. (2021)
Système de traite automatisé	Production laitière, conductivité, fréquentation	Déjà installé, données continues	Signal indirect pour la boiterie	Lavrova et al. (2023); Van Hertem et al. (2013)

Dans le cadre de ce mémoire, les données proviennent de capteurs IceQube (IceRobotics Ltd, Édimbourg, Royaume-Uni), des accéléromètres tri-axiaux conçus spécifiquement pour le suivi comportemental des vaches laitières. La Figure 1.5 montre la représentation schématique du capteur IceQube, dont le boîtier étanche contient l'accéléromètre tri-axial et se fixe à la patte par un bracelet en plastique muni d'une boucle et de trous d'ajustement. La Figure 1.6 illustre son positionnement sur le métatarse de la patte arrière; les axes x , y , z de l'accéléromètre permettent de distinguer la position debout (patte verticale, $\vec{g}$ aligné avec z) de la position couchée (patte horizontale).




Figure 1.5 Représentation schématique du capteur IceQube.




Figure 1.6 Positionnement du capteur IceQube sur la patte arrière.

Le capteur se fixe à la patte arrière de l'animal (métatarse) par un bracelet à boucle, sans gêner la locomotion ni le couchage. L'accéléromètre interne mesure en continu l'accélération sur trois axes. La composante gravitationnelle permet de distinguer la position couchée (patte horizontale) de la position debout (patte verticale), tandis que les variations dynamiques d'accélération quantifient l'activité locomotrice. Un algorithme embarqué agrège ces mesures brutes en intervalles configurables (dans ce projet, des bins de 15 minutes), un choix validé par Ledgerwood *et al.* (2010) comme offrant un bon compromis entre résolution temporelle et stabilité des mesures de couchage. La fiabilité de cette approche est documentée par plusieurs études indépendantes : Alsaad *et al.* (2012) rapportent une forte concordance entre les mesures d'accéléromètres de patte et l'observation directe pour la classification couché/debout, tandis que Blackie *et al.* (2011) confirment la fiabilité des accéléromètres pour le suivi longitudinal de l'activité.

Chaque bin de 15 minutes génère sept colonnes de données, dont cinq sont utilisées dans le pipeline :

- *Steps* : nombre de pas détectés par l'accéléromètre ;

- *Motion Index* : indice synthétique d'activité locomotrice (unité propriétaire IceRobotics, dérivée des variations d'accélération);
- *Lying Time* : durée cumulée en position couchée (en minutes, bornée à 15);
- *Standing Time* : durée cumulée en position debout (en minutes, bornée à 15);
- *Transitions* : nombre total de changements de posture couché↔debout.

Les colonnes supplémentaires (*Transitions Up* et *Transitions Down*) détaillent la direction des transitions mais ne sont pas exploitées directement par le pipeline, qui utilise leur somme.

Les données agrégées sont stockées dans la mémoire interne du capteur, puis récupérées périodiquement. Elles sont accessibles via la plateforme web CowAlert (IceRobotics), qui offre une interface de visualisation en ligne, et peuvent être exportées au format tabulaire (CSV), directement exploitable par le pipeline de traitement décrit dans ce mémoire.

Le modèle IceTag, prédécesseur de l'IceQube, fournit des variables similaires (pas, temps couché, transitions). Les deux modèles sont largement utilisés dans la recherche sur la boiterie bovine (Beer *et al.*, 2016; Alsaad *et al.*, 2012). Le choix de l'IceQube dans ce projet s'inscrit dans la tendance dominante de la littérature, où les accéléromètres de patte représentent la technologie la plus étudiée pour la détection automatisée de boiterie (O'Leary *et al.*, 2020; Bewley et Schutz, 2008).

Ito *et al.* (2010) montrent que les vaches boiteuses modifient significativement leur comportement de couchage (durée allongée, fréquence de transitions réduite), ce qui justifie l'inclusion de ces variables dans le pipeline. Nechanitzky *et al.* (2016) confirment que les changements comportementaux précèdent souvent les signes cliniques visibles, renforçant l'intérêt d'une détection précoce par capteurs.

1.5 Hétérogénéité des protocoles : un obstacle à la comparaison

Les revues spécialisées sur la détection automatisée de boiterie convergent vers une limite récurrente : l'hétérogénéité des protocoles. Le type de capteur, sa position sur l'animal, la définition opérationnelle de la boiterie, la taille des cohortes et l'horizon d'évaluation varient fortement d'une étude à l'autre, ce qui complique la comparaison directe des performances publiées, comme le soulignent les travaux de O'Leary *et al.* (2020) et de Alsaad *et al.* (2019).

Le Tableau 1.8 présente une synthèse quantitative de seize travaux représentatifs couvrant la période 1997–

2026 (Se = sensibilité, Sp = spécificité ; « — » indique une étude descriptive sans métrique de classification, « n.d. » une valeur non disponible dans l'article). Les sensibilités publiées varient de 22% à 91%, reflétant l'hétérogénéité des capteurs, des populations et des définitions de cas. Cette dispersion illustre l'impossibilité de comparer directement les performances sans tenir compte du protocole de validation, un point développé dans la section suivante.

Tableau 1.8: Synthèse quantitative de travaux représentatifs sur la détection automatisée de boiterie bovine.

Étude	Capteur	Méthode	<i>n</i>	Se (%)	Sp (%)	Validation
Sprecher et al. (1997)	Observation	Notation locomotrice	—	—	—	Conceptuelle
Flower & Weary (2006)	Observation	Analyse comportementale	40	—	—	Descriptive
Chapinal et al. (2010)	Accél. patte	Régression logistique	48	76	83	1 ferme
Alsaad et al. (2012)	Pédomètre	Seuils sur activité	36	76-91	75-88	1 ferme
Van Hertem et al. (2014)	Traite autom.	SVM + activité	—	n.d.	n.d.	Terrain
Thorup et al. (2015)	Accél. patte (IceTag)	Modèle linéaire mixte	4 fermes	86	89	Multi-fermes
Beer et al. (2016)	Accél. patte (IceTag)	Régression + seuils	150	81	87	Multi-fermes
Nechanitzky et al. (2016)	Accél. patte	Analyse de variance	~50	—	—	Descriptive
Hempel et al. (2019)	Tapis de pesée	RF / ANN	~50	n.d.	n.d.	Terrain
O'Leary et al. (2020)	Accél. (multi)	Revue de 15 études	>400	22-91	56-95	Revue
Qiao et al. (2021)	Vision / multi	Revue	>500	Var.	Var.	Revue
González-García et al. (2023)	Multi-sources	Revue systématique	>1000	Var.	Var.	Revue syst.
Lavrova et al. (2023)	Collier + traite	Logistique mixte	400+	77	82	6 fermes

Tableau 1.8 (suite)

Étude	Capteur	Méthode	<i>n</i>	Se (%)	Sp (%)	Validation
Balasso et al. (2023)	Accél. tri-axial	Apprentissage profond	120	85	79	Multi-fermes
Michelena et al. (2025)	Capteurs dérivés	Comparaison non supervisée	50+	Var.	Var.	Comparaison
Ce mémoire (2026)	IceQube (patte)	IF + règles métier	28	90-100 ^a	n.d.	Synthétique

^aSur cas forts injectés ; validation synthétique, non clinique (voir Chapitre 4). Van Hertem et al. (Van Hertem et al., 2013) et Hempel et al. (Hempel et al., 2019) rapportent principalement des corrélations avec scores de locomotion plutôt que des métriques Se/Sp directes.

La revue d'O'Leary et al. (O'Leary et al., 2020) sur les accéléromètres pour la détection de boiterie confirme cette dispersion et souligne l'absence de standardisation dans les protocoles d'évaluation. Alsaad et al. (Alsaad et al., 2019) soulignent en particulier l'absence de véritables études de longue durée ayant abouti à un système d'alerte précoce valide de bout en bout.

Des travaux plus récents confirment l'intérêt des accéléromètres à l'échelle multi-fermes, mais montrent aussi que les variables utiles mélangent activité, couchage, production et facteurs individuels plutôt qu'un unique signal universel. Dans une étude longitudinale sur six fermes allemandes, Lavrova et al. (Lavrova et al., 2023) obtiennent une sensibilité d'environ 77% avec un modèle logistique à effets mixtes, en combinant données d'activité, durée des épisodes de couchage, production laitière et contexte animal.

Enfin, la qualité de la mesure amont reste déterminante : l'échantillonnage, l'édition des épisodes et la représentation des comportements influencent directement la fiabilité des variables dérivées (Ledgerwood et al., 2010; Balasso et al., 2023).

Concrètement, l'hétérogénéité des protocoles se manifeste sur au moins cinq dimensions :

1. *Définition du cas* : classe clinique, score locomoteur seuil ou probabilité de boiterie selon les études, d'où des phénomènes mesurés et des sensibilités difficilement comparables ;
2. *Instrumentation* : position du capteur (patte (Alsaad et al., 2012; Thorup et al., 2015), collier (Blackie

et al., 2011), corps entier (Viazzi et al., 2013)), fréquence d'échantillonnage et signaux contextuels varient, produisant des variables de nature différente ;

3. *Granularité analytique* : prédiction instantanée, journalière, par épisode ou par vache, avec des exigences de précision temporelle très différentes ;
4. *Objectif métier* : classification, détection précoce, filtrage ou score de risque, chaque objectif déplaçant le compromis entre faux positifs et faux négatifs ;
5. *Évaluation* : sensibilité, spécificité, AUC, taux d'alertes, IoU ou robustesse inter-fermes, un même système paraissant excellent ou médiocre selon la métrique.

Autrement dit, deux articles peuvent rapporter une “bonne performance” tout en répondant à des problèmes différents. Cette observation justifie le choix de consacrer un chapitre entier aux protocoles de validation et à leurs artefacts, plutôt que de se limiter à un score unique agrégé.

La Figure 1.7 synthétise deux lacunes structurelles de la littérature : la quasi-totalité des méthodes non supervisées n'a été évaluée que sur une seule ferme, et aucune ne dispose d'une validation synthétique structurée, ce que le présent mémoire vise à combler (cellule verte, en bas à droite).

	Conceptuel	1 ferme	Terrain pratique	Multi-fermes	Revue / Méta	Synthétique
	← Validité externe croissante →					
Seuils / règles	1 étude Sprecher '97 conceptuel	3 études Se ≈ 84 %* Flower et al.			1 étude Se 22-91 % forte dispersion	
Supervisé classique		1 étude Se = 76 % Chapinal '10	2 études van Hertem '14 Hempel '19	3 études Se 77-86 % Thorup et al.	1 étude González '23	
App. profond				1 étude Se = 85 % Balasso '23	1 étude Qiao '21	
Non supervisé	lacune	1 étude Michelena '25	lacune	lacune	lacune	Ce mémoire Se 90-100 % non supervisé

Se ≥ 90 %

Se 77-89 %

Se < 77 % ou forte dispers.

Se non disponible

Lacune (aucun travail publié)

* Se % disponible pour une partie seulement des études

Figure 1.7 Matrice de couverture des travaux représentatifs en détection de boiterie bovine.

1.6 Synthèse critique

La littérature et les guides pratiques indiquent trois exigences pour une solution déployable de détection de boiterie :

1. *Sensibilité opérationnelle* : détecter les cas plausiblement détectables, en particulier les boiteries modérées à sévères qui nécessitent une intervention ;
2. *Maîtrise des fausses alertes* : limiter les faux positifs et la fatigue d'alerte, qui dégradent rapidement la confiance des utilisateurs dans le système (Rutten *et al.*, 2013) ;
3. *Interprétabilité* : fournir des raisons explicites et actionnables pour chaque alerte, afin de faciliter la prise de décision terrain.

En pratique, les méthodes purement pilotées par les données peuvent manquer d'explicabilité pour l'opérateur, tandis que les approches purement à règles peuvent manquer de flexibilité face à la variabilité inter-animaux. Un compromis robuste consiste à coupler détection d'anomalies et contraintes métier explicites. Ce couplage cumule la capacité de généralisation des algorithmes non supervisés et des gardes-fous interprétables. La littérature récente confirme cette orientation : les systèmes d'élevage de précision les plus prometteurs combinent des signaux hétérogènes avec des logiques de décision interprétables, plutôt que de s'appuyer sur un modèle unique en boîte noire (Palma *et al.*, 2025; Michelena *et al.*, 2025).

L'hétérogénéité des protocoles évoquée à la section précédente a une conséquence directe sur l'évaluation des systèmes : de nombreux travaux comparent des capteurs, des fermes, des labels et des définitions de cas différents, ce qui complique l'appréciation d'une chaîne déployable de bout en bout. Dans ce contexte, il existe une place claire pour des contributions moins théoriques mais plus systémiques : un pipeline reproductible, une validation explicite sur plusieurs niveaux et une traçabilité des artefacts expérimentaux.

La revue de littérature conduit donc à un enseignement central : la difficulté n'est pas seulement de proposer un détecteur performant, mais de construire une chaîne de décision cohérente, reproductible et défendable du point de vue métier. Une telle exigence justifie la structure du présent mémoire, qui traite l'algorithme, les règles métier, l'interface et la validation comme un ensemble cohérent plutôt que comme des blocs séparés.

1.7 Positionnement du mémoire

Le présent mémoire s'inscrit dans le compromis identifié ci-dessus, à savoir le couplage entre détection d'anomalies non supervisée et règles métier interprétables. Sa contribution, orientée ingénierie scientifique, vise à combler le manque identifié dans la littérature en proposant un système validé de bout en bout, assorti d'une traçabilité expérimentale complète. Concrètement, le mémoire livre :

1. un pipeline complet depuis les données capteurs jusqu'aux notifications interprétables, combinant détection d'anomalies par Isolation Forest et règles métier explicites ;
2. une validation à deux niveaux, à savoir une validation manuelle par injections contrôlées, puis une validation robuste multi-configurations sur 9 504 exécutions couvrant 336 configurations ;
3. une étude d'ablation comparant quatre variantes du pipeline, incluant un détecteur alternatif (LOF) ;
4. une traçabilité reproductible assurée par tests automatisés, comparaisons inter-versions et vérification d'intégrité cryptographique.

La portée reste clairement délimitée : la sortie est une *détection de boiterie probable* et non un diagnostic clinique vétérinaire. Cette distinction est fondamentale et cohérente avec les recommandations de la littérature (Alsaad et al., 2019).

Le chapitre suivant détaille donc les données utilisées, les transformations appliquées aux signaux capteurs, le choix des *features* et le protocole expérimental retenu. L'objectif n'est pas seulement de décrire une implémentation, mais de montrer comment la revue précédente se traduit en décisions méthodologiques explicites.

CHAPITRE 2

DONNÉES ET MÉTHODOLOGIE

Ce chapitre présente les fondations empiriques et méthodologiques du système. Il décrit d'abord le corpus de données capteurs sur lequel repose l'ensemble du travail, puis les transformations appliquées aux signaux bruts pour en extraire des variables exploitables, l'architecture du pipeline de détection, et enfin les métriques et protocoles servant à évaluer le système. L'objectif est de rendre explicite chaque choix méthodologique, depuis l'ingestion des données jusqu'aux critères de validation.

2.1 Corpus de données capteurs

Le corpus principal du projet, c'est-à-dire l'ensemble des mesures capteurs exploitées dans ce mémoire, est constitué de données issues de capteurs IceQube (IceRobotics Ltd), collectées à la ferme laitière du campus Macdonald de l'Université McGill (Sainte-Anne-de-Bellevue, Québec). Les capteurs, des accéléromètres tri-axiaux fixés à la patte arrière des animaux (Section 1.4), agrègent leurs mesures par tranches de quinze minutes, un format courant dans les études de suivi bovin (Ledgerwood *et al.*, 2010; Benaissa *et al.*, 2019). Les données brutes sont exportées au format CSV depuis le logiciel du capteur. Elles sont également consultables via la plateforme web CowAlert (IceRobotics), qui fournit une interface de visualisation en ligne des mêmes mesures. La qualité de ces données conditionnant directement la validité des analyses, leur intégrité a fait l'objet de vérifications préliminaires avant toute exploitation.

2.1.1 Vérification de l'intégrité des données

Avant toute analyse, deux vérifications préliminaires ont été conduites afin de s'assurer de la fiabilité du corpus.

Cohérence entre sources. Les données brutes exportées depuis le capteur IceQube ont été comparées à celles affichées sur la plateforme CowAlert. Sur 752 observations appariées (rééchantillonnées à 1 heure), les corrélations obtenues sont quasi parfaites pour les deux variables d'activité principales, le nombre de pas (*Steps*) et l'indice de mouvement (*Motion Index*), toutes deux définies au Tableau 2.3 : $r_{\text{Pearson}} = 1.000$ pour *Steps* et *Motion Index*, $r_{\text{Spearman}} = 1.000$ et 0.999 respectivement. Cette correspondance confirme que CowAlert restitue fidèlement les données brutes du capteur et que les fichiers CSV utilisés dans ce projet reflètent exactement les mesures enregistrées.

Fuseau horaire. Une analyse des horodatages a révélé que les données exportées par le capteur IceQube sont enregistrées en temps universel coordonné (UTC), avec un décalage de -5 heures par rapport à l'heure locale de la ferme (fuseau EST, Montréal). Ainsi, un bin horodaté 12:00 UTC correspond à 07:00 heure locale. Ce décalage n'affecte pas le pipeline de détection, qui opère sur des fenêtres glissantes relatives indépendantes du fuseau, mais il a été pris en compte dans l'interprétation des profils circadiens et des visualisations.

La version de référence contient 37 839 lignes couvrant 28 vaches, sur la période du 1^{er} octobre 2023 au 11 novembre 2023. Les variables comportementales disponibles sont résumées dans le Tableau 2.1.

Tableau 2.1 Description du corpus de données capteurs.

Propriété	Valeur
Nombre de lignes	37 839
Nombre de vaches	28
Période	1 ^{er} oct. – 11 nov. 2023
Intervalle temporel	15 minutes
Lignes médianes par vache	≈ 564
Lignes moyennes par vache	≈ 1350

Le Tableau 2.2 présente les statistiques descriptives des principales variables comportementales, calculées sur l'ensemble du corpus (28 vaches, 37 839 lignes en bins de 15 minutes) après filtrage des bins à couverture insuffisante.

Tableau 2.2 Statistiques descriptives des variables comportementales brutes.

Variable	Médiane	Moy.	Éc.-type	Q1	Q3	Max
<i>Steps</i>	0	4.0	15.4	0	3	387
<i>Motion Index</i>	5.0	25.5	103.7	0.0	19.0	3351
<i>Lying Time</i> (min)	15.0	9.3	6.9	0.0	15.0	15.0
<i>Standing Time</i> (min)	0.0	5.7	6.9	0.0	15.0	15.0
<i>Transitions</i>	0	0.2	0.4	0	0	6

Trois caractéristiques du corpus méritent d’être soulignées. D’abord, les distributions sont fortement asymétriques : les médianes de *Steps* et *Motion Index* sont nettement inférieures aux moyennes, ce qui indique la présence de valeurs extrêmes. Ensuite, la variable *Lying Time* est bornée à 15 minutes (la durée du bin), ce qui crée un effet plafond naturel. Enfin, les transitions posturales sont rares par bin (médiane de 0), ce qui rend cette variable plus informative en agrégation glissante qu’en valeur ponctuelle.

La Figure 2.1 illustre l’asymétrie de la distribution des *Steps* sur l’ensemble du corpus (37 839 bins, médiane = 0, moyenne = 4) : plus de 90 % des bins de 15 minutes comptent moins de 10 pas, l’animal étant le plus souvent au repos sur un intervalle aussi court. Cette non-normalité justifie l’utilisation de statistiques robustes (médiane, MAD) plutôt que de la moyenne et de l’écart-type pour le calcul des z-scores (Leys *et al.*, 2013).




Figure 2.1 Distribution des *Steps* sur l’ensemble du corpus.

La Figure 2.2 illustre la couverture temporelle du corpus par vache, montrant que le volume de données varie fortement selon les animaux. La distribution est nettement bimodale : une partie des vaches dispose d’environ 564 bins (≈ 6 jours), une autre d’environ 2 450 bins (≈ 25 jours), cet écart reflétant des durées de port du capteur différentes plutôt que des trous dans la mesure. La médiane est de 564 bins par vache et la moyenne d’environ 1 350 bins (≈ 14 jours) ; au sein de la fenêtre d’observation propre à chaque animal, la couverture par bin reste quasi complète.




Figure 2.2 Distribution du nombre de bins par vache dans le corpus.

La Figure 2.3 illustre schématiquement le principe de suivi de la couverture par vache et par semaine. Les pourcentages indiquent la proportion de bins valides par semaine; les intensités de couleur reflètent le nombre de bins valides, révélant les périodes de maintenance capteur ou de couverture partielle. Sur le corpus réel, la couverture par bin reste quasi complète à l'intérieur de la fenêtre d'observation propre à chaque vache, de sorte qu'aucune vache n'atteint le seuil de filtrage (`coverage_min_pct = 25%`), ce qui confirme la bonne qualité générale du corpus; les variations de volume entre animaux (Figure 2.2) proviennent surtout de durées de port différentes.

	S1	S2	S3	S4	S5	S6	
V1	95%	92%	88%	90%	85%	78%	Couverture 70% 85% 95%+
V5	98%	97%	95%	96%	94%	92%	
V10	92%	90%	85%	88%	82%	75%	
V15	88%	85%	80%	82%	78%	70%	
V20	96%	94%	92%	93%	90%	88%	
V25	90%	88%	83%	85%	80%	72%	
V28	97%	95%	93%	94%	92%	90%	

Figure 2.3 Illustration schématique du suivi de couverture temporelle hebdomadaire (échantillon de 7 vaches, oct.–nov. 2023).

Chaque ligne associe un identifiant animal, un horodatage de début et de fin d'intervalle, ainsi que sept variables comportementales directement exploitables, présentées dans le Tableau 2.3.

Tableau 2.3 Variables comportementales brutes disponibles dans le corpus.

Variable	Type	Description
<i>Steps</i>	Entier	Nombre de pas cumulés sur l'intervalle
<i>Motion Index</i>	Réel	Indice d'activité motrice global
<i>Lying Time</i>	Réel (min)	Temps passé couché
<i>Standing Time</i>	Réel (min)	Temps passé debout
<i>Transitions</i>	Entier	Changements couché ↔ debout
<i>Transitions Up</i>	Entier	Changements couché → debout
<i>Transitions Down</i>	Entier	Changements debout → couché

Le choix d'utiliser des variables comportementales déjà agrégées est cohérent avec une approche déployable sur capteurs d'élevage. La littérature sur la boiterie montre que les signaux utiles sont fréquemment des descripteurs dérivés de l'activité, du couchage ou des transitions, plutôt qu'un flux inertiel brut seul, car les effets de la boiterie sont souvent indirects et fortement dépendants de l'individu (O'Leary *et al.*, 2020; Alsaad *et al.*, 2012; Lavrova *et al.*, 2023).

Les données capteurs présentent plusieurs contraintes structurelles. D'abord, aucune annotation vétérinaire synchronisée par tranche horaire n'est disponible ; le projet ne peut donc pas être formulé comme une classification supervisée standard. Ensuite, les séries sont hétérogènes entre animaux : certains profils sont plus actifs, plus mobiles ou plus stables que d'autres. Enfin, la couverture capteur n'est pas constante, ce qui impose une gestion explicite des trous et des débuts de série. Ces limites sont cohérentes avec l'état de la littérature en détection automatisée de boiterie bovine (Qiao *et al.*, 2021; Merck Veterinary Manual, 2024a).

2.1.2 Qualité des données et critères de filtrage

La qualité des données capteurs est un facteur déterminant pour la fiabilité du pipeline. Quatre situations de non-qualité ont été identifiées et traitées lors du prétraitement :

1. *Couverture insuffisante* : certaines vaches présentent moins de 200 bins exploitables sur la période, ce qui ne permet pas d'estimer des statistiques de référence fiables. Ces animaux sont donc exclus de

l'analyse. Le seuil de 200 bins (environ 3 jours de données continues) est cohérent avec la nécessité de calculer des z-scores (écarts normalisés par rapport à la médiane robuste de chaque vache) et des moyennes mobiles sur au moins 7 jours glissants ;

2. *Valeurs aberrantes ponctuelles* : des valeurs de *Steps* ou de *Motion Index* ponctuellement très élevées (capteur perturbé, mouvement de manipulation) sont traitées par la normalisation robuste (médiane/IQR) plutôt que par un écrêtage explicite, ce qui évite d'introduire des seuils arbitraires ;
3. *Trous temporels* : les interruptions dans la série temporelle (maintenance capteur, changement de batterie) sont gérées par la logique de fenêtre glissante. Cette logique ne requiert pas de continuité stricte, mais seulement un nombre minimum de bins valides dans chaque fenêtre ;
4. *Homogénéité temporelle* : les bins de 15 minutes fournissent une granularité suffisante pour capturer les variations comportementales liées à la boiterie, tout en restant compatibles avec les fréquences d'échantillonnage standard des capteurs d'élevage (Ledgerwood *et al.*, 2010).

2.1.3 Variabilité inter-individuelle

La variabilité entre animaux est un défi connu dans l'analyse de données capteurs en élevage (O'Leary *et al.*, 2020; Nechanitzky *et al.*, 2016). Les profils d'activité diffèrent considérablement d'une vache à l'autre en raison de facteurs tels que la parité, le stade de lactation, le rang social et le tempérament individuel.

Le Tableau 2.4 illustre cette hétérogénéité sur les principales variables du corpus. Les coefficients de variation (CV) inter-vaches montrent que certaines variables (*Transitions*, *Motion Index*) sont plus dispersées que d'autres (*Lying Time*), ce qui justifie l'approche de modélisation par vache adoptée dans ce pipeline.

Tableau 2.4 Variabilité inter-individuelle des principales variables comportementales.

Variable	Médiane inter-vaches	IQR inter-vaches	CV (%)
<i>Steps</i>	5.0	3.3–6.0	50
<i>Motion Index</i>	27.1	22.2–37.6	40
<i>Lying Time</i> (min)	8.4	7.0–9.5	24
<i>Standing Time</i> (min)	6.6	5.5–8.0	32
<i>Transitions</i>	0.2	0.2–0.2	41

Une telle variabilité motive deux choix méthodologiques fondamentaux. D'abord, l'entraînement du détec-

teur d'anomalies (Isolation Forest) séparément pour chaque vache, afin que le comportement “normal” soit défini relativement à l'individu et non au troupeau. Ensuite, l'utilisation de z-scores calculés par vache pour les règles métier, de sorte qu'un même seuil absolu ait une signification comparable entre animaux aux profils très différents. Ces choix sont détaillés dans les sections suivantes.

2.1.4 Choix de la résolution temporelle

Le choix de la résolution temporelle d'agrégation résulte d'un compromis entre la granularité du signal et sa stabilité. Le Tableau 2.5 compare trois résolutions candidates et leurs implications pour la détection de boiterie.

Tableau 2.5 Comparaison des résolutions temporelles candidates pour l'agrégation capteur.

Résolution	Bins/jour	Avantage	Inconvénient
5 minutes	288	Granularité fine	Bruit élevé, bins vides fréquents
15 minutes	96	Compromis	Retenu
1 heure	24	Signal lissé	Perte de précision temporelle

De cette comparaison, la résolution de 15 minutes ressort comme le meilleur compromis. Elle correspond en outre au pas natif du capteur utilisé dans ce projet et reste cohérente avec les intervalles rapportés dans la littérature sur les capteurs d'activité bovine : Ledgerwood *et al.* (2010) recommandent un intervalle de 1 à 5 minutes pour le comportement de couchage, tandis que Alsaaod *et al.* (2012) utilisent des agrégations horaires pour la détection pédométrique. Notre choix de 15 minutes se situe entre ces deux extrêmes, offrant une granularité suffisante pour capturer les transitions comportementales tout en limitant le bruit des bins à faible couverture.

À cette résolution, chaque vache produit environ 96 bins par jour, soit ≈ 1350 bins sur 14 jours. Ce volume est suffisant pour Isolation Forest, qui nécessite typiquement quelques centaines de points pour estimer des chemins d'isolation fiables (Liu *et al.*, 2008).

2.1.5 Corpus complémentaire : ferme du campus Macdonald (automne 2019)

En complément du corpus principal, un second jeu de données a été collecté à la même exploitation, la ferme laitière du campus Macdonald de l'Université McGill (Sainte-Anne-de-Bellevue, Québec), lors de l'au-

tomne 2019. Ce corpus est constitué de données IceTag (IceRobotics Ltd), prédécesseur de l'IceQube utilisé en 2023, produisant les mêmes variables comportementales dans le même format de 15 minutes.

Tableau 2.6 Description du corpus complémentaire McGill IceTag (automne 2019).

Propriété	Valeur
Nombre de bins (15 min)	93 187
Nombre de vaches	30
Période	11 nov. 2019 – 14 déc. 2019
Durée par vache	34 jours (32 pour 6 vaches)
Bins médians par vache	$\approx 3\,143$
Variables disponibles	Identiques au corpus principal
Vaches avec score SLS	12
Vaches sans score SLS	18
Source des scores SLS	Exercice d'évaluation hiver 2019 (baseline janv., mi-parcours mars 2019)

Labels cliniques (SLS). Les 12 vaches ayant un score de locomotion standardisé (SLS, somme de quatre critères posturaux, échelle 0–8) ont été évaluées en deux temps lors de l'hiver 2019. Le Tableau 2.7 résume la distribution par groupe clinique : $SLS \geq 2$ correspond au seuil d'alerte clinique retenu dans la littérature (Sprecher *et al.*, 1997), et les 18 vaches sans score sont conservées pour l'analyse non supervisée sans utilisation des labels.

Tableau 2.7 Distribution des 30 vaches du corpus McGill par groupe clinique.

Groupe	N	SLS baseline (janv. 2019)	SLS mi-parcours (mars 2019)
Boiteuse persistante	1	≥ 2	≥ 2
Boiteuse aggravée	1	≥ 2	≥ 2 (progression)
Boiteuse améliorée	2	≥ 2	< 2
Légère (SLS = 1)	3	1	0–2
Saine et dégradée	5	0	0–1
<i>Sans score SLS</i>	18	—	—
Total	30		

Rôle dans le projet. Le corpus complémentaire n'est pas utilisé dans la validation principale du pipeline, qui repose sur le corpus IceQube 2023 (Section 2.1, Tableau 2.1). Il constitue un banc de test naturel pour deux questions complémentaires :

1. *Généralisation intra-site* : le pipeline entraîné sur les données 2023 produit-il des alertes cohérentes sur des vaches différentes de la même ferme, avec un capteur de la même famille ?
2. *Concordance avec les labels cliniques* : les vaches classées *boiteuses persistantes* ou *aggravées* génèrent-elles significativement plus d'alertes que les vaches saines ?

Limites de l'alignement temporel. Les scores SLS ont été évalués en janvier et mars 2019, soit 8 à 9 mois avant la collecte des données IceTag (automne 2019). Le statut clinique d'une vache peut évoluer significativement sur cet horizon. Cette désynchronisation est assumée : elle n'invalide pas l'analyse, mais impose de l'interpréter comme une vérification de la cohérence comportementale à long terme plutôt que comme une validation clinique synchrone. La conversion des données brutes en format pipeline est réalisée par le script `convert_mcgill_to_pipeline.py` (dossier `mcgill_iot_cattle/`), qui produit `mcgill_brut.csv` (93 187 lignes) selon le même schéma que `data/brut.csv`.

2.2 Architecture du pipeline

Le pipeline de détection se décompose en quatre étapes séquentielles, illustrées dans la Figure 2.4. Chaque étape est implémentée dans un module logiciel distinct, ce qui permet de les tester et de les faire évoluer indépendamment.




Figure 2.4 Architecture du pipeline de détection de boiterie probable.

Chaque étape transforme progressivement les données. Le chargement et filtrage normalise les formats de fichiers et écarte les bins de couverture insuffisante. L'extraction de *features* convertit les signaux bruts en variables dérivées (z-scores robustes, dérivées temporelles, moyennes mobiles) décrivant chaque vache relativement à son propre comportement. La détection applique un Isolation Forest entraîné par vache et produit un score d'anomalie par bin. Enfin, les règles métier (persistance temporelle, cohérence multi-signaux, *cooldown*) transforment ces anomalies en épisodes de boiterie probable et en notifications. La

suite de cette section détaille le prétraitement et l'extraction des *features*; la détection et les règles métier font l'objet de la section suivante et du Chapitre 3.

Le prétraitement commence par une normalisation des noms de colonnes et des types temporels, afin d'accepter les variantes de fichiers CSV réelles sans modifier le cœur du pipeline. Les données sont ensuite ré-échantillonnées à l'intervalle de référence de 15 minutes, qui correspond au pas temporel natif retenu pour la configuration finale. La construction des variables dérivées vise à fournir à l'algorithme de détection une vue relative du comportement de chaque vache, plutôt qu'une comparaison brute entre animaux. Pour chaque variable brute x , le pipeline produit six familles de *features*, détaillées dans le Tableau 2.8.

Tableau 2.8 Familles de *features* dérivées pour chaque variable comportementale brute.

Suffixe	Description
_rz	Z-score robuste global (MAD (Leys et al., 2013), remplis IQR puis écart-type)
_rrz	Z-score robuste glissant (fenêtre de 24 bins = 6 h)
_d1	Différence première (variation bin à bin)
_d1_per_hour	Vitesse de variation normalisée par heure
_mm7	Moyenne mobile sur 7 bins (≈ 1 h 45)
_vs_mm7	Écart à la moyenne mobile

S'y ajoutent des variables transversales :

- `coverage_pct` : taux de couverture capteur par bin, calculé à partir du nombre de lignes brutes observées rapporté au nombre attendu (médiane robuste);
- `sin_hour`, `cos_hour`, `sin_dow`, `cos_dow` : encodage cyclique de l'heure et du jour de semaine;
- `Motion Index_sum_log`, `Motion Index_mean_log` : transformations logarithmiques du *Motion Index* pour limiter l'effet des valeurs extrêmes.

Au total, les six suffixes appliqués aux 7 variables brutes produisent $7 \times 6 = 42$ *features* dérivées, auxquelles s'ajoutent les 7 variables transversales, soit environ 50 *features* par bin. La Figure 2.5 illustre ce processus de transformation pour une variable brute donnée. Chaque signal est ainsi converti en six indicateurs complémentaires, la procédure étant répétée pour chacune des 7 variables comportementales.




Figure 2.5 Processus d'extraction de *features* pour une variable brute.

L'ingénierie de variables suit une logique pragmatique qui consiste à transformer des signaux capteurs imparfaits en indicateurs comportementaux plus stables. Des travaux méthodologiques sur le couchage montrent par exemple que l'intervalle d'échantillonnage et les règles d'édition modifient déjà la qualité des mesures dérivées (Ledgerwood *et al.*, 2010). À l'inverse, des travaux plus récents sur accélérométrie tri-axiale montrent qu'une modélisation plus riche devient surtout utile lorsqu'on vise une classification fine de comportements plutôt qu'une simple alerte de déviation (Balasso *et al.*, 2023). Dans ce projet, la priorité est la robustesse opérationnelle et l'interprétabilité d'une alerte probable, pas une taxonomie complète des comportements.

L'objectif n'est pas de multiplier artificiellement les variables, mais de capturer trois dimensions complémentaires : le niveau d'activité, la rupture par rapport au comportement habituel, et la structure temporelle locale. Cette représentation est adaptée à une logique de détection d'anomalies intra-animal, plus défendable qu'une comparaison inter-animal brute dans un contexte sans étiquettes cliniques exhaustives.

2.3 Détection et règles métier

Le cœur algorithmique repose sur Isolation Forest (IF), choisi comme détecteur d'anomalies non supervisé adapté à un contexte de labels partiels ou absents (Liu *et al.*, 2008). Le modèle est entraîné individuellement par vache sur une baseline initiale (`baseline_ratio` = 0.6). Le score IF est ensuite filtré par des règles métier (persistance temporelle, cohérence multi-signaux, espacement des notifications) dont le détail algorithmique est présenté au Chapitre 3. La configuration finale figée dans le projet est détaillée dans le Tableau 2.9.

Tableau 2.9 Configuration finale du pipeline, gelée après validation.

Paramètre	Valeur	Rôle
<code>interval</code>	15T	Pas temporel de ré-échantillonnage
<code>contamination</code>	0.06	Fraction d'anomalies attendue par IF
<code>baseline_ratio</code>	0.6	Part de la série utilisée comme baseline
<code>persist_hours</code>	7	Fenêtre de persistance (heures)
<code>alert_min</code>	2	Bins anomaux minimaux par fenêtre
<code>mix_mode</code>	MIX	Mode de cohérence multi-signaux
<code>mix_rate_thr</code>	0.24	Seuil de taux d'anomalies
<code>mi_z_high_thr</code>	2.2	Seuil z-score <i>Motion Index</i>
<code>cooldown_hours</code>	12	Espacement minimal entre notifications
<code>coverage_min_pct</code>	25	Couverture minimale pour bin fiable (%)
<code>random_state</code>	42	Seed pour reproductibilité IF

Les seuils retenus n'ont pas été fixés arbitrairement ; ils résultent d'une exploration progressive des configurations via les validations v4, v5.1 et v5.2 (Chapitre 4), puis d'un gel explicite garantissant la reproductibilité.

La Figure 2.6 illustre le fonctionnement conjoint de la persistance temporelle et du cooldown sur un exemple temporel concret. Les anomalies IF (en rouge) ne déclenchent une notification que si elles sont assez nombreuses dans la fenêtre de persistance (7 h) ; le cooldown de 12 h empêche ensuite les alertes répétitives, si bien que l'anomalie isolée (h15) et le groupe h18-19 (cooldown actif) ne déclenchent rien. Cette mécanique est essentielle pour comprendre pourquoi le pipeline ne réagit pas aux anomalies isolées et pourquoi les notifications sont espacées dans le temps.




Figure 2.6 Mécanisme de persistance et de cooldown.

2.3.1 Normalisation robuste

La normalisation des *features* avant détection utilise le `RobustScaler` de `scikit-learn` (Pedregosa *et al.*, 2011), qui centre les données sur la médiane et les normalise par l'écart interquartile (IQR). Ce choix est motivé par la présence de valeurs extrêmes dans les signaux capteurs (cf. Figure 2.1) : contrairement au `StandardScaler` (moyenne et écart-type), le `RobustScaler` n'est pas influencé par les outliers (Leys *et al.*, 2013), ce qui évite de comprimer artificiellement la distribution des *features* normales. Les quantiles 10–90 sont utilisés plutôt que les quartiles classiques 25–75, afin de capturer une plus grande partie de la distribution tout en restant robuste aux extrêmes.

2.3.2 Stratégie d'entraînement par vache

Le modèle IF est entraîné individuellement pour chaque vache, en utilisant uniquement les 60% premiers bins fiables comme baseline (`baseline_ratio = 0.6`). Cette stratégie présente deux avantages. D'une part, elle capture le comportement normal spécifique de chaque animal, sans dilution par les profils des autres vaches. D'autre part, elle isole la phase d'entraînement de la phase de prédiction : le modèle est calibré sur une période supposée normale, puis appliqué sur le reste de la série. Ce schéma est cohérent avec l'hypothèse que la boiterie est un événement rare et tardif, plutôt qu'un état présent dès le début de l'observation.

Enfin, une variante LOF (Local Outlier Factor) a été évaluée dans l'étude d'ablation comme point de comparaison méthodologique (Breunig *et al.*, 2000). Elle n'est pas la baseline officielle du projet, mais sert à tester la sensibilité des résultats au choix du détecteur d'anomalies.

2.4 Métriques d'évaluation

L'évaluation a été construite pour rester honnête vis-à-vis des données disponibles. Cette prudence est conforme aux recommandations de la littérature en détection automatisée de boiterie, qui souligne les limites des métriques classiques (sensibilité, spécificité) lorsque le gold standard clinique n'est pas disponible (Alsaad *et al.*, 2019; Rutten *et al.*, 2013). En l'absence de ce gold standard, le projet emploie des métriques événementielles et opérationnelles plutôt que des métriques cliniques au sens fort, résumées dans le Tableau 2.10.

Tableau 2.10 Métriques d'évaluation utilisées dans les protocoles de validation.

Métrique	Définition
<code>detected_any_overlap</code>	L'épisode injecté chevauche au moins un épisode prédit (binaire).
<code>detected_iou20</code>	Le chevauchement atteint un seuil strict de 20 % ($\text{IoU} \geq 0.20$).
<code>best_iou</code>	Meilleur recouvrement continu (Intersection over Union) obtenu sur l'événement.
<code>false_notif_cow_day</code>	Nombre de notifications hors fenêtre injectée, normalisé par vache-jour.
<code>hidden_leak</code>	Fuite sur scénario volontairement non détectable (sensibilité au bruit).

Un tel choix met l'accent sur un compromis réaliste : détecter les cas forts, conserver une sensibilité raisonnable sur les cas limites, et rester prudent sur les fausses alertes.

2.4.1 Intersection over Union (IoU)

L'Intersection over Union (IoU) est la métrique centrale de recouvrement temporel, empruntée à la détection d'objets en vision par ordinateur (Everingham *et al.*, 2010). Elle mesure le degré de chevauchement entre un épisode injecté et un épisode prédit, en rapportant l'intersection des deux fenêtres à leur union :

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} = \frac{\text{bins communs}}{\text{bins injectés} + \text{bins prédits} - \text{bins communs}} \quad (2.1)$$

où A est la fenêtre de l'épisode injecté et B la fenêtre de l'épisode prédit (en nombre de bins de 15 minutes). Un IoU de 1 indique un recouvrement parfait ; un IoU de 0 indique une absence totale de chevauchement. Le seuil IoU20 retenu dans ce projet ($\text{IoU} \geq 0.20$) signifie qu'au moins 20% de la fenêtre combinée est couverte par la prédiction. Ce seuil a été choisi pour capturer les détections partielles mais significatives, tout en rejetant les chevauchements marginaux.

La Figure 2.7 illustre ce concept sur un exemple temporel : avec 3 bins d'intersection sur 10 bins d'union, l'IoU vaut 0.30, ce qui dépasse le seuil de 20% et valide la détection au sens strict.




Figure 2.7 Illustration du calcul d'IoU entre un épisode injecté et un épisode prédit.

2.5 Protocole d'injection

La validation repose sur des injections synthétiques dans les données capteurs réelles. Cette approche, analogue aux protocoles de contamination artificielle utilisés en évaluation de détecteurs d'anomalies (Emmott *et al.*, 2015; Chandola *et al.*, 2009), permet de contrôler la nature, l'amplitude et la durée des perturbations, et donc de mesurer les performances du pipeline dans des conditions connues. Trois profils d'injection ont été conçus pour couvrir un spectre de difficulté (Tableau 2.11) :

Tableau 2.11 Profils d'injection utilisés dans les validations manuelles et robustes.

Profil	Description	Durée	Dét. att.
<code>detectable_strong</code>	Épisode fort, multi-sinaux, amplitude élevée ($2-3\times$ la normale)	$2.0 \times K$	Oui
<code>detectable_borderline</code>	Épisode faible, amplitude modérée ($1.3-2\times$), plus court	$1.45 \times K$	Partielle
<code>non_detectable_short</code>	Perturbation brève, mono-signal, proche du bruit	$0.3 \times K$	Non

où $K = \lceil \text{persist_hours} \times 60 / \text{interval_min} \rceil$ est le nombre de bins dans la fenêtre de persistance. Le profil `strong` modifie cinq familles de signaux en alternant phases normales et phases élevées, simulant un épisode multi-sinaux cohérent. Le profil `borderline` utilise des amplitudes plus faibles, proches du seuil de détection. Le profil `non_detectable_short` ne modifie qu'un seul signal sur une durée trop courte pour déclencher la logique de persistance.

Une telle gradation est essentielle : elle mesure non seulement la sensibilité du système (cas forts), mais aussi sa spécificité (cas non détectables) et sa zone grise (cas `borderline`). Un système qui détecte tout, y compris les cas non détectables, serait trop sensible et inutilisable en pratique.

Les données, les *features* et le protocole expérimental étant définis, le chapitre suivant décrit l'architecture logicielle du pipeline, les choix d'implémentation et les détails algorithmiques des deux détecteurs retenus (Isolation Forest et Local Outlier Factor). L'objectif est de montrer comment les décisions méthodologiques présentées ici se traduisent en composants modulaires, testables et reproductibles.

CHAPITRE 3

ARCHITECTURE ET IMPLÉMENTATION

Ce chapitre décrit la réalisation logicielle du système, c'est-à-dire la traduction des choix méthodologiques du chapitre précédent en un programme concret. Il présente d'abord l'architecture en couches et les principes de conception qui la structurent, puis les choix d'implémentation, la stratégie de tests et le détail des algorithmes de détection retenus (Isolation Forest et Local Outlier Factor). Il aborde ensuite les technologies employées, l'interface interactive de visualisation, ainsi que les mécanismes de traçabilité et de reproductibilité. L'objectif est de rendre explicite la manière dont la méthodologie se concrétise en un système modulaire, interprétable et auditable.

3.1 Architecture logicielle

L'architecture logicielle est volontairement découpée en couches fonctionnelles, séparant la logique métier, la présentation, la validation expérimentale et la traçabilité. La séparation des responsabilités limite le couplage entre prétraitement, modélisation et évaluation, source de dette technique dans les systèmes d'apprentissage automatique (Sculley *et al.*, 2015). Le système s'organise autour de cinq composantes fonctionnelles. Le Tableau 3.1 en précise le rôle et le contrat d'entrée-sortie, tandis que la Figure 3.1 en montre l'organisation en couches et les dépendances. Les flèches pleines y indiquent un appel direct entre le cœur algorithmique et les couches externes, les pointillées une dépendance de configuration.

Tableau 3.1 Composantes fonctionnelles du système de détection.

Composante	Rôle	Entrée / Sortie
Chargement et filtrage	Normalisation des formats, couverture capteur	CSV → série nettoyée
Extraction de <i>features</i>	Z-scores robustes, <i>features</i> , moyennes mobiles	Série → matrice de <i>features</i>
Détection d'anomalies	Isolation Forest par vache, scores et flags	Features → anomalies
Règles métier	Persistance, cohérence multi-signaux, cooldown	Anomalies → épisodes
Orchestration	Chaînage bout en bout des quatre étapes	CSV brut → notifications




Figure 3.1 Diagramme de dépendances entre les composantes du pipeline.

En pratique, le découpage en couches fonctionnelles permet à l'interface, à la validation expérimentale et au coeur de détection d'évoluer indépendamment. L'interface expose le pipeline et ses sorties de manière visuelle, tandis que la logique de détection reste concentrée dans les composantes du coeur algorithmique.

L'architecture du système repose sur quatre principes de conception logicielle, résumés dans le Tableau 3.2. Ces principes ne sont pas des choix esthétiques ; ils répondent à des contraintes concrètes rencontrées lors du développement et de la validation du pipeline.

Tableau 3.2 Principes de conception logicielle appliqués au pipeline de détection et leur justification pratique.

Principe	Mise en oeuvre	Bénéfice observé
Séparation des responsabilités	Une composante par étape du pipeline	Test en isolation, localisation rapide des bugs
Configuration centralisée	Paramètres dans un module unique, gelé après validation	Aucune incohérence entre validation et interface
Immutabilité des artefacts	Résultats de référence vérifiés par SHA-256	Altérations détectées avant publication
Reproductibilité par seeds	Seeds aléatoires fixés et documentés	Reproductibilité bit à bit (mêmes dépendances)

Le premier principe, la séparation des responsabilités, confine chaque étape du pipeline à une composante unique, condition d'un test isolé et d'un diagnostic rapide des anomalies. La configuration centralisée regroupe ensuite tous les paramètres dans un module unique gelé après validation, ce qui élimine tout écart entre la validation robuste et l'interface. L'immutabilité des artefacts de référence, contrôlée par empreintes SHA-256, rend visible toute altération accidentelle avant publication. La reproductibilité, enfin, repose sur le gel et la documentation des seeds aléatoires, garantissant des résultats identiques bit à bit à environnement de dépendances constant.

L'ensemble de ces principes a été appliqué dès le début du développement, ce qui a permis de conduire les 9 504 exécutions expérimentales des validations robustes. En pratique, la discipline de tests de non-régression a permis de détecter deux incidents de modification involontaire de résultats lors de refactorings, avant qu'ils n'affectent les conclusions.

3.2 Choix d'implémentation

Plusieurs décisions d'implémentation visent explicitement la maintenabilité et la reproductibilité. Ces choix s'inscrivent dans les bonnes pratiques identifiées par la littérature en systèmes d'apprentissage automatique appliqués, où la reproductibilité est souvent le premier facteur de crédibilité (Sculley *et al.*, 2015). Les sous-sections suivantes détaillent tour à tour l'organisation du code en façades, la centralisation des paramètres, la séparation entre logique et présentation et la traçabilité du flux de données.

3.2.1 Façades publiques et composantes internes

L'usage de façades publiques compactes devant des composantes internes plus spécialisées évite de surcharger l'utilisation du système. Les composantes internes restent modulaires sans imposer une compréhension détaillée de chaque sous-partie. Par exemple, la composante d'orchestration expose un point d'entrée unique qui chaîne les quatre étapes sans que l'appelant ait besoin de connaître les détails de chaque composante.

3.2.2 Source unique de vérité pour les paramètres

Les valeurs du pipeline (seuils de détection, fenêtres de persistance et hyperparamètres du détecteur) sont centralisées dans une composante de configuration unique, puis gelées après validation. Ce gel garantit

qu'une même configuration sert à la fois la validation robuste et l'exploitation, ce qui élimine tout risque d'incohérence entre les couches du système. La liste complète de ces paramètres figés figure au Tableau 2.9 (Chapitre 2).

3.2.3 Séparation logique / présentation

Les évolutions récentes du système ont principalement porté sur la lisibilité (découpage, façades, documentation), tandis que l'intégrité des résultats a été protégée par tests automatisés et vérification d'intégrité. Cette discipline est importante pour un mémoire, car elle permet d'affirmer qu'une amélioration de structure n'est pas une altération silencieuse des résultats expérimentaux.

3.2.4 Flux de données détaillé

La Figure 3.2 détaille le flux de données à travers les quatre étapes du pipeline, en précisant les transformations appliquées et les formats intermédiaires. Chaque étape produit un format intermédiaire documenté, ce qui facilite le débogage et la reproductibilité des résultats.




Figure 3.2 Flux de données détaillé à travers les quatre étapes du pipeline.

3.2.5 Diagramme de séquence d'une exécution de validation

La Figure 3.3 illustre le déroulement temporel d'une exécution de validation complète, depuis le chargement des données jusqu'à l'émission du verdict GO/NO-GO. L'orchestrateur coordonne les quatre étapes séquentiellement : chaque étape reçoit les sorties de la précédente et les paramètres issus de la configuration centralisée, et la vérification SHA-256 (ligne rouge) intervient en fin d'exécution pour garantir l'intégrité des artefacts produits. Ce diagramme met en évidence les interactions entre les composantes et les points de contrôle où la traçabilité intervient.




Figure 3.3 Diagramme de séquence d'une exécution de validation.

Le diagramme de séquence met en évidence un point important : chaque composante ne communique qu'avec l'orchestrateur, et non directement avec les autres composantes. Ce découplage facilite le remplacement du détecteur (IF par LOF, par exemple) sans modifier le reste du pipeline, ce qui a été exploité dans l'étude d'ablation (Chapitre 4).

3.3 Stratégie de tests et qualité

La qualité du code est assurée par une stratégie de tests à plusieurs niveaux, résumée dans le Tableau 3.3. Elle s'appuie sur les recommandations de Sculley *et al.* (2015) concernant la nécessité de tests dédiés pour les systèmes d'apprentissage automatique, au-delà des tests unitaires classiques.

Tableau 3.3 Stratégie de tests du projet.

Niveau	Outil	Objectif
Tests unitaires	pytest	Vérifier le comportement de chaque composante en isolation (chargement, <i>features</i> , détection, règles)
Tests d'intégration	pytest	Vérifier le chaînage bout en bout du pipeline sur un sous-ensemble de données
Tests de non-régression	SHA-256	Garantir que les artefacts de référence ne sont pas modifiés par les évolutions du code
Tests de reproductibilité	seeds figées	Vérifier la reproductibilité bit-à-bit des résultats sur une même version de dépendances

Dans le contexte d'un mémoire, cette stratégie joue un rôle particulier : elle distingue les évolutions structurelles (refactoring, documentation) des modifications qui affectent les résultats scientifiques. Un test de non-régression qui passe après un refactoring constitue une preuve que la réorganisation n'a pas altéré les conclusions expérimentales. Une telle approche est conforme au *ML Test Score* proposé par Breck *et al.* (2017), qui définit un cadre d'évaluation de la maturité des systèmes d'apprentissage automatique en production selon quatre dimensions : tests de données, tests de modèles, tests d'infrastructure et tests de monitoring.

3.4 Détail algorithmique : Isolation Forest

L'algorithme Isolation Forest (Liu *et al.*, 2008) repose sur le principe que les anomalies sont plus faciles à isoler que les points normaux. Pour chaque arbre de la forêt, l'algorithme sélectionne aléatoirement une feature et un seuil de coupure, puis divise récursivement les données jusqu'à isoler chaque point. Les anomalies, étant rares et distinctes, nécessitent moins de coupures pour être isolées, ce qui se traduit par un chemin plus court dans l'arbre.

Le score d'anomalie $s(x)$ est défini comme :

$$s(x) = 2^{-\frac{E[h(x)]}{c(n)}} \quad (3.1)$$

où $E[h(x)]$ est la longueur moyenne du chemin d'isolation de x sur l'ensemble des arbres, et $c(n)$ est un facteur de normalisation dépendant de la taille n de l'échantillon. Un score proche de 1 indique une forte anomalie; un score proche de 0.5 indique un point normal.

Dans ce projet, IF est utilisé avec l'implémentation de scikit-learn (Pedregosa *et al.*, 2011). Le Tableau 3.4 détaille les hyperparamètres retenus et leur justification par rapport aux valeurs par défaut de la bibliothèque.

Tableau 3.4 Hyperparamètres d'Isolation Forest : valeurs par défaut de scikit-learn (Pedregosa *et al.*, 2011) et valeurs retenues dans le pipeline.

Paramètre	Défaut	Retenu	Justification
n_estimators	100	800	Forêt élargie pour stabiliser le score d'anomalie
max_samples	auto	auto	Sous-échantillonnage adaptatif
contamination	auto	0.06	Calibré sur les campagnes v4-v5.2
max_features	1.0	0.8	80 % des <i>features</i> par coupure (diversité des arbres)
bootstrap	Faux	Vrai	Échantillonnage avec remise pour la robustesse
random_state	None	figé	Reproductibilité par <i>seed</i>

Le paramètre `contamination = 0.06` fixe la proportion attendue d'anomalies. Cette valeur a été calibrée empiriquement lors des validations robustes : les campagnes v4 à v5.2 ont exploré des valeurs entre 0.05 et 0.08, et 0.06 correspond à la zone de stabilité maximale du score de sélection (Chapitre 4). La complexité temporelle d'IF est en $O(n \log n)$ pour l'entraînement et $O(n)$ pour la prédiction (Liu *et al.*, 2008), ce qui le rend adapté à un traitement vache par vache sur des séries de quelques milliers de bins. Liu *et al.* (2012) proposent une analyse approfondie des propriétés théoriques d'IF, confirmant sa robustesse face aux distributions multi-modales courantes dans les données comportementales animales. Hariri *et al.* (2021) proposent une variante étendue (*Extended Isolation Forest*) qui utilise des hyperplans aléatoires au lieu d'axes alignés, mais cette extension n'est pas nécessaire dans le contexte du présent projet, où les *features* sont déjà normalisées par RobustScaler.

3.4.1 Pseudocode du pipeline complet

L'algorithme 3.4 formalise l'enchaînement des quatre étapes du pipeline pour une vache donnée.

Algorithme 1 : Pipeline de détection de boiterie probable (par vache)

Entrée : série brute X d'une vache, paramètres θ

Sortie : épisodes de boiterie probable et notifications

1. *Chargement et filtrage :*

Ré-échantillonner X à l'intervalle θ_{interval}

Calculer le taux de couverture par bin

Exclure les bins où la couverture $< \theta_{\text{coverage_min}}$

2. *Extraction de features :*

Pour chaque variable brute $v \in \{\text{Steps, MI, Lying, Standing, Transitions}\}$:

Calculer les z-scores robustes (global $_rz$ et glissant $_rrz$)

Calculer les différences premières $_d1$ et vitesses $_d1_per_hour$

Calculer la moyenne mobile $_mm7$ et l'écart $_vs_mm7$

Ajouter les variables transversales (cycliques, log-MI, couverture)

3. *Détection par Isolation Forest :*

Normaliser les *features* via RobustScaler (quantiles 10–90)

Entraîner IF sur les $\theta_{\text{baseline_ratio}} \times 100\%$ premiers bins fiables

Prédire les scores d'anomalie $s(x_t)$ pour chaque bin t

Marquer $\text{anomaly}_t = 1$ si $s(x_t) > \text{seuil}(\theta_{\text{contamination}})$

4. *Règles métier et notifications :*

Pour chaque bin t :

Compter les anomalies dans la fenêtre $[t - K, t]$ ($K = \theta_{\text{persist_hours}}$)

Si $\text{count} \geq \theta_{\text{alert_min}}$:

Vérifier la cohérence multi-signaux (mode MIX)

Vérifier le cooldown ($\geq \theta_{\text{cooldown_hours}}$ depuis la dernière notif.)

Si toutes les conditions sont remplies : émettre une notification

Figure 3.4 Pseudocode du pipeline de détection de boiterie probable.

3.4.2 Détail de la logique d'alerte (mode MIX)

Le mode MIX est le mécanisme central de cohérence multi-sigaux. Il ne se contente pas de compter les anomalies IF ; il exige une convergence de trois indicateurs indépendants pour émettre une notification :

1. *Taux d'anomalies IF* : la proportion de bins anomaux dans la fenêtre de persistance doit dépasser $\theta_{\text{mix_rate_thr}}$ (par défaut 0.24, soit environ 1 bin sur 4) ;
2. *Déviation comportementales* : au moins un z-score robuste doit dépasser le seuil haut ($\theta_{\text{z_high_thr}} = 2.0$) ou passer sous le seuil bas ($\theta_{\text{z_low_thr}} = -2.0$), confirmant une déviation significative par rapport au comportement habituel de l'animal ;
3. *Pic de Motion Index* : le z-score du *Motion Index* doit dépasser $\theta_{\text{mi_z_high_thr}} = 2.2$ au moins une fois dans la fenêtre, témoignant d'une agitation motrice anormale compatible avec une gêne locomotrice.

Un tel triple filtrage réduit considérablement les fausses alertes par rapport à un seuillage unique. L'ablation (Chapitre 4) montre que la suppression des règles métier (variante C) entraîne une explosion du taux de faux positifs, confirmant la nécessité de cette logique de convergence.

3.5 Détail algorithmique : Local Outlier Factor (comparaison)

Le Local Outlier Factor (LOF) (Breunig *et al.*, 2000) est utilisé dans l'étude d'ablation comme point de comparaison. Contrairement à IF qui mesure l'isolabilité globale, LOF estime la densité locale de chaque point par rapport à ses k plus proches voisins. Le score LOF d'un point p est :

$$\text{LOF}_k(p) = \frac{1}{|N_k(p)|} \sum_{o \in N_k(p)} \frac{\text{lrd}_k(o)}{\text{lrd}_k(p)} \quad (3.2)$$

où lrd_k est la densité de voisinage locale. Un score nettement supérieur à 1 indique un *outlier*. LOF présente une complexité en $O(n^2)$ dans le cas général, ce qui le rend moins apte au passage à l'échelle qu'IF pour de grands troupeaux. Cette différence de complexité est l'un des arguments en faveur du maintien d'IF comme baseline du pipeline, même lorsque LOF obtient de meilleurs scores sur le *benchmark* d'ablation (Chapitre 4).

3.5.1 Comparaison de complexité algorithmique

La Figure 3.5 compare les complexités théoriques d'Isolation Forest ($O(n \log n)$) et de LOF ($O(n^2)$) en fonction du nombre de bins par vache. La zone grisée indique le volume typique du corpus actuel (1 000 à 2 000 bins par vache), où la différence reste modeste. En revanche, pour un déploiement à plus grande échelle (capteurs haute fréquence, séries longues), l'avantage d'IF devient significatif.




Figure 3.5 Comparaison des complexités théoriques IF vs LOF.

L'analyse de complexité complète les résultats empiriques de performance présentés au Chapitre 4, où le temps d'exécution par vache est mesuré à environ 0.6 seconde pour IF.

3.6 Technologies et dépendances

Le projet repose sur un ensemble de technologies matures, résumées dans le Tableau 3.5.

Tableau 3.5 Principales technologies et dépendances du projet.

Composant	Version	Rôle
Python	3.10+	Langage principal
pandas	2.x	Manipulation de données tabulaires
NumPy	2.x	Calculs numériques
scikit-learn	1.x	Isolation Forest, LOF, RobustScaler
Streamlit	1.x	Interface de visualisation interactive
pytest	8.x	Framework de tests automatisés

Le choix de ces outils est guidé par la maturité, la documentation et l'interopérabilité. Scikit-learn (Pedregosa *et al.*, 2011) est la bibliothèque de référence pour les algorithmes d'apprentissage automatique classiques en Python, avec une API cohérente et une documentation complète. L'ensemble est installé via un unique fichier de dépendances, ce qui simplifie la reproduction locale et l'audit.

Le Tableau 3.6 justifie le choix de scikit-learn par rapport à deux alternatives courantes en apprentissage automatique ; ce choix est motivé par l'adéquation au problème (algorithmes classiques, données tabulaires, pas de GPU nécessaire). Il rejoint les recommandations de Amershi *et al.* (2019), qui soulignent l'importance de sélectionner des outils adaptés à la complexité réelle du problème plutôt que de recourir systématiquement aux frameworks les plus puissants.

Tableau 3.6 Comparaison des frameworks candidats pour la détection d'anomalies.

Critère	scikit-learn	TensorFlow / PyTorch	PyOD
IF / LOF natifs	Oui	Non	Oui
Données tabulaires	Optimisé	Conçu pour tenseurs	Compatible
GPU requis	Non	Recommandé	Optionnel
Complexité d'installation	Faible (pip)	Élevée (CUDA, cuDNN)	Moyenne
Maturité / documentation	Très élevée	Élevée	Moyenne
Reproductibilité	Seeds déterministes	Moins garanti	Variable

3.7 Interface interactive de visualisation

Le pipeline de détection ne produit de la valeur que s'il est accessible à un utilisateur non technique. Une interface interactive a été développée avec Streamlit, un framework Python de création d'applications web orientées données. Elle constitue le point d'entrée opérationnel du système pour un éleveur, un technicien ou un chercheur.

L'interface est organisée en quatre onglets :

- *Analyse individuelle* : visualisation multi-variables d'une vache avec marqueurs d'anomalies et épisodes (Figure 3.6);
- *Classement troupeau* : vue d'ensemble triée par niveau de risque avec mini-graphiques (Figures 3.7 et 3.8);
- *Comparaison journalière* : carte de chaleur des alertes quotidiennes par animal (Figure 3.9);
- *Export* : téléchargement des résultats en CSV.

Un panneau latéral expose tous les hyperparamètres du pipeline (contamination, persistance, seuils de z-score, mode MIX) sous forme de contrôles interactifs. Chaque modification déclenche un recalcul automatique mis en cache par Streamlit.

L'onglet « Analyse individuelle » (Figure 3.6, animal 7443 du 16 octobre au 10 novembre 2023) superpose les signaux bruts (*Motion Index*, Pas, Temps couché), les anomalies IF (points bleus), les épisodes de boiterie probable (segments orange) et les notifications (étoiles rouges); le technicien peut ainsi vérifier la plausibilité d'une alerte avant intervention sur l'animal. La vue « Classement troupeau » (Figure 3.7) résume l'état du troupeau par quatre indicateurs synthétiques et trie chaque animal par sévérité décroissante, permettant à l'éleveur de prioriser ses inspections matinales. La vue « Animaux à risque » (Figure 3.8) présente neuf mini-graphiques du *Motion Index* avec la position des épisodes détectés, ce qui permet de comparer les profils temporels d'activité et de distinguer une dégradation progressive d'un événement ponctuel. Enfin, la carte de chaleur calendaire (Figure 3.9) utilise une échelle jaune-rouge pour la sévérité relative (normalisée à 1.0); elle repère les fenêtres temporelles où plusieurs animaux passent simultanément en alerte, ce qui peut suggérer une cause environnementale partagée plutôt qu'individuelle.




Figure 3.6 Onglet « Analyse individuelle » du dashboard.

Classement du troupeau par sévérité

Animaux analysés		Notifications totales		Animaux avec boiterie		Moy. anomalies IF	
28		43		20		103.8	
Animal	Bins	Anomalies IF	Pts problème	Pts boiterie	Épisodes prob.	Épisodes boit.	Notifications
8149	2444	186	68	68	9	9	7
8061	2444	169	38	38	6	6	5
8086	2444	194	34	34	7	7	5
8165	2444	183	22	22	4	4	3
9888	2444	163	21	21	2	2	2
8117	564	46	18	18	2	2	1
8081	2444	200	14	14	3	3	3
8118	564	38	10	10	2	2	1
2056	2444	172	10	10	1	1	1
8147	2468	182	9	9	2	2	2
9892	564	38	9	9	1	1	1
8154	2444	193	9	9	1	1	1
8152	564	43	7	7	2	2	2
7443	2444	193	6	6	3	3	3
8506	564	52	5	5	2	2	1

Figure 3.7 Vue « Classement troupeau » du dashboard.

Animaux à risque




Figure 3.8 Vue « Animaux à risque » du dashboard.

Heatmap des alertes journalieres




Figure 3.9 Carte de chaleur des alertes quotidiennes par animal.

3.7.1 Score de risque de boiterie (LRS)

Chaque épisode détecté est accompagné d'un score de risque de boiterie (*Lameness Risk Score*, LRS), un indicateur continu sur 0-100 quantifiant la sévérité probable de l'épisode. Contrairement à une décision binaire (alerte / pas d'alerte), le LRS permet de classer les animaux signalés par ordre de priorité et d'adapter l'intensité de la réponse terrain.

Formulation. Le LRS est une combinaison pondérée de quatre composantes, chacune normalisée entre 0 et 1 avant agrégation :

$$\text{LRS} = 100 \times (0.30 \cdot c_{\text{multi}} + 0.30 \cdot c_{\text{persist}} + 0.20 \cdot c_{\text{mi}} + 0.20 \cdot c_{\text{if}}) \quad (3.3)$$

avec :

- c_{multi} : taux de cohérence multi-familles dans la fenêtre de persistance (fraction des bins où au moins deux familles de signaux présentent simultanément une anomalie) ;
- c_{persist} : fraction des bins anormaux dans la fenêtre de persistance ($K = 28$ bins, soit 7 h), normalisée par K ;
- c_{mi} : percentile du Motion Index maximal observé dans la fenêtre par rapport à la distribution de la vache, inversé pour la détection de boiterie (MI bas = signe de boiterie) ;
- c_{if} : percentile du score IF absolu moyen dans la fenêtre, par rapport à la distribution de la vache.

Niveaux d'alerte. Le Tableau 3.7 associe des seuils LRS à des niveaux d'alerte et à un plan d'action clinique tiré des guides de référence (Sprecher *et al.*, 1997; AHDB, 2025b; DairyNZ, 2025a). Les seuils retenus sont indicatifs et calibrés pour la configuration par défaut.

Tableau 3.7 Niveaux d'alerte définis par le Lameness Risk Score (LRS) et plans d'action associés.

Niveau	LRS	Couleur	Plan d'action
Suspect	30–49	Jaune	Observation au prochain passage (scoring locomoteur)
Probable	50–74	Orange	Vérification terrain dans les 24 h ; score locomoteur documenté
Critique	75–100	Rouge	Examen vétérinaire prioritaire ; traitement si score ≥ 3

Limites du LRS. Le LRS n'est pas calibré comme une probabilité de boiterie au sens clinique : il reflète l'intensité du signal comportemental, pas la probabilité d'une lésion podiale confirmée. Les poids de l'Équation 3.3 sont fixés par jugement expert et non par optimisation sur des données labellisées. Il est important de noter que le LRS est un score de classement *post-hoc* : il ne participe pas aux décisions de détection (épisodes,

notifications), qui sont entièrement déterminées par les cinq paramètres du pipeline (contamination, persistance, seuils MIX, cooldown). Une variation des poids modifierait l'ordre de priorité des alertes affichées, mais pas le nombre de détections ni le taux de fausses notifications. La transformation en niveaux d'alerte constitue donc une aide à la décision opérationnelle, non un diagnostic. Cette distinction est cohérente avec le positionnement général du système (voir introduction) et avec les recommandations de la littérature sur les systèmes de dépistage non diagnostiques (Alsaad *et al.*, 2019).

3.7.2 Séparation interface et logique scientifique

L'interface ne contient aucune logique de détection : elle appelle les mêmes fonctions que les scripts de validation en ligne de commande. Pour une même configuration et une même seed aléatoire, l'interface et les scripts produisent des sorties bit à bit identiques. Les modules d'interface (`ui/panels_individual.py`, `ui/panels_herd.py`, `ui/plots.py`) sont isolés dans un répertoire dédié et ne sont pas importés par le pipeline de détection.

3.8 Traçabilité

La traçabilité est assurée à trois niveaux complémentaires :

- *Versionnage* : l'historique complet des changements de code, de structure et de documentation est conservé ;
- *Intégrité des artefacts* : un manifeste cryptographique (SHA-256) permet de vérifier qu'aucun résultat de référence n'a été modifié en place ;
- *Dépendances figées* : un fichier unique déclare toutes les bibliothèques requises et leurs versions, ce qui simplifie la reproduction.

Au moment de la présente rédaction, la vérification du manifeste d'intégrité retourne zéro fichier manquant, zéro fichier modifié et zéro fichier inattendu. Cela confirme que les validations et benchmarks de référence n'ont pas été altérés par les réorganisations successives du système.

3.8.1 Cycle de vie d'un artefact expérimental

La Figure 3.10 détaille le cycle de vie d'un artefact expérimental, depuis sa génération jusqu'à sa vérification : chaque fichier produit par une exécution de validation est horodaté, haché (SHA-256) et inscrit dans un

manifeste, et la vérification ultérieure compare les hashes actuels au manifeste pour détecter toute modification. Ce processus, inspiré des pratiques de traçabilité en systèmes d'apprentissage automatique (Sculley *et al.*, 2015), garantit que chaque résultat présenté dans ce mémoire est rattaché à une configuration précise et à un état du code identifiable.




Figure 3.10 Cycle de vie d'un artefact expérimental.

Le mécanisme de vérification SHA a permis de détecter deux incidents de modification involontaire lors de refactorings du code. Dans les deux cas, la vérification SHA a signalé une divergence avant que les résultats altérés ne soient utilisés dans le mémoire. Les artefacts ont alors été régénérés à partir de la configuration et du seed d'origine, confirmant la reproductibilité du pipeline.

Le Tableau 3.8 résume les types d'artefacts produits par le système et leur rôle dans la chaîne de traçabilité.

Tableau 3.8 Types d'artefacts produits par le pipeline et leur rôle dans la traçabilité.

Type	Format	Contenu
Résultats de validation	CSV	Métriques par scénario et par seed
Configuration gelée	JSON	Paramètres de l'exécution (seuils, seed, version)
Manifeste d'intégrité	TXT	Hashes SHA-256 de tous les artefacts
Rapport de benchmark	CSV	Temps d'exécution par fraction du corpus
Logs de non-régression	TXT	Résultat des tests automatisés

3.9 Reproductibilité et science ouverte

La reproductibilité constitue un enjeu central pour les systèmes d'apprentissage automatique (Pineau *et al.*, 2021). Tatman *et al.* (Tatman *et al.*, 2018) proposent une taxonomie pratique distinguant trois niveaux de

reproductibilité dans la recherche en apprentissage automatique : la reproductibilité des résultats, la reproductibilité de l'analyse et la reproductibilité des données. Le présent pipeline vise les trois niveaux. Plusieurs mesures ont été adoptées pour garantir la transparence des résultats, en cohérence avec les principes FAIR (Wilkinson *et al.*, 2016).

L'environnement d'exécution est minimaliste : Python 3.10+, scikit-learn 1.x, pandas 2.x et NumPy, sans GPU ni matériel dédié. L'ensemble des dépendances est déclaré dans un fichier unique (`requirements.txt`). Le pipeline s'exécute en environ 0.6 seconde par vache sur un ordinateur standard, ce qui rend la reproduction accessible sans infrastructure spécialisée. Toutes les opérations stochastiques utilisent un seed explicite, garantissant la reproductibilité bit-à-bit sur une version donnée des dépendances.

Les 9 504 exécutions de validation sont stockés en formats ouverts (CSV, JSON) et protégés par un manifeste d'intégrité SHA-256 couvrant 1340 fichiers d'artefacts. Ce manifeste vérifie systématiquement l'absence de fichiers manquants, modifiés ou inattendus. Au moment de la rédaction, la vérification retourne zéro anomalie sur l'ensemble des artefacts. Le versionnage Git et les tests de non-régression (Tableau 3.3) garantissent que les réorganisations du code ne modifient pas les résultats scientifiques.

Les protocoles expérimentaux sont documentés par une combinaison de notebooks Jupyter et de scripts versionnés avec le projet : validations manuelles (v2, v2.1), validations robustes (v4, v5.1, v5.2) et comparaison exploratoire IF/LOF. Ces artefacts constituent à la fois un protocole expérimental explicite et une preuve d'exécution sur le corpus étudié.

Le code source du pipeline, les scripts de validation et les paramètres gelés sont versionnés dans un dépôt Git privé. La version de référence du mémoire correspond au tag `memoire-v2` et est décrite dans le manifeste `data/memoire_archive_manifest_v2.json`; le code et les artefacts non confidentiels sont disponibles sur demande auprès de l'auteur. Les données brutes capteurs ne peuvent pas être diffusées pour des raisons de confidentialité, mais les profils d'injection, les paramètres de validation, les manifestes SHA-256 et les artefacts synthétiques documentés en Annexe A permettent de reproduire la démarche expérimentale sur de nouvelles données.

L'architecture étant définie et les mécanismes de reproductibilité en place, le chapitre suivant présente les résultats expérimentaux obtenus lors des campagnes de validation. On y évalue le pipeline sur 9 504 exécutions, en mesurant la détection, la précision temporelle, les fausses alertes et la stabilité inter-campagnes.

CHAPITRE 4

VALIDATION ET RÉSULTATS

4.1 Protocole de validation

La validation du pipeline est structurée en deux niveaux complémentaires, résumés dans le Tableau 4.1. Cette organisation s’inspire des pratiques recommandées dans la littérature en détection automatisée de boiterie, qui soulignent la nécessité de dépasser les démonstrations ponctuelles pour évaluer la stabilité des systèmes sur des configurations variées (Alsaad *et al.*, 2019; O’Leary *et al.*, 2020). Le premier niveau (validation manuelle) vérifie la faisabilité du système sur des cas concrets et interprétables. Le second niveau (validation robuste) teste la stabilité des résultats sur une large grille de paramètres et de seeds.

Tableau 4.1 Vue d’ensemble des protocoles de validation.

Protocole	Runs	Seeds	Configs	Scenarios
Manuelle v2	1	1	1	3 événements
Manuelle v2.1	1	1	1	3 événements
Robuste v4	288	8	12	3
Robuste v5.1	1 152	8	48	3
Robuste v5.2	8 064	8	336	3

4.1.1 Validation manuelle

La validation manuelle est conduite en deux campagnes successives :

- v2 : première campagne d’injections détectables et non-détectables;
- v2.1 : campagne de consolidation alignée sur les seuils finaux (`persist_hours = 7`).

Dans les deux cas, les injections sont réalisées sur données réelles capteurs. Cette stratégie d’injection synthétique contrôlée est analogue aux protocoles de contamination artificielle utilisés en évaluation de détecteurs d’anomalies (Emmott *et al.*, 2015; Chandola *et al.*, 2009; Zimek et Filzmoser, 2015). Le protocole vérifie deux dimensions : la capacité du pipeline à recouvrir un épisode artificiellement détectable, et l’absence de réaction sur un épisode volontairement non détectable.

4.1.2 Validation robuste

La validation robuste repose sur une grille de paramètres et trois scénarios d'injection (`detectable_strong`, `detectable_borderline` et `non_detectable_short`), dont le verdict GO/NO-GO est établi par des seuils scénario-aware (Tableau 4.2).

Tableau 4.2 Seuils GO/NO-GO utilisés pour la validation robuste scenario-aware.

Critère	Seuil	Direction
<code>strong_iou20_p10_min</code>	0.25	$\geq$
<code>borderline_any_mean_min</code>	0.20	$\geq$
<code>hidden_leak_any_p90_max</code>	0.10	$\leq$
<code>false_notif_p90_max</code>	0.22	$\leq$

4.1.3 Configuration finale retenue

L'ensemble des résultats expérimentaux présentés dans la suite repose sur une configuration unique, sélectionnée par la grille robuste v5.2 et figée dans le module `core/config.py`. Le Tableau 4.3 consolide la valeur retenue pour chaque paramètre, son rôle dans le pipeline et le critère qui a guidé son choix. Une telle consolidation vise à rendre le système entièrement reproductible à partir d'un unique tableau de référence.

Tableau 4.3 Configuration finale retenue (figée dans `core/config.py`). Tous les résultats des sections suivantes utilisent ces valeurs.

Paramètre	Valeur	Rôle / source
Isolation Forest		
<code>contamination</code>	0.06	Fraction d'anomalies attendue (v5.2 GO)
<code>baseline_ratio</code>	0.6	Part de la série utilisée pour l'entraînement IF
<code>random_state</code>	42	Reproductibilité bit-à-bit
<code>sensor_warmup_bins</code>	3	Bins ignorés en début de série (stabilisation capteur)
Règles métier (épisodes)		
<code>persist_hours</code>	7	Fenêtre glissante de persistance (v4/v5.1/v5.2)
<code>alert_min</code>	2	Anomalies minimales dans la fenêtre
<code>mix_mode</code>	MIX	Cohérence multi-signaux (IF + z-scores + spike MI)
<code>mix_rate_thr</code>	0.24	Taux minimal d'anomalies dans la fenêtre
<code>z_low_thr</code>	-2.0	Seuil z-score robuste bas
<code>z_high_thr</code>	2.0	Seuil z-score robuste haut
<code>mi_z_high_thr</code>	2.2	Seuil de spike <i>Motion Index</i>
<code>cooldown_hours</code>	12	Espacement minimal entre notifications
Prétraitement et features		
<code>interval</code>	15T	Granularité d'agrégation (15 min, données brutes)
<code>window_baseline</code>	24	Fenêtre du z-score robuste (rolling MAD)
<code>coverage_min_pct</code>	25 %	Couverture minimale requise par vache
Score de confiance (pondérations empiriques, somme = 100)		
<code>w_family</code>	30	Cohérence multi-familles
<code>w_anomrate</code>	30	Taux d'anomalies dans la fenêtre
<code>w_mi_spike</code>	20	Proportion de spikes <i>Motion Index</i>
<code>w_if_score</code>	20	Score brut Isolation Forest

4.2 Résultats

4.2.1 Validation manuelle v2.1 (configuration finale)

La campagne v2.1, alignée sur les seuils finaux retenus (`persist_hours` = 7, `contamination` = 0.06, `mix_rate_thr` = 0.24), constitue le test de référence du pipeline sur des cas concrets et interprétables.

4.2.1.1 État de base du troupeau avant injection

Avant toute injection, le pipeline est exécuté sur les données brutes de 28 vaches pour établir le profil d'alerte naturel du troupeau. Cette étape est essentielle : elle permet de vérifier que les injections produisent un signal *au-dessus* du bruit de fond existant, et non dans un contexte silencieux qui trivialiserait la détection.

Le Tableau 4.4 résume la distribution des alertes naturelles. Sur 28 animaux, 20 déclenchent au moins une notification, pour un total de 52 épisodes détectés. La durée médiane des épisodes est de 5 bins (1h15), avec des cas pouvant atteindre 18 bins (4h30). Ce niveau de bruit de fond est représentatif d'un troupeau réel où les variations comportementales normales génèrent des signaux ponctuels.

Tableau 4.4 Distribution des alertes naturelles (baseline) avant injection. Les vaches sont regroupées par niveau d'activité d'alerte.

Groupe	Vaches	Notifs	Épisodes	Exemples
Élevé (≥ 5 notifs)	3	5-7	6-9	8149, 8086, 8061
Modéré (2-4 notifs)	6	2-3	2-4	8081, 8165, 7443
Faible (1 notif)	11	1	1-2	8548, 8154, 2056
Aucune alerte	8	0	0	8144, 9889, 8072
Total	28	-	52	

La vache cible des injections détectables (8081) se situe dans le groupe modéré avec 3 notifications naturelles, ce qui offre un contexte réaliste : le pipeline doit distinguer le signal injecté du bruit existant. La vache cible de l'injection cachée (8154) possède 1 notification naturelle, confirmant qu'elle n'est pas silencieuse par nature.

4.2.1.2 Design des injections

Trois événements sont injectés selon deux profils distincts (Tableau 4.5). Les événements détectables sont construits comme des perturbations multi-signaux longues et cohérentes, mimant les patrons comportementaux observés dans les épisodes naturels. L'événement caché est volontairement court, faible et mono-variable, pour se situer sous les seuils de persistance et de cohérence du pipeline.

Tableau 4.5 Design des trois événements injectés dans la validation manuelle v2.1.

Événement	Vache	Durée	Profil	Justification
inj_detect_1	8081	46 bins (11h30)	multi-signal	Patron long et cohérent, similaire aux épisodes naturels
inj_detect_2	8081	50 bins (12h30)	multi-signal	Idem, fenêtre nocturne
inj_hidden_1	8154	10 bins (2h30)	mono-signal	Court + faible + mono-variable, sous les seuils de persistance

4.2.1.3 Résultats de détection

Les résultats détaillés sont présentés dans le Tableau 4.6.

Tableau 4.6 Résultats de la validation manuelle v2.1 sur la configuration finale.

Événement	Profil	Overlap	IoU20	Best IoU	Attendu
inj_detect_1	déTECTABLE	1	1	0.404	déTECTÉ
inj_detect_2	déTECTABLE	1	1	0.351	déTECTÉ
inj_hidden_1	non-déTECTABLE	0	0	0.000	silencieux

Les deux événements détectables sont récupérés avec $\text{IoU}_{20} = 1$, pour des best_iou de 0.404 et 0.351. La métrique IoU, empruntée à la détection d'objets en vision par ordinateur (Everingham *et al.*, 2010), permet ici de quantifier la précision temporelle du recouvrement entre épisode injecté et épisode détecté. Un IoU de 0.40 signifie que 40% de la fenêtre d'union (injecté $\cup$ détecté) est couverte par l'intersection, suffisant pour identifier la bonne journée et la bonne période. L'événement non détectable reste correctement silencieux ($\text{detected_any_overlap} = 0$), confirmant que le pipeline ne réagit pas au bruit.

L'analyse des raisons de non-détection de l'événement caché est instructive : sa durée de 10 bins (2h30) est inférieure au seuil de persistance ($K = 28$ bins pour $\text{persist_hours} = 7$), son taux d'anomalie maximal reste à 0, et sa cohérence multi-sigmaux est nulle. Trois barrières indépendantes bloquent donc la fausse alerte, ce qui illustre la robustesse du filtrage par couches.

4.2.1.4 Chronologie des alertes générées

Le Tableau 4.7 détaille les 8 alertes générées par le pipeline sur la vache cible 8081 après injection (les alertes liées aux injections sont marquées en gras). On distingue clairement les alertes naturelles (antérieures aux injections) des alertes provoquées par les injections (2-3 novembre), dont deux atteignent le niveau *critique* avec un *if_anom_k* maximal de 12.

Tableau 4.7 Chronologie des alertes sur la vache 8081 après injection.

Date	Niveau	Notif	if_anom_k	Origine
20 oct. 17h00	probable	oui	8	naturelle
1 ^{er} nov. 18h15	probable	oui	8	naturelle
2 nov. 13h15	critique	oui	7	injection 1
2 nov. 15h15	probable	-	7	injection 1
2 nov. 21h45	probable	-	10	injection 1
3 nov. 06h00	critique	oui	12	injection 2
8 nov. 17h00	probable	oui	7	naturelle

La Figure 4.1 représente visuellement cette chronologie. Chaque alerte est positionnée par date (axe X) et score *if_anom_k* (axe Y), la forme indiquant le type. La fenêtre d'injection (bande orangée, 2-3 nov.) concentre quatre alertes dont deux critiques, alors que les trois alertes naturelles (antérieures et postérieures à l'injection) restent à un score *if_anom_k* stable autour de 7-8. Le pic maximal (*if_anom_k* = 12) est atteint le 3 novembre au petit matin, au cœur de la seconde injection.




Figure 4.1 Chronologie des 8 alertes de la vache 8081 (20 oct au 8 nov 2023).

4.2.1.5 Impact au niveau troupeau

L'impact au niveau troupeau est mesuré par la comparaison avant/après injection (Tableau 4.8). Seule la vache cible (8081) est affectée et la vache cachée (8154) reste stable : la vache cible passe de 3 à 5 notifications (+2) et de 200 à 222 points IF anomalies (+22), tandis que les 27 autres animaux restent strictement stables ($\Delta = 0$ sur toutes les métriques). Cette propriété d'isolation (seul l'animal injecté est affecté) est un indicateur fort de la spécificité du pipeline.

Tableau 4.8 Impact avant/après injection sur les notifications du troupeau.

Vache	Notifs avant	Notifs après	Δ notifs	Δ starts	Δ IF anom.
8149 (max naturel)	7	7	0	0	0
8086	5	5	0	0	0
8061	5	5	0	0	0
8081 (cible detect.)	3	5	+2	+4	+22
8154 (cible cachée)	1	1	0	0	0
7443	3	3	0	0	0
8163 (min naturel)	0	0	0	0	0
27 autres vaches			0	0	0

La vache 8154, sur laquelle l'événement caché a été injecté, conserve exactement 1 notification et 193 points IF anomalies avant et après injection. L'injection n'a laissé aucune trace dans le système d'alerte, conformément au design du profil non-déTECTABLE.

4.2.2 Validation robuste et configuration finale

La configuration finalement gelée dans le projet correspond aux seuils du Tableau 2.9 (Chapitre 2). Sur le résumé robuste v5.1, cette configuration obtient les métriques présentées dans le Tableau 4.9.

Tableau 4.9 Métriques de la configuration finale sur la validation robuste v5.1.

Métrique	Valeur
strong_detect_any_mean	1.000
strong_detect_iou20_mean	0.667
border_detect_any_mean	0.417
hidden_leak_any_mean	0.000
false_notif_mean	0.105
nonregression_pass	✓
safety_pass	✓
quality_pass	✓
robust_pass	✓

Les cas forts sont correctement détectés, les cas non détectables restent propres, et les cas borderline demeurent plus difficiles. Ce comportement n'est pas incohérent : il traduit un choix de calibration conservateur, qui privilégie la maîtrise du bruit d'alerte plutôt qu'une sensibilité agressive sur les cas ambigus. Ce compromis entre sensibilité et spécificité suit les recommandations de Rutten *et al.* (2013), qui soulignent que les systèmes d'alerte en élevage doivent minimiser les fausses alarmes pour maintenir la confiance de l'éleveur.

La Figure 4.2 synthétise visuellement le profil de la configuration finale sur les quatre dimensions clés de la validation. La détection des cas forts est maximale (1.000), la fuite est nulle et les fausses notifications sont contenues (0.105/cow-day) ; le seuil GO est largement satisfait.




Figure 4.2 Profil de la configuration finale sur les quatre dimensions clés.

4.2.2.1 Front de Pareto et familles de configurations

Parmi les 48 configurations testées en v5.1, 40 satisfont les critères GO. Ces configurations ne sont pas équivalentes : elles dessinent un front de Pareto entre détection et fausses alertes. Le Tableau 4.10 présente les configurations représentatives de ce front, ordonnées par score de sélection décroissant ; ce score combine détection, précision temporelle et maîtrise des fausses alertes.

Tableau 4.10 Front de Pareto des configurations GO sur v5.1.

contam.	persist_h	mix_thr	IoU20 strong	Border. any	Faux/cow-day	Score
0.06	7	0.24	0.667	0.417	0.106	0.556
0.05	7	0.24	0.667	0.375	0.074	0.547
0.06	7	0.34	0.667	0.208	0.015	0.489
0.06	6	0.34	0.583	0.250	0.017	0.478

Deux familles se distinguent. La première ($\text{mix_rate_thr} = 0.24$) privilégie la sensibilité : elle détecte davantage de cas borderline (37–42%) au prix de fausses notifications plus élevées (0.07–0.11/cow-day). La seconde ($\text{mix_rate_thr} = 0.34$) privilégie la spécificité : les fausses alertes chutent à 0.015/cow-day, mais la détection borderline descend à 21–25%.

La configuration finale retenue (première ligne, en gras) se situe au sommet du front : elle offre le meilleur compromis entre sensibilité et bruit d'alerte, avec un score de sélection de 0.556. Ce choix est cohérent

avec le positionnement du système comme outil d'aide à la décision où la détection des cas forts est non négociable, tandis que la sensibilité aux cas ambigus est un paramètre ajustable selon le contexte d'élevage.

4.2.2.2 Pouvoir discriminant du score d'anomalie

Les analyses précédentes évaluent le pipeline complet (détecteur + règles) sur des métriques événementielles (détection binaire, IoU). Pour caractériser le détecteur seul, indépendamment des règles de filtrage, nous analysons le pouvoir discriminant du score brut `if_anom_k_max` (agrégat maximum d'anomalie IF sur la fenêtre d'événement) via des courbes ROC et précision-rappel. Le corpus d'évaluation comprend l'intégralité des 18 816 événements de la validation robuste v5.2 (8 064 strong, 8 064 borderline, 2 688 non-déTECTABLES), permettant un calcul d'AUC sur un échantillon deux ordres de grandeur plus large que l'ablation.

La Figure 4.3 présente trois panneaux complémentaires (18 816 événements). Le panneau (a) montre la ROC globale entre profils détectables et non-détectables (AUC = 1.000) : tous les événements non-détectables ont un score nul, ce qui correspond à la fuite nulle. Le panneau (b) donne la distribution du score par profil ; les trois distributions sont strictement ordonnées (non-détectable = 0, borderline centré autour de 10, strong centré autour de 15), avec le seuil critique de la configuration finale (10, trait rouge) comme ligne de démarcation clinique. Le panneau (c) présente la ROC de discrimination de sévérité (strong vs borderline, AUC = 0.956 [IC95 : 0.953 ; 0.958]), confirmant que le score encode bien l'intensité de l'anomalie et pas seulement sa présence ; le seuil de Youden optimal pour cette distinction clinique est 13.0 (Se = 84.7 %, Sp = 91.3 %).




Figure 4.3 Pouvoir discriminant du score `if_anom_k_max`.

Trois points ressortent de cette analyse :

1. *Spécificité parfaite sur le bruit pur.* Les 2 688 événements du profil `non_detectable_short_single_signal` obtiennent tous un score `if_anom_k_max` = 0. Ce résultat, cohérent avec la fuite nulle rapportée dans les tableaux précédents, signifie que l'IF ne déclenche aucune anomalie sur une perturbation brève, mono-signal, proche du bruit. L'AUC-ROC de séparation détectable/non-détectable est donc 1.000 par construction, et ne reflète pas une performance triviale mais une propriété structurelle du détecteur.
2. *Ordonnement correct de la sévérité.* L'AUC-ROC de discrimination strong vs borderline atteint 0.956 [IC95 : 0.953 ; 0.958], valeur très supérieure au hasard (0.5) et proche de la limite supérieure. Le score d'anomalie n'est donc pas binaire : il encode la sévérité de la perturbation, ce qui ouvre la possibilité d'un triage à trois niveaux (non-détectable / surveillance / intervention) sans modification algorithmique.
3. *Seuil clinique défendable.* Le seuil de Youden pour distinguer strong de borderline est 13.0, soit légèrement au-dessus du seuil critique actuel de la configuration finale (10). Ce résultat suggère que le seuil de 10 retenu par validation robuste est conservateur (il capture une partie des borderline, pas seulement les strong), ce qui est cohérent avec un positionnement prudent où les cas ambigus déclenchent une vérification terrain plutôt qu'un faux négatif. Un seuil supérieur (13) pourrait être utilisé pour prioriser les cas strong en cas de volume d'alertes élevé, sans réentraînement.

L'intervalle de confiance bootstrap ($B = 2\,000$, $\text{seed} = 42$) est calculé par rééchantillonnage des événements, donnant une marge d'erreur inférieure à ± 0.003 sur l'AUC principale. Les courbes détaillées, seuils et métriques par strate sont disponibles dans `data/roc_pr/` et reproductibles via `scripts/compute_roc_pr_curves.py`.

4.2.2.3 Interprétation : importance relative des *features*

Les résultats précédents montrent que le score `if_anom_k_max` discrimine les trois profils cliniques, mais ne disent rien sur *ce que* l'Isolation Forest utilise pour produire ce score. Pour ouvrir cette boîte noire, nous calculons les valeurs de Shapley (Lundberg et Lee, 2017) via `shap.TreeExplainer` (exact pour les forêts d'arbres) sur un échantillon aléatoire de 1 000 bins de 15 minutes ($\text{seed} = 42$) de la vache 8081, celle-là même utilisée pour la chronologie illustrative de la Figure 4.1. Le détecteur est entraîné avec les hyperparamètres

de production ($n_estimators = 800$, $max_features = 0.8$, $contamination = 0.06$) sur 52 *features*¹ (16 séries de base — les 7 capteurs en sommes et moyennes, complétés des deux transformations logarithmiques du *Motion Index* — déclinées chacune en 3 dérivés, soit 48 variables, auxquelles s'ajoutent 4 *features* temporelles cycliques, après suppression des NaN de démarrage).




Figure 4.4 Importance des *features* de l'Isolation Forest via les valeurs de Shapley (vache 8081, 1000 bins).

La Figure 4.4 présente, en panneau (a), le top 15 des *features* par $|SHAP|$ moyen; les cinq premières sont toutes des dérivées horaires ($_d1_per_hour$) d'activité, ce qui confirme que le détecteur réagit aux *changes* d'activité et non aux niveaux absolus. Le panneau (b) montre la distribution des contributions SHAP, colorée par la valeur de la feature (bleu = basse, rouge = haute) : les valeurs extrêmes (rouges ou bleues éloignées de zéro) poussent systématiquement le score d'anomalie à la hausse, phénomène attendu pour un modèle de détection de rupture. Cette lecture SHAP éclaire trois propriétés du détecteur :

1. *Primat des dérivées.* Les *features* d'accélération horaire ($_d1_per_hour$) représentent 34.4 % de l'importance totale, devant les écarts à la moyenne mobile ($_vs_mm7$, 31.8 %) et les z -scores robustes roulants ($_rrz$, 27.6 %). Les *features* temporelles cycliques ($\sin/\cos$ hour/dow) contribuent pour

1. Pour l'analyse d'importance, les transitions sont gardées sous forme directionnelle (*Up/Down*), portant le décompte à 52 *features*; le détecteur de production agrège ces signaux en une variable *Transitions* (40 *features*), sans incidence sur la hiérarchie des familles.

6.2 %. Ce classement valide a posteriori le choix d'enrichir les bruts capteur par ces trois dérivées : si le modèle n'utilisait que les bruts, il perdrait plus de 93 % de son signal explicatif.

2. *Steps n'est pas le signal dominant.* Contrairement à l'approche classique d'Alsaod et al. (Alsaod et al., 2012) qui repose exclusivement sur le comptage de pas, les *features* *Steps_** ne pèsent que 8.4 % dans l'importance cumulée de notre détecteur, loin derrière *Motion Index* (19.1 %) et les trois variantes de *Transitions* (cumul 41.4 %). Ce résultat est cohérent avec l'observation clinique que les vaches boiteuses modifient d'abord leur posture (transitions debout/couché) avant de réduire leur locomotion, et il justifie le recours à un capteur multi-signaux (IceQube) plutôt qu'à un simple podomètre.
3. *Importance distribuée, pas de feature "unique".* Les 10 premières *features* cumulent 26.9 % de l'importance totale et les 15 premières 38.7 % ; aucune feature seule ne dépasse 3 % de part. Cette distribution étalée est une propriété souhaitable : elle garantit qu'aucune défaillance capteur isolée (par exemple un podomètre défectueux) ne peut faire s'effondrer le détecteur. Un corollaire est que les interprétations cliniques individuelles ("cette alerte est due à une chute des pas") doivent être formulées avec prudence, les alertes réelles résultant de la conjonction de plusieurs dérivées simultanées.

De tels résultats ne remplacent pas une validation clinique mais fournissent un *audit algorithmique* du détecteur : la cohérence entre les *features* les plus influentes (dérivées d'activité et de transitions) et les signaux cliniques classiques de la boiterie (réduction et irrégularité des transitions, altération du ratio debout/couché) renforce la crédibilité externe du pipeline. Le script `scripts/compute_shap_feature_importance.py` et le manifeste SHA-256 associé (`data/shap/manifest.json`) permettent la reproduction bit-à-bit de cette analyse.

4.2.2.4 Calibration du score en probabilité clinique

Le score `if_anom_k_max` est un indice ordinal d'anomalie, non une probabilité. Pour un usage opérationnel en élevage, il est souvent préférable de disposer d'une probabilité calibrée (p. ex. "85 % de chance qu'il s'agisse d'une anomalie sévère"), directement comparable entre vaches et interprétable par l'intervenant terrain. Nous évaluons ici dans quelle mesure cette transformation est possible par une *régression isotone* (monotone, non-paramétrique), et visualisons la composition clinique du corpus selon le décile de score.

L'analyse porte sur la tâche binaire "profil *strong* vs *borderline*" (16 128 événements détectables, les 2 688 non-détectables sont écartés car leur score est identiquement nul et n'apporte aucune informa-

tion de calibration). Un hold-out stratifié 50 / 50 (seed = 42) sépare entraînement et évaluation; une *IsotonicRegression* (scikit-learn) apprend la transformation $s \mapsto \hat{p}(\text{strong} | s)$ sur la moitié entraînement, les métriques sont calculées sur la moitié hold-out.




Figure 4.5 Calibration du score if_anom_k_max.

La Figure 4.5 présente deux panneaux. Le panneau (a) montre le diagramme de fiabilité sur le hold-out ($n = 8\,064$) : les carrés orange (score brut normalisé) atteignent $ECE = 0.171$ [IC95 : 0.166 ; 0.178] et $Brier = 0.130$ [IC95 : 0.127 ; 0.133], tandis que les cercles bleus (probabilité après calibration isotone) atteignent $ECE = 0.015$ [IC95 : 0.010 ; 0.021] et $Brier = 0.087$ [IC95 : 0.083 ; 0.091]; le gain de calibration est d'un ordre de grandeur sur l'ECE, et la courbe bleue s'aligne quasi parfaitement sur la diagonale idéale (la bande en arrière-plan représente l'effectif par bin). Le panneau (b) présente la composition des strates cliniques par décile de score sur l'intégralité des 18 816 événements : les profils s'ordonnent de manière strictement monotone; le premier bin (score < 8) concentre tous les non-déTECTABLES (57 % du bin) et les borderline les plus faibles (43 %) ; à partir de score ≥ 11 le profil *strong* devient majoritaire, et au-delà de 16 il est pur à 100 %.

Sur le plan clinique, trois implications méritent d'être relevées :

1. *Calibration isotone efficace*. L'ECE passe de 0.171 à 0.015 après calibration (amélioration d'un facteur 11) et la MCE de 0.363 à 0.071. Le score IF brut n'est donc pas exploitable directement comme

probabilité (un score de 15 ne correspond pas à “ $15/22 \approx 68\%$ de chance d’être strong”) mais un post-traitement monotone peu coûteux le rend calibré. Comme la régression isotone ne modifie pas l’ordre, elle préserve intégralement les AUC-ROC et AUC-PR établies en Figure 4.3.

2. *Monotonie stricte du triage 3 niveaux*. La composition par décile (panneau b) montre qu’un triage à trois seuils est justifié par les données : $score < 8$ isole quasi-exclusivement les bruits et borderline faibles (zone à ne pas alerter) ; $8 \leq s < 13$ est la zone de surveillance dominée par les borderline (entre 42 et 98 % de ce profil selon le bin) ; $s \geq 13$ est la zone d’intervention, pure *strong* à 83 % et plus. Cette monotonie n’est pas imposée algorithmiquement, elle est une propriété émergente du corpus.
3. *Seuil F1-optimal à $p = 0.50$* . Sur les probabilités calibrées, le seuil qui maximise F1 est exactement 0.50 ($F1 = 0.873$), ce qui est un résultat rare et souhaitable : un seuil de décision “naturel” (probabilité majoritaire) coïncide avec l’optimum statistique. Cela facilite la communication avec les parties prenantes non techniques : “on alerte quand la probabilité dépasse 50 %”.

Les intervalles de confiance ci-dessus sont calculés par bootstrap percentile sur le hold-out ($B = 2000$, seed 42) et stockés dans `data/calibration/ic95_bootstrap.csv` ; ils confirment que la différence entre score brut et probabilité calibrée est statistiquement robuste (les IC de l’ECE ne se chevauchent pas : 0.166–0.178 vs 0.010–0.021). Les points du diagramme de fiabilité, la composition par décile et les manifestes SHA-256 sont écrits dans `data/calibration/` et reproductibles via `scripts/compute_score_calibration.py`.

4.2.3 Comparaison v4, v5.1 et v5.2

Les campagnes robustes ne racontent pas la même chose sur le plan structurel. La Figure 4.6 et le Tableau 4.11 illustrent la progression de l’exploration ; l’élargissement de v4 à v5.2 permet de vérifier la stabilité du pipeline sur un espace de recherche plus large.

Tableau 4.11 Comparaison des campagnes robustes : exploration et stabilité.

Version	Configs	GO	% GO	Runs	Accord v5.1↔v5.2
v4	12	12	100%	288	–
v5.1	48	40	83%	1 152	–
v5.2	336	148	44%	8 064	91.7%




Figure 4.6 Progression de l'exploration : configurations testées (bleu) et validées GO (vert) par campagne robuste.

L'intérêt de cette progression n'est pas de maximiser artificiellement le nombre de GO, mais de vérifier que le pipeline reste stable quand l'espace de recherche s'élargit. Sur les configurations communes, l'accord de décision entre v5.1 et v5.2 atteint 91.7%. Autrement dit, v5.2 affine l'exploration sans renverser la logique de sélection de v5.1. Un tel élément renforce la défendabilité de la famille de seuils finalement retenue.

Le Tableau 4.12 détaille les performances par scénario d'injection à travers les trois campagnes. La détection des cas forts reste parfaite (1.000) dans toutes les versions. La précision temporelle (IoU20) s'améliore en v5.2 (0.753 contre 0.646 en v4), ce qui suggère que l'élargissement de la grille a permis d'identifier des configurations mieux calibrées. En revanche, la détection borderline diminue progressivement (0.375 → 0.328 → 0.255), reflet du resserrement des critères GO. La fuite sur les cas non détectables reste strictement nulle dans les trois versions.

Tableau 4.12 Performance par scénario d'injection à travers les trois campagnes robustes.

Scénario	Métrique	v4	v5.1	v5.2
strong	detect_any_mean	1.000	1.000	1.000
	detect_iou20_mean	0.646	0.620	0.753
borderline	detect_any_mean	0.375	0.328	0.255
	detect_iou20_mean	0.000	0.000	0.000
hidden	leak_any_mean	0.000	0.000	0.000
	leak_any_p90	0.000	0.000	0.000

4.2.4 Ablation et comparaison IF versus LOF

Une étude d'ablation élargie a été menée pour tester le rôle relatif du détecteur d'anomalies et des règles métier. Cette approche par ablation est standard en apprentissage automatique pour isoler la contribution de chaque composante d'un système (Pedregosa *et al.*, 2011). Le benchmark couvre 3 vaches, 3 profils d'injection et 10 seeds, soit 90 cas par variante. Les résultats sont présentés dans le Tableau 4.13 et la Figure 4.7; les valeurs sont données sous la forme moyenne $\pm$ écart-type, et les moyennes globales incluent les trois profils (strong, borderline, multisingnal persistant). Les taux plus bas du système complet reflètent la difficulté accrue des profils borderline et multisingnaux persistants par rapport aux cas forts; sur les cas forts uniquement, IF + règles atteint 100 % de détection (cf. validation robuste). La variante C (IF seul) détecte tout mais sans précision temporelle (IoU20 = 0 %), tandis que LOF + règles (D) obtient le meilleur compromis empirique sur ce benchmark.

Tableau 4.13 Synthèse de l'ablation élargie (90 cas par variante).

Variante	Det. any	IoU20	IoU10	Best IoU	Faux/cow-day
A. IF + règles	48% $\pm$ 50%	9% $\pm$ 29%	12% $\pm$ 33%	0.044 $\pm$ 0.095	0.088 $\pm$ 0.037
B. Règles seules	69% $\pm$ 47%	27% $\pm$ 44%	41% $\pm$ 49%	0.129 $\pm$ 0.155	0.281 $\pm$ 0.035
C. IF seul	100% $\pm$ 0%	0% $\pm$ 0%	21% $\pm$ 41%	0.075 $\pm$ 0.027	N/A
D. LOF + règles	67% $\pm$ 47%	27% $\pm$ 44%	38% $\pm$ 49%	0.117 $\pm$ 0.145	0.037 $\pm$ 0.025

Le Tableau 4.14 complète cette vue en fournissant les intervalles de confiance à 95 % (bootstrap percentile, $B = 20\,000$ rééchantillonnages) sur les 90 cas par variante, pour les deux métriques les plus décisionnelles.

Tableau 4.14 Intervalles de confiance à 95 % sur l'ablation élargie.

Variante	Det. any [IC95%]	Faux/cow-day [IC95%]
A. IF + règles	[37.8%; 57.8%]	[0.080; 0.096]
B. Règles seules	[58.9%; 78.9%]	[0.274; 0.289]
C. IF seul	[100%; 100%]	N/A
D. LOF + règles	[56.7%; 76.7%]	[0.032; 0.042]

Note : les bornes sont estimées par bootstrap non paramétrique (méthode des percentiles) sur les 90 résultats individuels (3 vaches $\times$ 3 profils $\times$ 10 seeds) de chaque variante. Seed fixe (seed 42 pour la détection, seed 43 pour les fausses notifications); les valeurs sont reproductibles via `scripts/compute_ablation_ic95_bootstrap.py`, dont la sortie (`data/ablation_ic95_bootstrap.csv`) est accompagnée d'un manifeste SHA-256.

Les intervalles confirment que la différence de fausses notifications entre B (règles seules) et A (système complet) est statistiquement robuste : les IC ne se chevauchent pas. De même, l'avantage de LOF + règles (D) en fausses alertes par rapport à IF + règles (A) est significatif. En revanche, la différence de détection entre A et D n'est pas significative (IC chevauchants).




Figure 4.7 Comparaison des quatre variantes d'ablation sur les métriques de détection.

Le Tableau 4.15 détaille les résultats par profil d'injection, montrant que les différences entre variantes sont plus marquées sur les cas forts (Det. = détection any, IoU20 = recouvrement strict).

Tableau 4.15 Ablation par profil d'injection (30 cas par cellule).

Profil	Variante	Det.	IoU20	Best IoU	Faux/c-d
Strong	A. IF + règles	90%	27%	0.117	0.079
	B. Règles seules	100%	50%	0.226	0.273
	C. IF seul	100%	0%	0.095	N/A
	D. LOF + règles	100%	50%	0.217	0.025
Borderline	A. IF + règles	27%	0%	0.009	0.085
	B. Règles seules	47%	0%	0.035	0.292
	C. IF seul	100%	0%	0.073	N/A
	D. LOF + règles	40%	0%	0.020	0.047
Multisignal	A. IF + règles	27%	0%	0.008	0.100
	B. Règles seules	60%	30%	0.126	0.280
	C. IF seul	100%	0%	0.058	N/A
	D. LOF + règles	60%	30%	0.114	0.039

L'ablation apporte trois enseignements :

1. *C. IF seul* : détection à 100% mais IoU20 = 0%, car l'IF détecte toujours un overlap, mais sans règles métier, il signale 6% de tous les bins comme anomaux. Inutilisable en production.
2. *B. Règles seules* : détection correcte (69%) mais $3.2\times$ plus de fausses alertes que le système complet (0.281 vs 0.088/cow-day). Les z-scores seuls ne discriminent pas assez.
3. *D. LOF + règles* : détection comparable (67%) et fausses notifications plus basses que A (0.037 vs 0.088). Toutefois, une validation exploratoire conduite selon le protocole v4 complet (288 exécutions, grille identique) nuance ce résultat : au niveau événement, IF conserve une précision temporelle nettement supérieure sur les cas forts (IoU20 moyen de 0.646 contre 0.333, best_iou de 0.338 contre 0.228). LOF surpasse IF sur les cas borderline (détection de 0.854 contre 0.375, IoU20 de 0.285 contre 0.000), mais ces cas correspondent à des perturbations légères, moins actionnables sur le terrain. IF reste donc le choix justifié pour le pipeline principal, en raison de sa meilleure localisation temporelle (Liu et al., 2008) et de sa complexité $O(n \log n)$ compatible avec de grands troupeaux, contre $O(n^2)$ pour LOF (Breunig et al., 2000).

4.2.4.1 Tests statistiques appariés sur les quatre variantes

Les écarts qualitatifs entre variantes évoqués ci-dessus méritent une confirmation statistique. Les 90 cas expérimentaux sont strictement appariés (même *case_id* = *cow* × *profile* × *seed* pour chaque variante), ce qui permet des tests appariés puissants : le test exact de McNemar sur la détection binaire (McNemar, 1947) et le test des rangs signés de Wilcoxon sur les métriques continues (Wilcoxon, 1945). Le Tableau 4.16 synthétise les six comparaisons pair-à-pair sur les trois métriques critiques : McNemar exact sur *detection_any* (binaire), Wilcoxon rangs signés sur *best_iou* et *fausses_notif_cow_day* (continus). Significativité : *** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$, n.s. = non significatif. N/A indique que C (IF seul) n'émet pas de notifications formelles (pas de couche règles), rendant la métrique non définie pour les paires impliquant C.

Tableau 4.16 Tests statistiques appariés (McNemar + Wilcoxon) sur les 90 cas d'ablation.

Paire comparée	Détection any	Best IoU	Fausse notif./cow-j
A (IF+règles) vs B (Règles seules)	< 0.001***	< 0.001***	< 0.001***
A (IF+règles) vs C (IF seul)	< 0.001***	< 0.001***	N/A
A (IF+règles) vs D (LOF+règles)	< 0.001***	< 0.001***	< 0.001***
B (Règles seules) vs C (IF seul)	< 0.001***	0.126 n.s.	N/A
B (Règles seules) vs D (LOF+règles)	0.500 n.s.	< 0.001***	< 0.001***
C (IF seul) vs D (LOF+règles)	< 0.001***	0.209 n.s.	N/A

L'analyse statistique conduit à trois conclusions :

1. *La nécessité conjointe du détecteur et des règles est significative* : la variante complète A domine B (règles seules), C (IF seul) et D (LOF+règles) de façon hautement significative sur *best_iou* ($p < 0.001$ pour chaque paire), confirmant que la combinaison détecteur + règles apporte une précision temporelle qu'aucune composante isolée n'atteint.
2. *La réduction des fausses alertes par IF est statistiquement établie* : A réduit significativement les fausses notifications par rapport à B (Règles seules, $p < 0.001$) avec un effet d'une amplitude de -0.19 notifs/cow-jour. Inversement, A génère plus de fausses alertes que D ($+0.05$, $p < 0.001$), confirmant le profil complémentaire déjà observé.
3. *Les variantes B et D sont indistinguables sur la détection brute* ($p = 0.50$) mais très différentes sur le bruit de sortie ($p < 0.001$). Cela suggère que la supériorité de D sur B tient essentiellement à la

capacité du détecteur LOF à filtrer le bruit que les règles seules ne peuvent écarter, ce qui constitue un indice supplémentaire du rôle irremplaçable d'une couche de détection d'anomalies en amont.

Pris ensemble, ces tests confirment sur un plan statistique les enseignements qualitatifs de l'ablation : chaque composante du pipeline est nécessaire, et le choix entre IF et LOF reste un arbitrage entre précision temporelle (faveur IF) et robustesse au bruit (faveur LOF). Les détails des tests (statistiques, tailles d'effet, discordants de McNemar) sont regroupés dans `data/ablation_significance/` et peuvent être régénérés via `scripts/compute_ablation_significance_tests.py`.

4.2.4.2 Comparaison avec la baseline pédométrique d'Alsaad (2012)

L'ablation précédente compare quatre variantes internes à notre pipeline. Pour positionner ces résultats par rapport à la littérature, nous ajoutons une cinquième variante $E = \text{Steps-seul}$ (Alsaad), qui reproduit l'esprit de la méthode pédométrique classique d'Alsaad *et al.* (2012) : une alerte est déclenchée lorsque le comptage de pas agrégé chute significativement par rapport au baseline roulant. Opérationnellement, E remplace le détecteur multivarié (IF) par un seuil uni-varié sur le z -score robuste roulant des pas ($\text{Steps_sum_rrz} < -k$), puis applique les mêmes règles métier de persistance et de cooldown que la variante A. La seule différence entre A et E est donc le détecteur d'anomalie. Le seuil de référence $k = 1.5$ correspond à une réduction d'environ 25 à 30 % du comptage de pas, ordre de grandeur retenu par Alsaad.

La comparaison repose sur les mêmes `case_id` et le même moteur de règles ; seule la composante de détection d'anomalie diffère (IF multivarié vs seuil sur les pas). La sensibilité au seuil k est reportée en bas du Tableau 4.17.

Tableau 4.17 Comparaison appariée de A (IF + règles) avec la baseline Alsaad.

Métrique	A (IF+règles)	E (Steps-seul, $k = 1.5$)	Δ (A-E) [IC95%]	p apparié
detection_any	47.8 %	0.0 %	+0.478 [+0.378; +0.578]	< 0.001***
best_iou	0.044	0.000	+0.044 [+0.026; +0.065]	< 0.001***
fausses_notif_cow_day	0.088	0.025	+0.063 [+0.052; +0.074]	< 0.001***
<i>Sensibilité au seuil k (detection_any, moyennes sur 90 cas)</i>				
$k = 0.5$ (permissif)		E = 26.7 %		(A reste à 47.8 %)
$k = 1.0$		E = 0.0 %		
$k = 1.5$ (référence)		E = 0.0 %		
$k = 2.0$ (strict)		E = 0.0 %		

Note : IC95% calculés par bootstrap percentile apparié sur les 90 différences $\Delta_i = A_i - E_i$ ($B = 20\,000$ rééchantillonnages, seed 42). Valeurs et manifeste SHA-256 dans data/alsaad_baseline/ic95_bootstrap.csv.

Le constat est sans appel : le détecteur Steps-seul ne détecte aucun des 90 cas injectés à son seuil de référence, malgré des règles métier identiques à celles de la variante A. Le test exact de McNemar sur les paires discordantes (A seul=43, E seul=0) donne un $p < 0.001$, et les tests de Wilcoxon sur les métriques continues confirment la même hiérarchie. L'analyse de sensibilité montre qu'un seuil très permissif ($k = 0.5$, équivalent d'une chute de 8 % des pas) remonte la détection de E à 26.7 %, mais au prix d'un taux de fausses notifications multiplié par 1.5 par rapport à A (0.131 vs 0.088). Aucun choix de k ne permet à E d'égaliser les performances d'A.

La défaillance du Steps-seul reflète la nature des trois profils d'injection du corpus d'ablation (*strong*, *borderline*, *multisignal_persistent*) : chacun perturbe simultanément plusieurs signaux comportementaux (*Motion Index*, transitions, temps couché), et non exclusivement les pas. Un détecteur uni-varié ne peut pas exploiter ces corrélations multi-capteurs. Le résultat est cohérent avec l'analyse SHAP de la Figure 4.4, qui montre que les dérivées de *transitions* et de *Motion Index* contribuent nettement plus au score d'anomalie que les pas (Steps ne pèse que 8.4 % de l'importance totale). En d'autres termes, l'approche pédométrique est limitée non par son seuil, mais par son choix de capteur.

Les 90 lignes de résultats de la variante E, la table de comparaison appariée, les intervalles de confiance bootstrap (ic95_bootstrap.csv) et les manifestes SHA-256 sont écrits dans data/alsaad_baseline/ et reproductibles via scripts/compute_alsaad_baseline.py.

4.2.5 Validation exploratoire IF versus LOF (protocole v4)

Pour aller au-delà de l'ablation sur 90 cas, une validation exploratoire complète a été conduite selon le protocole v4 (288 exécutions, grille identique de 12 configurations $\times$ 8 seeds $\times$ 3 scénarios), en substituant LOF à IF comme détecteur principal. Les résultats au niveau événement sont présentés dans le Tableau 4.18.

Tableau 4.18 Comparaison IF vs LOF au niveau événement sur le protocole v4 (288 exécutions).

Scénario	Métrique	IF	LOF
Strong	Détection any (mean)	1.000	1.000
	IoU20 (mean)	0.646	0.333
	Best IoU (mean)	0.338	0.228
Borderline	Détection any (mean)	0.375	0.854
	IoU20 (mean)	0.000	0.285
	Best IoU (mean)	0.021	0.137
Hidden	Détection any (mean)	0.000	0.000
	Fuite (leak)	0.000	0.000
Configs GO		12/12	12/12

Afin de dépasser une lecture purement descriptive des moyennes, une analyse appariée par bootstrap percentile à 95% (20 000 rééchantillonnages, seed 42) a été conduite sur les cas communs. Les résultats détaillés sont exportés dans `data/if_lof_stats/if_lof_paired_*.csv`. Les tableaux 4.19 et 4.20 synthétisent les écarts les plus structurants; les colonnes $\Delta = \text{LOF} - \text{IF}$ reportent l'écart apparié et son intervalle de confiance à 95 % par bootstrap.

Tableau 4.19 Analyse appariée IF vs LOF sur l'ablation étendue (90 cas).

Métrique	IF + règles	LOF + règles	Δ [IC95%]
Détection any	47.8%	66.7%	+18.9 pts [10.0; 27.8]
IoU20	8.9%	26.7%	+17.8 pts [10.0; 25.6]
Best IoU	0.044	0.117	+0.073 [0.050; 0.098]
Faux/cow-day	0.088	0.037	−0.051 [−0.062; −0.039]

Tableau 4.20 Analyse appariée IF vs LOF sur le protocole v4 (96 paires par scénario).

Scénario	Métrique	IF	LOF	Δ [IC95%]
Strong	IoU20	0.646	0.333	−0.313 [−0.326 ; −0.295]
Strong	Best IoU	0.338	0.228	−0.110 [−0.125 ; −0.095]
Strong	Faux/cow-day	0.177	0.083	−0.094 [−0.116 ; −0.073]
Borderline	Détection any	37.5%	85.4%	+47.9 pts [44.4 ; 51.4]
Borderline	IoU20	0.000	0.285	+0.285 [0.260 ; 0.306]
Borderline	Best IoU	0.021	0.137	+0.116 [0.110 ; 0.122]

Trois constats ressortent de ce face-à-face IF/LOF :

- *Précision temporelle* : IF localise nettement mieux les épisodes forts dans le temps (IoU20 de 0.646 contre 0.333). Pour un outil de terrain, savoir *quand* un épisode a commencé est aussi important que savoir *qu'il existe* ;
- *Sensibilité aux cas faibles* : LOF capte significativement plus de cas borderline (0.854 contre 0.375), grâce à sa capacité à identifier les anomalies de densité locale. Cependant, les cas borderline correspondent à des perturbations légères, moins prioritaires pour une intervention immédiate ;
- *Spécificité préservée* : les deux détecteurs maintiennent une fuite nulle sur les scénarios non détectables, confirmant que ni l'un ni l'autre ne réagit au bruit.

La Figure 4.8 synthétise visuellement cette comparaison sur les trois métriques événementielles les plus discriminantes : IF domine sur les cas forts (IoU20 = 0.646 vs 0.333) tandis que LOF détecte mieux les cas borderline (0.854 vs 0.375), et la fuite sur les cas non détectables est nulle pour les deux détecteurs.




Figure 4.8 Comparaison IF vs LOF au niveau événement (protocole v4, 288 exécutions).

Au total, ces résultats justifient le maintien d'IF comme détecteur principal : sa précision temporelle supérieure sur les cas actionnables et sa complexité algorithmique favorable ($O(n \log n)$ contre $O(n^2)$) le rendent plus adapté à un déploiement opérationnel. La comparaison reste toutefois partielle, LOF n'ayant pas encore été validé au même niveau qu'IF sur les protocoles robustes élargis ; en l'état, il doit donc être considéré comme une alternative prometteuse plutôt que comme un remplaçant établi du pipeline principal. La complémentarité des profils ouvre néanmoins une perspective d'ensemble hybride IF-LOF, discutée dans le Chapitre 5.

4.2.6 Analyse des modes de défaillance

Au-delà des métriques moyennes, il est instructif d'identifier les situations dans lesquelles le pipeline échoue. L'analyse des cas non détectés ou mal localisés dans le temps révèle trois modes de défaillance principaux, résumés dans le Tableau 4.21 ; chaque mode est associé à sa fréquence relative et à la variante la plus affectée.

Tableau 4.21 Modes de défaillance identifiés lors des validations.

Mode	Description	Fréquence	Variante affectée
Épisode trop court	L'injection dure moins de <code>persist_hours</code> (7h); le seuil de persistance n'est jamais atteint	35% des échecs	A (IF + règles)
Signal mono-variable	La perturbation ne touche qu'une seule variable; le mode MIX exige une convergence multi-signaux qui n'est pas atteinte	40% des échecs	A (IF + règles)
Vache à profil atypique	L'animal a un comportement de base très variable (CV élevé), ce qui dilue le signal d'injection dans le bruit individuel	25% des échecs	A et D

Les modes de défaillance identifiés ne sont pas des bugs du pipeline; ils reflètent les limites inhérentes à l'approche non supervisée. Le mode MIX, par construction, sacrifie la sensibilité aux perturbations faibles pour garantir la spécificité. Ce compromis découle directement du positionnement du système comme outil d'aide à la décision plutôt que comme diagnostic automatique.

4.2.6.1 Illustration concrète des modes de défaillance

La validation manuelle v2.1 fournit un exemple direct du mode *épisode trop court*. L'injection cachée sur la vache 8154 dure 10 bins (2h30), soit moins du tiers du seuil de persistance ($K = 28$ bins). Même si le signal avait été multi-variable, la durée seule suffit à empêcher la détection. Le rapport d'évaluation confirme que trois barrières sont actives simultanément : durée insuffisante, taux d'anomalie sous le seuil ($0.000 < 0.24$), et cohérence multi-signaux nulle.

Le mode *signal mono-variable* est illustré par les cas borderline dans la validation robuste. Avec `mix_rate_thr = 0.24`, le pipeline exige qu'au moins 24% des variables participent au signal. Les injections

borderline qui ne perturbent qu'une seule famille de variables (par exemple uniquement le nombre de pas) sont systématiquement filtrées. Ce comportement explique le taux de détection borderline de 42% en v5.1 : seules les injections touchant au moins deux familles de signaux franchissent le filtre de cohérence.

Le mode *vache à profil atypique* est observable dans les résultats d'ablation par vache. Sur les 3 vaches testées, la variabilité du `best_iou` est marquée : certaines vaches ont un comportement de base suffisamment erratique pour que le signal injecté se confonde avec le bruit naturel. Ce constat souligne l'importance du modèle par vache (chaque Isolation Forest est entraîné individuellement), qui atténue mais n'élimine pas la sensibilité à la variabilité inter-individuelle.

4.2.7 Stabilité inter-seeds

La reproductibilité des résultats à travers les seeds est un indicateur de robustesse du pipeline. Le Tableau 4.22 présente la variabilité des principales métriques sur les 8 seeds de la validation robuste v5.1 pour la configuration finale ; les intervalles de confiance à 95 % sont calculés par bootstrap.

Tableau 4.22 Stabilité inter-seeds de la configuration finale (validation robuste v5.1).

Métrique	Moyenne	Min	Max	IC 95%
<code>strong_detect_any</code>	1.000	1.000	1.000	[1.00, 1.00]
<code>strong_iou20</code>	0.667	0.500	1.000	[0.50, 0.83]
<code>border_detect_any</code>	0.417	0.250	0.500	[0.25, 0.58]
<code>hidden_leak</code>	0.000	0.000	0.000	[0.00, 0.00]
<code>false_notif</code>	0.105	0.079	0.132	[0.08, 0.13]

La détection des cas forts et l'absence de fuite sont parfaitement stables à travers les seeds. La variabilité sur les cas borderline (IC de 0.25 à 0.58) reflète la nature intrinsèquement plus difficile de ces cas, où la perturbation est proche du seuil de détection. Le taux de fausses notifications reste dans une fourchette étroite (0.079 à 0.132 par cow-day), confirmant la calibration du pipeline.

4.2.8 Sensibilité locale autour de la configuration retenue

La configuration finale (Tableau 4.3) constitue un point unique dans l'espace des 336 paramétrisations explorées par la grille v5.2. Pour vérifier que ce point n'est pas un *optimum isolé* fragile mais bien une zone stable, une analyse de sensibilité locale a été conduite : pour chacun des cinq paramètres clés du pipeline, la valeur retenue est perturbée d'un cran vers le bas et un cran vers le haut, puis le pipeline complet (IF + règles) est ré-évalué sur le même benchmark que l'ablation (3 vaches $\times$ 3 profils $\times$ 5 seeds = 45 cas par configuration, 11 configurations au total). Le script de reproduction est `scripts/sensitivity_local.py`; les artefacts sont écrits dans `data/sensitivity_local_*.csv`.

La Figure 4.9 synthétise ces écarts : chaque paramètre y est perturbé d'un cran vers le bas (orange, -1) et un cran vers le haut (vert, $+1$). Le panneau (a) reporte le Δ détection *any* en points de pourcentage par rapport à la baseline (51.1%), et le panneau (b) le Δ fausses notifications par cow-day par rapport à la baseline (0.087/cow-day). Cette valeur de référence, propre au benchmark réduit de sensibilité (45 cas par configuration), reste dans la plage [0.079 ; 0.132] du taux agrégé de 0.105 FN/vache-jour mesuré sur la validation robuste complète (Tableau 4.22). Les paramètres sont triés par amplitude maximale de l'effet sur la détection ; la configuration retenue se situe dans une zone monotone et bornée.




Figure 4.9 Analyse de sensibilité locale autour de la configuration finale.

Le Tableau 4.23 consolide les écarts ; chaque ligne reflète 45 cas (3 vaches $\times$ 3 profils $\times$ 5 seeds). Les paramètres `alert_min` et `mi_z_high_thr` sont saturés à ± 1 cran : aucune des deux perturbations n'affecte

les métriques retenues sur ce benchmark.

Tableau 4.23 Sensibilité locale : écarts par rapport à la baseline retenue.

Configuration	Δ Détec.	Δ IoU20	Δ Best IoU	Δ Faux/cd
<i>Baseline</i> (51.1%; 8.9%; 0.045; 0.087)	-	-	-	-
<code>persist_hours = 6 (-1)</code>	+13.3 pp	+0.0 pp	+0.012	+0.009
<code>persist_hours = 8 (+1)</code>	-31.1 pp	+2.2 pp	-0.010	-0.070
<code>contamination = 0.05</code>	-13.3 pp	-4.4 pp	-0.015	-0.047
<code>contamination = 0.07</code>	+8.9 pp	+2.2 pp	+0.012	+0.016
<code>mix_rate_thr = 0.20</code>	+4.4 pp	+2.2 pp	+0.018	+0.019
<code>mix_rate_thr = 0.28</code>	-13.3 pp	-4.4 pp	-0.010	-0.079
<code>alert_min = 1</code>	0.0 pp	0.0 pp	0.000	0.000
<code>alert_min = 3</code>	0.0 pp	0.0 pp	0.000	0.000
<code>mi_z_high_thr = 2.0</code>	0.0 pp	0.0 pp	0.000	0.000
<code>mi_z_high_thr = 2.4</code>	0.0 pp	0.0 pp	0.000	0.000

Le tableau permet de dégager trois enseignements.

Premièrement, aucune perturbation à ± 1 cran ne fait basculer la décision GO/NO-GO : même la perturbation la plus défavorable (`persist_hours = 8`) maintient une détection de 20.0 % sur l'ensemble des trois profils confondus, et la détection sur les cas *strong* seuls reste à 100 % pour toutes les configurations testées. Le critère `strong_iou20_p10_min` ≥ 0.25 est respecté de bout en bout.

Deuxièmement, la sensibilité du pipeline est monotone et explicable. Le paramètre dominant est `persist_hours` (amplitude 31.1 pp) : assouplir la fenêtre de persistance (-1) améliore la détection au prix d'une légère hausse des fausses notifications, durcir la fenêtre ($+1$) tue plus de la moitié des détections borderline et coupe 80 % des fausses alertes. `contamination` et `mix_rate_thr` suivent la même logique de compromis avec une amplitude moitié moindre (13.3 pp). L'asymétrie observée pour `persist_hours` (+13.3 pp en assouplissant contre -31.1 pp en durcissant) confirme que la valeur retenue (7) se situe près du « bord supérieur » de la zone d'opérabilité, c'est-à-dire que le système privilégie la spécificité sans sacrifier excessivement la sensibilité.

Troisièmement, deux paramètres sont saturés à ± 1 cran sur ce benchmark : `alert_min` et `mi_z_high_thr`

produisent zéro changement sur les métriques retenues. Cela traduit un effet de seuil : la cohérence multi-sigaux (MIX) couvre le rôle de `alert_min` sur les cas testés, et le seuil de *spike Motion Index* (`mi_z_high_thr`) ne se déclenche que sur les cas *strong* dont le signal MI dépasse largement les voisins testés (2.0–2.4). Les deux paramètres concernés pourraient être affinés sur un benchmark plus difficile sans risque de régression sur la grille actuelle.

L'ensemble confirme que la configuration v5.2 GO retenue n'est pas un point isolé dans l'espace des paramètres mais une zone stable où les voisins immédiats préservent la décision GO/NO-GO et les ordres de grandeur des métriques.

4.2.9 Performance, scalabilité et intégrité

Le benchmark de performance complet porte sur le corpus versionné de 28 vaches et 37 839 lignes. Les résultats sont présentés dans le Tableau 4.24 et la Figure 4.10 : le temps d'exécution croît linéairement avec le nombre de vaches (≈ 0.6 s/vache), ce qui confirme la complexité linéaire d'Isolation Forest.

Tableau 4.24 Benchmark de performance du pipeline complet selon la fraction du corpus.

Fraction	Vaches	Lignes	Temps (s)	Lignes/s	Vaches/s
25%	7	11 493	4.43	2 596	1.58
50%	14	18 892	8.37	2 257	1.67
75%	21	30 272	13.24	2 286	1.59
100%	28	37 839	16.92	2 236	1.65




Figure 4.10 Scalabilité du pipeline.

La décomposition du temps cœur montre que la majeure partie du coût de calcul provient du détecteur IF, comme illustré dans la Figure 4.11 : Isolation Forest représente 89 % du temps de calcul, contre 8.2 % pour les *features* et 2.6 % pour les règles d'alerte.




Figure 4.11 Décomposition du temps cœur du pipeline sur 28 vaches.

Enfin, la stabilité des artefacts est vérifiée par un manifeste cryptographique SHA-256, conformément aux bonnes pratiques de traçabilité en apprentissage automatique (Sculley *et al.*, 2015). La vérification retourne zéro fichier manquant, zéro fichier modifié et zéro fichier inattendu. Cet élément complète les métriques de performance : il ne s'agit pas seulement d'un pipeline qui fonctionne, mais d'un pipeline dont les résultats de référence restent contrôlables dans le temps.

4.2.10 Analyse de la variabilité inter-vache

Le taux agrégé de 0.105 FN/vache-jour masque une variabilité inter-individuelle substantielle : les 28 vaches se répartissent en quatre groupes, du quasi-silence (≤ 0.024 FN/vache-jour, 7 vaches) aux profils très actifs (0.20–0.37, 7 vaches) dont le comportement naturellement irrégulier abaisse le seuil effectif de détection. Un tel phénomène est bien documenté dans la littérature sur la détection d'anomalies (Chandola *et al.*,

2009). Deux pistes d'amélioration en découlent : une calibration individuelle du seuil de contamination, et une pondération des alertes intégrant l'historique comportemental de chaque animal. L'analyse complète, incluant la distribution par quartile et les mécanismes de variabilité, est présentée en Annexe A.

4.3 Positionnement par rapport à la littérature

Les résultats obtenus dans ce mémoire doivent être mis en perspective avec les travaux publiés dans le domaine de la détection de boiterie par capteurs. Le Tableau 4.25 présente une comparaison synthétique des performances rapportées par six études représentatives, couvrant différents types de capteurs, de populations et de méthodes (Se = sensibilité, Sp = spécificité, FP = taux de faux positifs) ; les métriques ne sont pas directement comparables en raison de différences de protocole (voir analyse plus bas).

Tableau 4.25 Positionnement du système proposé par rapport aux travaux publiés.

Étude	Capteur	Se	Sp	Vaches	Méthode
Alsaad <i>et al.</i> (2012)	Pédomètre	90%	86%	36	Seuils sur activité
Chapinal <i>et al.</i> (2010)	Accéléromètre	76%	83%	48	Régression logistique
Beer <i>et al.</i> (2016)	IceTag	81%	87%	150	Régression + seuils
Thorup <i>et al.</i> (2015)	Accéléromètre	86%	89%	4 fermes	Modèle linéaire mixte
Lavrova <i>et al.</i> (2023)	Accéléromètre	72%	91%	6 fermes	Logistique à effets mixtes
Ce mémoire	Comportemental	100% ^a	90% ^b	28	IF + règles métier

^aDétection des cas forts (strong_detect_any = 1.000). ^bEstimée à partir du taux de fausses notifications (0.105/cow-day) et de la fuite nulle sur les cas non détectables. La comparaison directe avec les métriques Se/Sp classiques est limitée par l'absence de gold standard vétérinaire dans notre protocole.

La comparaison avec la littérature appelle plusieurs nuances importantes. Premièrement, les métriques ne sont pas directement comparables : les études citées utilisent un scoring locomoteur vétérinaire comme référence (gold standard), alors que notre protocole repose sur des injections synthétiques. Deuxièmement, la sensibilité de 100% rapportée ici concerne les cas forts uniquement ; sur les cas borderline, la détection tombe à 42%, ce qui illustre la limite d'un seuil de persistance conservateur. Troisièmement, notre corpus

(28 vaches, une ferme) est plus restreint que celui de Beer *et al.* (2016) (150 vaches) ou Lavrova *et al.* (2023) (6 fermes), ce qui limite la généralisabilité des résultats.

Malgré ces réserves, deux éléments différencient favorablement notre approche :

- *Profondeur de validation* : avec 9 504 exécutions sur 336 configurations, notre protocole évalue la stabilité du système sur un espace de paramètres bien plus large que les études citées, qui utilisent typiquement une seule configuration validée par cross-validation ;
- *Approche non supervisée* : contrairement aux méthodes supervisées (Chapinal *et al.*, 2010; Beer *et al.*, 2016; Lavrova *et al.*, 2023), notre système ne requiert pas d'annotations vétérinaires pour l'entraînement, ce qui le rend déployable sans campagne de scoring préalable. Cette propriété est particulièrement pertinente dans les contextes où l'expertise vétérinaire régulière n'est pas disponible (Rutten *et al.*, 2013).

4.3.1 Distribution des recouvrements temporels

La distribution des `best_iou` par scénario sur les configurations GO de v5.2 confirme les métriques agrégées : les cas forts se concentrent autour de 0.30–0.35 (localisation correcte de la journée et de la période), les cas borderline présentent une distribution bimodale avec un pic à zéro, et les cas non détectables restent strictement à zéro. La fragilité sur les cas faibles est cohérente avec les approches par seuil de persistance (Alsaad *et al.*, 2019). La figure détaillée est présentée en Annexe A.

4.3.2 Gel des seuils et traçabilité de la décision

À l'issue des campagnes de validation, les seuils finaux ont été gelés dans un fichier versionné (`final_thresholds_v1.json`), horodaté au 24 février 2026. Ce fichier documente les valeurs retenues (Tableau 4.3), les critères GO (Tableau 4.2) et la provenance des campagnes ayant conduit à cette sélection. Le manifeste SHA-256 protège ce fichier : toute modification future nécessite une nouvelle campagne de validation et un nouveau fichier de gel. Les détails sont présentés en Annexe A.

4.4 Validation exploratoire sur le corpus complémentaire IceTag 2019

La validation principale du pipeline repose sur des injections synthétiques contrôlées (sections précédentes). Pour compléter cette démarche, le pipeline gelé (paramètres identiques à ceux du Tableau 2.9) a

été appliqué sans modification au corpus complémentaire IceTag décrit à la Section 2.1.5 : 30 vaches de la même ferme (campus Macdonald), 93 187 bins de 15 minutes, automne 2019, capteur IceTag (prédécesseur de l'IceQube utilisé pour le corpus principal). L'objectif est double : vérifier la *portabilité technique* du pipeline vers une cohorte et un capteur différents, et examiner la *concordance* entre les alertes produites et les scores cliniques SLS disponibles pour 12 vaches.

4.4.1 Portabilité technique

Le pipeline s'exécute sans modification de code sur le corpus complémentaire converti au format standard. Les 30 vaches sont traitées en ≈ 25 secondes, avec une couverture de 100 % pour 29 vaches sur 30 (une vache présente une couverture de 79 % en raison de données manquantes en fin de période). Ce résultat confirme que l'architecture est indépendante du corpus d'entraînement initial et compatible avec un capteur de la même famille.

4.4.2 Concordance avec les scores cliniques SLS

Le Tableau 4.26 présente les résultats du pipeline pour les 12 vaches disposant de scores SLS, regroupées selon la classification clinique définie à la Section 2.1.5. Les notifications correspondent aux alertes de boiterie probable émises sur 34 jours d'observation (automne 2019) ; les scores SLS proviennent des évaluations de janvier et mars 2019 (décalage de 8 à 9 mois).

Tableau 4.26 Résultats du pipeline gelé sur les 30 vaches du corpus complémentaire IceTag 2019.

Vache	Groupe clinique	SLS	Épisodes	Notif.	Pts critiques
821	Boiteuse persistante	2→2	5	4	3
3444	Boiteuse aggravée	2→4	5	4	5
2057	Légère aggravée	1→2	4	4	11
5874	Boiteuse améliorée	2→1	4	3	3
5857	Boiteuse améliorée	2→1	2	2	3
2081	Intermédiaire	1→—	6	5	7
2063	Intermédiaire	1→0	7	4	5
3437	Intermédiaire	0→1	4	4	6
5875	Intermédiaire	0→1	4	3	15
8500	Intermédiaire	0→1	0	0	0
2078	Saine stricte	0→0	0	0	0
5879	Saine stricte	0→0	7	7	16
Sans score SLS ($n = 18$)		—	3.8 ^a	3.6 ^a	5.3 ^a

^aValeurs médianes ; étendue : 0–8 notifications, 0–17 points critiques.

4.4.3 Interprétation

Les résultats appellent trois observations :

1. *Cohérence partielle pour les cas stables.* Les cinq vaches du groupe *boiteuse stricte* ($SLS \geq 2$ à au moins une évaluation) déclenchent toutes des alertes (2 à 4 notifications sur 34 jours). La vache 2078 (saine stricte, $SLS = 0$ aux deux évaluations) ne déclenche aucune alerte. Ces cas sont cohérents avec les attentes cliniques.
2. *Contre-exemple.* La vache 5879 (saine stricte, $SLS = 0$ aux deux évaluations) déclenche 7 notifications, le nombre le plus élevé parmi les 12 vaches avec score. Ce résultat constitue un contre-exemple direct. Deux interprétations non exclusives sont possibles : (a) la vache a développé une boiterie entre mars et novembre 2019 (8 mois sans évaluation clinique), ou (b) le pipeline sur-détecte sur ce profil comportemental particulier.
3. *Séparation non discriminante.* Le nombre moyen de notifications est de 3.4 pour les boiteuses strictes ($n = 5$) et de 3.5 pour les saines strictes ($n = 2$). Ces effectifs sont trop faibles pour tout test statistique

formel ; l'absence de séparation observée peut refléter le décalage temporel autant qu'une limite du pipeline.

4.4.4 Limites et portée

Un tel résultat ne constitue pas une validation clinique. Le décalage de 8 à 9 mois entre les scores SLS (hiver 2019) et les données capteurs (automne 2019) interdit toute conclusion sur la capacité du pipeline à discriminer les animaux boiteux au moment de l'observation. Il démontre en revanche deux propriétés utiles :

- le pipeline est techniquement portable vers une cohorte et un capteur différents de la même exploitation, sans modification de code ni de paramètres ;
- les alertes produites sont partiellement cohérentes avec les antécédents cliniques lorsque le statut est stable (vaches 821, 3444, 2078), mais pas lorsque le statut a pu évoluer (vache 5879).

Une validation clinique synchrone, avec des scores SLS contemporains des données capteurs, reste nécessaire pour quantifier la sensibilité et la spécificité réelles du système. Cette perspective est discutée au Chapitre 5.

4.4.5 Synthèse du chapitre

En résumé, ce chapitre a présenté les résultats de validation du pipeline sur cinq campagnes totalisant 9 504 exécutions expérimentales, complétées par une validation exploratoire sur le corpus complémentaire IceTag 2019. Les principales conclusions sont :

1. Le pipeline détecte 100 % des cas forts avec une localisation temporelle correcte (best_iou médian ≈ 0.33) et maintient une fuite nulle sur les cas non détectables ;
2. Les fausses notifications sont contrôlées à 0.105 par cow-day, en dessous du seuil de tolérance rapporté dans la littérature (Rutten *et al.*, 2013) ;
3. L'ablation confirme que chaque composante (IF + règles) est nécessaire : l'IF seul manque de précision, les règles seules manquent de spécificité ;
4. La comparaison IF vs LOF révèle des profils complémentaires, ouvrant une perspective d'ensemble hybride ;
5. La validation exploratoire sur le corpus McGill confirme la portabilité technique du pipeline et une cohérence partielle avec les antécédents cliniques, sans toutefois permettre de conclusion clinique en raison du décalage temporel entre scores et données ;

6. La comparaison avec la littérature montre que, malgré l'absence de gold standard vétérinaire, le système atteint des performances compétitives grâce à la profondeur de sa validation et à son approche non supervisée.

CHAPITRE 5

DISCUSSION ET LIMITES

5.1 Points forts de l'approche

5.1.1 Positionnement méthodologique clair

Le système ne prétend pas diagnostiquer cliniquement la boiterie; il produit une alerte de boiterie probable, interprétable et exploitable comme aide à la décision. Ce positionnement explicite réduit le risque de surpromesse scientifique et respecte une exigence récurrente de la littérature : les systèmes de détection automatisée doivent être évalués dans leur contexte opérationnel plutôt que comparés à des standards cliniques dont les labels sont souvent absents ou incertains (Alsaad *et al.*, 2019).

5.1.2 Architecture hybride IF + règles métier

L'ablation montre qu'un détecteur d'anomalies seul produit des alertes impulsives (variante C : 100% de détection mais aucune précision temporelle), tandis qu'un système purement à règles devient rigide et générateur de faux positifs (variante B : $3.2\times$ plus de fausses alertes). Le couplage retenu permet d'obtenir des épisodes plus plausibles et des notifications plus défendables, conformément à l'approche préconisée par les travaux récents en élevage de précision (Michelena *et al.*, 2025).

5.1.3 Profondeur de validation

Peu de projets de cette envergure dépassent la simple démonstration visuelle. Ici, la validation combine injections manuelles (Tableau 4.6), grilles robustes multi-seeds sur 9 504 exécutions au total (Tableau 4.1), comparaison inter-versions avec 91.7% d'accord (Tableau 4.11), benchmark performance (Tableau 4.24) et vérification SHA des artefacts. Cette chaîne rend le projet beaucoup plus crédible qu'une simple interface appuyée sur quelques exemples choisis.

5.1.4 Honnêteté de l'ablation

L'ablation étendue apporte une discussion utile sur le choix du détecteur. La comparaison IF/LOF (Chapitre 4) révèle des profils complémentaires : IF domine sur la précision temporelle des cas forts, tandis que LOF capte mieux les cas borderline. IF est maintenu comme détecteur principal pour sa meilleure précision sur les cas

actionnables et sa complexité algorithmique favorable ($O(n \log n)$ contre $O(n^2)$). Une telle transparence illustre la démarche du mémoire : documenter les alternatives testées plutôt que les masquer.

Le Tableau 5.1 synthétise les principales forces et limites discutées dans les sections suivantes.

Tableau 5.1 Synthèse des forces et limites du système proposé.

Forces	Limites
Positionnement explicite (alerte, pas diagnostic)	Pas de validation clinique au sens strict
Architecture hybride IF + règles (interprétable)	Fragilité sur les cas borderline ($\sim 42\%$ en validation robuste finale)
Validation multi-niveaux (9 504 exécutions)	Mono-ferme, mono-capteur, 41 jours
Ablation honnête avec comparaison LOF	Validation LOF limitée au protocole v4
Scalabilité linéaire (≈ 0.6 s/vache)	IF représente 89% du temps de calcul
Traçabilité SHA-256 et reproductibilité	Seuils dépendants du corpus courant

5.2 Limites

5.2.1 Absence de labels cliniques exhaustifs

La validation est technique et méthodologique, pas clinique au sens fort. Les injections synthétiques simulent un comportement compatible avec la boiterie, mais ne sont pas des cas cliniques confirmés par un vétérinaire. Cette limite est inhérente au contexte du projet : les labels cliniques synchronisés par tranche de 15 minutes n'existent pas dans le corpus disponible. Elle est toutefois partagée par la majorité des travaux publiés dans le domaine (O'Leary *et al.*, 2020; Qiao *et al.*, 2021).

5.2.2 Cas borderline encore fragiles

Les scénarios limites (borderline) restent moins bien capturés que les cas forts. Sur l'ablation élargie (Tableau 4.15), la détection *any* pour les cas borderline atteint seulement 27% pour IF + règles et 40% pour LOF + règles. Un tel constat rejoint les observations de Chapinal *et al.* (2010), qui rapportent que les boiteries légères (score 2) sont les plus difficiles à détecter automatiquement, même avec des capteurs de haute précision. Il doit être assumé comme une limite du système.

5.2.3 Dépendance aux seuils

Même si les seuils ont été explorés et justifiés via une grille de 336 configurations (v5.2), ils restent liés au contexte expérimental du corpus courant. Un changement de capteur, de race, de saison ou de conditions d'élevage pourrait nécessiter un recalibrage. Ce constat est partagé par Thorup *et al.* (2015), qui observent des variations significatives de performance entre fermes avec les mêmes capteurs. Le gel des seuils est une mesure de reproductibilité, pas une garantie d'universalité.

5.2.4 Généralisation à confirmer

Les artefacts montrent une bonne stabilité interne sur le corpus présent (28 vaches, 37 839 lignes, 41 jours ; σ inter-seed de détection sur la configuration finale : voir Tableau 4.22), mais cette stabilité ne préjuge pas de la généralisation. La littérature rappelle que l'hétérogénéité des protocoles entre études reste un obstacle majeur au transfert d'un détecteur d'une exploitation à l'autre (Alsaad *et al.*, 2019; O'Leary *et al.*, 2020). Plus précisément, cinq axes de généralisation restent à valider avant tout déploiement clinique :

1. *Multi-fermes*. Le corpus provient d'une seule exploitation. Les profils d'activité dépendent de la conduite d'élevage (fréquence de traite, accès au parcours, conception des stalles), ce qui peut modifier la distribution des *features* de base (Steps, Motion Index, transitions) et donc recalibrer implicitement les seuils de règle et le contour de l'Isolation Forest. Un plan réaliste consisterait à ré-évaluer la configuration figée sur au moins 3 fermes indépendantes avant d'énoncer des performances cibles.
2. *Multi-capteurs*. Les données proviennent exclusivement du podomètre IceQube. Un changement de capteur (AfiAct, Smartbow, CowManager, accéléromètre brut au collier) modifie la définition opérationnelle des variables : un « pas » IceQube n'est pas un « pas » AfiAct, et le *Motion Index* n'existe pas chez tous les fournisseurs. Les *features* dérivées (*_rrz, *_d1_per_hour, *_vs_mm7) sont en revanche définies de manière *capteur-agnostique* à partir de séries temporelles brutes, ce qui laisse une voie de portage, mais qui doit être testée empiriquement.
3. *Multi-saisons*. La fenêtre d'observation (octobre–novembre) couvre une période automnale. Les schémas comportementaux peuvent différer en été (stress thermique, pâturage) ou en hiver (stabilisation prolongée, luminosité réduite). La normalisation robuste rolling (*_rrz) absorbe une partie des variations lentes, mais des effets de niveau persistants pourraient dégrader l'AUC de 0.956 (§4.2.2.2) observée sur ce corpus.

4. *Validation clinique des injections*. Les profils d'ablation (*strong*, *borderline*, *multisignal_persistent*) sont construits sur des hypothèses plausibles mais non calibrées contre des cas cliniques réels scorés par locomotion. Le chiffre d'*detection_any* de 47.8 % sur 90 cas injectés ne doit donc pas être lu comme une sensibilité clinique. La baseline pédométrique d'Alsaad (§4.2.4.2) est elle aussi évaluée sur ces mêmes injections, ce qui rend la *comparaison* valide (mêmes cas, même moteur de règles) sans pour autant trancher la question de la performance absolue en conditions réelles.
5. *Dérive temporelle*. Sur 41 jours, les dérives lentes (vieillessement du capteur, changement d'alimentation, variation parité/stade de lactation) ne peuvent pas être observées. Un suivi longitudinal de 6 à 12 mois permettrait d'estimer la fréquence de ré-étalonnage nécessaire (§5.7.2 a proposé un scénario de dérive calibration, mais son seuil de déclenchement est pour l'instant fixé sans données longitudinales).

En résumé, les performances rapportées au Chapitre 4 sont des performances *internes* à un corpus méthodologique, et non des performances attendues *en champ*. Le Tableau 5.1 cadre ce positionnement et la section « Perspectives » de la conclusion en tire les priorités de recherche.

5.2.5 Biais potentiels du corpus

Le corpus de 28 vaches sur 41 jours, bien que suffisant pour une validation méthodologique, présente des biais potentiels qui doivent être assumés :

- *Biais saisonnier* : les données couvrent octobre–novembre, une période automnale où les conditions de logement et de parcours peuvent influencer les comportements de manière spécifique. Les schémas comportementaux pourraient différer en été (pâturage, chaleur) ou en hiver (stabulation prolongée) ;
- *Biais de sélection* : les 28 vaches du corpus ne constituent pas un échantillon représentatif au sens épidémiologique. La composition du troupeau (parité, stade de lactation, race) n'est pas documentée dans les données capteurs ;
- *Biais d'injection* : les profils synthétiques simulent des déviations comportementales plausibles mais pas cliniquement validées. L'amplitude et la forme des perturbations injectées reposent sur des hypothèses raisonnables mais non calibrées contre des cas cliniques réels.

De tels biais ne remettent pas en cause la validité de la démarche méthodologique (validation reproductible, ablation, comparaison IF/LOF), mais ils délimitent la portée des conclusions : les performances rapportées

sont valides pour ce corpus, dans ces conditions, et la généralisation reste à confirmer.

5.3 Menaces à la validité

Toute étude empirique est exposée à des menaces qui peuvent limiter la portée de ses conclusions. Cette section complète les limites identifiées ci-dessus en les organisant selon le cadre classique de Shadish *et al.* (2002), adapté aux études en génie logiciel par Wohlin *et al.* (2012) et Feldt et Magazinius (2010).

Validité interne. Les injections synthétiques simulent des déviations comportementales plausibles mais ne reproduisent pas la pathophysiologie réelle de la boiterie : un animal cliniquement boiteux peut présenter des modifications plus complexes (Whay *et al.*, 2003). Les profils injectés constituent donc une approximation qui favorise potentiellement le détecteur. Par ailleurs, les variables d'entrée sont mécaniquement corrélées (une vache couchée plus longtemps est nécessairement moins active), ce qui amplifie le signal mais limite l'interprétabilité de la contribution individuelle de chaque variable. Enfin, le modèle IF est entraîné sur les 60 % premiers bins de chaque vache (`baseline_ratio` = 0.6), sous l'hypothèse que cette période représente un comportement normal. Si une vache est déjà boiteuse au début de l'observation, la baseline est contaminée et le modèle risque de normaliser un comportement pathologique. Une telle hypothèse est raisonnable dans un contexte de suivi continu (la boiterie clinique est un événement qui évolue dans le temps), mais elle n'a pas été vérifiée empiriquement sur le corpus principal faute de labels cliniques synchrones.

Validité externe. Les données proviennent d'une seule exploitation, d'un seul type de capteur (IceQube), sur 41 jours en période automnale. Le contexte expérimental est typique des élevages Holstein en stabulation libre ; les résultats ne sont pas directement transférables à d'autres races, systèmes de logement ou saisons (Galindo et Broom, 2000). La fenêtre temporelle restreinte ne permet pas non plus de capturer les variations comportementales à long terme.

Validité de construit. Le système produit une alerte de "boiterie probable", définie opérationnellement comme une déviation comportementale détectée par le pipeline. Ce construit ne correspond pas à la boiterie clinique, qui nécessite un examen physique et un score de locomotion validé (Sprecher *et al.*, 1997). La métrique IoU, empruntée à la vision par ordinateur (Everingham *et al.*, 2010), suppose que le recouvrement temporel est un indicateur pertinent de la qualité de détection, hypothèse raisonnable pour des épisodes continus mais potentiellement inadaptée pour des boiteries intermittentes.

Validité de conclusion. Les 90 cas par variante d'ablation suffisent pour détecter des différences marquées mais limitent la capacité à identifier des effets de taille modérée. Les résultats sont présentés principalement sous forme de moyennes agrégées ; une analyse appariée complémentaire avec IC95% a été ajoutée pour la comparaison IF/LOF, mais le mémoire ne propose pas de modélisation statistique hiérarchique complète ni d'intervalles pour l'ensemble des tableaux. La sensibilité de la performance à la configuration finale, qui constitue un point unique dans l'espace des 336 paramétrisations, fait l'objet d'une analyse locale dédiée (Section 4.2.8) qui montre qu'aucune perturbation à ± 1 cran ne fait basculer la décision GO/NO-GO ; une analyse globale de l'ensemble de l'espace des paramètres reste hors-périmètre.

5.4 Spécificité de la détection et diagnostic différentiel

Une question naturelle face à un système de détection de boiterie probable est celle de la *spécificité étiologique* : lorsqu'une alerte est émise, comment le système distingue-t-il une boiterie d'une autre cause possible de modification comportementale ? La présente section clarifie la portée réelle des alertes produites et documente les mécanismes par lesquels le pipeline limite (sans les éliminer) les principaux confondants cliniques.

5.4.1 Ce que détecte réellement le pipeline

Le système ne détecte pas la boiterie au sens clinique. Il détecte une *anomalie comportementale persistante sur des variables locomotrices*, conforme au positionnement explicite de l'introduction (« boiterie probable », et non diagnostic). Trois propriétés du pipeline orientent cette détection vers des signatures compatibles avec une boiterie plutôt que vers des anomalies comportementales génériques :

1. *Ciblage des variables locomotrices.* Les cinq variables utilisées (*Motion Index*, pas, temps couché, temps debout, transitions) sont le cœur de la locomotion bovine. Une pathologie qui n'affecte pas la locomotion (ex. : mammite subclinique sans signe systémique) ne déclenchera pas le système.
2. *Filtre de persistance ($K = 28$ bins, soit 7 h).* Les événements comportementaux brefs (pic d'activité isolé, bousculade, changement ponctuel de stalle) sont filtrés avant de pouvoir générer une notification.
3. *Cohérence multi-signaux (mode MIX).* Une vraie boiterie affecte typiquement plusieurs familles de signaux de manière corrélée : moins de pas, plus de temps couché, moins de transitions. Une perturbation qui n'affecte qu'une famille isolée est filtrée par la règle de cohérence.

5.4.2 Confondants cliniques et mécanismes de mitigation

Le Tableau 5.2 recense les principales causes non pathologiques ou pathologiques non-boiteuses susceptibles de modifier le comportement locomoteur d'une vache laitière, et indique pour chacune le mécanisme du pipeline qui limite le risque de fausse alerte.

Tableau 5.2 Confondants potentiels et mécanismes de mitigation par le pipeline.

Confondant	Risque de déclenchement	Mécanisme de mitigation
Œstrus (chaleurs)	Modéré à élevé	Signature d'activité <i>augmentée</i> (opposée à la boiterie); durée typique 6–18 h, parfois filtrée par la persistance de 7 h; croisement possible avec détection d'œstrus existante.
Mammite subclinique	Faible à modéré	Signature différente (léthargie isolée sans déséquilibre locomoteur cohérent); la cohérence multi-sigaux filtre les anomalies mono-famille.
Vêlage	Faible	Dates de vêlage connues de l'éleveur; exclusion triviale en pré-traitement. La modification comportementale est par ailleurs très brève à l'échelle de l'horizon de persistance.
Stress thermique	Très faible	Affecte l'ensemble du troupeau simultanément; la spécificité individuelle du pipeline (seule la vache cible réagit, cf. Tableau 4.8) filtre naturellement ces perturbations globales.
Changement de ration, stress social	Très faible	Mêmes arguments que le stress thermique : perturbation à l'échelle du troupeau, filtrée par la spécificité individuelle.
Problème podal non boiteux (ex. : lésion débutante)	Modéré	Peut déclencher une alerte; ce déclenchement est <i>cliniquement pertinent</i> , car il attire l'attention sur un animal à risque avant l'apparition d'une boiterie franche.

5.4.3 Positionnement clinique : outil de priorisation, pas de diagnostic

La portée des alertes doit être lue comme celle d'un *test de dépistage* (screening), et non d'un test diagnostique. Un test de dépistage est conçu pour identifier les animaux qui justifient une vérification plus approfondie ; le diagnostic différentiel définitif reste la prérogative du vétérinaire ou d'un éleveur expérimenté, sur la base d'un examen clinique, d'un score de locomotion (Sprecher *et al.*, 1997) ou d'un examen podal. Cette division du travail est cohérente avec la pratique du dépistage en médecine humaine : un test positif ne signe pas la maladie, il justifie une investigation.

Concrètement, une alerte produite par le système doit être interprétée comme : « cette vache présente une déviation comportementale persistante sur ses variables locomotrices ; une vérification terrain est recommandée ». Les alertes émises par le système déclenchent dans l'interface l'affichage d'un plan d'action clinique temporisé (Section 3.7), qui oriente l'utilisateur vers les étapes d'un examen vétérinaire structuré.

5.4.4 Limites assumées

Deux limites doivent être reconnues explicitement. D'une part, le pipeline ne permet pas, en l'état, de distinguer algorithmiquement une boiterie d'un œstrus prolongé sans information complémentaire : seule la signature statistique (activité *augmentée* typique de l'œstrus vs *diminuée* typique de la boiterie) offre une piste de différenciation, qui n'a pas été intégrée comme règle formelle. D'autre part, l'absence de *gold standard* clinique dans le corpus empêche toute mesure quantitative de la spécificité étiologique du système ; les arguments présentés ci-dessus sont qualitatifs et s'appuient sur la plausibilité mécanistique, non sur une validation empirique.

L'intégration de sources de données cliniques complémentaires (production laitière, température corporelle, dates de vêlage, diagnostics vétérinaires) constitue un axe d'amélioration naturel, cohérent avec les perspectives développées en Chapitre 5.9.3.

5.5 Mise en perspective avec la littérature

Le système proposé se situe dans la famille des approches hybrides non-supervisées appliquées à la détection de boiterie. À titre de comparaison, Lavrova *et al.* (Lavrova *et al.*, 2023) obtiennent une sensibilité d'environ 77% avec un modèle logistique à effets mixtes sur six fermes allemandes, en combinant activité, couchage et production laitière. Le présent projet atteint 90% de détection sur les cas forts (Tableau 4.15),

mais dans un contexte mono-ferme et sans labels cliniques. La comparaison directe des performances est donc délicate, conformément à la mise en garde d'Alsaad et al. (Alsaad *et al.*, 2019) sur l'hétérogénéité des protocoles.

Michelen et al. (Michelen, 2025) montrent que le choix de l'algorithme non supervisé dépend du compromis visé entre sensibilité et faux positifs. Ce constat est exactement celui que l'ablation illustre dans ce projet : IF et LOF représentent deux points différents sur cette courbe de compromis, sans supériorité universelle de l'un sur l'autre.

La revue de Chandola et al. (Chandola *et al.*, 2009) sur la détection d'anomalies souligne que les méthodes basées sur l'isolation et celles basées sur la densité locale ont des profils de performance complémentaires : les premières excellent sur les anomalies globales (points isolés dans l'espace des *features*), les secondes sur les anomalies contextuelles (points normaux globalement mais déviants localement). La validation exploratoire IF/LOF de ce projet confirme empiriquement cette distinction théorique.

Par rapport à des approches supervisées comme celles d'Alsaad et al. (Alsaad *et al.*, 2012), qui obtiennent des performances élevées mais sur des cohortes labellisées cliniquement, le présent projet se distingue par sa capacité à fonctionner en l'absence de labels, tout en maintenant une validation multi-niveaux explicite. Cette différence de paradigme est structurelle : la détection non supervisée est moins précise au sens clinique, mais plus déployable dans les contextes réels où les labels cliniques sont rares ou absents (Qiao *et al.*, 2021).

Enfin, les travaux récents de Palma et al. (Palma *et al.*, 2025) sur l'IA en élevage laitier identifient la boiterie comme l'un des cas d'usage où la combinaison capteurs + règles métier offre le meilleur rapport entre déployabilité et fiabilité. Le présent projet s'inscrit directement dans cette famille d'approches.

Le Tableau 4.25 (Chapitre 4) situe le présent projet par rapport aux travaux les plus proches. La sensibilité élevée sur les cas forts (90-100%) doit être relativisée : elle est mesurée sur des injections synthétiques, pas sur des cas cliniques confirmés. En revanche, aucun des travaux cités ne propose une validation multi-niveaux aussi étendue (9 504 exécutions, ablation 4 variantes, vérification d'intégrité), ce qui constitue la contribution distinctive de ce mémoire.

5.6 Comparaison avec les systèmes commerciaux

Il est pertinent de situer le système par rapport aux solutions commerciales déployées en élevage. Le Tableau 5.3 compare trois systèmes représentatifs.

Tableau 5.3 Comparaison du système proposé avec des solutions commerciales de suivi comportemental bovin.

Système	Capteur	Algorithme	Transparence	Validation publiée
CowManager	Boucle auriculaire	Propriétaire (boîte noire)	Faible	Études indépendantes limitées
IceQube / IceTag	Patte (accéléromètre)	Seuils + modèles internes	Partielle	Beer <i>et al.</i> (2016)
Heatime / SCR	Collier (ruminantion + activité)	Propriétaire	Faible	Stangaferro <i>et al.</i> (2016)
Ce mémoire (code ouvert)	Accéléromètre Totale	IF + règles 9 504 exécutions, ablation, SHA		

Le contraste principal est structurel : là où les systèmes commerciaux fonctionnent comme des boîtes noires rarement évaluées de manière indépendante (Rutten *et al.*, 2013), le pipeline proposé est entièrement documenté et validé quantitativement. En contrepartie, ces systèmes bénéficient d'avantages opérationnels (intégration aux logiciels de traite, calibration multi-fermes, support technique) que le prototype académique ne possède pas.

5.7 Implications pratiques pour l'éleveur

En configuration finale, le système produit 0.105 notification par vache-jour (Tableau 4.9), soit environ 10 à 11 alertes quotidiennes pour un troupeau de 100 vaches. Ce volume reste en dessous du seuil critique

au-delà duquel les éleveurs cessent de consulter les alertes ($\sim 40\%$ de faux positifs, (Rutten *et al.*, 2013)), et demeure compatible avec une consultation matinale avant la première traite.

L'asymétrie des erreurs justifie l'arbitrage opérationnel retenu. Un faux positif coûte 5–10 minutes de vérification ; un faux négatif se traduit par un animal souffrant non traité à temps, avec un coût estimé entre 75 et 300 USD par cas (Green *et al.*, 2002; Rodrigues *et al.*, 2017). Le choix de privilégier la précision temporelle (IF + règles) sur la sensibilité maximale (LOF seul) vise à préserver la confiance de l'éleveur dans le système.

Le Tableau 5.4 présente un scénario détaillé d'intégration dans la journée type d'un élevage de 100 vaches (troupeau Holstein, stabulation libre).

Tableau 5.4 Scénario de journée type pour un élevage de 100 vaches.

Moment	Action	Durée estimée	Sortie attendue
5h45	Exécution automatique du pipeline	≈ 1 min (100 vaches)	Fichier d'alertes horodaté
6h00	Consultation des alertes (interface ou CSV)	5–8 min	Liste de 10–11 vaches prioritaires, avec score de confiance
6h15	Traite du matin : observation ciblée	2–3 min/vache signalée	Score locomoteur rapide (1–5) pour chaque vache signalée
7h00	Décision vétérinaire ou traitement	Selon gravité	Appel vétérinaire si score ≥ 3 ; soins locaux si score 2
14h00	Traite du soir : re-vérification rapide	1 min/vache signalée	Confirmer la résolution ou escalader
Vendredi	Bilan hebdomadaire	10 min	Récidives, tendances troupeau, ajustement éventuel

Un tel scénario mobilise environ 30 à 40 minutes supplémentaires par jour pour un éleveur de 100 vaches. Appliqué à une exploitation déjà équipée de capteurs IceQube, ce qui est le cas typique, le pipeline s'intègre sans acquisition de nouveau matériel.

5.7.1 Analyse coût-bénéfice

La viabilité économique d'un système de détection précoce repose sur l'équilibre entre les coûts évités grâce aux interventions plus rapides et les coûts opérationnels liés à la vérification des alertes. Le Tableau 5.5 présente ce bilan pour trois tailles de troupeau, sous les hypothèses conservatrices suivantes : prévalence 25 %, coût moyen par cas non détecté de 200 USD, réduction de 40 % avec détection précoce, 0.5 h/jour pour la vérification des alertes.

Hypothèses de calcul. Les coûts évités s'appuient sur les estimations de Green *et al.* (2002) (perte de production 270–574 kg/lactation) et de Bruijn *et al.* (2010) (coûts vétérinaires directs et réforme anticipée). Une détection précoce réduit le coût par cas de 30 à 50% en permettant une intervention avant l'aggravation clinique, soit une économie de 60–100 USD par cas détecté à temps (Rodrigues *et al.*, 2017). Le coût opérationnel est estimé à 30 min/vache-jour d'alerte à 20 USD/h, mais chaque notification correspond le plus souvent à un épisode en cours et non à une nouvelle vache (le taux de *cas distincts* est significativement inférieur au nombre brut d'alertes).

Tableau 5.5 Estimation indicative du coût-bénéfice du système pour différentes tailles de troupeau.

Troupeau	Cas/an	Coûts évités (USD)	Coût vérif./an (USD)	Coût non- détectés	Solde net (USD)
50 vaches	12	+960	1 825	–240	–1 105
100 vaches	25	+2 000	3 650	–500	–2 150
200 vaches	50	+4 000	7 300	–1 000	–4 300

Interprétation. Le solde est négatif dans ces hypothèses, ce qui reflète honnêtement la limite du prototype actuel : les alertes sont comptées individuellement par bin de 15 minutes, alors que l'éleveur ne vérifierait en pratique qu'une fois par jour les animaux signalés. En appliquant le coût de vérification au nombre de *vaches distinctes signalées* plutôt qu'au nombre d'alertes brutes, l'équilibre s'améliore sensiblement. De plus, l'analyse n'inclut pas les bénéfices indirects de la détection précoce : réduction de la réforme involontaire, amélioration de la fertilité, bien-être animal, et réduction de la charge mentale liée à la surveillance manuelle quotidienne.

Au final, ces chiffres soulignent deux axes prioritaires pour les travaux futurs : (i) un regroupement intelligent des alertes par épisode et par animal pour réduire la charge de vérification, et (ii) une calibration individuelle

par vache (voir Section 4.2.10) pour limiter les sur-alertes sur les animaux naturellement actifs. Avec ces améliorations, un troupeau de 100 vaches pourrait dépasser le seuil de viabilité économique.

5.7.2 Architecture opérationnelle de bout-en-bout

Au-delà de la journée type (Tableau 5.4), la viabilité opérationnelle du système dépend de trois propriétés qui n'apparaissent ni dans les métriques événementielles ni dans le bilan coût-bénéfice : la *latence* de l'alerte, la *distribution des responsabilités* entre l'éleveur, le vétérinaire et le technicien, et la *gestion des exceptions*. Cette sous-section explicite ces propriétés pour un déploiement réaliste sur une ferme équipée de capteurs IceQube connectés à un logiciel de gestion de troupeau.

5.7.2.0.1 Budget de latence.

La latence de bout-en-bout, c'est-à-dire le temps écoulé entre le moment où une anomalie comportementale se produit dans l'étable et le moment où l'éleveur reçoit la notification, se décompose en quatre composantes dont les ordres de grandeur sont résumés au Tableau 5.6.

Tableau 5.6 Budget de latence du système de bout-en-bout (100 vaches, fréquence 15 min, capteurs IceQube).

Étape	Description	Ordre de grandeur
Acquisition capteur	Agrégation 15 min sur le collier	≤ 15 min
Téléchargement	Passerelle Wi-Fi ou cellulaire → base locale	1–5 min
Exécution pipeline	Features + IF + règles (0.6 s/vache, cf. §4.2.9)	1–2 min
Notification	Écriture CSV, push e-mail ou interface	< 1 min
Total	Budget de latence bout-en-bout	20–25 min

Un tel budget est compatible avec l'usage visé (consultation matinale avant la traite) mais n'est pas compatible avec une détection en temps réel de chutes ou de ruptures accidentelles, pour lesquelles le délai de 15 min d'agrégation du capteur constitue un plancher incontournable. Toute latence inférieure à 20 min

nécessiterait un changement de résolution capteur (non couvert par le matériel actuel) ou une détection sur bins bruts sans fenêtre de confirmation, au prix d'une explosion attendue des faux positifs.

5.7.2.0.2 Rôles et responsabilités.

Le système ne produit qu'un signal de triage; toute action clinique reste sous responsabilité humaine. Le Tableau 5.7 précise la matrice RACI-lite (*Responsable, Approuve, Consulté, Informé*) pour les étapes clés du processus.

Tableau 5.7 Matrice de responsabilités pour le workflow de détection.

Étape	Éleveur	Vétérinaire	Technicien	Système
Maintenance capteurs	A	–	R	I
Exécution quotidienne	I	–	C	R
Consultation alertes	R	–	–	I
Vérification terrain	R	C	–	I
Diagnostic différentiel	C	R	–	–
Décision de traitement	A	R	–	–
Saisie retour clinique	R	C	–	I
Recalibration annuelle	C	–	R	–

Un point important ressort de cette matrice : le système n'est *responsable* que de deux étapes (exécution, notification), et n'a jamais de rôle d'approbation. Ce positionnement, cohérent avec la catégorie "outil de priorisation, pas de diagnostic" défendue en Section 5.4, limite l'exposition réglementaire du projet, puisqu'il ne relève pas d'un dispositif médical vétérinaire au sens du règlement européen 2017/746 ou de son équivalent canadien. L'éleveur reste l'unique responsable de la vérification terrain, le vétérinaire du diagnostic, et l'équipe technique de la maintenance capteurs, soit trois compétences déjà présentes dans une exploitation équipée de capteurs.

5.7.2.0.3 Plan de contingence.

Trois scénarios d'exception méritent un protocole explicite pour éviter qu'une défaillance dégrade la confiance dans l'ensemble du système :

1. *Panne capteur sur une ou plusieurs vaches.* Le pipeline détecte naturellement l'absence de données d'entrée (aucun bin pour une vache donnée sur une fenêtre de 24 h) et n'émet aucune alerte pour cette vache, plutôt qu'une fausse négative silencieuse. Un rapport quotidien liste les vaches sans signal, déclenchant une vérification matérielle par le technicien. L'absence d'alerte sur un animal sans capteur *ne doit jamais être interprétée comme une absence de boiterie* : c'est la raison d'être du rapport parallèle.
2. *Indisponibilité du vétérinaire.* Lorsque le vétérinaire référent ne peut être joint, l'alerte reste active dans l'interface sur 72 h (équivalent d'un long week-end) et l'éleveur peut escalader vers un second vétérinaire via le contact de secours. Les alertes répétitives sur la même vache sont fusionnées pour éviter la fatigue d'alerte, conformément à l'axe (i) identifié dans l'analyse coût-bénéfice.
3. *Dérive de calibration.* La calibration (Section 4.2.2.4) est vérifiée en continu par comparaison de la distribution empirique du score `if_anom_k_max` à la distribution de référence du corpus d'entraînement. Un test de Kolmogorov-Smirnov glissant à $p < 0.01$ déclenche un drapeau de recalibration ; tant que le drapeau est levé, les probabilités calibrées affichées à l'éleveur sont remplacées par le score ordinal brut et une mention explicite ("*calibration en cours de vérification*").

5.7.2.0.4 Boucle de rétroaction clinique.

La Figure 5.2 (p. 115) suggère une boucle de retour d'expérience comme perspective d'amélioration. Concrètement, chaque vérification terrain produit un triplet (*alerte, score locomoteur observé, décision prise*) qui, agrégé sur 3 à 6 mois, permettrait deux raffinements : (a) un ré-entraînement annuel de la régression isotone de calibration sur les *vraies* étiquettes cliniques (et non plus la distinction strong vs borderline simulée), et (b) une calibration par vache individuelle (§4.2.10) informée par le taux de vrais positifs historique de cet animal. Aucun des deux raffinements ne modifie l'architecture : ils se branchent sur la même régression isotone déjà validée sur corpus synthétique, avec un apprentissage continu transparent pour l'éleveur.

5.8 Perspectives de déploiement

Le passage d'un prototype académique à un outil opérationnel en ferme nécessite de combler plusieurs écarts. Le benchmark de performance (0.6 s/vache) garantit une exécution quotidienne rapide, mais l'intégration aux logiciels de gestion de troupeau, la calibration multi-fermes et la validation clinique terrain restent à réaliser. Le Tableau 5.8 synthétise ces conditions.

Tableau 5.8 Conditions de déploiement opérationnel et statut dans le projet actuel.

Condition	Statut	Effort estimé
Performance (<5 min/troupeau)	Satisfait	-
Reproductibilité (seeds, SHA)	Satisfait	-
Calibration mono-ferme	Satisfait	-
Intégration logiciel de gestion	Non couvert	Moyen
Calibration multi-fermes	Non couvert	Important
Interface éleveur simplifiée	Prototype	Moyen
Validation clinique terrain	Non couvert	Important

5.8.1 Retour sur la validation exploratoire IceTag 2019

La Section 4.4 a présenté les résultats de l'application du pipeline gelé au corpus complémentaire IceTag (30 vaches, même ferme, automne 2019). La portabilité technique est confirmée, et les alertes sont partiellement cohérentes avec les antécédents cliniques pour les cas stables (vaches 821, 3444, 2078). En revanche, le cas de la vache 5879 (saine stricte mais fortement alertée) et les effectifs trop réduits ($n = 5$ vs $n = 2$) empêchent de conclure à une validation clinique.

Une telle limitation est essentiellement imputable au décalage de 8 à 9 mois entre les scores SLS (hiver 2019) et les données capteurs (automne 2019). Une validation clinique synchrone, dans laquelle les évaluations locomotrices seraient contemporaines des enregistrements capteurs, constitue la prochaine étape nécessaire. Une telle étude permettrait de quantifier la sensibilité et la spécificité réelles du système contre un gold standard vétérinaire, et de déterminer si les alertes observées sur la vache 5879 reflètent une boiterie acquise entre les évaluations ou une sur-détection du pipeline. La généralisation inter-fermes resterait également à confirmer.

5.9 Considérations d'usage et éthique

5.9.1 Responsabilité algorithmique et bien-être animal

L'adoption d'un système de détection crée une obligation implicite envers les animaux surveillés (Broom, 2017) : un faux négatif n'est pas une simple erreur statistique, mais un animal souffrant non identifié à temps

(Whay *et al.*, 2003). Une telle asymétrie éthique justifie le choix de privilégier la précision temporelle sur la sensibilité maximale, et impose que la notification soit toujours suivie d'une vérification terrain, idéalement articulée avec un scoring locomoteur (Sprecher *et al.*, 1997; AHDB, 2025b; DairyNZ, 2025a). Comme le soulignent Estévez-Moreno *et al.* (2019), un système qui génère trop de bruit peut paradoxalement dégrader le bien-être animal en créant un faux sentiment de sécurité.

5.9.2 Confiance et adoption

La confiance dans la fiabilité des alertes est souvent plus déterminante que la performance brute (Bewley *et al.*, 2015; Venkatesh *et al.*, 2003). Le phénomène de *fatigue d'alerte* (Rutten *et al.*, 2013) constitue le principal obstacle à l'adoption durable : les éleveurs cessent de consulter les notifications au-delà d'un seuil critique de faux positifs. Le présent système, avec 0.105 notification par vache-jour en configuration MIX, reste sous ce seuil. La transparence des règles métier (seuil de score, fenêtre glissante, cooldown) constitue un levier supplémentaire de confiance, en distinguant l'approche des systèmes commerciaux fonctionnant comme des boîtes noires (cf. Tableau 5.3).

5.9.3 Protection des données

Les données capteurs révèlent indirectement les pratiques d'élevage et constituent un actif informationnel sensible dont la propriété reste largement non résolue (Wolfert *et al.*, 2017). Le présent projet, en fonctionnant entièrement en local, préserve la souveraineté de l'éleveur sur ses données. Plus largement, trois choix de conception répondent aux principes d'IA responsable (Carbonell, 2016) : traçabilité complète (versionnage, SHA-256), documentation explicite des limites, et architecture locale sans centralisation sur des serveurs tiers (Palma *et al.*, 2025; Michelena *et al.*, 2025).

La Figure 5.1 synthétise le profil du système proposé sur six dimensions complémentaires. Les forces (sensibilité forte, maîtrise des faux positifs, scalabilité, interprétabilité) contrastent avec la faiblesse attendue en généralisation multi-fermes (0.30), conformément aux limites du corpus. Ce type de représentation permet de visualiser les forces et les faiblesses du pipeline de manière globale et de comparer différentes configurations ou approches alternatives.




Figure 5.1 Profil radar du système sur six dimensions d'évaluation.

La Figure 5.2 illustre le positionnement du système dans le flux décisionnaire d'un élevage : la notification est un signal de triage, la décision finale revenant à l'opérateur, et les flèches pointillées indiquent une boucle de retour d'expérience envisagée comme perspective d'amélioration.




Figure 5.2 Positionnement du système dans le flux décisionnaire d'un élevage.

En résumé, ce chapitre a mis en perspective les forces et les limites du système, identifié les menaces à la validité et discuté les considérations éthiques liées à son déploiement. La conclusion qui suit synthétise les contributions principales de ce mémoire et propose des perspectives de travail futur à court, moyen et long terme.

CONCLUSION

Synthèse

Ce mémoire avait pour objectif de concevoir un système reproductible de détection de boiterie probable à partir de données capteurs bovines, tout en conservant une logique interprétable et scientifiquement défendable. Cet objectif est atteint.

Le système proposé combine un détecteur d'anomalies non supervisé (Isolation Forest) avec des règles métier explicites (persistance temporelle, cohérence multi-sigaux, espacement des notifications). Cette architecture hybride transforme des signaux capteurs bruts et bruités en épisodes de boiterie probable, interprétables et actionnables pour le suivi d'élevage.

Rappel des résultats principaux

La validation du système a été conduite à deux niveaux complémentaires :

- *Validation manuelle* (v2.1) : les deux événements détectables injectés sont récupérés avec un recouvrement strict ($IoU \geq 0.20$), tandis que l'événement volontairement non détectable reste silencieux. L'impact sur le troupeau est localisé à la seule vache cible (+2 notifications), les 27 autres animaux restant strictement stables ;
- *Validation robuste* : sur 9 504 exécutions couvrant 336 configurations, le système détecte 100% des cas forts en détection brute ($strong_detect_any_mean=1.000$), atteint un recouvrement strict moyen de 0.667 sur ces cas forts, maintient une fuite nulle sur les scénarios non détectables, et contrôle les fausses notifications à 0.105 par vache et par jour. L'accord de décision entre les campagnes v5.1 et v5.2 atteint 91.7%, confirmant la stabilité de la calibration ;
- *Ablation élargie* : l'étude sur 90 cas par variante montre que chaque composante du pipeline est nécessaire. L'IF seul détecte tout mais sans précision temporelle ; les règles seules génèrent $3.2\times$ plus de fausses alertes. LOF + règles obtient le meilleur compromis empirique sur ce benchmark, ouvrant une piste d'amélioration crédible. Les écarts entre variantes sont confirmés par des tests statistiques appariés (McNemar exact, Wilcoxon signed-rank) ;

- *Comparaison à une baseline et calibration* : la comparaison à la baseline pédométrique historique d'Alsaad (2012) s'appuie sur des intervalles de confiance à 95 % par bootstrap (B=20 000), et les scores bruts du détecteur sont recalibrés par régression isotonique avec IC95 par bootstrap (B=2 000), atteignant Brier = 0.087 [IC95 % : 0.083 ; 0.091] et ECE = 0.015 [IC95 % : 0.010 ; 0.021] ;
- *Interprétabilité* : une analyse SHAP (TreeExplainer sur Isolation Forest) et des courbes ROC/précision-rappel complètent les règles métier en documentant l'importance relative des variables dérivées utilisées par le détecteur.

Le benchmark de performance confirme une scalabilité linéaire (≈ 0.6 seconde par vache), compatible avec un déploiement en temps raisonnable sur des troupeaux de taille courante. Une matrice RACI documente l'intégration opérationnelle du système dans le workflow de ferme (éleveur, vétérinaire, technicien, système).

Contribution

La contribution principale ne réside pas dans l'invention d'un nouvel algorithme théorique, mais dans l'assemblage rigoureux d'un système appliqué et sa validation défendable. Le projet délivre :

1. un pipeline complet et modulaire, depuis l'ingestion des données capteurs jusqu'aux notifications ;
2. un protocole de validation en deux niveaux, documentant explicitement les forces et les limites du système ;
3. une étude d'ablation honnête, qui ne masque pas les alternatives crédibles, et étayée par des tests appariés (McNemar exact, Wilcoxon signed-rank) ;
4. une comparaison à une baseline pédométrique historique (Alsaad 2012) avec intervalles de confiance à 95 % par bootstrap, et une calibration isotonique des scores assortie des métriques Brier et ECE ;
5. une couche d'interprétabilité (SHAP TreeExplainer, courbes ROC/précision-rappel) complémentaire aux règles métier ;
6. une interface interactive (dashboard Streamlit) rendant les alertes directement exploitables par l'utilisateur final (visualisation par vache, classement du troupeau, carte de chaleur temporelle) ;
7. une matrice RACI documentant l'intégration opérationnelle du système dans le workflow de ferme ;
8. une traçabilité expérimentale complète (SHA-256), garantissant que les résultats présentés sont reproductibles et auditaibles.

Limites

La principale limite du système est l'absence de validation clinique synchrone : les performances rapportées reposent sur des injections synthétiques, pas sur des cas de boiterie confirmés par un vétérinaire. Une validation exploratoire sur le corpus complémentaire IceTag 2019 (30 vaches de la même ferme, 12 avec scores SLS) a confirmé la portabilité technique du pipeline et une cohérence partielle avec les antécédents cliniques, sans toutefois permettre de conclusion clinique en raison du décalage de 8 à 9 mois entre les évaluations et les données capteurs (Section 4.4). Cette limite est mise en perspective par la profondeur du protocole de validation interne : 9 504 exécutions sur 336 configurations, ablation à 4 variantes, stabilité inter-seeds, et traçabilité cryptographique des résultats. La fragilité sur les cas borderline, la dépendance aux seuils calibrés sur un seul corpus, et la généralisation à d'autres fermes et capteurs restent des axes d'amélioration. Ces limites sont partagées par la majorité des travaux publiés dans le domaine.

Disponibilité

Le code source du pipeline, les scripts de validation et les paramètres gelés sont versionnés dans un dépôt Git privé. La version de référence du mémoire correspond au tag `memoire-v2`, accompagné des manifestes d'intégrité SHA-256 des artefacts expérimentaux. Le code et les artefacts non confidentiels sont disponibles sur demande auprès de l'auteur. Les données brutes capteurs ne peuvent être diffusées pour des raisons de confidentialité, mais les profils d'injection, les paramètres de chaque campagne et la procédure de reproduction (Annexe A) permettent de reproduire intégralement la démarche sur de nouvelles données.

Perspectives

Plusieurs axes de travail futur sont identifiés :

1. *Validation multi-fermes* : étendre la validation à de nouveaux corpus provenant de fermes et de systèmes capteurs différents, afin de tester la généralisabilité des seuils et de l'architecture ;
2. *Labels cliniques* : intégrer des labels cliniques mieux synchronisés lorsque des collaborations vétérinaires le permettent, afin de calculer des métriques de performance au sens clinique strict ;
3. *Ensemble hybride IF-LOF* : la validation exploratoire (protocole v4, 288 exécutions) révèle des profils complémentaires entre les deux détecteurs : IF plus précis temporellement sur les cas forts, LOF plus

sensible sur les cas borderline (Chapitre 5). Un ensemble hybride combinant ces forces constitue une piste d'amélioration crédible, à valider sur les protocoles v5.1 et v5.2 ;

4. *Enrichissement des signaux* : explorer l'ajout de variables physiologiques (production laitière, température, poids) et environnementales (météo, saison) pour améliorer la spécificité de la détection ;
5. *Déploiement opérationnel* : évaluer le système dans un contexte d'utilisation réelle, avec des retours d'éleveurs et de vétérinaires sur l'utilité et l'acceptabilité des alertes produites.

ANNEXE A

DÉTAILS DE VALIDATION ET REPRODUCTIBILITÉ

Paramètres figés

La configuration finale retenue est gelée après les campagnes de validation. Elle fixe notamment un intervalle de 15 minutes, une contamination de 0.06, une fenêtre de persistance de 7 heures, un minimum de 2 bins anomaux par fenêtre, un mode de cohérence multi-signaux (MIX) avec un seuil de taux d'anomalies de 0.24, un cooldown de 12 heures et un seuil z-score sur le *Motion Index* de 2.2. Le Tableau 2.9 (Chapitre 2) présente ces paramètres en détail. Un fichier de référence documente la provenance expérimentale de ces choix et les campagnes de validation associées.

Grille de paramètres explorée

Le Tableau A.1 présente la grille complète de paramètres explorée au cours des campagnes de validation robuste. Cette grille a été élargie progressivement de v4 (12 configurations) à v5.2 (336 configurations).

Tableau A.1 Grille de paramètres explorée dans les validations robustes. Les colonnes v4/v5.1/v5.2 donnent le nombre de valeurs testées pour chaque paramètre; le nombre de configurations est le *produit* de ces comptes.

Paramètre	Valeurs explorées (union des campagnes)	v4	v5.1	v5.2
contamination	0.05, 0.06, 0.07, 0.08	3	3	4
persist_hours	6, 7, 8	2	2	3
alert_min	2, 3	1	1	2
mix_mode	MIX	1	1	1
mix_rate_thr	0.16, 0.18, 0.20, 0.22, 0.24, 0.28, 0.34	2	4	7
mi_z_high_thr	2.2, 2.5	1	2	2
Total configs (= produit)		12	48	336
Seeds		8	8	8
Scénarios		3	3	3
Total exécutions		288	1152	8 064

L'élargissement progressif de la grille permet de vérifier que les seuils retenus ne sont pas un optimum local fragile, mais une zone de stabilité dans l'espace des paramètres. La colonne "v5.2" correspond à la grille la plus large, utilisée pour le verdict final de robustesse.

Campagnes de référence

Les principales campagnes de validation utilisées dans ce mémoire sont les suivantes :

- *Validation manuelle v2* : première campagne d'injections détectables et non-détectables, servant de référence historique ;
- *Validation manuelle v2.1* : campagne de consolidation alignée sur les seuils finaux (`persist_hours` = 7) ;
- *Validation robuste v4* : 288 exécutions, grille de 12 configurations, 3 scénarios, 8 seeds ;
- *Validation robuste v5.1* : 1 152 exécutions, grille élargie à 48 configurations, ajout des paramètres `mi_z_high_thr` et de seuils supplémentaires ;
- *Validation robuste v5.2* : 8 064 exécutions, grille complète de 336 configurations, vérification de stabilité à grande échelle ;
- *Validation exploratoire LOF* : 288 exécutions selon le protocole v4, avec LOF comme détecteur en remplacement d'IF (comparaison au niveau événement) ;
- *Benchmark de performance* : mesure de scalabilité sur le corpus complet, avec décomposition du temps par composante ;
- *Ablation étendue* : 90 cas par variante (3 vaches $\times$ 3 profils $\times$ 10 seeds), comparaison IF/LOF/règles seules.

Au total, les campagnes de validation représentent 9 504 exécutions expérimentales indépendantes, générant plus de 28 000 évaluations événementielles individuelles.

Détails des profils d'injection

Les injections synthétiques modifient les colonnes brutes du capteur (*Steps*, *Motion Index*, *Lying Time*, *Standing Time*, *Transitions*) en appliquant des multiplicateurs par phases. Le Tableau A.2 détaille les amplitudes utilisées pour le profil `detectable_strong` ; les phases y alternent entre repos (proche de 0) et épisode (valeurs élevées) toutes les 6 bins (≈ 1 h 30).

Tableau A.2 Multiplicateurs d'injection pour le profil `detectable_strong`.

Signal	Phase repos	Phase épisode
<i>Steps</i>	0.02 – 0.10	1.80 – 2.80
<i>Motion Index</i>	0.01 – 0.08	2.00 – 3.40
<i>Lying Time</i>	2.60 – 4.20	0.65 – 1.10
<i>Standing Time</i>	0.04 – 0.20	1.25 – 2.10
<i>Transitions</i>	0.03 – 0.15	3.00 – 5.20

Les multiplicateurs sont tirés uniformément dans les intervalles indiqués, ce qui introduit une variabilité réaliste entre injections. Le Tableau A.3 compare les quatre profils d'injection utilisés dans les campagnes de validation ; les valeurs indiquent l'intervalle [min, max] des multiplicateurs appliqués aux signaux bruts.

Tableau A.3 Multiplicateurs d'injection pour les quatre profils.

Signal	Strong	Multisignal	Borderline	Hidden
<i>Steps</i> (épisode)	1.80–2.80	1.40–2.20	1.35–1.95	~0.86
<i>Motion Index</i> (ép.)	2.00–3.40	1.60–2.80	1.70–2.45	~0.86
<i>Lying Time</i> (ép.)	0.65–1.10	0.70–1.30	0.62–0.98	1.00
<i>Standing Time</i> (ép.)	1.25–2.10	1.10–1.90	1.15–1.70	1.00
<i>Transitions</i> (ép.)	3.00–5.20	2.50–4.80	1.85–3.05	~0.86
Familles touchées	5/5	5/5	5/5	1/5
Amplitude relative	forte	modérée	faible	quasi-nulle

Le profil *hidden* (non détectable) constitue le contrôle négatif : il ne modifie qu'une seule famille de signaux avec un multiplicateur proche de 1 ($\mathcal{N}(0.86, 0.04)$, clippé à $[0.70, 0.98]$), ce qui produit une variation indistinguable du bruit naturel. La graduation des amplitudes entre *strong*, *multisignal*, *borderline* et *hidden* permet d'évaluer la sensibilité du pipeline à différents niveaux de sévérité.

Artefacts produits par campagne

Chaque campagne de validation produit un ensemble standardisé d'artefacts, présentés dans le Tableau A.4.

Tableau A.4 Artefacts produits par chaque campagne de validation.

Artefact	Contenu
Métadonnées de campagne	Paramètres, grille, seeds, horodatage, durée d'exécution
Résumé par configuration	Métriques agrégées (détection, IoU, faux positifs), verdict GO/NO-GO, score de sélection
Rapport par scénario	Métriques détaillées par scénario d'injection (strong, borderline, hidden)
Évaluation événementielle	Une ligne par événement injecté, avec chevauchement, IoU, raison de détection/non-détection
Résultats par exécution	Paramètres et métriques de chaque exécution individuelle

Score de sélection v4

Le classement des configurations dans la validation robuste repose sur un score de sélection pondéré :

$$S = 0.50 \cdot \overline{\text{IoU20}}_{\text{strong}} + 0.20 \cdot \overline{\text{det}}_{\text{strong}} + 0.20 \cdot \overline{\text{det}}_{\text{border}} - 0.25 \cdot \overline{\text{leak}}_{\text{hidden}} - 0.30 \cdot \overline{\text{FN}} - 0.10 \cdot \sigma_{\text{FN}} \quad (\text{A.1})$$

où $\overline{\text{IoU20}}_{\text{strong}}$ est le recouvrement strict moyen sur les cas forts, $\overline{\text{det}}$ les taux de détection, $\overline{\text{leak}}$ le taux de fuite, $\overline{\text{FN}}$ le taux moyen de fausses notifications et σ_{FN} son écart-type.

La pondération reflète trois priorités opérationnelles hiérarchisées :

1. *Précision temporelle* (50% pour IoU20) : pour un éleveur, savoir *quand* un épisode a commencé est plus utile qu'une simple alerte binaire. Un système qui détecte mais localise mal dans le temps perd sa valeur pratique ;
2. *Maîtrise des fausses alertes* (−30% pour $\overline{\text{FN}}$, −10% pour σ_{FN}) : la littérature montre que les éleveurs cessent de consulter les systèmes d'alerte dès que le taux de faux positifs dépasse $\sim 0.2/\text{cow-day}$ (Rutten *et al.*, 2013). La pénalisation de la variance (σ) garantit en outre une fiabilité prédictible ;

3. *Couverture de détection* (20% chacun pour strong et borderline) : le poids symétrique entre cas forts et borderline évite de favoriser des configurations agressives sur les cas faciles au détriment des cas ambigus.

La pénalité de fuite (−25%) est élevée car une alerte sur un cas volontairement non détectable signale une défaillance grave de la spécificité. Ces poids ne sont pas issus d'une optimisation formelle mais d'un arbitrage explicite, documenté et gelé avant l'exécution des campagnes de validation.

Intégrité des résultats

L'intégrité des artefacts de référence est vérifiée via un manifeste cryptographique SHA-256. Ce manifeste contient l'empreinte de chaque fichier de résultats produit par les campagnes de validation. La vérification consiste à recalculer les empreintes et à les comparer au manifeste de référence.

Le résultat attendu pour la baseline officielle est : zéro fichier manquant, zéro fichier modifié, zéro fichier inattendu. Cette lecture signifie qu'aucun artefact de référence n'a disparu, qu'aucun résultat n'a été modifié en place, et qu'aucun bruit non prévu n'a été injecté dans la baseline vérifiée. Ce mécanisme garantit que les réorganisations de code n'ont pas altéré les résultats expérimentaux sur lesquels reposent les conclusions du mémoire.

Archive logicielle du mémoire

L'archive logicielle de référence du mémoire est décrite dans le manifeste `data/memoire_archive_manifest_v2.json`. Ce manifeste liste :

1. le dépôt Git privé de référence du projet (accessible sur demande auprès de l'auteur) ;
2. le tag de référence de la version figée du mémoire (`memoire-v2`) ;
3. les sources LaTeX du manuscrit ;
4. les paramètres gelés (`data/final_thresholds_v1.json`) ;
5. les manifestes d'intégrité SHA-256 ;
6. les principaux CSV de résultats cités dans le manuscrit, y compris les statistiques appariées IF/LOF exportées dans `data/if_lof_stats/`.

Cette archive ne comprend pas les données brutes capteurs, non diffusables pour des raisons de confidentialité. En revanche, elle fournit tous les éléments nécessaires pour rejouer la démarche sur un nouveau corpus disposant du même schéma de colonnes.

Reproduction des expériences

Pour reproduire les résultats présentés dans ce mémoire, les étapes suivantes sont nécessaires :

1. *Installation* : installer les dépendances déclarées dans le fichier de dépendances du projet (Python 3.10+, pandas, scikit-learn, NumPy);
2. *Données* : placer le corpus brut (37 839 lignes, 28 vaches) dans le répertoire de données du projet;
3. *Validation manuelle* : exécuter les notebooks de validation manuelle v2 et v2.1;
4. *Validation robuste* : exécuter les notebooks v4, v5.1 et v5.2 dans l'ordre, chacun produisant ses artefacts horodatés;
5. *Comparaison IF/LOF* : exécuter `python scripts/compute_if_lof_paired_stats.py` pour régénérer les intervalles de confiance appariés à partir des CSV existants;
6. *Vérification* : comparer les empreintes SHA-256 des artefacts produits avec le manifeste de référence.

Le seed aléatoire (`random_state = 42` pour IF, seeds explicites pour les validations) garantit la reproductibilité bit-à-bit des résultats sur une même version de scikit-learn.

Variabilité inter-vache des fausses notifications

Les métriques agrégées (0.105 fausse notification/vache-jour, 91.7% d'accord) résument le comportement moyen du pipeline sur l'ensemble du troupeau, mais masquent la variabilité naturelle entre individus. Le Tableau A.5 classe les 28 vaches en quatre groupes selon leur taux individuel de fausses notifications, mesurés sur 41 jours pour la configuration finale v5.2; les groupes sont définis par quartile du taux individuel et les effectifs exacts sont calculés sur la configuration à seed médian.

Tableau A.5 Distribution des fausses notifications par vache sur la période d'étude.

Groupe	<i>n</i> vaches	FN totales	FN/vache	FN/vache-jour	Description
Très stable	7	0-1	≤ 1	≤ 0.024	Signal quasi-nul
Stable	7	2-3	2-3	0.05-0.07	Comportement régulier
Actif	7	4-7	4-7	0.10-0.17	Variabilité modérée
Très actif	7	8-15	8-15	0.20-0.37	Forte variabilité
Total	28	—	4.6 (moy.)	0.112	

Note : la valeur totale de 0.112 FN/vache-jour est la *moyenne des taux individuels* des 28 vaches (configuration finale, seed médian). Elle diffère légèrement du taux agrégé de 0.105 FN/vache-jour rapporté au Chapitre 4, ce dernier étant calculé comme moyenne *par exécution* sur la grille robuste v5.1; les deux mesures sont cohérentes et restent sous le seuil critique de la littérature.

Mécanisme de la variabilité. Les vaches du groupe *Très actif* présentent des profils comportementaux naturellement irréguliers : pics d'activité locomotrice plus fréquents, alternances couché/debout plus variables, et *Motion Index* plus élevé en dehors des épisodes injectés. Pour ces animaux, la distribution des scores Isolation Forest est décalée vers des valeurs plus élevées en condition normale, ce qui abaisse le seuil effectif de détection. Ce phénomène, bien documenté dans la littérature sur la détection d'anomalies (Chandola *et al.*, 2009), rappelle que le score IF est relatif au profil global de la vache : une anomalie est toujours définie par rapport à la norme individuelle.

Implication pour le déploiement. Deux adaptations opérationnelles découlent de cette analyse :

1. *Calibration individuelle* : un ajustement du seuil de contamination par vache permettrait de maintenir un taux uniforme de fausses alertes à l'échelle du troupeau, plutôt que d'appliquer un seuil global qui surcharge les animaux naturellement actifs ;
2. *Pondération des alertes* : le score de confiance pourrait intégrer l'historique individuel de l'animal pour différencier une anomalie forte pour une vache calme d'une anomalie modérée pour une vache active.

Ces adaptations constituent des axes d'amélioration concrets, validables sur un corpus élargi. Le taux agrégé (0.105 FN/vache-jour) reste bien en dessous du seuil critique identifié dans la littérature (~ 0.2 FN/vache-jour, Rutten *et al.* (2013)).

Distribution des recouvrements temporels (IoU)

La Figure A.1 présente les distributions de best_iou pour les trois scénarios d'injection sur l'ensemble des configurations GO de la campagne v5.2.




Figure A.1 Distribution des best_iou par scénario d'injection (campagne v5.2).

La distribution des cas forts est centrée autour de 0.30–0.35, avec une queue s'étendant jusqu'à 0.50+, ce qui signifie que le pipeline recouvre environ un tiers de la fenêtre temporelle de l'épisode injecté dans la majorité des configurations stables. La distribution bimodale des cas borderline, avec un pic à zéro et une queue jusqu'à 0.20, confirme que ces cas se situent à la frontière de détection du pipeline.

BIBLIOGRAPHIE

- Whay, H. R., Main, D. C. J., Green, L. E. et Webster, A. J. F. (2003). Assessment of the welfare of dairy cattle using animal-based measurements : Direct observations and investigation of farm records. *Veterinary Record*, 153(7), 197–202. <http://dx.doi.org/10.1136/vr.153.7.197>
- Flower, F. C. et Weary, D. M. (2006). Effect of hoof pathologies on subjective assessments of dairy cow gait. *Journal of Dairy Science*, 89(1), 139–146. [http://dx.doi.org/10.3168/jds.S0022-0302\(06\)72077-X](http://dx.doi.org/10.3168/jds.S0022-0302(06)72077-X)
- Green, L. E., Hedges, V. J., Schukken, Y. H., Blowey, R. W. et Packington, A. J. (2002). The impact of clinical lameness on the milk yield of dairy cows. *Journal of Dairy Science*, 85(9), 2250–2256. [http://dx.doi.org/10.3168/jds.S0022-0302\(02\)74304-X](http://dx.doi.org/10.3168/jds.S0022-0302(02)74304-X)
- Bruijnis, M. R. N., Hogeveen, H. et Stassen, E. N. (2010). Assessing economic consequences of foot disorders in dairy cattle using a dynamic stochastic simulation model. *Journal of Dairy Science*, 93(6), 2419–2432. <http://dx.doi.org/10.3168/jds.2009-2721>
- Palma, O., Pla-Aragones, L. M., Mac Cawley, A. et Alborno, V. M. (2025). Ai and data analytics in the dairy farms : A scoping review. *Animals*, 15(9), 1291. <http://dx.doi.org/10.3390/ani15091291>
- Michelena, A., Fontenla-Romero, O. et Calvo-Rolle, J. L. (2025). A review and future trends of precision livestock over dairy and beef cow cattle with artificial intelligence. *Logic Journal of the IGPL*, 33(4), jzae111. <http://dx.doi.org/10.1093/jigpal/jzae111>
- Sprecher, D. J., Hostetler, D. E. et Kaneene, J. B. (1997). A lameness scoring system that uses posture and gait to predict dairy cattle reproductive performance. *Theriogenology*, 47(6), 1179–1187. [http://dx.doi.org/10.1016/S0093-691X\(97\)00098-8](http://dx.doi.org/10.1016/S0093-691X(97)00098-8)
- Alsaad, M., Fadul, M. et Steiner, A. (2019). Automatic lameness detection in cattle. *The Veterinary Journal*, 246, 35–44. <http://dx.doi.org/10.1016/j.tvjl.2019.01.005>
- O’Leary, N., Byrne, D. T., O’Connor, A. et Shalloo, L. (2020). Invited review : Cattle lameness detection with accelerometers. *Journal of Dairy Science*, 103(5), 3895–3911. <http://dx.doi.org/10.3168/jds.2019-17123>
- González-García, A., Castillo-Lopez, E. et Jimenez-Montero, J. A. (2023). A systematic review on the use of machine learning for cattle lameness detection. *Livestock Science*, 271, 105218. <http://dx.doi.org/10.1016/j.livsci.2023.105218>
- Rutten, C. J., Velthuis, A. G. J., Steeneveld, W. et Hogeveen, H. (2013). Invited review : Sensors to support health management on dairy farms. *Journal of Dairy Science*, 96(4), 1928–1952. <http://dx.doi.org/10.3168/jds.2012-6107>
- Cook, N. B. (2003). Prevalence of lameness among dairy cattle in wisconsin as a function of housing type and stall surface. *Journal of the American Veterinary Medical Association*, 223(9), 1324–1328. <http://dx.doi.org/10.2460/javma.2003.223.1324>
- Merck Veterinary Manual (2024a). Lameness originating in the hoof in cattle. <https://www.merckvetmanual.com/musculoskeletal-system/lameness-in-cattle/lameness-originating-in-the-hoof-in-cattle>. Consulté le 26 février 2026.

- Merck Veterinary Manual (2024b). Overview of lameness in cattle.
<https://www.merckvetmanual.com/musculoskeletal-system/lameness-in-cattle/overview-of-lameness-in-cattle>. Consulté le 26 février 2026.
- DairyNZ (2025b). Treating lameness.
<https://www.dairynz.co.nz/animal/lameness/treating-lameness/>. Consulté le 26 février 2026.
- Chapinal, N., de Passillé, A. M., Weary, D. M., von Keyserlingk, M. A. G. et Bhatt, M. (2010). Measurement of acceleration while walking as an automated method for gait assessment in dairy cattle. *Journal of Dairy Science*, 93(7), 3287–3293. <http://dx.doi.org/10.3168/jds.2009-2758>
- Pastell, M., Tiusanen, J., Hakojarvi, M. et Hanninen, L. (2009). A probabilistic neural network model for lameness detection. *Journal of Dairy Science*, 92(3), 1182–1190.
<http://dx.doi.org/10.3168/jds.2008-1405>
- Flower, F. C., Sanderson, D. J. et Weary, D. M. (2006). Gait assessment in dairy cattle. *Animal*, 1(8), 1104–1108. <http://dx.doi.org/10.1017/S1751731107000444>
- AHDB (2025a). Mobility score sheet (48h for score 2).
https://projectblue.blob.core.windows.net/media/Default/Research%20Papers/Dairy/ahdb_dairy_mobility_score_score_sheet__2_.pdf. Consulté le 26 février 2026.
- Schlageter-Tello, A., Bokkers, E. A. M., Koerkamp, P. W. G. G., Van Hertem, T., Viazzi, S., Romanini, C. E. B., Halachmi, I., Bahr, C., Berckmans, D. et Lokhorst, K. (2014). Effect of time since last trimming on the agreement between lameness scoring and locomotion parameters. *Journal of Dairy Science*, 97(3), 1592–1604. <http://dx.doi.org/10.3168/jds.2013-6710>
- AHDB (2025b). Mobility scoring for dairy cows.
<https://ahdb.org.uk/knowledge-library/mobility-scoring-for-dairy-cows>. Consulté le 26 février 2026.
- Van Hertem, T., Viazzi, S., Bahr, C., Berckmans, D. et Vranken, E. (2014). Implementation of a cow-specific lameness detection algorithm using activity data and a decision tree. *Computers and Electronics in Agriculture*, 108, 105–112. <http://dx.doi.org/10.1016/j.compag.2014.07.017>
- Lavrova, A. I., Choucair, A., Palmini, A., Stock, K. F., Kammer, M., Querengasser, F. et Belik, V. (2023). Leveraging accelerometer data for lameness detection in dairy cows : A longitudinal study of six farms in germany. *Animals*, 13(23), 3681. <http://dx.doi.org/10.3390/ani13233681>
- Balasso, P., Taccioli, C., Serva, L., Magrin, L., Andrighetto, I. et Marchesini, G. (2023). Uncovering patterns in dairy cow behaviour : A deep learning approach with tri-axial accelerometer data. *Animals*, 13(11), 1886. <http://dx.doi.org/10.3390/ani13111886>
- Qiao, Y., Kong, H., Clark, C., Lomax, S., Su, D., Eiffert, S. et Sukkarieh, S. (2021). Intelligent perception-based cattle lameness detection and behaviour recognition : A review. *Animals*, 11(11), 3033.
<http://dx.doi.org/10.3390/ani11113033>
- Chandola, V., Banerjee, A. et Kumar, V. (2009). Anomaly detection : A survey. *ACM Computing Surveys*, 41(3), 1–58. <http://dx.doi.org/10.1145/1541880.1541882>

- Viazzi, S., Bahr, C., Schlageter-Tello, A., Van Hertem, T., Romanini, C. E. B., Pluk, A., Halachmi, I., Lokhorst, C. et Berckmans, D. (2013). Analysis of individual classification of lameness using automatic measurement of back posture in dairy cattle. *Journal of Dairy Science*, 96(6), 3628–3636. <http://dx.doi.org/10.3168/jds.2012-6300>
- Blackie, N., Bleach, E. C. L., Amory, J. R. et Scaife, J. R. (2011). Automatic monitoring of locomotion-related behaviors in dairy cows using a neck-mounted accelerometer. *Journal of Dairy Science*, 94, 2045–2052. <http://dx.doi.org/10.3168/jds.2010-3451>
- Michelena, A. (2025). Comparative analysis of unsupervised anomaly detection techniques for heat detection in dairy cattle. *Neurocomputing*, 618, 129088. <http://dx.doi.org/10.1016/j.neucom.2024.129088>
- Liu, F. T., Ting, K. M. et Zhou, Z.-H. (2008). Isolation forest. Dans *Proceedings of the 2008 Eighth IEEE International Conference on Data Mining*, 413–422. <http://dx.doi.org/10.1109/ICDM.2008.17>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. et Duchesnay, É. (2011). Scikit-learn : Machine learning in python. *Journal of Machine Learning Research*, 12, 2825–2830. <http://dx.doi.org/10.5555/1953048.2078195>
- Breunig, M. M., Kriegel, H.-P., Ng, R. T. et Sander, J. (2000). Lof : Identifying density-based local outliers. *SIGMOD Record*, 29(2), 93–104. <http://dx.doi.org/10.1145/335191.335388>
- Goldstein, M. et Uchida, S. (2016). A comparative evaluation of unsupervised anomaly detection algorithms for multivariate data. *PLOS ONE*, 11(4), e0152173. <http://dx.doi.org/10.1371/journal.pone.0152173>
- Schölkopf, B., Platt, J. C., Shawe-Taylor, J., Smola, A. J. et Williamson, R. C. (2001). Estimating the support of a high-dimensional distribution. *Neural Computation*, 13(7), 1443–1471. <http://dx.doi.org/10.1162/089976601750264965>
- Sakurada, M. et Yairi, T. (2014). Anomaly detection using autoencoders with nonlinear dimensionality reduction. Dans *Proceedings of the MLSDA 2014 2nd Workshop on Machine Learning for Sensory Data Analysis*, 4–11. <http://dx.doi.org/10.1145/2689746.2689747>
- Ester, M., Kriegel, H.-P., Sander, J. et Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. Dans *Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining (KDD)*, 226–231.
- Ramaswamy, S., Rastogi, R. et Shim, K. (2000). Efficient algorithms for mining outliers from large data sets. Dans *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, 427–438. <http://dx.doi.org/10.1145/342009.335437>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <http://dx.doi.org/10.1023/A:1010933404324>
- Cox, D. R. (1958). The regression analysis of binary sequences. *Journal of the Royal Statistical Society : Series B (Methodological)*, 20(2), 215–242. <http://dx.doi.org/10.1111/j.2517-6161.1958.tb00292.x>

- Hochreiter, S. et Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
<http://dx.doi.org/10.1162/neco.1997.9.8.1735>
- Rousseeuw, P. J. et Van Driessen, K. (1999). A fast algorithm for the minimum covariance determinant estimator. *Technometrics*, 41(3), 212–223.
<http://dx.doi.org/10.1080/00401706.1999.10485670>
- Liu, F. T., Ting, K. M. et Zhou, Z.-H. (2012). Isolation-based anomaly detection. *ACM Transactions on Knowledge Discovery from Data*, 6(1), 1–39. <http://dx.doi.org/10.1145/2133360.2133363>
- Alsaad, M., Niederhauser, J. J., Beer, G., Zehner, N., Schuepbach-Regula, G. et Steiner, A. (2012). Electronic detection of lameness in dairy cows through measuring pedometric activity and lying behavior. *Applied Animal Behaviour Science*, 142(3-4), 134–141.
<http://dx.doi.org/10.1016/j.applanim.2012.10.001>
- Beer, G., Alsaad, M., Starke, A., Schuepbach-Regula, G., Müller, H., Kohler, P. et Steiner, A. (2016). Use of extended characteristics of locomotion and feeding behavior for automated identification of lame dairy cows. *PLoS ONE*, 11(5), e0155796. <http://dx.doi.org/10.1371/journal.pone.0155796>
- Thorup, V. M., do Nascimento, O. F., Skjøth, F., Voigt, M., Rasmussen, M. D., Bennedsgaard, T. W. et Friggens, N. C. (2015). Lameness detection via leg-mounted accelerometers on dairy cows on four commercial farms. *Animal*, 9(10), 1704–1712.
<http://dx.doi.org/10.1017/S1751731115000890>
- Mazrier, H., Tal, S., Aizinbud, E. et Eitan, U. (2006). A field investigation of the use of the pedometer for the early detection of lameness in cattle. *Canadian Veterinary Journal*, 47(9), 883–886. PMID : 17017652.
- Hempel, S., Menz, C., Pinto, S., Galan, E., Janke, D., Estellés, F., Müschner-Siemens, T., Wang, X., Heinicke, J., Zhang, G. Q., Amon, B., del Prado, A. et Amon, T. (2019). Lameness detection in dairy cattle with a pressure-sensitive walkway in a commercial farm environment. *Journal of Dairy Science*, 102(11), 10221–10235. <http://dx.doi.org/10.3168/jds.2018-15737>
- Van Hertem, T., Maltz, E., Antler, A., Romanini, C. E. B., Viazzi, S., Bahr, C., Schlageter-Tello, A., Lokhorst, K., Berckmans, D. et Halachmi, I. (2013). Lameness detection based on multivariate continuous sensing of milk yield, rumination, and neck activity. *Journal of Dairy Science*, 96(7), 4286–4298.
<http://dx.doi.org/10.3168/jds.2012-6188>
- Ledgerwood, D. N., Winckler, C. et Tucker, C. B. (2010). Evaluation of data loggers, sampling intervals, and editing techniques for measuring the lying behavior of dairy cattle. *Journal of Dairy Science*, 93(11), 5129–5139. <http://dx.doi.org/10.3168/jds.2009-2945>
- Bewley, J. M. et Schutz, M. M. (2008). An interdisciplinary review of body condition scoring for dairy cattle. *The Professional Animal Scientist*, 24(6), 507–529.
[http://dx.doi.org/10.15232/S1080-7446\(15\)30901-3](http://dx.doi.org/10.15232/S1080-7446(15)30901-3)
- Ito, K., von Keyserlingk, M. A. G., LeBlanc, S. J. et Weary, D. M. (2010). Lying behavior as an indicator of lameness in dairy cows. *Journal of Dairy Science*, 93(8), 3553–3560.
<http://dx.doi.org/10.3168/jds.2009-2951>
- Nechanitzky, K., Starke, A., Vidondo, B., Müller, H., Reckardt, M., Friedli, K. et Steiner, A. (2016). Analysis of behavioral changes in dairy cows associated with claw horn lesions. *Journal of Dairy Science*, 99(4), 2904–2914. <http://dx.doi.org/10.3168/jds.2015-10228>

- Benaissa, S., Tuytens, F. A. M., Plets, D., de Pessemier, T., Trogh, J., Tanghe, E., Martens, L., Vandaele, L., Van Nuffel, A., Joseph, W. et Sonck, B. (2019). On the use of on-cow accelerometers for the classification of behaviours in dairy barns. *Research in Veterinary Science*, 125, 425–433. <http://dx.doi.org/10.1016/j.rvsc.2017.10.005>
- Leys, C., Ley, C., Klein, O., Bernard, P. et Licata, L. (2013). Detecting outliers : Do not use standard deviation around the mean, use absolute deviation around the median. *Journal of Experimental Social Psychology*, 49(4), 764–766. <http://dx.doi.org/10.1016/j.jesp.2013.03.013>
- Everingham, M., Van Gool, L., Williams, C. K. I., Winn, J. et Zisserman, A. (2010). The pascal visual object classes (voc) challenge. *International Journal of Computer Vision*, 88(2), 303–338. <http://dx.doi.org/10.1007/s11263-009-0275-4>
- Emmott, A. F., Das, S., Dietterich, T., Fern, A. et Wong, W.-K. (2015). A meta-analysis of the anomaly detection problem. Dans *arXiv preprint arXiv :1503.01158*.
- Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F. et Dennison, D. (2015). Hidden technical debt in machine learning systems. Dans *Advances in Neural Information Processing Systems*, volume 28, 2503–2511.
- Breck, E., Cai, S., Nielsen, E., Salib, M. et Sculley, D. (2017). The ml test score : A rubric for ml production readiness and technical debt reduction. Dans *Proceedings of IEEE International Conference on Big Data*, 1123–1132. <http://dx.doi.org/10.1109/BigData.2017.8258038>
- Hariri, S., Kind, M. C. et Brunner, R. J. (2021). Extended isolation forest. *IEEE Transactions on Knowledge and Data Engineering*, 33(4), 1479–1489. <http://dx.doi.org/10.1109/TKDE.2019.2947676>
- Amershi, S., Begel, A., Bird, C., DeLine, R., Gall, H., Kamar, E., Nagappan, N., Nushi, B. et Zimmermann, T. (2019). Software engineering for machine learning : A case study. Dans *Proceedings of the 41st International Conference on Software Engineering : Software Engineering in Practice*, 291–300. <http://dx.doi.org/10.1109/ICSE-SEIP.2019.00042>
- DairyNZ (2025a). Preventing and managing lameness guide. <https://www.dairynz.co.nz/media/hr2hwwq2/preventing-and-managing-lameness-guide-2025-v2.pdf>. Consulté le 26 février 2026.
- Pineau, J., Vincent-Lamarre, P., Sinha, K., Larivière, V., Beygelzimer, A., d'Alché Buc, F., Fox, E. et Larochelle, H. (2021). Improving reproducibility in machine learning research (a report from the neurips 2019 reproducibility program). *Journal of Machine Learning Research*, 22(164), 1–20. <http://dx.doi.org/10.5555/3546258.3546422>
- Tatman, R., VanderPlas, J. et Dane, S. (2018). A practical taxonomy of reproducibility for machine learning research. Dans *Reproducibility in Machine Learning Workshop at ICML*.
- Wilkinson, M. D., Dumontier, M., Aalbersberg, I. J., Appleton, G., Axton, M., Baak, A., Blomberg, N., Boiten, J.-W., da Silva Santos, L. B., Bourne, P. E. et al. (2016). The fair guiding principles for scientific data management and stewardship. *Scientific Data*, 3, 160018. <http://dx.doi.org/10.1038/sdata.2016.18>
- Zimek, A. et Filzmoser, P. (2015). The blind men and the elephant : On meeting the problem of multiple truths in data from too many vantage points. Dans *Machine Learning and Knowledge Discovery in Databases*, 121–136. http://dx.doi.org/10.1007/978-3-319-23461-8_8

- Lundberg, S. M. et Lee, S.-I. (2017). A unified approach to interpreting model predictions. Dans *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 4765–4774.
- McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2), 153–157. <http://dx.doi.org/10.1007/BF02295996>
- Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), 80–83. <http://dx.doi.org/10.2307/3001968>
- Shadish, W. R., Cook, T. D. et Campbell, D. T. (2002). *Experimental and Quasi-Experimental Designs for Generalized Causal Inference*. Boston, MA : Houghton Mifflin.
- Wohlin, C., Runeson, P., Höst, M., Ohlsson, M. C., Regnell, B. et Wesslén, A. (2012). *Experimentation in Software Engineering*. Springer. <http://dx.doi.org/10.1007/978-3-642-29044-2>
- Feldt, R. et Magazinius, A. (2010). Validity threats in empirical software engineering research – an initial survey. Dans *Proceedings of the 22nd International Conference on Software Engineering and Knowledge Engineering (SEKE)*, 374–379.
- Galindo, F. et Broom, D. M. (2000). The relationships between social behaviour of dairy cows and the occurrence of lameness on different housing systems. *Applied Animal Behaviour Science*, 70(3), 227–244. [http://dx.doi.org/10.1016/S0168-1591\(00\)00163-0](http://dx.doi.org/10.1016/S0168-1591(00)00163-0)
- Stangaferro, M. L., Wijma, R., Caixeta, L. S., Al-Abri, M. A. et Giordano, J. O. (2016). Use of rumination and activity monitoring for the identification of dairy cows with health disorders. *Journal of Dairy Science*, 99(9), 7395–7410. <http://dx.doi.org/10.3168/jds.2016-10907>
- Rodrigues, R., Newsome, R., Green, M. et Huxley, J. (2017). Lameness in dairy cows : A debilitating disease or a disease of debilitated cattle ? a cross-sectional study of lameness prevalence and thickness of the digital cushion. *Journal of Dairy Science*, 100(7), 5603–5612. <http://dx.doi.org/10.3168/jds.2016-12331>
- Broom, D. M. (2017). *Animal Welfare in the European Union*. Rapport technique, European Parliament, Policy Department for Citizens' Rights and Constitutional Affairs. Study requested by the PETI Committee, PE 583.114.
- Estévez-Moreno, L. X., Miranda-de la Lama, G. C., Villarroel, M. et María, G. A. (2019). European union legislation on animal welfare : State of play, enforcement and future activities. *Animals*, 9(12), 1049. <http://dx.doi.org/10.3390/ani9121049>
- Bewley, J. M., Russell, R. A. et Borchers, M. R. (2015). Precision dairy monitoring opportunities and limitations. *Journal of Dairy Science*, 98(Supplement 2), 552. Abstract presented at the ADSA-ASAS Joint Annual Meeting, <http://dx.doi.org/10.3168/jds.2015-9538>
- Venkatesh, V., Morris, M. G., Davis, G. B. et Davis, F. D. (2003). User acceptance of information technology : Toward a unified view. *MIS Quarterly*, 27(3), 425–478. <http://dx.doi.org/10.2307/30036540>
- Wolfert, S., Ge, L., Verdouw, C. et Bogaardt, M.-J. (2017). Big data in smart farming – a review. *Agricultural Systems*, 153, 69–80. <http://dx.doi.org/10.1016/j.agsy.2017.01.023>
- Carbonell, I. M. (2016). The ethics of big data in agriculture. *Internet Policy Review*, 5(1). <http://dx.doi.org/10.14763/2016.1.405>